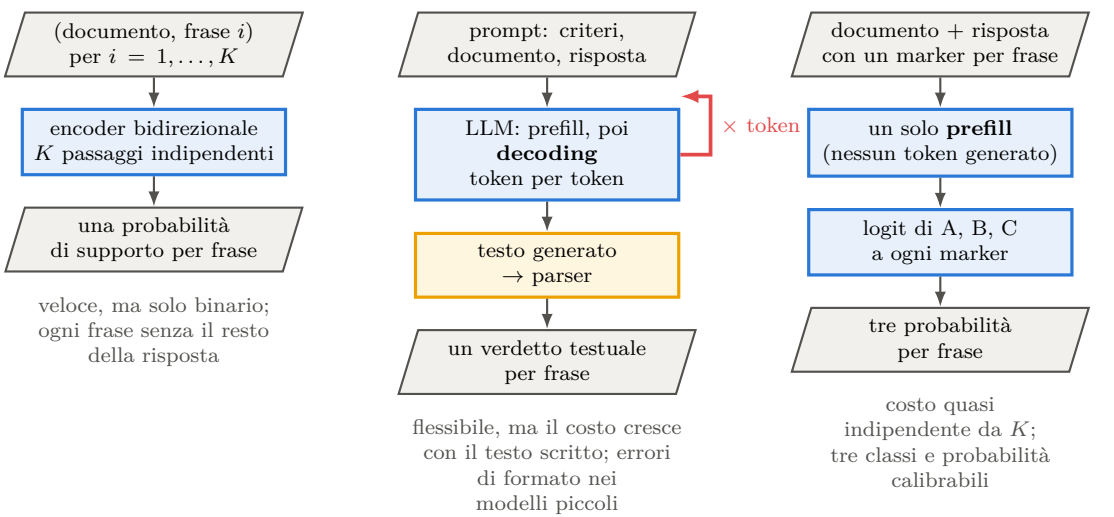

Encoder specializzato
(MiniCheck, HHEM)
(documento, frase i)
per $i = 1, \ldots, K$
encoder bidirezionale
K passaggi indipendenti
una probabilità
di supporto per frase
veloce, ma solo binario;
ogni frase senza il resto
della risposta
Giudice generativo
(LLM-as-a-judge)
prompt: criteri,
documento, risposta
LLM: prefill, poi
decoding
token per token
× token
testo generato
→ parser
un verdetto testuale
per frase
flessibile, ma il costo cresce
con il testo scritto; errori
di formato nei
modelli piccoli
Decision Model specialista
(GroundOne)
documento + risposta
con un marker per frase
un solo **prefill**
(nessun token generato)
logit di A, B, C
a ogni marker
tre probabilità
per frase
costo quasi
indipendente da K;
tre classi e probabilità
calibrabili