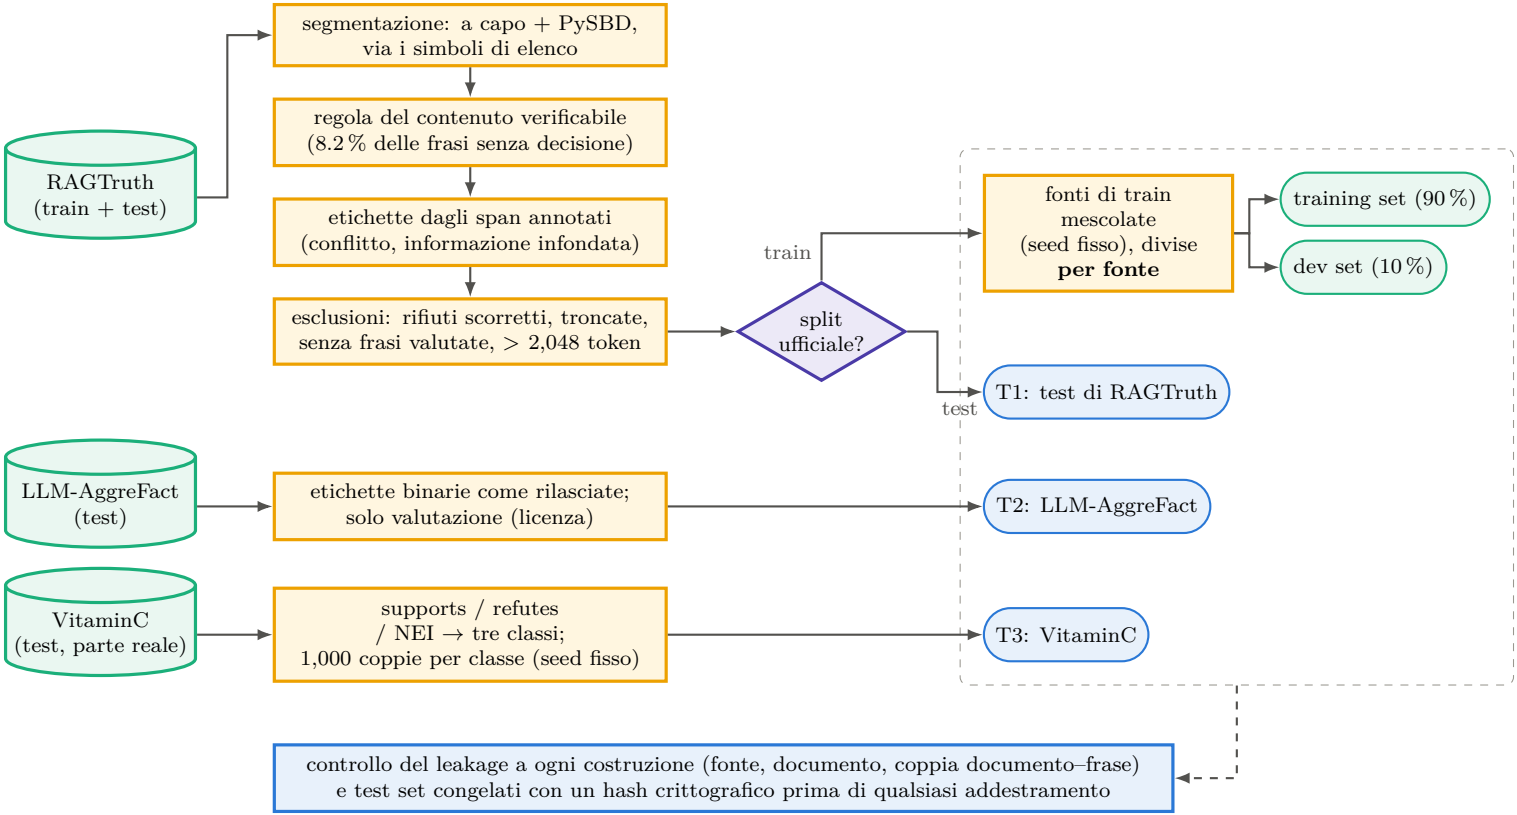

RAGTruth
(train + test)
segmentazione: a capo + PySBD,
via i simboli di elenco
regola del contenuto verificabile
(8.2 % delle frasi senza decisione)
etichette dagli span annotati
(conflitto, informazione infondata)
esclusioni: rifiuti scorretti, troncate,
senza frasi valutate, > 2,048 token
split
ufficiale?
train
test
fonti di train
mescolate
(seed fisso), divise
per fonte
training set (90 %)
dev set (10 %)
T1: test di RAGTruth
LLM-AggreFact
(test)
etichette binarie come rilasciate;
solo valutazione (licenza)
T2: LLM-AggreFact
VitaminC
(test, parte reale)
supports / refutes
/ NEI → tre classi;
1,000 coppie per classe (seed fisso)
T3: VitaminC
controllo del leakage a ogni costruzione (fonte, documento, coppia documento–frase)
e test set congelati con un hash crittografico prima di qualsiasi addestramento