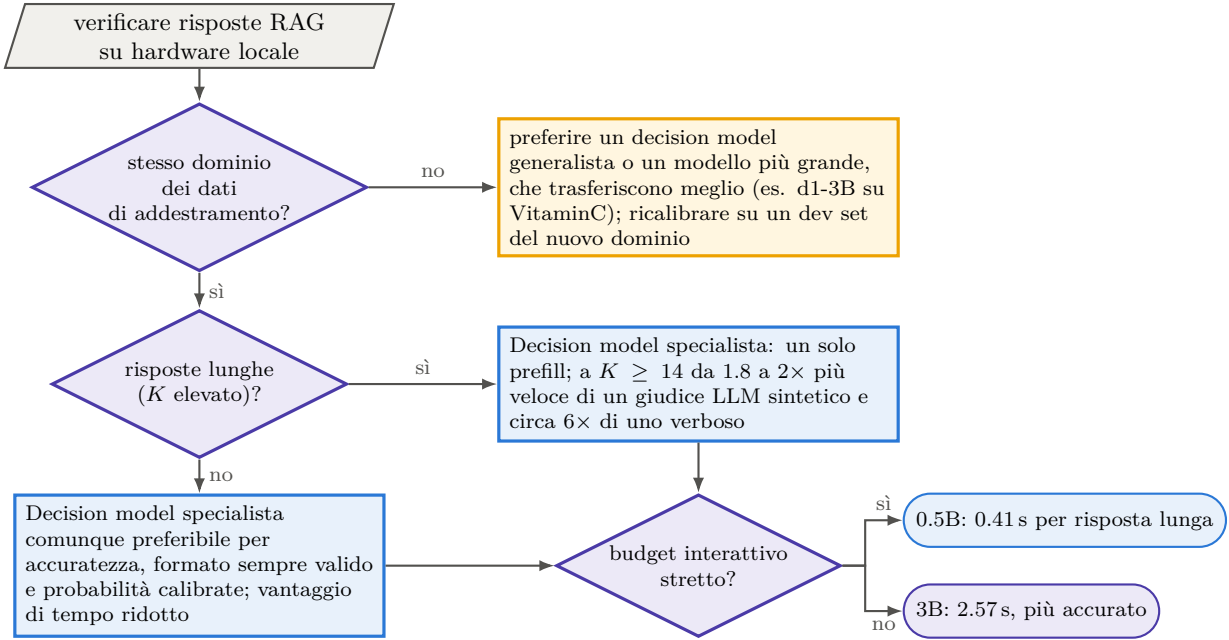

verificare risposte RAG
su hardware locale
stesso dominio
dei dati
di addestramento?
no
preferire un decision model
generalista o un modello più grande,
che trasferiscono meglio (es. d1-3B su
VitaminC); ricalibrare su un dev set
del nuovo dominio
sì
risposte lunghe
(K elevato)?
sì
Decision model specialista: un solo
prefill; a K ≥ 14 da 1.8 a 2× più
veloce di un giudice LLM sintetico e
circa 6× di uno verboso
no
Decision model specialista
comunque preferibile per
accuratezza, formato sempre valido
e probabilità calibrate; vantaggio
di tempo ridotto
budget interattivo
stretto?
sì
0.5B: 0.41 s per risposta lunga
no
3B: 2.57 s, più accurato