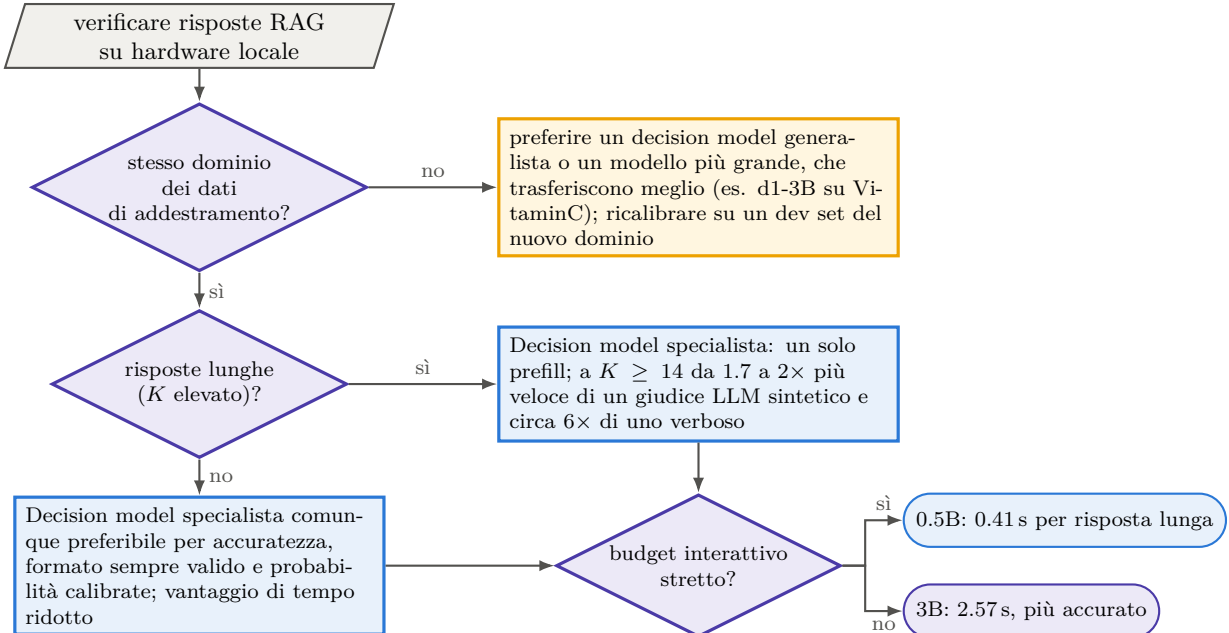

verificare risposte RAG su hardware locale
stesso dominio dei dati di addestramento?
no
preferire un decision model generalista o un modello più grande, che trasferiscono meglio (es. d1-3B su VitaminC); ricalibrare su un dev set del nuovo dominio
sì
risposte lunghe (K elevato)?
sì
Decision model specialista: un solo prefill; a $K \geq 14$ da 1.7 a 2× più veloce di un giudice LLM sintetico e circa 6× di uno verboso
no
Decision model specialista comunque preferibile per accuratezza, formato sempre valido e probabilità calibrate; vantaggio di tempo ridotto
budget interattivo stretto?
sì
0.5B: 0.41 s per risposta lunga
no
3B: 2.57 s, più accurato