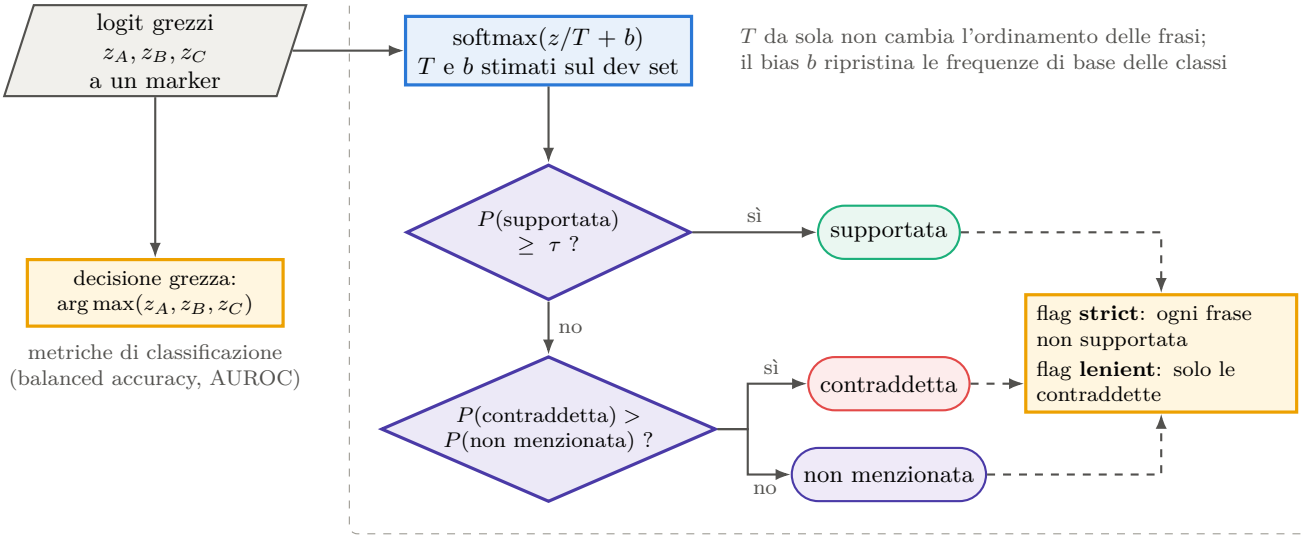

logit grezzi
z_A, z_B, z_C
a un marker
softmax$(z/T + b)$
T e b stimati sul dev set
T da sola non cambia l'ordinamento delle frasi;
il bias b ripristina le frequenze di base delle classi
P(supportata)
$\geq \tau$?
sì
supportata
no
P(contraddetta) >
P(non menzionata) ?
sì
contraddetta
no
non menzionata
flag **strict**: ogni frase non supportata
flag **lenient**: solo le contraddette
decisione grezza:
$\arg\max(z_A, z_B, z_C)$
metriche di classificazione
(balanced accuracy, AUROC)
riquadro tratteggiato: probabilità calibrate, usate per ECE, soglie,
selective prediction ed etichette e flag restituiti dall'API