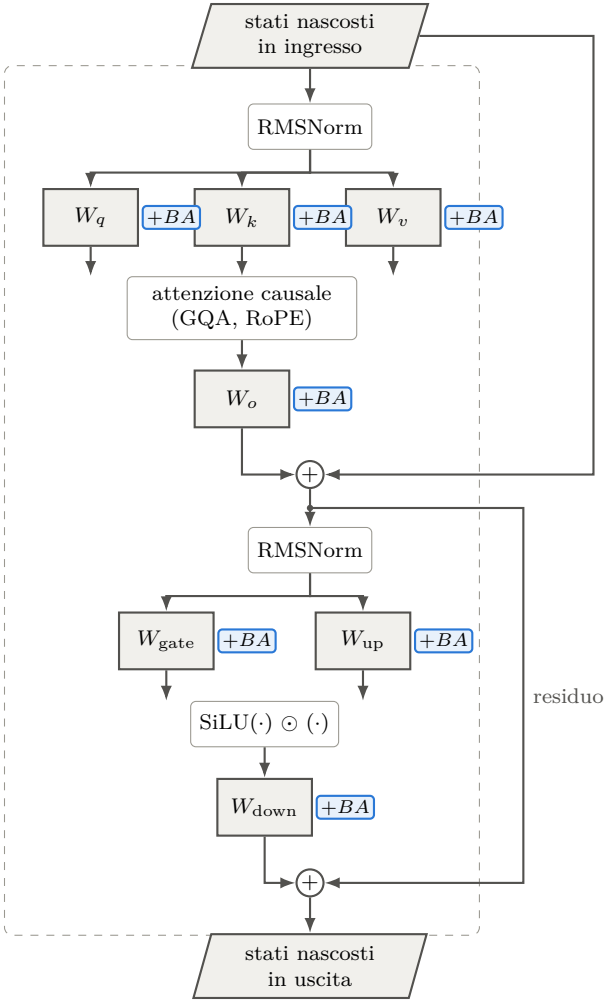


un blocco transformer di Qwen2.5, ripetuto 24 volte (0.5B) o 36 (3B)

W — pesi del modello base, congelati a 8 bit

$+BA$ — adapter LoRA addestrabile (rango 16, scala 2)

parametri addestrabili per blocco:

- 0.5B: 366,592
- 3B: 831,488

in totale:

- 0.5B: 8.8 milioni (1.8 % del modello)
- 3B: 29.9 milioni (1.0 % del modello)

Embedding e testa di output (condivisi) restano congelati e senza adapter.
Le frecce a destra sono le connessioni residue.