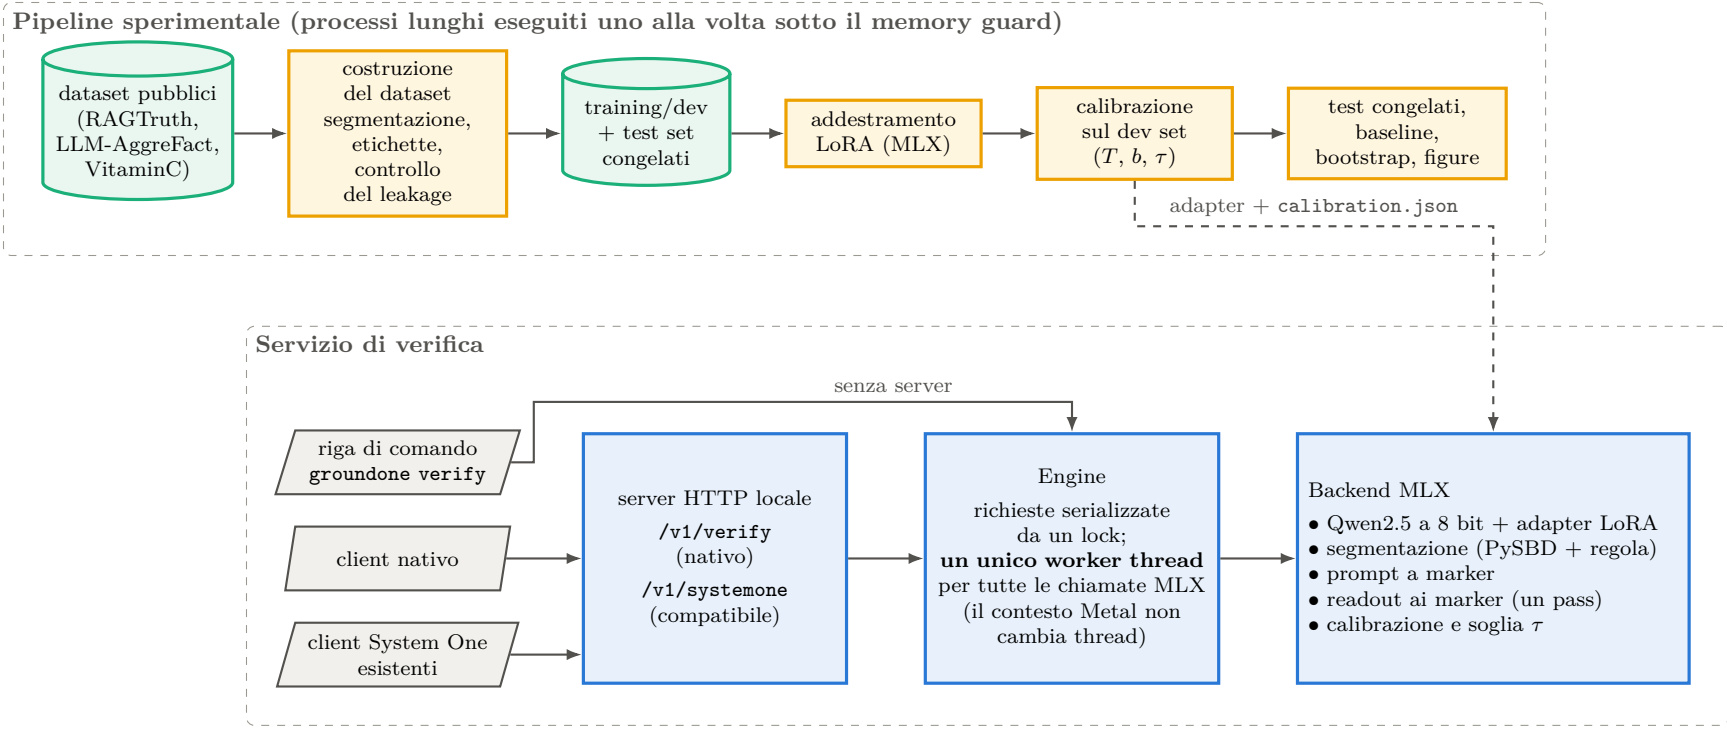

Pipeline sperimentale (processi lunghi eseguiti uno alla volta sotto il memory guard)
dataset pubblici (RAGTruth, LLM-AggreFact, VitaminC)
costruzione del dataset segmentazione, etichette, controllo del leakage
training/dev + test set congelati
addestramento LoRA (MLX)
calibrazione sul dev set (T, b, τ)
test congelati, baseline, bootstrap, figure
adapter + calibration.json
Servizio di verifica
senza server
riga di comando groundone verify
client nativo
client System One esistenti
server HTTP locale
/v1/verify (nativo)
/v1/systemone (compatibile)
Engine
richieste serializzate da un lock;
un unico worker thread
per tutte le chiamate MLX
(il contesto Metal non cambia thread)
Backend MLX
• Qwen2.5 a 8 bit + adapter LoRA
• segmentazione (PySBD + regola)
• prompt a marker
• readout ai marker (un pass)
• calibrazione e soglia τ
tutto gira sul portatile: modelli, dati e richieste non lasciano la macchina