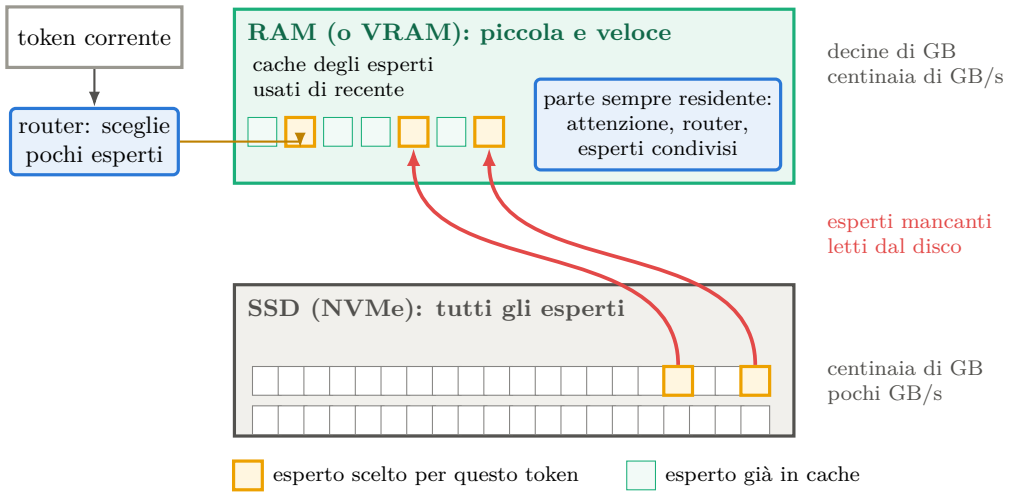

token corrente
router: sceglie pochi esperti
RAM (o VRAM): piccola e veloce
cache degli esperti usati di recente
parte sempre residente: attenzione, router, esperti condivisi
decine di GB
centinaia di GB/s
esperti mancanti letti dal disco
SSD (NVMe): tutti gli esperti
centinaia di GB
pochi GB/s
esperto scelto per questo token
esperto già in cache