

Politecnico di Torino

Politecnico di Torino

Corso di Laurea Magistrale in Ingegneria Informatica

A.A. 2025/2026

Sessione di laurea Dicembre 2026

GroundOne: un decision model specialista per la verifica della groundedness nella RAG locale

Fine-tuning di modelli linguistici compatti come verificatori calibrati a singolo forward pass su Apple Silicon

Relatore:

Prof. Paolo Garza

Candidato:

Francesco Pio De Dominicis

Sommario

La retrieval-augmented generation (RAG) è ormai il modo standard per dare ai modelli linguistici accesso a documenti privati, e oggi l'intera pipeline può essere eseguita sul dispositivo dell'utente con hardware di fascia consumer, a vantaggio della privacy, dell'uso offline e dei costi. Il recupero dei documenti, tuttavia, non elimina le allucinazioni: le risposte generate contengono ancora frasi che il contesto recuperato non supporta o che lo contraddicono. Individuarle è un prerequisito per assistenti locali affidabili e, poiché il controllo va eseguito su ogni risposta, deve trovare posto sulla stessa macchina, dalle risorse limitate, che ospita il generatore.

La località è l'asse portante di questo lavoro e ha una conseguenza tecnica precisa. Su un singolo dispositivo leggere testo costa poco, scriverlo costa molto: il modello legge l'input in un unico forward pass, cioè in un solo passaggio attraverso tutti i suoi strati, limitato dalla capacità di calcolo, ma genera l'output un token alla volta, e ogni token è limitato dalla banda di memoria necessaria a leggere tutti i pesi. Sul portatile usato in questa tesi scrivere un token costa da quattordici a sedici volte più che leggerne uno, e una rassegna dell'hardware locale attuale, dagli smartphone ai portatili fino a macchine dedicate come il Mac Studio di Apple e il DGX Spark di NVIDIA, mostra ovunque la stessa asimmetria, con un hardware nuovo che accelera la lettura molto più della scrittura. I migliori modelli open-weight sono ormai indietro di pochi mesi rispetto alla frontiera chiusa, e quelli che entrano in una scheda grafica consumer di 6–12 mesi, per cui pipeline locali capaci sono realistiche; la questione è come verificarle a un costo che il dispositivo possa sostenere.

La verifica segue oggi due paradigmi. I **verificatori basati su encoder**, come AlignScore, MiniCheck e HHEM, sono piccoli e veloci, ma restituiscono un unico punteggio fisso per ogni coppia di documento e frase. I **giudici LLM**, invece, sono flessibili, ma scrivono i verdetti token per token, per cui il loro costo cresce con la quantità di testo prodotto; i giudici LLM piccoli violano spesso il formato di output, e la confidenza che esprimono è raramente utilizzabile come probabilità. Di recente è emersa una terza famiglia: i **decision model**, come il proprietario Jev e i modelli open SemIf e Rizzo-Flow, che rispondono a domande chiuse in un unico forward pass e restituiscono una probabilità per ciascuna opzione di risposta

senza generare testo; quelli open la leggono dai logit. Le evidenze a loro favore provengono per lo più dagli stessi autori, e le implementazioni open sono quasi tutte generaliste. Non era ancora stato studiato in modo controllato se un decision model compatto, specializzato in un unico task, possa eguagliare i giudici LLM e gli encoder dedicati, da dove derivi il suo vantaggio e se le sue probabilità siano utilizzabili, il tutto su hardware consumer.

Questa tesi progetta, addestra e valuta **GroundOne**, un decision model specializzato in un'unica decisione: stabilire, per ogni frase di una risposta RAG, se il documento recuperato la supporta, la contraddice o non la menziona. Ogni frase della risposta è seguita da un marker, e i verdetti di tutte le K frasi si leggono dai logit di tre lettere di risposta in un unico forward pass, senza generare testo. Modelli Qwen2.5 da 0.5B e 3B parametri sono sottoposti a fine-tuning con LoRA sulle risposte di RAGTruth annotate manualmente, con una loss pesata per classe e ristretta alle tre lettere; una temperatura e un bias stimati sul dev set calibrano le probabilità, e una soglia scelta sugli stessi dati le traduce in etichette coerenti e in segnalazioni secondo la policy strict o lenient. Tutto, dalla costruzione del dataset all'addestramento, dalla valutazione alla messa in servizio, gira su un unico portatile Apple M4 con 16 GB di memoria, con MLX e senza servizi esterni, e ogni baseline è eseguita sulla stessa macchina. La valutazione usa tre test set costruiti e congelati prima dell'addestramento (la partizione di test di RAGTruth, LLM-AggreFact e VitaminC) e confronta GroundOne con indizi elementari che non leggono mai il documento nel suo insieme, con i modelli non addestrati, con giudici LLM della stessa dimensione, con e senza probabilità, con due decision model generalisti e con encoder specializzati, riportando intervalli calcolati con un bootstrap a cluster.

Sul test set di RAGTruth GroundOne raggiunge una balanced accuracy a tre classi di 0.769 con 0.5B parametri e di 0.832 con 3B, contro 0.37 e 0.44 dei modelli non addestrati (per il 3B su un sottoinsieme di 600 risposte); il suo AUROC (0.905 e 0.940) supera quello degli encoder (circa 0.82), e in balanced accuracy a tre classi il modello supera nettamente entrambi i decision model generalisti: Rizzo-Flow, otto volte più grande del 0.5B, e d1-3B di Liquid AI, della stessa dimensione del 3B, che si ferma a 0.657 e a sua volta è molto più forte sul test fuori dominio VitaminC. Su LLM-AggreFact il 3B è alla pari con MiniCheck-RoBERTa (74.8 contro 74.0), sopra il modello 7B zero-shot pubblicato e sotto il decision model chiuso Jev, misurato in modo indipendente (78.6). Quando la risposta contiene quattordici o più frasi ($K \geq 14$) e nulla è stato letto prima, GroundOne risulta da 1.8 a 2 volte più veloce di un giudice LLM sintetico e circa sei volte più veloce di uno verboso della stessa dimensione e, a differenza dei giudici LLM, produce sempre un output valido. Al netto della lettura del testo, comune a ogni approccio, la sua decisione è da 18 a 33 volte più rapida di quella del giudice LLM sintetico. Con le fonti già nella KV cache, lette in anticipo mentre l'utente legge la risposta

oppure per una verifica precedente, il vantaggio complessivo diventa di 3.4–3.6 volte, e dopo una riscrittura, quando GroundOne riusa anche l'inizio della risposta, fino alla prima frase modificata, e i suoi verdetti, da 7 a 12 volte su tutte le risposte. Consuma anche meno energia (5.5 joule per risposta con il 0.5B, 33 con il 3B), ma il risparmio è minore di quello sul tempo, perché un prefill lungo assorbe più potenza del decoding. Combinando le specifiche dei produttori con la lunghezza misurata degli output dei giudici LLM, un giudice LLM da 3B deve spendere almeno 1.8 secondi soltanto per scrivere i verdetti di una risposta lunga sul portatile della tesi, e 0.12 secondi persino sulla scheda grafica consumer più veloce: un costo che GroundOne non paga su nessun hardware. Quando si chiede loro lo stesso output, i giudici LLM forniscono probabilità che distinguono a stento le decisioni corrette da quelle errate, mentre la calibrazione porta a 0.019 l'Expected Calibration Error di GroundOne sul test set, cioè lo scarto medio tra la confidenza dichiarata e la frequenza osservata delle risposte corrette. Anche il modo di leggere la decisione conta: a parità di modello addestrato, confrontare soltanto le tre lettere ammesse è più accurato che lasciare al modello generare liberamente il proprio verdetto, con un guadagno di balanced accuracy di 0.25 per il 0.5B e di 0.07 per il 3B. Restano alcuni aspetti da migliorare, che indicano direzioni naturali per il lavoro futuro: le prestazioni calano su domini lontani da quello di addestramento, come il fact checking di VitaminC; le allucinazioni più sottili, nascoste in frasi che per il resto ricalcano fedelmente la fonte, vengono individuate solo in parte; infine, l'addestramento non è ancora del tutto stabile al variare del seed, un aspetto che semplici modifiche all'ottimizzatore potrebbero attenuare.

Infine, GroundOne Studio, un'applicazione per macOS, mette il verificatore al lavoro in un assistente RAG completo che gira in un unico processo sul portatile, senza rete: recupero, generazione, verifica e confronto con un giudice LLM locale richiedono al massimo 6.9 GB di memoria allocata da MLX con il generatore 3B predefinito. La risposta del generatore compare per prima, e la verifica e la riscrittura delle frasi segnalate avvengono su richiesta. In un caso di studio con 100 errori iniettati GroundOne segnala l'errore in 97 delle 98 risposte in cui la frase riceve un verdetto, il giudice LLM in 84; dopo due giri di riscrittura mirata le risposte che contengono ancora l'errore scendono al 6 %, con numeri e date per lo più ripristinati dalla fonte e frasi inventate cancellate. Il verdetto a tre classi decide la riparazione: le frasi contraddette vengono corrette, quelle non menzionate spesso tolte.

Ringraziamenti

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Tristique senectus et netus et malesuada fames ac turpis. Pretium nibh ipsum consequat nisl vel pretium lectus quam. Urna molestie at elementum eu facilisis sed odio morbi quis. Sed egestas egestas fringilla phasellus faucibus scelerisque eleifend. At in tellus integer feugiat. Mauris rhoncus aenean vel elit scelerisque mauris pellentesque pulvinar. Commodo sed egestas egestas fringilla. Nunc lobortis mattis aliquam faucibus purus in massa. Facilisis magna etiam tempor orci eu lobortis elementum nibh. Elementum curabitur vitae nunc sed velit dignissim. Neque volutpat ac tincidunt vitae. Massa id neque aliquam vestibulum morbi blandit cursus risus at. Porta non pulvinar neque laoreet suspendisse interdum consectetur. Turpis in eu mi bibendum. Ut tristique et egestas quis ipsum suspendisse. Integer quis auctor elit sed vulputate mi sit amet. Viverra nam libero justo laoreet sit amet cursus.

Indice

Elenco delle figure x

1 Introduzione 1
- 1.1 Motivazione . . . 1
  - 1.1.1 La RAG sul dispositivo dell'utente . . . 1
  - 1.1.2 Le allucinazioni e la necessità di verificare . . . 2
  - 1.1.3 Il costo di verificare una risposta su un laptop . . . 3
- 1.2 Decision Model . . . 3
- 1.3 Approccio e domande di ricerca . . . 5
- 1.4 Ambito . . . 7
- 1.5 Contributi . . . 7
- 1.6 Risultati principali . . . 8
- 1.7 Struttura della tesi . . . 9

2 Inferenza locale dei modelli linguistici 11
- 2.1 Dai modelli remoti ai modelli locali . . . 11
- 2.2 Modelli open-weight e small language model . . . 14
  - 2.2.1 Open-weight non significa open source . . . 14
  - 2.2.2 Il divario con i modelli chiusi si sta chiudendo . . . 16
  - 2.2.3 Small language model . . . 17
- 2.3 Il costo dell'inferenza su un singolo dispositivo . . . 19
  - 2.3.1 Prefill e decoding . . . 19
  - 2.3.2 Il modello roofline . . . 20
  - 2.3.3 Un limite inferiore alla generazione . . . 21
- 2.4 L'hardware per l'inferenza locale . . . 22
  - 2.4.1 Classi di hardware . . . 23
  - 2.4.2 L'asimmetria vale per ogni classe . . . 27
- 2.5 Runtime e quantizzazione . . . 28
  - 2.5.1 Runtime . . . 28
  - 2.5.2 Motori di inferenza specializzati . . . 28
  - 2.5.3 Quantizzazione . . . 31

2.5.4 Generare più in fretta senza generare meno . . . 32
2.6 Energia . . . 32
2.7 Conseguenze per la verifica sul dispositivo . . . 33

3 Fondamenti e stato dell'arte 34
3.1 Decision Model . . . 34
3.2 Retrieval-augmented generation e allucinazioni . . . 37
3.3 Verifica della groundedness . . . 37
3.4 Calibrazione e selective prediction . . . 38
3.5 Parameter-efficient fine-tuning . . . 40
3.6 Lacuna nella letteratura . . . 41

4 GroundOne: metodo e implementazione 43
4.1 Task e decisione . . . 43
4.2 Tutti i verdetti in un solo forward pass . . . 44
4.3 Obiettivo di addestramento . . . 48
4.4 Calibrazione . . . 50
4.5 Software . . . 55

5 Dati 57
5.1 Task ed etichette . . . 57
5.2 Dataset di partenza . . . 58
5.3 Costruzione . . . 60
5.4 Il dataset risultante . . . 62
5.5 Affidabilità dei test set . . . 64
5.6 Analisi esplorativa . . . 65
5.7 Controllo del leakage . . . 68

6 Impostazione sperimentale 70
6.1 Modelli . . . 70
6.2 Baseline . . . 71
6.3 Metriche . . . 75
6.4 Protocollo statistico . . . 75
6.5 Latenza, energia e hardware . . . 76
6.6 Licenze e condizioni d'uso . . . 78

7 Risultati 80
7.1 Addestramento . . . 80
7.2 Variabilità tra seed . . . 82
7.3 Accuratezza sul test set RAG (T1) . . . 84
7.4 Confronto con le baseline . . . 85
7.5 Trasferimento a un dominio diverso (T3) . . . 88

7.6 Readout e generazione a confronto . . . 89
7.7 Calibrazione e selective prediction . . . 90
7.8 Probabilità a parità di output . . . 92
7.9 Latenza in funzione di K . . . 93
7.9.1 Lettura del testo e decisione . . . 94
7.10 Energia per verifica . . . 101
7.11 Località: esecuzione offline, quantizzazione e co-residenza . . . 102
7.12 Analisi degli errori . . . 104

8 GroundOne Studio: un'applicazione locale e un caso di studio 105
8.1 Obiettivi e requisiti . . . 105
8.2 Scelte di piattaforma . . . 106
8.3 Architettura . . . 107
8.4 Porting di GroundOne in Swift . . . 108
8.5 Libreria e recupero dei documenti . . . 110
8.6 L'uso dell'applicazione . . . 111
8.7 Caso di studio: errori iniettati . . . 116
8.8 Un esempio: un errore numerico sottile . . . 121
8.9 Probabilità calibrate e soglia di decisione . . . 122
8.10 Limiti . . . 123

9 Discussione, limiti e minacce alla validità 124
9.1 Quando conviene un decision model specialista . . . 124
9.2 Limiti . . . 127
9.3 Minacce alla validità . . . 130

10 Conclusioni e sviluppi futuri 132
10.1 Sintesi dei risultati . . . 132
10.2 Sviluppi futuri . . . 133

A Output di ogni sistema su una stessa risposta 136
A.1 Verdetti frase per frase . . . 137
A.2 Output grezzi . . . 138

Bibliografia 140

Elenco delle figure

1.1 Due modi di verificare le K frasi di una risposta. Parallelogrammi: input e output; rettangoli blu: componenti del modello; rettangolo giallo: elaborazione esterna al modello; rombi: decisioni. Il decision model legge documento e risposta una sola volta e, per ogni frase, sceglie fra tre risposte ammesse, restituendo anche la probabilità. L'LLM generativo ripassa dal modello per ogni token scritto (ciclo in rosso), e i verdetti vanno poi ricavati dal testo, che può non rispettare il formato richiesto. 5

2.1 Capacità del miglior modello chiuso e del miglior modello open-weight nel tempo, sull'indice aggregato di capacità di Epoch AI (punti: singoli modelli; linee: migliore fino a quel momento). Grafico ricavato dalla tabella dati pubblicata da Epoch AI [34]. 16

2.2 Artificial Analysis Intelligence Index (versione 4.3.2, dieci valutazioni) al 20 ottobre 2026, ridisegnato dal grafico pubblicato [35]. In arancione i modelli chiusi, in blu quelli open-weight; tratteggiato l'unico modello che Artificial Analysis classifica come piccolo. Tra parentesi l'impostazione di ragionamento con cui è stato valutato ciascun modello. Lo stato open-weight è ricavato dai dati della stessa leaderboard. È un'istantanea: punteggi e classifica cambiano a ogni nuovo rilascio. 18

2.3 Tempo per token quando il modello legge l'input (prefill) e quando scrive l'output (decoding), misurato sulla macchina della tesi (Apple M4, 16 GB, MLX a 8 bit, una richiesta alla volta). Prefill: mediana su contesti di 500, 1000 e 2000 token. 20

2.4 Modello roofline della macchina della tesi [43]. Tetto inclinato: banda di memoria dichiarata da Apple (120 GB/s). Tetto piatto: throughput raggiunto nel prefill, limite inferiore del picco non pubblicato. Intensità calcolate per uno strato feed-forward di Qwen2.5 con pesi a 8 bit e attivazioni a 16 bit; l'attenzione è trascurata. . . . 22

2.5 Memoria necessaria per i pesi di un modello in funzione della sua dimensione e della precisione (numero di parametri moltiplicato per i bit per peso, compreso mezzo bit di scale per gruppo nei formati quantizzati). Linee tratteggiate: tagli di memoria comuni nell'hardware locale. La KV cache, le attivazioni e gli altri modelli in esecuzione si aggiungono a questo valore. 23

2.6 Le due architetture dell'hardware per l'inferenza locale. Rettangoli blu: unità di calcolo; rettangoli verdi: memoria; rettangolo arancione: i pesi del modello; spessore delle linee: banda indicativa. Valori di capacità e banda dalla Tabella 2.2. In un sistema discreto un modello che non entra nella VRAM deve passare dal collegamento PCIe, molto più lento; in un sistema a memoria unificata il modello può occupare quasi tutta la memoria della macchina, ma ogni token generato la legge a una velocità inferiore a quella di una scheda grafica di fascia alta. 24

2.7 Alcuni dei sistemi per l'inferenza locale confrontati in questa sezione (immagini non in scala). Fonti: (a), (c) Apple; (b) LoMit, Wikimedia Commons, CC0; (d), (e) NVIDIA. Le immagini dei produttori sono materiale promozionale, riprodotto a scopo di documentazione scientifica. 25

2.8 L'hardware per l'inferenza locale sui due assi che stabiliscono che cosa può girare: capacità di memoria (quali modelli entrano) e banda di memoria (quanto velocemente si generano i token). Specifiche dei produttori: marcatori in corrispondenza della configurazione con più memoria, barre ombreggiate sull'intervallo di tagli di memoria offerti; la macchina della tesi è rappresentata con i suoi 16 GB effettivi. 27

2.9 Limiti inferiori al costo della generazione di testo su ciascuna classe di hardware locale, calcolati come byte dei pesi divisi per la banda dichiarata dal produttore (una richiesta alla volta; KV cache trascurata). (a) Tempo per token generato con i due modelli base di GroundOne a 8 bit; rombi: tempo di decoding misurato sulla macchina della tesi. (b) Tempo minimo che un giudice LLM da 3B impiega soltanto per scrivere i verdetti di una risposta di quattordici o più frasi (mediana dei token generati nel protocollo di latenza). Un decision model non genera alcun token, quindi per esso entrambi i costi sono nulli su ogni macchina. 29

2.10 Lo streaming degli esperti dall'SSD in un motore come Colibri. In memoria restano la parte del modello usata da ogni token (attenzione, router, esperti condivisi) e una cache degli esperti usati di recente; tutti gli esperti stanno sull'SSD. Per ogni token il router sceglie pochi esperti: quelli già in cache si usano subito, quelli mancanti si leggono dal disco, con una banda di pochi gigabyte al secondo. Per esempio, GLM-5.2 conserva sul disco tutti i suoi 429 GB di pesi e ne tiene residenti circa 10 GB [36]. Lo schema non è in scala. 30

3.1 Tre modi di verificare le K frasi di una risposta. Un encoder specializzato valuta ogni coppia (documento, frase) in un forward pass separato e restituisce solo una probabilità di supporto. Un giudice LLM legge tutto, ma scrive il proprio verdetto token per token (ciclo rosso), quindi il costo cresce con il testo prodotto e l'output va interpretato da un parser. Un decision model specialista legge documento e risposta in un solo prefill e ricava da ogni marker tre probabilità, senza generare alcun token. 39

3.2 Schema di una curva risk–coverage (forma illustrativa, non un risultato). Le decisioni sono ordinate dalla più sicura alla meno sicura; per ogni quota decisa (coverage) si riporta il tasso di errore (rischio) delle decisioni accettate. A coverage 1 il rischio coincide con l'errore complessivo; rinunciando alle decisioni meno sicure l'errore scende. L'area sotto la curva (AURC) riassume la curva in un numero: più è piccola, meglio la confidenza separa le decisioni corrette da quelle errate. 40

3.3 Low-rank adaptation applicata a uno strato lineare. La matrice dei pesi W resta congelata (in GroundOne a 8 bit); si addestrano soltanto le due matrici piccole A e B, il cui prodotto, scalato di α, si somma all'output dello strato. Con rango r l'adapter ha $r(d+k)$ parametri invece dei dk di W. 41

4.1 Il prompt a marker di GroundOne (design b). Le frasi della risposta sono numerate e ogni frase valutata è seguita dal marker " `Verdict:`"; una frase senza contenuto verificabile (qui un'intestazione) resta come contesto, senza marker. Il modello elabora l'intera sequenza in un solo forward pass, e l'output head, ristretto alle lettere A, B e C, si applica soltanto nelle posizioni dei marker. Per l'attenzione causale il verdetto della frase i dipende dal documento e dalle frasi da 1 a i. 45

4.2 Costo stimato della verifica di una risposta di $S = 800$ token in funzione di K, calcolato con le sole costanti misurate sull'M4: il tempo per token del prefill e del decoding e il numero medio di token che ciascun giudice LLM genera per verdetto sul sottoinsieme di latenza (K medio 8.7). È un modello analitico, non una misura: le latenze misurate sono nella Sezione 7.9. A parità di testo, il costo del decision model cresce di soli tre token di prefill per decisione, quello dei giudici LLM di alcuni token di decoding per decisione. Nelle risposte reali, però, le frasi in più allungano anche il testo, il cui prefill è comune a entrambi: la Sezione 7.9 separa le due componenti. 46

4.3 Le due soluzioni per ottenere K verdetti da una sola lettura. (b) Il readout a marker, adottato come predefinito, inserisce un marker dopo ogni frase e legge tutti i verdetti nello stesso passaggio. (a) La soluzione di riserva legge una volta il prefisso condiviso e vi accoda una breve domanda per ogni frase, valutate in batch; richiede però K copie della KV cache del prefisso, ed è il formato naturale per un modello non addestrato. 47

4.4 Dove GroundOne applica LoRA. Ogni blocco transformer di Qwen2.5 contiene sette proiezioni lineari: quattro nell'attenzione (W_q, W_k, W_v, W_o) e tre nel blocco MLP (W_{gate}, W_{up}, W_{down}). I loro pesi restano congelati a 8 bit, e a ciascuna si affianca un adapter di rango 16 (in blu) che ne corregge l'output secondo lo schema della Figura 3.3. Il blocco è ripetuto 24 volte nel 0.5B e 36 nel 3B; embedding e output head non hanno adapter. 49

4.5 Come nasce l'AUROC (schema con punteggi sintetici, non un risultato). (a) Distribuzione di $P(\text{supported})$ per le frasi supportate e non supportate: le due distribuzioni si sovrappongono, e ogni soglia accetta una parte delle une e delle altre. (b) Spostando la soglia da 1 a 0 si ottiene la curva ROC; il punto nero corrisponde alla soglia del pannello (a). L'area sotto la curva è l'AUROC: più le due distribuzioni sono separate, più la curva si avvicina all'angolo in alto a sinistra e l'area a 1. La diagonale corrisponde a punteggi casuali. 54

4.6 Dai logit alle etichette restituite. La decisione grezza, cioè l'argmax dei logit, serve alle metriche di classificazione del Capitolo 7. Le probabilità calibrate, ottenute con temperatura e bias stimati sul dev set, alimentano invece l'unica regola dell'output restituito: supportata se $P(\text{supported}) \geq \tau$, altrimenti la più probabile fra contraddetta e non menzionata. Da qui derivano i flag strict e lenient. 54

4.7 Architettura del software. In alto la pipeline sperimentale, dai dataset pubblici ai test congelati, eseguita sotto il memory guard; in basso il servizio di verifica, in cui riga di comando e server HTTP (endpoint nativo e compatibile) condividono lo stesso Engine, che serializza le richieste ed esegue ogni chiamata MLX su un unico worker thread. L'adapter e il file di calibrazione prodotti dalla pipeline sono gli unici artefatti che il servizio legge. 56

5.1 Costruzione del dataset. Le risposte di RAGTruth sono segmentate, filtrate dalle frasi senza contenuto verificabile, etichettate a partire dagli span e ripulite dalle esclusioni; lo split ufficiale di test diventa T1, mentre le fonti di addestramento sono divise per fonte in training set e dev set. LLM-AggreFact e VitaminC forniscono soltanto test set (T2 e T3). Un controllo automatico del leakage accompagna ogni costruzione, e i test set sono congelati con un hash prima di qualsiasi addestramento. 61

5.2 Regola con cui le annotazioni a livello di span di RAGTruth diventano etichette di frase. Le frasi senza contenuto verificabile restano nel prompt come contesto ma non sono decisioni; fra le altre, il conflitto prevale sull'informazione infondata. 62

5.3 Distribuzione delle classi fra le frasi etichettate di ciascuno split. Negli split di RAGTruth (train, dev e T1) circa l'88–91 % delle frasi è supportato. T2 (LLM-AggreFact) ha etichette binarie, quindi le affermazioni contraddette e non menzionate vi formano un'unica classe non supportata (tratteggio). T3 è campionato con 1,000 coppie per classe. 63

5.4 Distribuzione di K, il numero di frasi valutate per risposta, nel training set e in T1. Le linee tratteggiate delimitano le fasce di K usate per riportare i risultati. 64

5.5 Quota di frasi contraddette o non menzionate in base al modello che ha scritto la risposta, nel training set e in T1. 66

5.6 Sovrapposizione lessicale tra una frase e il suo documento, cioè quota delle parole di contenuto della frase presenti nel documento, per classe, nel training set, in T1 e in T3. Tra parentesi è indicata la media. 67

5.7 Quota di frasi contraddette o non menzionate in base alla posizione della frase nella risposta. 68

6.1 Mappa delle baseline. Ciascuna differisce da GroundOne per un aspetto preciso e risponde quindi a una domanda diversa: quanto conta l'addestramento (B1), quanto il readout ristretto rispetto al token generato (B2), quanto il modo di produrre il verdetto (giudici LLM B0a, B0b, B0d), quanto la specializzazione rispetto a un decision model generalista (B3, B3b), quanto l'architettura (encoder B4) e quanto basta senza leggere il documento (segnali elementari). 72

6.2 Bootstrap appaiato a cluster. Le frasi del test set sono raggruppate per gruppo di leakage (fonte, documento o pagina); a ogni ripetizione si estraggono i gruppi con reimmissione, si calcola la metrica dei due sistemi sulle stesse fonti estratte e se ne registra la differenza. Dopo $B = 2{,}000$ ripetizioni, i percentili 2.5 e 97.5 delle differenze danno l'intervallo al 95 %, e il doppio della quota di differenze di segno opposto a quello osservato dà il p-value bilaterale. 76

7.1 Tutte le differenze appaiate tra sistemi sui test set congelati, con l'intervallo bootstrap a cluster al 95 %. Il primo sistema (A) è sempre GroundOne, e nei confronti fra due modelli GroundOne il più grande o la prima esecuzione. In blu le differenze a favore di A, in arancione quelle a favore del secondo sistema (B), in grigio quelle non significative, il cui intervallo contiene lo zero. Sul test set di dominio (T1) quasi tutte le differenze favoriscono GroundOne, e le più ampie lo separano dallo stesso modello non addestrato e dal token che genererebbe (controllo B2): specializzazione e readout pesano più della dimensione. Su LLM-AggreFact (T2) le differenze si riducono e diverse non sono significative, mentre su VitaminC (T3) il quadro si rovescia a favore di d1-3B, Rizzo-Flow e MiniCheck-RoBERTa. Le righe "run 2" confrontano due addestramenti con la stessa procedura: due differenze sono significative anche lì, ed è per questo che le differenze più piccole della variabilità fra seed non vengono interpretate. 81

7.2 Balanced accuracy a tre classi sul dev set durante l'addestramento del modello 0.5B: valore complessivo (a sinistra) e valore per task (a destra). La linea punteggiata indica il livello casuale. Il 3B mostra lo stesso andamento sul proprio sottoinsieme di 200 risposte del dev set. 82

7.3 Balanced accuracy a tre classi sul dev set durante l'addestramento del modello 0.5B, con la stessa procedura e tre seed diversi. Due esecuzioni convergono allo stesso livello; la terza è collassata su un predittore costante ed è stata interrotta. 83

7.4 AUROC di P(supported) su T1 per task (question answering, summarization, data-to-text) e per sistema. Il vantaggio di GroundOne si concentra nel data-to-text; nella summarization MiniCheck-RoBERTa supera il 0.5B ed è alla pari con il 3B. 86
7.5 T1: AUROC di P(supported) per ogni sistema (a sinistra) e balanced accuracy a tre classi per i sistemi che hanno un output a tre classi (a destra). Rizzo-Flow è valutato su 300 risposte e il 3B non addestrato su 600; tutti gli altri sistemi, compreso d1-3B, sono valutati sull'intero test set. 86
7.6 Confronto dei sistemi su T3 (VitaminC): a sinistra l'AUROC di P(supported), a destra la balanced accuracy a tre classi per i sistemi con un output a tre classi. Rizzo-Flow è valutato su un sottocampione di 600 coppie; il tratteggio indica il livello casuale. Per MiniCheck-RoBERTa VitaminC fa parte della genealogia dei dati di addestramento. 89
7.7 Controllo B2 sull'intero T1. Con gli stessi pesi e lo stesso forward pass, il verdetto è letto dalle tre lettere di risposta (GroundOne) oppure preso come il token che emetterebbe la generazione greedy; gli errori di formato sono contati come errori. 90
7.8 Reliability diagram di P(supported) del 0.5B, prima della calibrazione (grezza) e dopo la calibrazione stimata sul dev set, per il dev set, T1 e T3. Ogni punto rappresenta una fascia di probabilità che contiene almeno 20 frasi. 90
7.9 Reliability diagram di P(supported) del 3B, prima e dopo la calibrazione stimata sul dev set, per il dev set, T1 e T3; ogni punto è una fascia di probabilità con almeno 20 frasi. Come per il 0.5B, la calibrazione si trasferisce a T1 ma non a T3. 91
7.10 Curve risk–coverage della decisione binaria del 0.5B con probabilità calibrate: tasso di errore al crescere del numero di frasi meno sicure che vengono rinviate. 92
7.11 Confronto a parità di output sulle 200 risposte del sottoinsieme di latenza. Ai giudici LLM della stessa dimensione si chiede l'output di GroundOne, con le probabilità lette dai logit della lettera generata oppure scritte in JSON; tutti i sistemi sono calibrati sul dev set con la stessa mappa. Sono considerate soltanto le frasi con un verdetto valido. 93
7.12 Tempo mediano per risposta in funzione di K sulle stesse 200 risposte di T1 (MLX in-process, una risposta alla volta, M4 con 16 GB). Sono confrontati GroundOne, il decision model con una domanda per frase e i giudici LLM sintetico e verboso. Scala logaritmica. 94

7.13 Tempo mediano per risposta scomposto in lettura del testo (prefill, in grigio, comune a ogni approccio) e decisione (in colore), per fascia di K, sulle stesse 200 risposte di T1. Le etichette indicano, per $K \geq 14$, quante volte il giudice LLM impiega più di GroundOne a decidere. 96

7.14 Composizione del prefill sulle 200 risposte di T1 usate per la latenza. (a) Token del prompt di GroundOne per parte, media per fascia di K; le etichette danno la quota del documento e quella di risposta e marker. (b) Tempo per parte con il 3B, ricavato dalle misure senza cache, con le sole istruzioni e con istruzioni e documento in cache come differenza tra le mediane per fascia, per cui ogni colonna somma al tempo mediano senza cache. In blu le parti che restano uguali tra verifiche sulle stesse fonti, le sole che si possono tenere in cache come blocco. 97

7.15 Speed-up di GroundOne sui giudici LLM nelle diverse situazioni, sulle stesse 200 risposte di T1 (rapporto fra i tempi mediani, scala logaritmica, intervalli bootstrap al 95 %; "tutte": tutte le risposte). In ogni situazione GroundOne e il giudice hanno la stessa cache. Le colonne tratteggiate, a destra della linea, escludono la lettura del testo: sono il limite a cui tende lo speed-up complessivo quando la lettura si riduce. n.m.: non misurato. 100

7.16 GroundOne, il decision model non addestrato e i giudici LLM sul sottoinsieme di latenza: balanced accuracy a tre classi, con gli errori di formato contati come errori, e quota di frasi il cui verdetto non è stato possibile interpretare. 102

7.17 Energia per risposta verificata su 100 risposte del sottoinsieme di latenza, misurata con `powermetrics` su CPU, GPU e Neural Engine al netto della potenza a riposo, insieme alla potenza netta media durante l'esecuzione. 103

8.1 Architettura di GroundOne Studio. Il nucleo conosce solo le porte; i motori, tutti nello stesso processo, sono il retriever, il generatore, GroundOne (verificatore e, passaggio per passaggio, attributore) e il giudice LLM, che usa gli stessi pesi di GroundOne con l'adapter rimosso. In blu le componenti in cui interviene GroundOne. 107

8.2 Il flusso d'uso. La risposta compare come l'ha scritta il generatore; la verifica, con GroundOne o con GroundOne e il giudice LLM, e la riscrittura avvengono solo su richiesta, e ogni riscrittura produce una nuova versione verificata di nuovo con la stessa modalità. . . . 111

8.3 La risposta nativa del generatore alla domanda “How does E-ZPass charge tolls?”, prima di qualunque verifica. A destra le due modalità di verifica. 112
8.4 La stessa risposta dopo la verifica con GroundOne e il giudice LLM. Le frasi sono colorate secondo il verdetto di GroundOne; il pannello riporta conteggi, tempi e disaccordi con il giudice LLM. 113
8.5 Il pannello di una frase selezionata: probabilità calibrate di GroundOne, verdetto del giudice LLM, tempi e azioni disponibili. 114
8.6 L’evidenza per una frase: il passaggio che, secondo GroundOne, contraddice più nettamente la frase, con il tratto più vicino evidenziato. 115
8.7 La sezione delle statistiche: indicatori principali, tempo di verifica in funzione del numero di frasi per GroundOne e per il giudice LLM, costo della stessa verifica su un giudice LLM in cloud. 117
8.8 Esito di ciascun errore iniettato dopo il ciclo, per tipo di errore, con GroundOne 3B: valore ripristinato dalla fonte, frase riscritta, frase cancellata, errore ancora presente e segnalato, errore accettato da GroundOne. 119

9.1 Da dove viene l’accuratezza di GroundOne su T1: lo stesso modello base non addestrato (readout, design a), addestrato ma con la decisione presa dal token che genererebbe (controllo B2, errori di formato contati come errori) e addestrato con il readout ristretto. Tra parentesi il guadagno rispetto al passaggio precedente. Il 3B non addestrato è valutato su 600 risposte; il tratteggio indica il livello casuale. 126
9.2 Quando conviene un decision model specialista, secondo i risultati di questa tesi. È una sintesi qualitativa: i tempi si riferiscono al portatile M4 e alle risposte con 14 o più frasi, e il trasferimento fuori dominio è quello osservato su LLM-AggreFact e VitaminC. 129

Capitolo 1

Introduzione

1.1 Motivazione

1.1.1 La RAG sul dispositivo dell'utente

La retrieval-augmented generation (RAG) è ormai l'approccio standard per far rispondere un modello linguistico a domande su documenti che non ha mai visto in addestramento. Un retriever seleziona i passaggi pertinenti alla domanda, e il modello scrive la risposta avendoli nel proprio contesto [1]. La stessa ricetta serve a un'azienda che consulta i propri report interni, a un avvocato che esamina un contratto e a uno studente che interroga i propri appunti, e in tutti questi casi il valore della risposta dipende dalla sua fedeltà ai documenti.

Fino a poco tempo fa una pipeline di questo tipo richiedeva un modello ospitato in remoto, raggiungibile via rete. Oggi non è più così. Modelli open-weight compatti e runtime efficienti girano su hardware consumer [2, 3], e i produttori di piattaforme integrano direttamente nei propri dispositivi modelli da pochi miliardi di parametri [4]. Il divario con i migliori modelli chiusi è ridotto e continua a ridursi: i modelli che entrano in una singola scheda grafica consumer raggiungono le prestazioni della frontiera del momento nel giro di sei-dodici mesi [5], e su una nota leaderboard il vantaggio del miglior modello chiuso sul miglior modello open-weight è sceso in un solo anno dall'8 % a meno del 2 % [6]. L'intera pipeline, dal recupero dei documenti alla risposta, può quindi restare sulla macchina dell'utente. Questo conta per quattro ragioni. Quando i documenti sono riservati o soggetti a regolamentazione, non lasciano mai il dispositivo; la privacy diventa così una proprietà tecnica del sistema, anziché una promessa del fornitore che l'utente non ha modo di verificare. Una recente disputa sulla paternità di un risultato tra OpenAI e due matematici, che avevano scritto bozze non ancora pubblicate all'interno di uno dei prodotti dell'azienda, ha mostrato quanto la questione sia concreta: lo stesso fornitore ha dichiarato di non poter escludere che dati derivati

da quell'utilizzo abbiano contribuito a migliorare i suoi modelli [7]. Quando manca la rete, l'assistente continua a funzionare. Quando il comportamento del sistema deve restare stabile, i pesi cambiano solo se è l'utente a cambiarli, invece di seguire gli aggiornamenti di un fornitore. Infine, il costo diventa quello dell'hardware e della sua energia, invece di un prezzo per token. I modelli locali, inoltre, espongono i propri logit, che le interfacce remote spesso nascondono o limitano: una proprietà che si rivela essenziale per l'approccio studiato in questa tesi.

La località, però, è anche un vincolo. Un laptop ha memoria, banda e batteria limitate, e ogni componente dell'assistente deve rientrarvi nello stesso momento. Questa tesi tratta la località come un requisito e non come un dettaglio: ogni fase del lavoro, dalla costruzione del dataset all'addestramento, dalla valutazione alla messa in servizio, gira su un unico laptop consumer con 16 GB di memoria, e nessuna dipende da un servizio esterno. Poiché la località è l'asse portante del lavoro, il Capitolo 2 è interamente dedicato a essa: perché conta, quali modelli e quale hardware la rendono possibile e quanto costa.

1.1.2 Le allucinazioni e la necessità di verificare

Il recupero dei documenti non elimina le allucinazioni. Anche con i passaggi giusti nel contesto, le risposte generate contengono ancora frasi che i passaggi non supportano, o che li contraddicono [8, 9]. Un esempio tratto dai dati usati in questa tesi mostra quanto il problema possa essere sottile. Chiamato a descrivere un ristorante a partire da una scheda strutturata, un modello scrive sei frasi scorrevoli. Quattro sono corrette. Una afferma che il ristorante è aperto sette giorni su sette, mentre la scheda indica che il lunedì è chiuso: la frase contraddice la fonte. Un'altra afferma che il ristorante ha una valutazione di 4.5 stelle su Google, mentre la scheda riporta la valutazione senza indicarne la fonte: la frase aggiunge un dettaglio che la fonte non menziona (Appendice A).

Da questo esempio seguono due osservazioni. In primo luogo, l'errore si trova in una singola frase di una risposta per il resto corretta, quindi un verdetto sull'intera risposta serve a poco: l'utente ha bisogno di sapere di quale frase diffidare. In secondo luogo, le due frasi sbagliate lo sono in modi diversi. Una contraddizione è un errore fattuale rispetto alla fonte, mentre un'aggiunta non supportata può essere un innocuo dettaglio di contorno oppure un'invenzione, e un'applicazione può voler trattare i due casi in modo diverso. Un verificatore utile, quindi, stabilisce per ogni frase se il documento la supporta, la contraddice o non la menziona. E poiché non si può pretendere che l'utente confronti ogni frase con la fonte, il verificatore deve essere eseguito su ogni risposta, in modo automatico, sulla stessa macchina che l'ha generata.

1.1.3 Il costo di verificare una risposta su un laptop

Un verificatore eseguito accanto al generatore si contende con esso la stessa memoria, lo stesso tempo e la stessa batteria. La soluzione più comune, cioè chiedere a un modello linguistico di giudicare la risposta, è costosa proprio dove un laptop è più debole. Un giudice LLM, cioè un large language model a cui si chiede di fare da giudice, scrive i propri verdetti token per token, e su hardware locale ogni token generato costa molto più di ogni token letto. La lettura del prompt è limitata dalla capacità di calcolo, che la GPU di un laptop gestisce bene, mentre la scrittura dell'output è limitata dalla banda di memoria, perché ogni nuovo token richiede di leggere tutti i pesi [10]. Sul laptop usato in questa tesi, leggere un token richiede circa 0.37 millisecondi con un modello da 0.5B parametri, mentre scriverne uno ne richiede circa 5.9, sedici volte di più, e l'asimmetria vale per ogni classe di hardware locale, dagli smartphone alle macchine dedicate all'IA (Capitolo 2). Un giudice LLM che spiega il proprio ragionamento prima di ogni verdetto moltiplica questo costo per la lunghezza della spiegazione, e il costo cresce ancora con il numero di frasi della risposta. I giudici LLM piccoli, inoltre, non rispettano il formato di output richiesto, e la confidenza che dichiarano è raramente utilizzabile come probabilità.

I verificatori basati su encoder[1] evitano del tutto la generazione. Modelli come AlignScore, MiniCheck e HHEM leggono una coppia di documento e frase e restituiscono un punteggio di supporto [11, 12, 13]. Sono piccoli e veloci, ma restituiscono un unico punteggio di supporto per ogni coppia: il loro output non distingue una contraddizione da un'omissione, leggono ogni frase senza il resto della risposta, e adattarli a una nuova decisione richiede un nuovo modello.

1.2 Decision Model

Un modo diverso di usare un modello linguistico per prendere decisioni ha attirato di recente l'attenzione: i *decision model*. La categoria è stata introdotta con il nome di *System One model* [14], che richiama il modo di pensare rapido e intuitivo contrapposto al ragionamento deliberato; questa tesi adotta il termine decision model, che l'ecosistema ha poi adottato. Invece di generare una risposta, un modello di questo tipo legge una sola volta la domanda e il contesto e restituisce una probabilità per ciascuna risposta ammissibile, per esempio leggendo i logit delle lettere delle opzioni alla fine del prompt (per esempio A: 90 %, B: 5 %, C: 5 %) [15, 16]. Ne seguono direttamente tre proprietà. Non viene generato alcun testo, quindi

[1] Un *encoder* è un transformer in cui ogni token vede tutti gli altri, sia quelli che lo precedono sia quelli che lo seguono. Produce una rappresentazione del testo invece di generarlo, come BERT e i modelli che ne derivano.

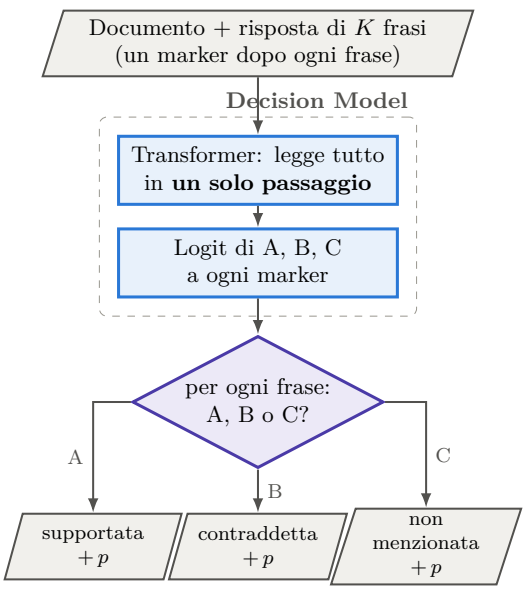
la decisione costa solo la lettura dell'input. L'output è sempre una delle risposte ammissibili, quindi è sempre valido. Molte domande sullo stesso contesto possono condividere un unico forward pass[2] su di esso, quindi ogni domanda aggiuntiva costa poco.

L'idea si presta bene alla verifica. Una risposta di K frasi pone K domande chiuse sullo stesso documento, ciascuna con tre risposte ammissibili. Un decision model può rispondere a tutte leggendo il documento una sola volta, e alla probabilità restituita per ogni frase si possono applicare una calibrazione e una soglia scelta dall'applicazione. Un LLM tradizionale, invece, produce la risposta in modo autoregressivo: dopo aver letto il documento deve generare i verdetti un token alla volta, con un nuovo passaggio nel modello per ogni token scritto, e solo alla fine il testo prodotto può essere interpretato come una decisione (Figura 1.1).

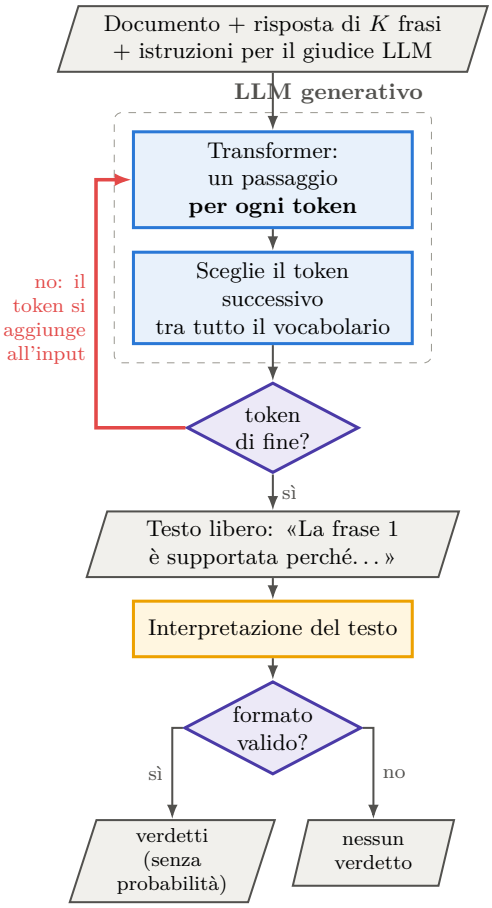
Il campo è giovane e si muove in fretta. Dopo il primo modello ospitato sono arrivate le implementazioni open [15, 16], e il 9 ottobre 2026 l'hub di Hugging Face ha introdotto ufficialmente un tag per i decision model, che il giorno successivo raccoglieva già circa 1500 modelli, più della metà dei quali pubblicati nelle settimane precedenti [17]. Anche organizzazioni affermate hanno rilasciato i propri, come d1-3B di Liquid AI e Clef di Cloudflare [18, 19]. Le evidenze, però, sono in ritardo rispetto ai rilasci. Provengono per lo più dagli autori di ciascun sistema, le valutazioni indipendenti sono recenti, ridimensionano quanto dichiarato dai produttori e sono meno favorevoli ai piccoli modelli open [20, 21], e una leaderboard comune rileva che i decision model generalisti con meno di un miliardo di parametri superano al più a stento la baseline banale, e per lo più restano al di sotto, nel rilevamento delle allucinazioni nelle risposte RAG [22]. Le implementazioni open, inoltre, sono quasi tutte sistemi generalisti in grado di rispondere a qualunque domanda tipizzata, e nessuna riporta una verifica a tre classi frase per frase su benchmark RAG.

Restano quindi aperti tre problemi. Il primo è capire se, per un singolo task, convenga usare un decision model piccolo e specializzato. Il secondo è capire come un modello di questo tipo si confronti con le alternative: un decision model generalista, un giudice LLM e un verificatore dedicato. Il terzo è capire da dove derivi l'eventuale vantaggio: dalla specializzazione, dal modo in cui la decisione viene letta oppure, più semplicemente, dalla dimensione del modello.

[2] Il *forward pass* è un passaggio completo dell'input attraverso tutti gli strati della rete: per un modello linguistico, il calcolo che a partire dai token in ingresso produce i logit del token successivo. Un modello generativo ne esegue uno per ogni token che scrive; un decision model ne esegue uno solo per leggere l'intero input.



(a) Decision model: una sola lettura e una decisione fra tre risposte ammesse per ogni frase.



(b) LLM tradizionale: un passaggio nel modello per ogni token, finché il testo non è completo.

Figura 1.1: Due modi di verificare le K frasi di una risposta. Parallelogrammi: input e output; rettangoli blu: componenti del modello; rettangolo giallo: elaborazione esterna al modello; rombi: decisioni. Il decision model legge documento e risposta una sola volta e, per ogni frase, sceglie fra tre risposte ammesse, restituendo anche la probabilità. L'LLM generativo ripassa dal modello per ogni token scritto (ciclo in rosso), e i verdetti vanno poi ricavati dal testo, che può non rispettare il formato richiesto.

1.3 Approccio e domande di ricerca

Questa tesi progetta, addestra e valuta GroundOne, un decision model compatto specializzato in un'unica decisione: stabilire, per ogni frase di una risposta RAG,

se il documento recuperato la supporta, la contraddice o non la menziona. La risposta viene scritta con un breve marker dopo ogni frase, e i verdetti di tutte le frasi si leggono in un unico forward pass, dai logit di tre lettere di risposta in corrispondenza dei marker, senza generare testo. Modelli Qwen2.5 da 0.5B e 3B parametri sono sottoposti a fine-tuning con LoRA sulle risposte di RAGTruth annotate manualmente [23, 24, 8], e le loro probabilità sono calibrate sul dev set. Tre test set sono stati costruiti e congelati prima di addestrare qualunque modello, così che nessuna scelta progettuale potesse essere ottimizzata su di essi. I tre problemi aperti diventano cinque domande di ricerca. Le prime due li riformulano in modo verificabile: RQ1 copre i primi due problemi e RQ2 il contributo del readout, mentre il ruolo della dimensione del modello viene isolato dalla scomposizione dei guadagni. Le altre tre aggiungono ciò che conta per un uso reale sul dispositivo, cioè l'affidabilità delle probabilità, il costo e il valore di una decisione a tre classi.

RQ1, specializzazione. Un decision model da 0.5B o 3B parametri, addestrato con fine-tuning sul task, riesce a stabilire se ogni frase è fedele al documento? E lo fa bene quanto modelli più grandi usati zero-shot[3] e quanto gli encoder specializzati in questa verifica?

RQ2, readout contro generazione. Quanto contribuisce il meccanismo del decision model, cioè il readout[4] della decisione dai logit, a parità di dimensione del modello? Il confronto è duplice: con giudici LLM che scrivono i propri verdetti e con lo stesso modello lasciato libero di generare la risposta. E come cambia la differenza quando aumenta il numero di frasi da verificare?

RQ3, calibrazione. Le probabilità restituite dal modello sono affidabili come misura di confidenza? In particolare, si possono usare per fissare una soglia di decisione e per rinviare all'utente i casi incerti? E sono migliori di quelle che si possono ottenere da un giudice LLM?

RQ4, costo sul dispositivo. Il verificatore rientra nei limiti di memoria, tempo ed energia di un laptop da 16 GB? E quanto costa rispetto a un giudice LLM eseguito sulla stessa macchina?

RQ5, oltre il punteggio binario. Che cosa guadagna chi usa il verificatore da una decisione a tre classi per ogni frase, rispetto al semplice punteggio di un verificatore binario?

---

[3]Un modello è usato *zero-shot* quando affronta un task senza alcun addestramento specifico e senza esempi nel prompt: riceve soltanto un'istruzione che descrive il compito.

[4]Con *readout* si indica la lettura della decisione direttamente dai logit del modello: invece di lasciargli scrivere una risposta, si confrontano i punteggi che assegna alle sole risposte ammesse (qui le lettere A, B e C) e si sceglie la più probabile.

1.4 Ambito

La tesi studia la fase di verifica in modo isolato. Il documento recuperato è dato, quindi la qualità del recupero non viene valutata, e una risposta è giudicata solo rispetto al documento da cui è stata generata, non rispetto alla conoscenza generale. GroundOne di per sé segnala le frasi ma non le corregge, e restituisce verdetti e probabilità anziché spiegazioni scritte; l'applicazione del Capitolo 8 aggiunge recupero e riscrittura, che non sono valutati come contributo sperimentale. I dati sono in inglese. I documenti più lunghi del contesto usato in addestramento vengono divisi in parti, come descritto nel Capitolo 6. Infine, gli esperimenti riguardano una sola classe di hardware, un laptop consumer con memoria unificata, e tutti i sistemi, baseline comprese, girano sulla stessa macchina.

1.5 Contributi

La tesi offre cinque contributi.

1. **GroundOne**, un decision model specialista e open per la verifica della groundedness a livello di frase, eseguito interamente su un laptop. Grazie a un marker inserito dopo ogni frase, legge tutti i verdetti di una risposta in un solo forward pass. È rilasciato come pacchetto installabile, con un'interfaccia a riga di comando e un'API HTTP locale che comprende anche un'interfaccia compatibile con l'interfaccia System One di Jev, già usata da altri client.

2. **Un dataset a livello di frase derivato da annotazioni pubbliche.** Nessuna etichetta è stata annotata ex novo: le annotazioni umane di RAGTruth, che marcano porzioni di testo, sono state convertite in un'etichetta a tre classi per ogni frase, con regole fissate in anticipo. I tre test set provengono da benchmark pubblici, sono stati verificati con controlli automatici, per esempio sulla segmentazione in frasi, e congelati prima di addestrare qualunque modello, con il leakage controllato a livello di documento[5].

3. **Una scomposizione controllata dei guadagni.** Il confronto isola il contributo della specializzazione, del readout ristretto e della dimensione del modello. GroundOne è confrontato con indizi elementari che non leggono mai il documento nel suo insieme, modelli non addestrati, giudici LLM con e senza

[5]Si parla di *leakage* (letteralmente "fuga" di informazione) quando dati del test set finiscono, direttamente o indirettamente, tra quelli usati per addestrare o configurare il modello: per esempio lo stesso documento, o risposte allo stesso documento, presenti in entrambi gli insiemi. Il modello può allora riconoscere esempi già visti invece di generalizzare, e le metriche di test risultano ottimistiche.

probabilità, due decision model generalisti (Rizzo-Flow, da 4B parametri, e d1-3B di Liquid AI, della stessa dimensione del 3B) ed encoder specializzati, tutti sullo stesso hardware e con intervalli ottenuti tramite bootstrap a cluster.

4. **Uno studio di calibrazione, tempo ed energia**: come le probabilità possano essere calibrate e tradotte in etichette coerenti, quanto aiutino a rinviare le decisioni incerte e come tempo ed energia di una verifica crescano con la lunghezza della risposta. Lo studio si inserisce in un'analisi dell'inferenza locale che combina le specifiche dei produttori con misure proprie per stabilire, per ogni classe di hardware consumer, il costo minimo che un verificatore che genera testo deve pagare e che un decision model non paga.

5. **GroundOne Studio**, un'applicazione per macOS in cui recupero, generazione e verifica avvengono nello stesso processo, sullo stesso portatile e senza servizi esterni. La risposta del generatore compare per prima; l'utente può poi verificarla con GroundOne, da solo o insieme a un giudice LLM eseguito in locale, vedere l'evidenza a supporto di ogni frase e far riscrivere le frasi segnalate. Un caso di studio con errori iniettati misura il ciclo di verifica e riscrittura.

1.6 Risultati principali

I risultati mostrano che la specializzazione funziona nel dominio per cui è stata pensata. Sul test set di RAGTruth GroundOne raggiunge una balanced accuracy[6] a tre classi di 0.769 con 0.5B parametri e di 0.832 con 3B, contro 0.37 e 0.44 degli stessi modelli prima dell'addestramento (per il 3B su un sottoinsieme di 600 risposte). Ordina le frasi supportate meglio degli encoder specializzati e, in balanced accuracy a tre classi, supera nettamente entrambi i decision model generalisti: Rizzo-Flow, otto volte più grande del 0.5B, e d1-3B, della stessa dimensione del 3B. Su LLM-AggreFact, un benchmark costruito da fonti diverse, il 3B è alla pari con il miglior encoder di piccole dimensioni.

Il meccanismo del decision model ripaga in velocità e in accuratezza. Quando una risposta contiene quattordici o più frasi e nulla è stato letto prima, il caso meno favorevole, GroundOne la verifica da 1.8 a 2 volte più velocemente di un giudice LLM sintetico e circa sei volte più velocemente di un giudice LLM verboso della stessa dimensione, con un output sempre valido e consumando meno energia.

[6] La *balanced accuracy* è la media, calcolata sulle classi, della recall, cioè della frazione di esempi di ciascuna classe classificati correttamente. A differenza dell'accuratezza semplice, non premia un modello che predice sempre la classe più frequente: un predittore costante ottiene 0.5 nel caso binario (50 se espressa in percentuale) e circa 0.33 con tre classi.

Il rapporto complessivo è limitato dalla lettura del testo, comune a ogni approccio: al netto di essa, GroundOne decide da 18 a 33 volte più in fretta del giudice LLM sintetico. Quando le fonti sono già nella KV cache, lette in anticipo mentre l'utente legge la risposta oppure per una verifica precedente, il vantaggio sulle stesse risposte lunghe sale a 3.4–3.6 volte, con la stessa cache per i due sistemi; dopo una riscrittura, quando GroundOne riusa anche l'inizio della risposta e i verdetti delle sue frasi, arriva, su tutte le risposte, da 7 a 12 volte, il caso più favorevole fra quelli misurati. Anche il modo di leggere la decisione conta: con lo stesso modello addestrato, scegliere la più probabile fra le sole tre lettere ammesse è più accurato che lasciare al modello generare liberamente il proprio verdetto, con un guadagno di balanced accuracy di 0.25 per il 0.5B e di 0.07 per il 3B. Dopo la calibrazione, le probabilità di GroundOne sono vicine alle frequenze osservate, mentre quelle dei giudici LLM a cui si chiede lo stesso output distinguono a stento le decisioni corrette da quelle errate.

Restano alcuni aspetti da migliorare, che indicano direzioni naturali per il lavoro futuro. Le prestazioni calano su domini lontani da quello di addestramento, dove il decision model generalista d1-3B risulta più forte; le allucinazioni più sottili, nascoste in frasi che per il resto ricalcano fedelmente la fonte, vengono individuate solo in parte; infine, l'addestramento non è ancora del tutto stabile al variare del seed[7].

Infine, l'applicazione GroundOne Studio mostra che attorno al verificatore si può costruire un assistente RAG completo, in un unico processo e senza rete, con al massimo 6.9 GB di memoria allocata da MLX con il generatore 3B predefinito. In un caso di studio con errori iniettati, GroundOne segnala l'errore in 97 delle 98 risposte in cui la frase riceve un verdetto, contro 84 del giudice LLM, e la riscrittura mirata riduce dal 100 % al 6 % le risposte che lo contengono ancora.

1.7 Struttura della tesi

Il Capitolo 2 è dedicato all'inferenza locale: le ragioni per mantenere i modelli sul dispositivo, i modelli open-weight e i modelli piccoli, il modello di costo dell'inferenza su un singolo dispositivo, il panorama dell'hardware, i runtime e la quantizzazione, l'energia e le conseguenze per la verifica. Il Capitolo 3 passa in rassegna i decision model e il loro ecosistema, le allucinazioni nella retrieval-augmented generation, i metodi di verifica, la calibrazione e il fine-tuning efficiente nei parametri. Il

[7] Il *seed* è il numero che inizializza il generatore di numeri casuali usato durante l'addestramento, per esempio per inizializzare i pesi aggiunti e per mescolare l'ordine dei dati. Ripetere l'addestramento con seed diversi produce modelli leggermente diversi: se i risultati cambiano molto da un seed all'altro, la procedura non è robusta.

Capitolo 4 descrive GroundOne: la decisione, il readout in un solo passaggio, l'obiettivo di addestramento, la calibrazione e l'output esposto dal servizio. Il Capitolo 5 definisce le etichette e descrive come sono stati costruiti, controllati e congelati il training set e i test set. Il Capitolo 6 presenta i modelli addestrati, le baseline, le metriche e il protocollo di misura. Il Capitolo 7 riporta i risultati, il Capitolo 8 presenta l'applicazione GroundOne Studio e il caso di studio, il Capitolo 9 discute il significato e i limiti dei risultati e il Capitolo 10 trae le conclusioni. L'Appendice A mostra l'output di tutti i sistemi sulla risposta di esempio descritta nella Sezione 1.1.2.

Capitolo 2

Inferenza locale dei modelli linguistici

Questa tesi costruisce un verificatore che gira interamente sulla macchina dell'utente, e questa scelta condiziona tutte le altre: la dimensione dei modelli, il modo in cui se ne leggono le decisioni, le misure e i confronti. Il capitolo spiega perché l'inferenza locale conta, che cosa la rende possibile oggi e quanto costa. Si parte dalle ragioni per mantenere un modello sul dispositivo e dai modelli open-weight che lo consentono. Si ricava poi un semplice modello di costo dell'inferenza su un singolo dispositivo, che mostra perché leggere un token costa molto meno che scriverlo, e si passa in rassegna l'hardware su cui girano i modelli locali, dal laptop usato in questo lavoro alle macchine desktop dedicate. Seguono il software e la quantizzazione, che portano i modelli alla portata di quell'hardware, e l'energia. Il capitolo si chiude traendo la conseguenza per la verifica, da cui discende il progetto di GroundOne descritto nei capitoli successivi.

2.1 Dai modelli remoti ai modelli locali

La maggior parte delle persone usa i modelli linguistici attraverso servizi remoti. L'input dell'utente viaggia in rete fino a un fornitore, un modello in un datacenter lo elabora e la risposta compie il percorso inverso. Il modello, l'hardware e le regole che governano i dati appartengono tutti al fornitore. Eseguire il modello sul dispositivo dell'utente cambia tutto questo in un colpo solo. Ne derivano cinque proprietà, e ciascuna conta per un assistente RAG che lavora su documenti privati.

La privacy come garanzia tecnica. Con un modello remoto, ogni documento e ogni domanda vengono inviati a una terza parte, e ciò che accade dopo (per quanto tempo vengono conservati, chi vi può accedere, se vengono usati per migliorare

i modelli futuri) è regolato da contratti e policy. L'utente può leggere la policy, ma non può verificare che venga rispettata. Con un modello locale i documenti non lasciano mai la macchina, e la questione non si pone nemmeno: la privacy diventa una proprietà del sistema anziché una promessa. Le rassegne sull'edge intelligence, cioè sull'esecuzione dei modelli su dispositivi periferici vicini all'utente, lo affermano esplicitamente: l'inferenza sul dispositivo elimina le fughe di dati privati e la necessità di una connessione a Internet [25].

Il diritto europeo rende concreta la differenza. Secondo il Regolamento generale sulla protezione dei dati (GDPR), il trattamento dei dati personali comprende esplicitamente la loro "comunicazione mediante trasmissione" [26, Art. 4(2)]. Inviare a un modello remoto un documento che contiene dati personali rende quindi il fornitore un responsabile del trattamento[1], vincolato da un contratto con le garanzie specifiche dell'Articolo 28. Se poi il fornitore opera al di fuori dell'Unione europea, il trasferimento dei dati deve avere una base giuridica: una decisione di adeguatezza[2], garanzie adeguate oppure una delle deroghe previste dagli Articoli 44–49 [26]. Un verificatore eseguito sul dispositivo dell'utente non coinvolge alcun responsabile del trattamento né alcun trasferimento. Non elimina ogni obbligo, perché l'organizzazione che lo usa deve comunque rispettare i principi dell'Articolo 5 e proteggere il dispositivo, ma elimina gli obblighi che dipendono dal doversi fidare di qualcun altro. Molti documenti riservati, come ricerche inedite, contratti o codice sorgente, non contengono affatto dati personali; per essi il regolamento non si applica, e l'argomento diventa di riservatezza.

Un episodio recente mostra che cosa sia in gioco. Nel settembre 2026 OpenAI ha annunciato che un proprio sistema multi-agente interno aveva prodotto una dimostrazione di blow-up (la formazione di una singolarità in tempo finito) per le equazioni di Navier–Stokes forzate, formalizzata nell'assistente di dimostrazione Lean, un risultato presentato come soluzione di uno dei problemi del Millennio, anche se la corrispondenza dell'enunciato formale con il problema è ancora in corso di verifica [7]. Due matematici, Tristan Buckmaster e Levent Alpöge, avevano diffuso più o meno nello stesso periodo risultati affini per le equazioni di Eulero, e ne hanno rivendicato la paternità. Buckmaster aveva scritto le proprie bozze nell'assistente di programmazione della stessa OpenAI, e ha chiesto all'azienda "whether the model had been trained on, or had access to, our sessions in Codex, into which we had been putting all our drafts" [27] (se il modello fosse stato addestrato sulle sessioni in Codex in cui i due avevano inserito tutte le bozze, o avesse avuto accesso a esse). OpenAI ha negato che i propri ricercatori o agenti avessero visto

[1]Nel GDPR il *titolare* del trattamento decide perché e come trattare i dati; il *responsabile* li tratta per conto del titolare, per esempio fornendo un servizio di calcolo.

[2]Una decisione con cui la Commissione europea riconosce che un paese terzo garantisce un livello di protezione dei dati sostanzialmente equivalente a quello europeo.

il lavoro prima della pubblicazione, ma ha aggiunto: "While unlikely, we cannot rule out that de-identified data derived from their usage of our products helped improve our models" [7, 28] (per quanto improbabile, non è possibile escludere che dati de-identificati derivati dal loro utilizzo dei prodotti dell'azienda abbiano contribuito a migliorarne i modelli). Nulla di quanto è pubblicamente noto indica che le bozze siano state usate impropriamente, e la disputa riguarda soprattutto la paternità del risultato. L'episodio mostra però che, una volta che un lavoro inedito è entrato in un modello remoto, né l'utente né, per sua stessa ammissione, il fornitore possono escludere che abbia contribuito ai modelli del fornitore. Con un modello locale la domanda non ha nemmeno senso.

I fornitori sono consapevoli del problema. Apple descrive l'elaborazione sul dispositivo come la pietra angolare del proprio approccio alla privacy e, per le richieste che eccedono le capacità del dispositivo, ha costruito Private Cloud Compute, un cloud dedicato con server su misura, nessun accesso privilegiato per il personale, nessuna conservazione persistente delle richieste e un registro pubblico delle immagini software che vi vengono eseguite [29]. Il progetto è un tentativo serio di rendere verificabile l'inferenza remota, e la sua stessa complessità è un argomento a favore della località. Per garantire la privacy nel cloud servono silicio su misura, un sistema operativo irrobustito e un'attestazione crittografica, cioè una prova firmata di quale software sia in esecuzione sui server. Anche così, il sistema poggia sulla fiducia nell'hardware, nella filiera di fornitura e nell'attestazione stessa, che soltanto i ricercatori di sicurezza, e non gli utenti, sono in grado di ispezionare [29].

Disponibilità. Un modello locale funziona senza rete e senza dipendere dalla disponibilità di un fornitore. Per un assistente usato in treno, in un reparto ospedaliero con connettività limitata o in un ambiente air-gapped, cioè isolato fisicamente da qualunque rete, questo è un requisito, non una comodità.

Stabilità e riproducibilità. I pesi di un modello locale cambiano solo quando è l'utente a cambiarli. Un modello remoto può essere aggiornato, riaddestrato o ritirato in qualunque momento, spesso senza preavviso, così che la stessa richiesta produca risposte diverse da un mese all'altro. Per un verificatore le cui soglie sono calibrate sui dati di sviluppo (Capitolo 4), un cambiamento silenzioso del modello sottostante invaliderebbe la calibrazione senza alcun avviso.

Costo. Un modello remoto si paga a token, e un verificatore che controlla ogni risposta moltiplica il numero di token elaborati. Un modello locale si paga una volta sola, con l'hardware, e poi costa soltanto l'energia che consuma.

Accesso agli stati interni del modello. Un modello locale espone i propri logit, i punteggi da cui si calcola ogni probabilità. Le interfacce remote spesso li

nascondono o li restituiscono solo per pochi token. L'approccio studiato in questa tesi legge la decisione direttamente dai logit di poche lettere di risposta e li calibra, quindi richiede questo accesso; in questo senso è possibile soltanto con un modello locale.

Il prezzo della località. Questi vantaggi hanno un costo. Un laptop ospita solo modelli piccoli, e deve ospitarli accanto al sistema operativo, alle applicazioni dell'utente e a ogni altro componente dell'assistente. Dispone di meno banda di memoria e di meno capacità di calcolo di un acceleratore da datacenter, e funziona a batteria. Una parte della letteratura conclude che un'esecuzione puramente sul dispositivo è troppo limitata e propone di dividere il lavoro con un server edge, cioè un server vicino all'utente, o con il cloud [25, 30]: un modello locale piccolo gestisce le richieste facili e inoltra quelle difficili, oppure scrive una bozza di risposta che un modello remoto più grande controlla. L'abbinamento di Apple tra un modello sul dispositivo e Private Cloud Compute è l'esempio più visibile [4, 29]. Queste soluzioni ibride riducono il costo della località ma ne sacrificano una parte dei benefici, perché tutto ciò che viene inoltrato lascia il dispositivo. Questa tesi adotta la posizione più rigorosa: l'intera verifica resta sul dispositivo, e il resto del capitolo esamina che cosa ciò richieda.

La Tabella 2.1 riassume il confronto.

2.2 Modelli open-weight e small language model

L'inferenza locale richiede un modello i cui pesi si possano scaricare. Questa sezione descrive che cosa siano questi modelli, quanto distino dai migliori modelli chiusi e quali siano abbastanza piccoli per un dispositivo personale.

2.2.1 Open-weight non significa open source

Un modello si dice *open-weight* quando i suoi parametri addestrati sono pubblicati e chiunque può eseguirli e modificarli. Non è la stessa cosa che essere open source. La Open Source Initiative definisce un sistema di IA open source attraverso le quattro libertà della tradizione del software libero (usare, studiare, modificare e condividere il sistema) e richiede che sia disponibile la forma preferita per modificarlo: i parametri, il codice completo usato per addestrarlo ed eseguirlo, e informazioni sui dati di addestramento sufficienti perché una persona esperta possa costruire un sistema sostanzialmente equivalente [31]. I dati in sé non devono necessariamente essere rilasciati, ma i soli pesi non bastano. La maggior parte dei modelli comunemente definiti open pubblica i pesi e una ricetta per l'inferenza, ma né il codice di addestramento né una descrizione dettagliata dei dati. Essere open è

Tabella 2.1: Inferenza remota e inferenza locale a confronto sulle proprietà che contano per un verificatore di documenti privati.

Proprietà	Modello remoto	Modello locale
Privacy	Contrattuale: i documenti sono inviati a un responsabile del trattamento; l'utente non può verificare come vengano usati.	Tecnica: i documenti non lasciano mai il dispositivo.
Normativa (GDPR)	Contratto con il responsabile (Art. 28); trasferimenti verso paesi terzi (Artt. 44–49).	Nessun responsabile e nessun trasferimento; restano i principi dell'Art. 5 e la sicurezza del dispositivo.
Disponibilità	Richiede la rete e l'operatività del fornitore.	Funziona offline.
Stabilità	Il fornitore può aggiornare o ritirare il modello.	I pesi cambiano solo se è l'utente a cambiarli.
Costo	Prezzo per token.	Hardware una tantum, poi energia.
Logit	Spesso nascosti o limitati.	Pienamente accessibili: readout e calibrazione possibili.
Capacità	Modelli di frontiera.	Modelli piccoli, limitati da memoria, banda e batteria.

quindi una questione di grado, non una proprietà binaria. Un indice recente valuta i modelli su cinque aspetti: la disponibilità dei pesi, la documentazione dei dati di pre-training e di post-training (le due fasi dell'addestramento, su testo generico e poi su istruzioni e preferenze), la metodologia e la licenza [32]. Nessun modello raggiunge il punteggio massimo; i modelli di ricerca interamente documentati, come OLMo, ottengono punteggi alti, mentre alcuni modelli open-weight molto diffusi pubblicano poco oltre ai pesi.

Le licenze aggiungono un'ulteriore distinzione. I due modelli sottoposti a fine-tuning in questa tesi appartengono alla stessa famiglia ma hanno licenze diverse: Qwen2.5-0.5B è rilasciato con la licenza permissiva Apache 2.0, mentre Qwen2.5-3B è rilasciato con una licenza di ricerca che ne limita l'uso commerciale [23]. Nella terminologia appena introdotta entrambi sono modelli open-weight, ed è questo il termine che la tesi usa per indicarli. La distinzione conta anche sul piano normativo. L'AI Act europeo attenua alcuni obblighi di trasparenza per i modelli general-purpose rilasciati con licenze libere e open source, ma non per quelli che presentano un rischio sistemico. Un modello si presume a rischio sistemico quando il suo

addestramento ha richiesto più di 10^{25} operazioni in virgola mobile (FLOP[3]) [33], molte più di quelle usate per i modelli di questa tesi.

2.2.2 Il divario con i modelli chiusi si sta chiudendo

L'inferenza locale avrebbe un interesse limitato se i modelli open-weight fossero molto indietro rispetto a quelli chiusi. Non lo sono. Sulla leaderboard Chatbot Arena, dove gli utenti confrontano le risposte di due modelli anonimi, il vantaggio del miglior modello chiuso sul miglior modello open-weight è sceso dall'8.04 % del gennaio 2024 all'1.70 % del febbraio 2025 [6]. Sul capabilities index di Epoch AI, che aggrega molti benchmark, i migliori modelli open-weight sono rimasti indietro rispetto alla frontiera chiusa di circa quattro mesi in media tra gennaio e maggio 2026 (Figura 2.1) [34].

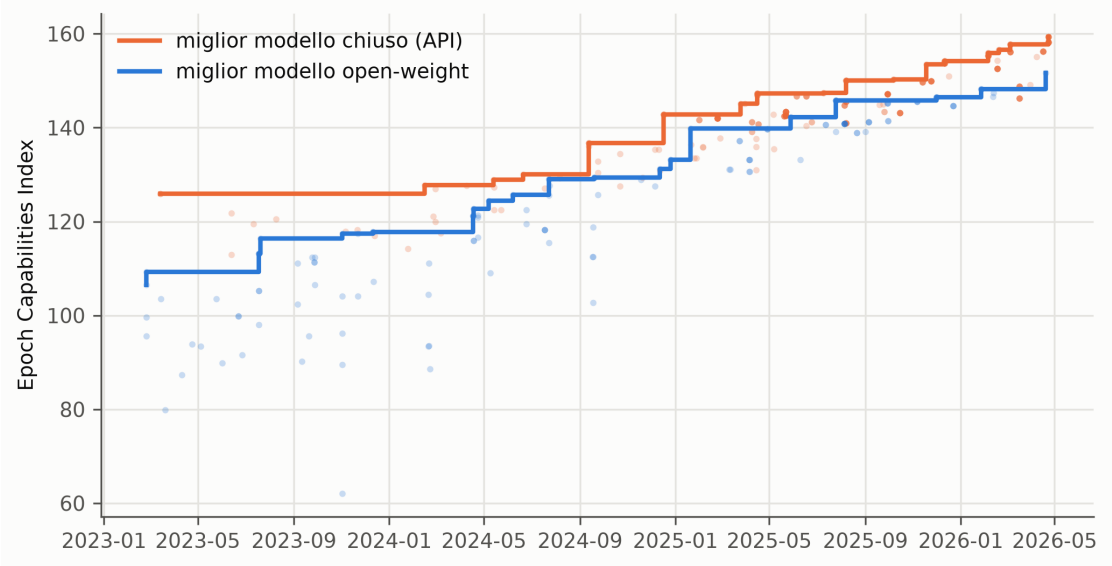


Figura 2.1: Capacità del miglior modello chiuso e del miglior modello open-weight nel tempo, sull'indice aggregato di capacità di Epoch AI (punti: singoli modelli; linee: migliore fino a quel momento). Grafico ricavato dalla tabella dati pubblicata da Epoch AI [34].

Una fotografia più recente conferma il quadro e ne mostra anche il limite. Sull'Intelligence Index di Artificial Analysis, che aggrega dieci valutazioni, al 20

[3]Un FLOP è una singola operazione aritmetica su numeri in virgola mobile, come una somma o una moltiplicazione. La velocità di calcolo si misura in FLOP al secondo: un TFLOP/s corrisponde a 10^{12} operazioni al secondo.

ottobre 2026 il miglior modello chiuso, Claude Opus 5.5, ottiene 58 punti, mentre il miglior modello open-weight, MiMo-V2.6-Pro, ne ottiene 46 (Figura 2.2) [35]. Diversi modelli open-weight, come DeepSeek V4.1 Flash, GLM-5.3 e Kimi K3, eguagliano o superano modelli chiusi di fascia media come Claude Haiku 5.5 e Gemini 3.8 Flash. Tutti questi modelli open-weight, però, appartengono alla classe dei modelli grandi, mentre l'unico modello del grafico che Artificial Analysis classifica come piccolo, Qwen3.8 27B, si ferma a 34 punti.

Questo non significa che i modelli grandi siano esclusi dall'hardware locale. I motori di inferenza specializzati descritti nella Sezione 2.5.2, come ds4 e Colibri, eseguono grandi modelli open-weight, per esempio DeepSeek V4 Flash e GLM-5.2, anche quando i loro pesi non entrano in memoria: tengono residente la parte sempre attiva e leggono il resto dall'SSD. Il limite si sposta allora dalla capacità alla velocità. Secondo gli autori di Colibri, GLM-5.2 genera 1.83 token al secondo su una macchina Strix Halo da 128 GB e meno di un token al secondo su un laptop [36]. Per un dispositivo personale, quindi, la domanda non è soltanto quale modello si riesca a eseguire, ma a quale velocità possa generare testo; ed è proprio la generazione la fase che un decision model evita.

Per un uso interattivo conta soprattutto il miglior modello che entra per intero nella memoria di un hardware consumer, e che può quindi generare senza dipendere dalla banda dell'SSD. Epoch AI misura direttamente questa grandezza. Considerando i modelli abbastanza piccoli da girare su una singola scheda grafica consumer, al massimo circa 28 miliardi di parametri per una scheda da 24 GB e circa 40 miliardi per una da 32 GB, rileva che su quattro benchmark essi raggiungono le prestazioni del modello di frontiera del momento dopo sei-dodici mesi [5]. Tre forze trainano il recupero: gli sviluppatori di modelli open-weight aumentano il calcolo di addestramento più o meno alla stessa velocità di quelli chiusi, la distillazione, cioè l'addestramento di un modello piccolo a imitare le risposte di uno grande, ne trasferisce gran parte delle capacità, e ogni nuova generazione di schede grafiche aumenta la dimensione dei modelli che vi trovano posto [37]. La stessa tendenza emerge dal lato opposto: il modello più piccolo con un punteggio superiore al 60 % sul benchmark MMLU, un insieme di domande a scelta multipla su 57 materie, aveva 540 miliardi di parametri nel 2022 e 3.8 miliardi nel 2024, una riduzione di 142 volte [6].

2.2.3 Small language model

All'estremo inferiore della scala si trovano gli *small language model*. Le definizioni variano; una rassegna che ne misura diverse decine sui dispositivi colloca l'intervallo tra 100 milioni e 5 miliardi di parametri, con architettura decoder-only, cioè quella dei comuni LLM che generano il testo da sinistra a destra [38]. I modelli piccoli vengono addestrati su molti più dati di quanto converrebbe se si volesse soltanto

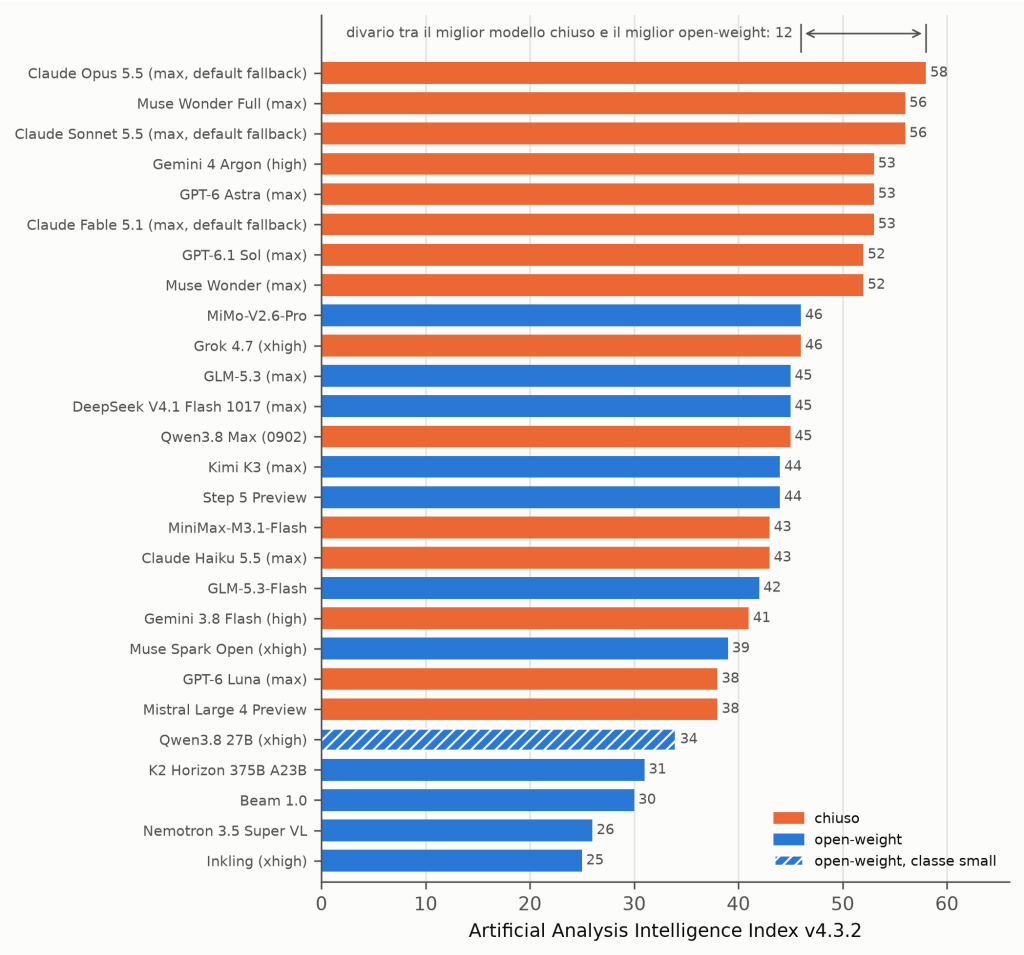


Figura 2.2: Artificial Analysis Intelligence Index (versione 4.3.2, dieci valutazioni) al 20 ottobre 2026, ridisegnato dal grafico pubblicato [35]. In arancione i modelli chiusi, in blu quelli open-weight; tratteggiato l'unico modello che Artificial Analysis classifica come piccolo. Tra parentesi l'impostazione di ragionamento con cui è stato valutato ciascun modello. Lo stato open-weight è ricavato dai dati della stessa leaderboard. È un'istantanea: punteggi e classifica cambiano a ogni nuovo rilascio.

minimizzare il costo dell'addestramento. Il motivo è che per essi il costo che conta è l'inferenza, ripetuta milioni di volte dopo l'addestramento: conviene quindi spendere di più una volta sola per ottenere un modello piccolo ma capace. Un modello da mezzo miliardo di parametri può così vedere migliaia di miliardi di token [38]. Misurati su dispositivi edge con pesi a 4 bit, i modelli tra 0.1 e 3 miliardi di parametri richiedono tra 0.3 e 2.5 GB di memoria, e con contesti lunghi la maggior parte della memoria è occupata dalla KV cache, che conserva il contesto già letto (Sezione 2.3.1), e dai buffer di calcolo [38]. Le ricerche sui modelli sotto il miliardo di parametri sostengono che, sugli smartphone, un'applicazione non dovrebbe usare più di circa un decimo della memoria del dispositivo, e mostrano che un modello da 350 milioni di parametri progettato con cura eguaglia un modello generalista da 7 miliardi su un task ristretto come l'invocazione di un'interfaccia applicativa [39].

I produttori di piattaforme hanno adottato la stessa idea. Il foundation model che Apple impiega sui propri dispositivi ha circa tre miliardi di parametri, è quantizzato a meno di quattro bit per peso ed è specializzato per ciascuna funzionalità con piccoli adapter low-rank, moduli aggiuntivi con pochi parametri addestrati sul singolo compito (Sezione 3.5) [4]; la famiglia Gemma 3n di Google è progettata per girare su smartphone e laptop con un'impronta di memoria ridotta, ed è promossa esplicitamente per la privacy e l'uso offline [40]. GroundOne segue lo stesso schema: un modello open-weight piccolo, quantizzato e specializzato da un adapter per un unico task.

2.3 Il costo dell'inferenza su un singolo dispositivo

Le sezioni precedenti spiegano perché un modello dovrebbe girare in locale e quali modelli possono farlo. Questa sezione spiega quanto costa eseguirne uno, e perché il costo dipende così tanto da ciò che gli si chiede di fare.

2.3.1 Prefill e decoding

Un modello linguistico decoder-only elabora una richiesta in due fasi. Nella fase di *prefill* legge l'intero prompt in una volta. Per farlo usa il meccanismo di attenzione, con cui ogni token raccoglie informazioni dai token che lo precedono: ogni strato calcola, per ciascun token di input, due vettori (una *chiave* e un *valore*) che i token successivi consulteranno, e li memorizza nella *KV cache* (dall'inglese key-value). Nella fase di *decoding* produce l'output un token alla volta; ogni nuovo token consulta la cache attraverso l'attenzione e la estende di una posizione [10]. Il prefill elabora molti token in parallelo, il decoding uno solo. I sistemi che servono i modelli

a molti utenti sfruttano questa differenza in vari modi, per esempio gestendo la cache a pagine per accogliere più richieste concorrenti [41] oppure eseguendo le due fasi su macchine diverse, ciascuna adatta alla propria [42].

La conseguenza è visibile sul laptop usato in questa tesi (Figura 2.3). Con il modello da 0.5B, leggere un token del prompt richiede meno di 0.4 millisecondi, mentre scrivere un token di output ne richiede 5.9, sedici volte di più. Con il modello da 3B i valori sono 2.2 e 31.8 millisecondi, quattordici volte di più. Un modello che scrive un breve paragrafo impiega quindi più tempo a scriverlo che a leggere un documento di mille-duemila token.

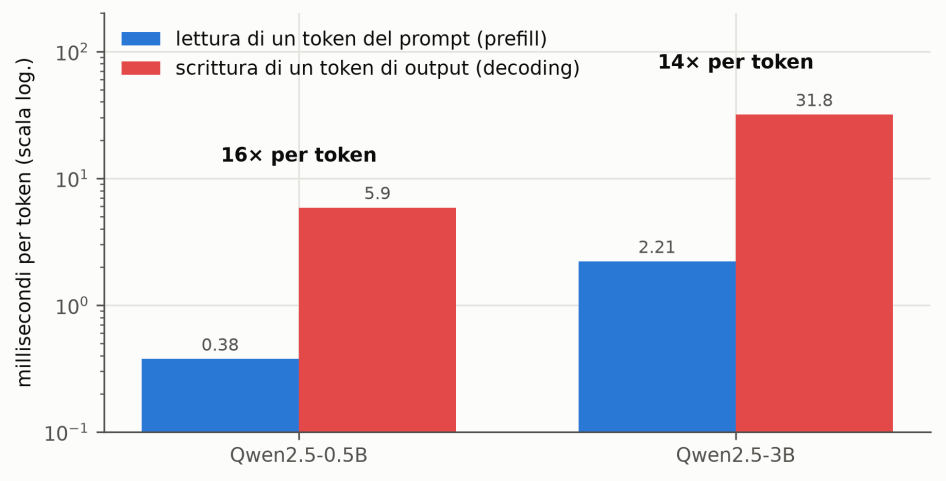


Figura 2.3: Tempo per token quando il modello legge l'input (prefill) e quando scrive l'output (decoding), misurato sulla macchina della tesi (Apple M4, 16 GB, MLX a 8 bit, una richiesta alla volta). Prefill: mediana su contesti di 500, 1000 e 2000 token.

2.3.2 Il modello roofline

La ragione di questa asimmetria è colta dal modello roofline, un semplice modello delle prestazioni introdotto per i processori multicore [43]. Una computazione è caratterizzata dalla sua *intensità aritmetica*, cioè dal numero di operazioni in virgola mobile che esegue per ogni byte letto dalla memoria. Un processore ha due limiti: una velocità di calcolo di picco e una banda di memoria di picco. La velocità raggiungibile è il minimo tra il calcolo di picco e il prodotto tra banda e intensità. Una computazione a bassa intensità è limitata dalla banda, una ad alta intensità dal calcolo; l'intensità alla quale i due limiti si incontrano si chiama punto di cresta (ridge point) [43].

Applicato a un transformer, il modello separa nettamente le due fasi [44]. Ogni matrice di pesi di uno strato lineare deve essere letta dalla memoria una volta per forward pass. Durante il prefill la stessa matrice moltiplica gli stati nascosti di centinaia o migliaia di token, quindi ogni byte di pesi serve per centinaia di operazioni: l'intensità è alta e il limite è il calcolo. Durante il decoding la matrice moltiplica un singolo vettore, quindi ogni peso serve per circa due operazioni: l'intensità è vicina a uno e il limite è la banda. Per un modello da 7 miliardi di parametri a 16 bit, gli strati lineari raggiungono intensità superiori a mille operazioni per byte nel prefill e di circa una nel decoding [44]. Nei datacenter questo squilibrio si attenua: il decoding di molte richieste contemporanee viene raggruppato in batch, così che ogni peso letto dalla memoria serve a generare più token e l'intensità sale [10]. Un dispositivo personale serve invece un solo utente, una richiesta alla volta, e non può contare su questo rimedio: è qui che l'asimmetria tra le due fasi pesa di più.

La Figura 2.4 traccia il roofline della macchina della tesi. Apple pubblica la banda di memoria, 120 GB/s, ma non la velocità di calcolo di picco [45]; il tetto piatto della figura è quindi la velocità effettivamente raggiunta durante il prefill, circa 2.8 TFLOP/s, che costituisce un limite inferiore del picco. Il ridge point si trova a circa 23 operazioni per byte. La generazione di un token si colloca a circa due operazioni per byte, un ordine di grandezza sotto il ridge point, mentre la lettura di un documento di centinaia di token si colloca un ordine di grandezza sopra. Le due fasi dello stesso modello, sulla stessa macchina, vivono in regimi diversi.

2.3.3 Un limite inferiore alla generazione

Poiché il decoding legge ogni peso una volta per ogni token generato, il suo tempo per token non può scendere sotto la dimensione dei pesi divisa per la banda di memoria, su qualunque hardware, a meno di ricorrere a tecniche come lo speculative decoding (Sezione 2.5.4) o a una quantizzazione più spinta. Per il modello da 3B a 8 bit, i cui pesi occupano circa 3.3 GB, questo limite vale 27 millisecondi per token su una macchina da 120 GB/s; i 31.8 millisecondi misurati lo superano solo di circa un sesto. Il limite dipende da due soli numeri, la dimensione del modello e la banda della macchina, e si applica a ogni modello che genera testo. È la chiave per confrontare l'hardware nella Sezione 2.4 e per la conseguenza tratta nella Sezione 2.7.

La capacità di memoria impone un secondo limite, ancora più rigido: i pesi devono entrare in memoria. Un modello richiede circa due byte per parametro nel formato a 16 bit usato in addestramento, uno a 8 bit e mezzo a 4 bit, più alcuni piccoli fattori di scala per ogni gruppo di pesi, necessari a ricostruirne il valore (Figura 2.5). Un modello da 7 miliardi di parametri a 16 bit richiede 14 GB per i

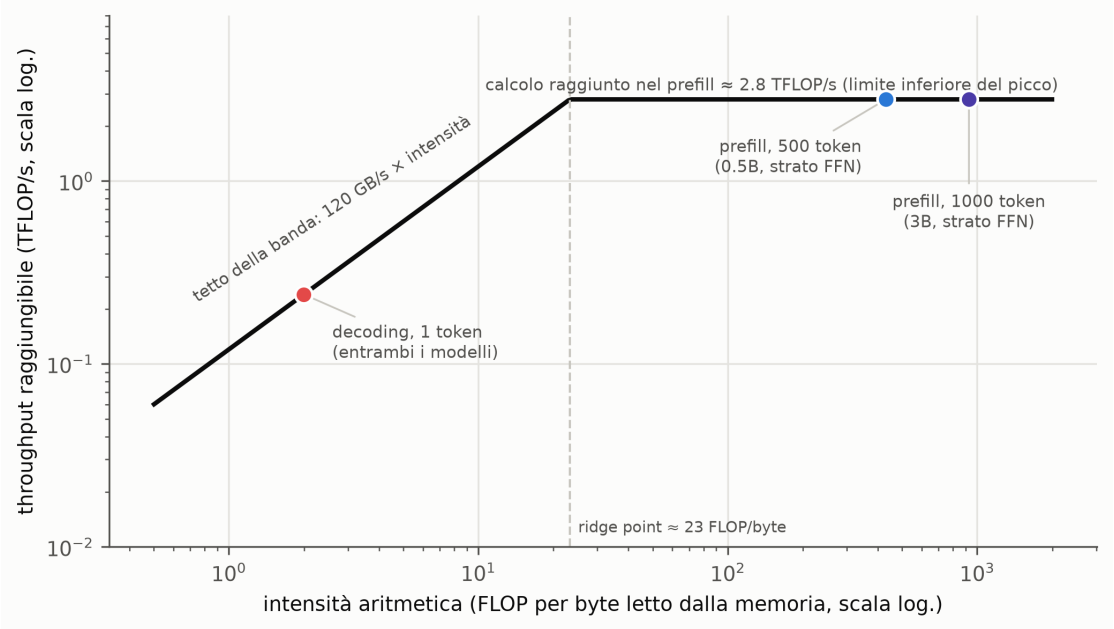


Figura 2.4: Modello roofline della macchina della tesi [43]. Tetto inclinato: banda di memoria dichiarata da Apple (120 GB/s). Tetto piatto: throughput raggiunto nel prefill, limite inferiore del picco non pubblicato. Intensità calcolate per uno strato feed-forward di Qwen2.5 con pesi a 8 bit e attivazioni a 16 bit; l'attenzione è trascurata.

soli pesi, più di quanto la maggior parte dei dispositivi personali possa mettere a disposizione [46]; a 4 bit ne richiede circa 4. A questi si aggiungono la KV cache, le attivazioni, il sistema operativo e ogni altro modello in esecuzione nello stesso momento. Un laptop da 16 GB può quindi ospitare un generatore da 7–8 miliardi di parametri a 4 bit accanto a un piccolo verificatore, ma non molto di più.

2.4 L'hardware per l'inferenza locale

Il modello di costo riduce la scelta dell'hardware per l'inferenza locale a tre grandezze. La *capacità di memoria* stabilisce quali modelli entrano. La *banda di memoria* stabilisce quanto velocemente possono generare. La *capacità di calcolo* stabilisce quanto velocemente possono leggere. Potenza e prezzo completano il quadro. Questa sezione passa in rassegna l'hardware disponibile a ottobre 2026 lungo questi assi, sulla base delle specifiche pubblicate dai produttori.

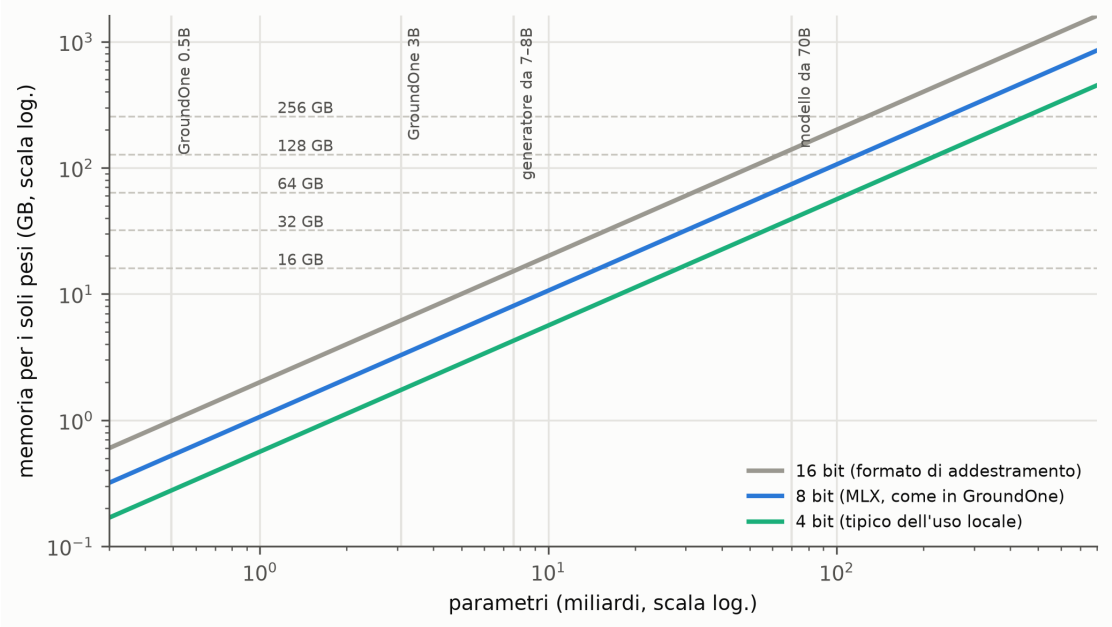


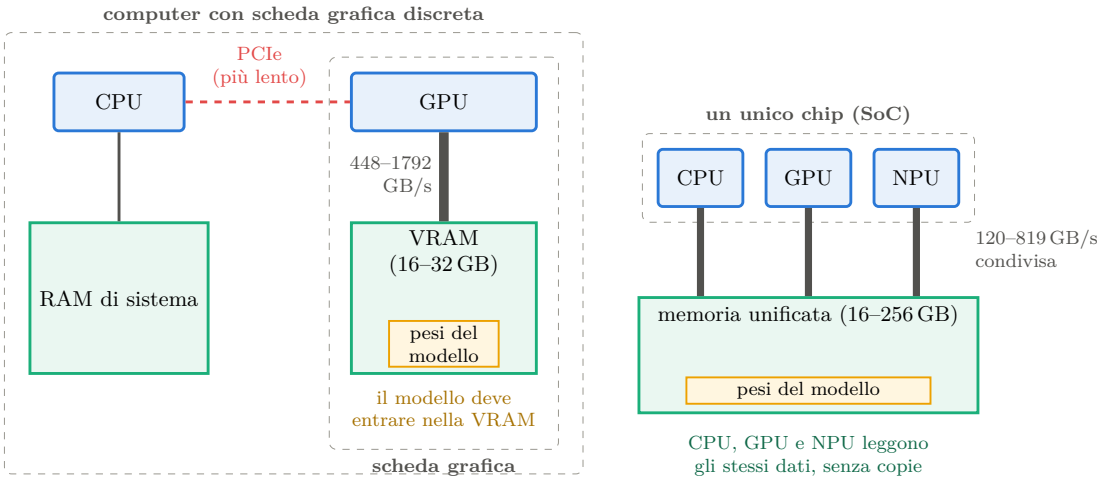
Figura 2.5: Memoria necessaria per i pesi di un modello in funzione della sua dimensione e della precisione (numero di parametri moltiplicato per i bit per peso, compreso mezzo bit di scale per gruppo nei formati quantizzati). Linee tratteggiate: tagli di memoria comuni nell'hardware locale. La KV cache, le attivazioni e gli altri modelli in esecuzione si aggiungono a questo valore.

2.4.1 Classi di hardware

Dominano due architetture. In un sistema *discreto* la scheda grafica ha una propria memoria, veloce ma piccola, e il modello deve entrare in essa. In un sistema a *memoria unificata* il processore e l'unità grafica condividono un unico, ampio blocco di memoria, così che un modello può usarne la maggior parte, con una banda però inferiore a quella di una scheda grafica di fascia alta. I processori di Apple, il DGX Spark di NVIDIA e il Ryzen AI Max (Strix Halo) di AMD seguono tutti questa seconda architettura. La Figura 2.6 mette a confronto le due architetture.

La Tabella 2.2 e la Figura 2.8 collocano le principali opzioni sui due assi della memoria. La Figura 2.7 mostra alcuni dei sistemi citati, per dare un'idea concreta di come si presentano.

Laptop. I laptop con 16–32 GB e 120–153 GB/s, come il MacBook Pro usato in questa tesi, sono i computer personali più diffusi su cui girano modelli locali. Ospitano senza difficoltà i modelli piccoli, e quelli da 7–8 miliardi di parametri a



(a) Sistema discreto: la GPU legge i pesi dalla propria VRAM, molto veloce ma limitata a 16–32 GB; il resto del sistema è raggiungibile solo attraverso il PCIe.

(b) Memoria unificata: CPU, GPU e NPU sullo stesso chip condividono un unico blocco di memoria, più ampio ma con una banda inferiore.

Figura 2.6: Le due architetture dell'hardware per l'inferenza locale. Rettangoli blu: unità di calcolo; rettangoli verdi: memoria; rettangolo arancione: i pesi del modello; spessore delle linee: banda indicativa. Valori di capacità e banda dalla Tabella 2.2. In un sistema discreto un modello che non entra nella VRAM deve passare dal collegamento PCIe, molto più lento; in un sistema a memoria unificata il modello può occupare quasi tutta la memoria della macchina, ma ogni token generato la legge a una velocità inferiore a quella di una scheda grafica di fascia alta.

4 bit. La macchina della tesi si trova in basso a sinistra nella Figura 2.8: se un verificatore funziona bene lì, funziona su tutto ciò che sta sopra.

Macchine desktop a memoria unificata. Una seconda classe, entro o vicino a un budget di circa tremila dollari, offre molta più memoria con una banda moderata. Il processore Strix Halo di AMD, venduto per esempio nel Framework Desktop, consente all'unità grafica di usare fino a 96 GB dei suoi 128 GB di memoria; al lancio, nell'agosto 2025, la configurazione da 128 GB costava 1999 dollari, con una potenza del processore di 55 W [51]. Il Mac mini di Apple con M5 Pro arriva a 64 GB a 307 GB/s [48]. Macchine di questo tipo possono ospitare modelli da decine di miliardi di parametri o modelli mixture-of-experts, composti da molte sottoreti (gli esperti) di cui ogni token ne attiva solo una parte, così che il decoding legge soltanto i pesi degli esperti attivi, al prezzo di una generazione più lenta che su una scheda grafica.



(a) MacBook Pro da 14 pollici con M4, la macchina della tesi.



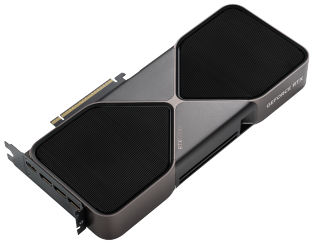
(b) Mac mini (2024, M4).



(c) Mac Studio.



(d) NVIDIA DGX Spark.



(e) Scheda grafica GeForce RTX 5090 Founders Edition.

Figura 2.7: Alcuni dei sistemi per l'inferenza locale confrontati in questa sezione (immagini non in scala). Fonti: (a), (c) Apple; (b) LoMit, Wikimedia Commons, CC0; (d), (e) NVIDIA. Le immagini dei produttori sono materiale promozionale, riprodotto a scopo di documentazione scientifica.

Macchine dedicate all'IA. Oltre questo budget, il Mac Studio con M3 Ultra unisce fino a 256 GB a 819 GB/s [49], mentre il DGX Spark di NVIDIA è un piccolo box desktop, con alimentatore da 240 W, che contiene 128 GB di memoria unificata con 273 GB/s di banda e un'unità grafica Blackwell da un petaflop (10^{15} operazioni al secondo) in aritmetica a 4 bit, valore che sfrutta la sparsità, cioè il salto dei pesi nulli [50]. Le due macchine compiono scelte opposte, e un confronto diretto mostra il modello di costo all'opera: su un modello da 8 miliardi di parametri con un prompt di 8000 token, il DGX Spark completa il prefill 3.8 volte più velocemente del Mac Studio, grazie al calcolo più elevato, mentre il Mac Studio genera 3.4 volte più velocemente, grazie a una banda tre volte superiore [53]. Lo stesso studio combina le due macchine, eseguendo il prefill sullo Spark e il decoding sul Mac: è la disaggregazione delle due fasi [42] portata su una scrivania.

Schede grafiche. Le schede dedicate offrono di gran lunga la banda più alta, fino a 1792 GB/s per la RTX 5090, ma al massimo 32 GB di memoria, con una

Tabella 2.2: Hardware per l'inferenza locale: specifiche pubblicate dai produttori (consultate l'11 ottobre 2026). Memoria: intervallo delle configurazioni offerte; banda: relativa a quelle configurazioni; N.d.: non dichiarato dalla fonte.

Sistema	Memoria (GB)	Banda (GB/s)	Tipo di memoria	Fonte
MacBook Pro, M4 (macchina della tesi: 16 GB)	16–32	120	Unificata	[45]
MacBook Pro / Mac mini, M5	16–32	153	Unificata	[47, 48]
Mac mini, M5 Pro	24–64	307	Unificata	[48]
MacBook Pro, M5 Max	36–128	460–614	Unificata	[47]
Mac Studio, M4 Max	36–128	410–546	Unificata	[49]
Mac Studio, M3 Ultra	96–256	819	Unificata	[49]
NVIDIA DGX Spark (GB10)	128	273	Unificata	[50]
Framework Desktop, AMD Strix Halo	32–128 (96 alla GPU)	N.d.	Unificata	[51]
NVIDIA RTX 5090	32	1792	Discreta	[52]
NVIDIA RTX 5080	16	960	Discreta	[52]
NVIDIA RTX 5060 Ti	16	448	Discreta	[52]

potenza di diverse centinaia di watt [52]. Sono l'opzione più veloce per qualunque modello vi entri, e inutilizzabili per qualunque modello non vi entri.

Smartphone e processori mobili. All'estremo opposto, gli smartphone hanno da 6 a 16 GB di memoria e una banda di qualche decina di gigabyte al secondo, condivisa da tutti i processori [30, 54]. Le loro unità di elaborazione neurale (NPU) sono veloci nelle moltiplicazioni di matrici a 8 bit, e quindi nel prefill: su uno smartphone, un modello da 7 miliardi di parametri a 4 bit legge il prompt a circa 770 token al secondo sulla NPU, contro 37 sull'unità grafica e 8 sui core del processore [54]. I sistemi di ricerca ne approfittano eseguendo il prefill sulla NPU e il decoding altrove [55].

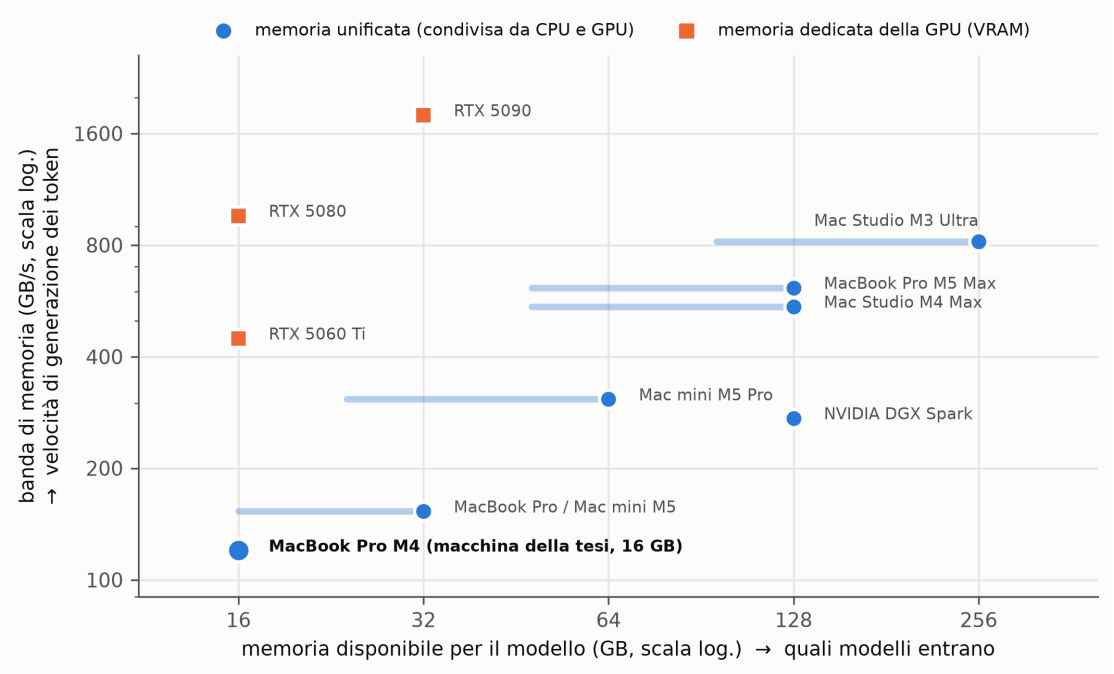


Figura 2.8: L'hardware per l'inferenza locale sui due assi che stabiliscono che cosa può girare: capacità di memoria (quali modelli entrano) e banda di memoria (quanto velocemente si generano i token). Specifiche dei produttori: marcatori in corrispondenza della configurazione con più memoria, barre ombreggiate sull'intervallo di tagli di memoria offerti; la macchina della tesi è rappresentata con i suoi 16 GB effettivi.

2.4.2 L'asimmetria vale per ogni classe

Le due fasi dipendono da proprietà diverse dell'hardware, e le generazioni più recenti lo rendono esplicito. Apple riporta che il processore M5, che aggiunge unità matriciali dedicate a ogni core grafico, riduce di 3.3–4.1 volte rispetto all'M4 il tempo al primo token, cioè l'attesa prima che il modello inizi a rispondere, dominata dal prefill, mentre la generazione diventa soltanto 1.19–1.27 volte più veloce, in linea con una banda di memoria passata da 120 a 153 GB/s [56]. È la stessa Apple ad attribuire il primo dato al calcolo e il secondo alla banda. Sui dispositivi edge, uno studio che confronta 18 coppie di configurazioni rileva che i rallentamenti si accumulano nel decoding, mentre il tempo di valutazione del prompt varia al massimo del 16 % [57]. Sugli smartphone, per i task con output breve, il prefill occupa la maggior parte della latenza [55]. L'hardware si sta quindi evolvendo per leggere più velocemente, molto più che per scrivere più velocemente.

La Figura 2.9a applica il limite inferiore della Sezione 2.3.3 all'hardware della

Tabella 2.2. Sulla scheda più veloce il modello da 3B potrebbe in linea di principio generare un token in 1.8 millisecondi; sulla macchina della tesi il limite è di 27 millisecondi, e il tempo misurato vi si avvicina. Un hardware migliore abbassa il limite, ma nessun hardware lo elimina.

2.5 Runtime e quantizzazione

2.5.1 Runtime

Il software per l'inferenza locale è maturato rapidamente. llama.cpp offre inferenza in C e C++ senza dipendenze esterne, con quantizzazione e supporto per la maggior parte degli acceleratori consumer [2]. Ha inoltre definito il formato GGUF, che raccoglie in un unico file il modello quantizzato e tutto ciò che serve per usarlo, come il tokenizer e il formato delle conversazioni. Strumenti come Ollama e LM Studio si basano su di esso e riducono a un solo comando lo scaricamento e l'avvio di un modello. MLX è un framework di calcolo progettato da Apple per la memoria unificata dei propri processori, con un'interfaccia vicina a NumPy [3]. Il suo pacchetto per modelli linguistici supporta la quantizzazione e il fine-tuning con LoRA direttamente sul dispositivo [58], ed è il runtime usato in tutta questa tesi.

Il runtime conta quanto il chip. Un confronto tra cinque runtime sulla stessa macchina Apple riporta velocità di decoding che differiscono di oltre un ordine di grandezza, con MLX e MLC-LLM in cima e il backend Metal generico di PyTorch in fondo [59]; i numeri dello studio non sono del tutto coerenti tra loro e vanno letti come indicativi, ma la dispersione è abbastanza ampia da resistere all'incertezza. Sugli smartphone, una valutazione di diversi runtime e dispositivi rileva grandi differenze di velocità, energia e comportamento termico sia tra runtime sia tra dispositivi [60].

2.5.2 Motori di inferenza specializzati

Accanto ai runtime generali è comparsa, nel 2026, una seconda famiglia di software: motori di inferenza scritti per pochi modelli, che rinunciano alla generalità per spingere più in là i limiti di memoria descritti nella Sezione 2.3. DwarfStar (ds4), sviluppato da Salvatore Sanfilippo, è un motore nativo ottimizzato per alcuni grandi modelli open-weight, a partire da DeepSeek V4 Flash, e pensato per Mac con almeno 96 GB di memoria, per il DGX Spark e per le macchine Strix Halo [61]. Due sue scelte riguardano da vicino questa tesi. La prima è una KV cache salvata su disco: una conversazione già letta si può riprendere senza rifare il prefill, che su modelli di queste dimensioni è la parte più costosa di una richiesta lunga. La seconda è la lettura dei pesi direttamente dall'SSD, che consente di eseguire modelli più grandi della memoria disponibile, al prezzo della velocità.

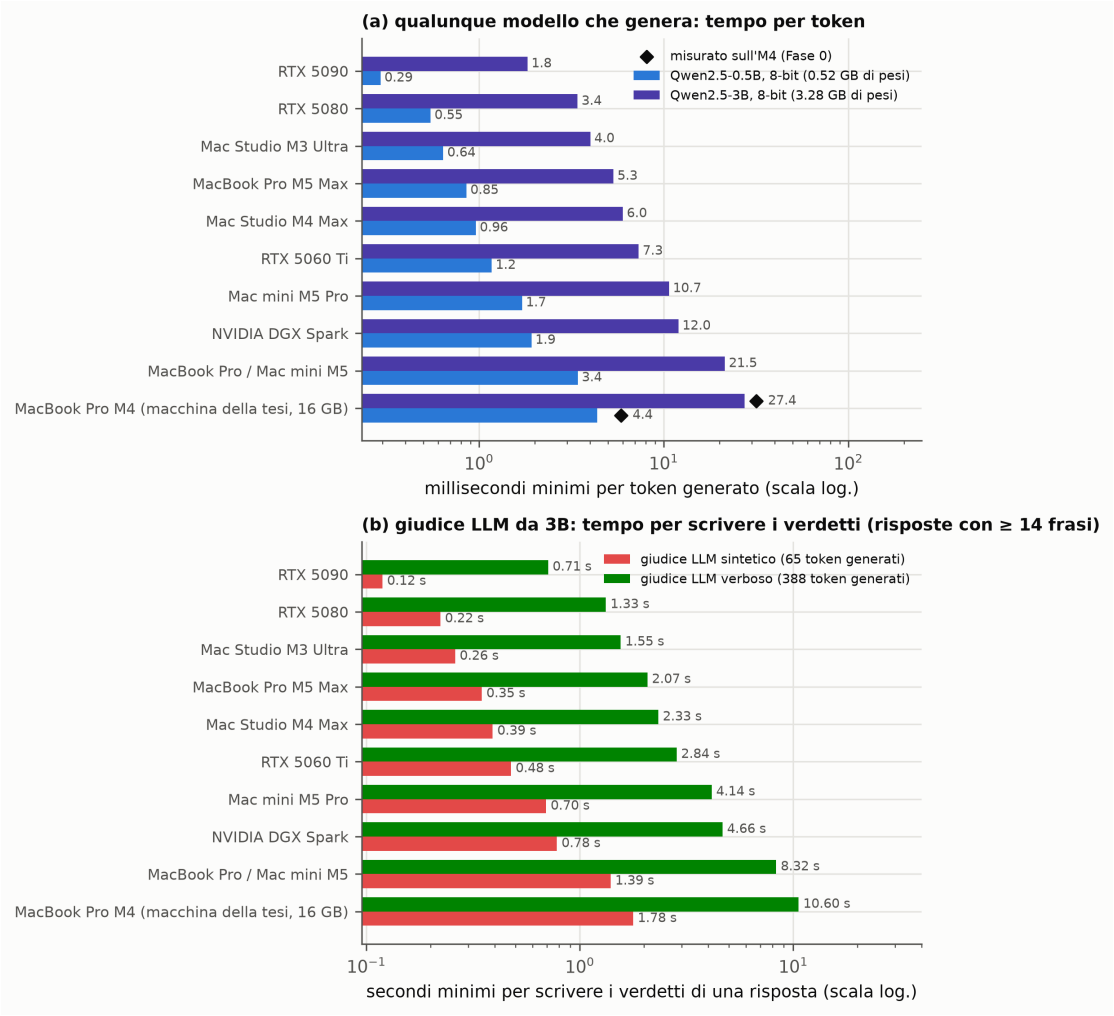


Figura 2.9: Limiti inferiori al costo della generazione di testo su ciascuna classe di hardware locale, calcolati come byte dei pesi divisi per la banda dichiarata dal produttore (una richiesta alla volta; KV cache trascurata). (a) Tempo per token generato con i due modelli base di GroundOne a 8 bit; rombi: tempo di decoding misurato sulla macchina della tesi. (b) Tempo minimo che un giudice LLM da 3B impiega soltanto per scrivere i verdetti di una risposta di quattordici o più frasi (mediana dei token generati nel protocollo di latenza). Un decision model non genera alcun token, quindi per esso entrambi i costi sono nulli su ogni macchina.

Colibri porta questa seconda idea all'estremo [36]. Sfrutta il fatto che un modello mixture-of-experts usa per ogni token solo una piccola parte dei propri pesi: tiene in memoria la parte sempre attiva e legge gli esperti dal disco quando il router li richiede. In questo modo GLM-5.2, un modello da 744 miliardi di parametri, gira su un laptop con 25 GB di memoria. Il prezzo è quello previsto dal modello di costo: la banda di un SSD è di pochi gigabyte al secondo, molto inferiore a quella della memoria, e secondo gli autori la generazione scende a 0.05–0.1 token al secondo a freddo su quel laptop e a 1.83 token al secondo su una macchina Strix Halo da 128 GB [36]. È la stessa idea di LLM in a flash [46], applicata ai modelli a esperti: la capacità di memoria smette di essere un limite rigido e si trasforma in un limite di banda, ancora più severo. La Figura 2.10 illustra il meccanismo.

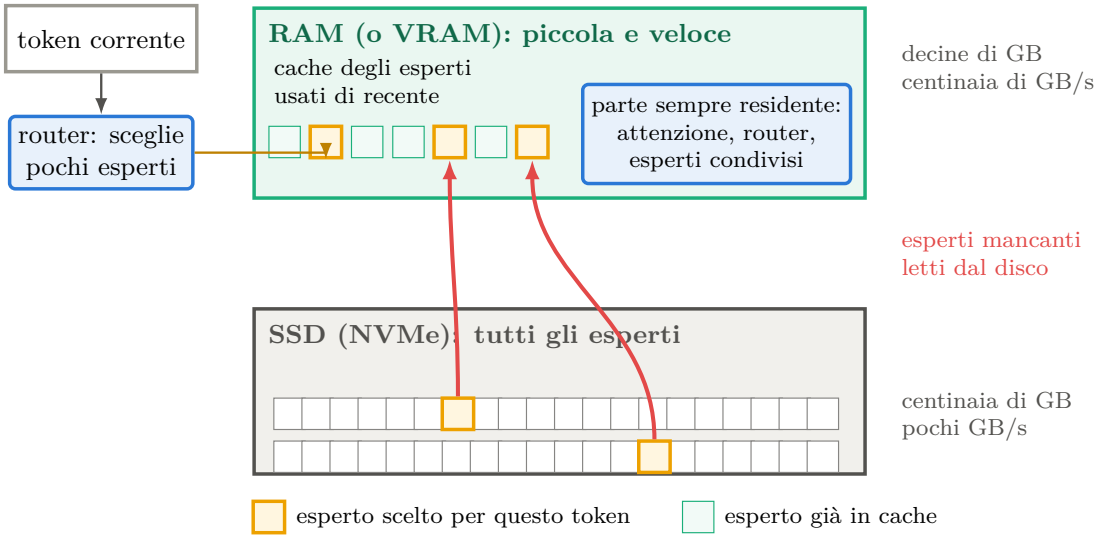


Figura 2.10: Lo streaming degli esperti dall'SSD in un motore come Colibri. In memoria restano la parte del modello usata da ogni token (attenzione, router, esperti condivisi) e una cache degli esperti usati di recente; tutti gli esperti stanno sull'SSD. Per ogni token il router sceglie pochi esperti: quelli già in cache si usano subito, quelli mancanti si leggono dal disco, con una banda di pochi gigabyte al secondo. Per esempio, GLM-5.2 conserva sul disco tutti i suoi 429 GB di pesi e ne tiene residenti circa 10 GB [36]. Lo schema non è in scala.

Colibri interessa questa tesi anche per un secondo motivo. Espone la stessa interfaccia System One di Jev, con la quale qualunque modello che esegue risponde a domande chiuse leggendo la probabilità di ciascuna opzione invece di generare la risposta, e include in modo nativo tre decision model: Laya, GLiNER2.5-Decide e Clef [36]. Gli autori riportano che, con Qwen3.6, quattro domande sullo stesso documento ricevono risposta 5.7 volte più velocemente che generando le stesse

risposte sulla stessa CPU. Si tratta di una misura dichiarata dal progetto e non verificata in questa tesi, ottenuta con modello e hardware diversi, ma va nella stessa direzione dei risultati del Capitolo 7. Che un motore pensato per eseguire modelli enormi su hardware modesto adotti la lettura delle decisioni come modalità di prima classe conferma che l'idea del decision model si sta diffondendo proprio dove generare costa di più.

2.5.3 Quantizzazione

La quantizzazione memorizza i pesi con meno bit dei 16 usati in addestramento. Sull'hardware locale serve a due scopi contemporaneamente: il modello occupa meno memoria e il decoding diventa più veloce, perché il suo tempo è dominato dalla lettura dei pesi. La Tabella 2.3 riassume i metodi che hanno segnato il campo.

Tabella 2.3: Metodi di quantizzazione dei pesi per i modelli linguistici.

Metodo	Idea e risultato principale	Fonte
LLM.int8()	Pesi e attivazioni a 8 bit; le poche dimensioni con valori anomali molto grandi (outlier) restano a 16 bit. Nessuna perdita fino a 175B parametri; fa risparmiare memoria ma non accelera i modelli piccoli.	[62]
GPTQ	Pesi a 3–4 bit, quantizzati strato per strato stimando quanto ogni peso influisca sull'errore. OPT-175B a 4 bit perde 0.03 di perplexity[a]; i modelli piccoli perdono di più; decoding 3.2–4.5× più veloce grazie alla banda.	[63]
AWQ	Pesi a 4 bit; l'1 % di canali più importanti, individuato dall'ampiezza delle attivazioni, è protetto tramite scalatura. Robusto rispetto ai dati di calibrazione; pensato per l'uso sul dispositivo.	[64]
GGUF k-quant	Formati a blocchi da 2 a 8 bit di llama.cpp, standard di fatto per la distribuzione consumer.	[2]
MLX affine	Pesi a 4 o 8 bit con una scala e un bias per gruppo di 64; supporta l'addestramento LoRA sul modello quantizzato (usato in questa tesi).	[58]
QLoRA	Modello base a 4 bit in formato normal float con adapter a 16 bit, per il fine-tuning con memoria limitata.	[65]

[a] La *perplexity* misura quanto un modello predice bene un testo: più è bassa, meno il modello è "sorpreso" dalle parole che incontra.

Due risultati di questa letteratura contano per la tesi. Il primo è che la quantizzazione aiuta la fase limitata dalla banda. GPTQ attribuisce interamente i propri speed-up ai prodotti matrice-vettore del decoding e dichiara di non ottenere alcuna riduzione del calcolo [63]; AWQ illustra lo stesso punto con un roofline: su una scheda grafica desktop, un prefill di 200 token richiede 10 millisecondi, mentre

generarne 20 ne richiede 310 [64]. Ridurre i bit dei pesi accelera quindi un modello che genera molto più di uno che si limita a leggere. Il secondo è che i modelli piccoli sono più fragili. GPTQ perde molta più accuratezza a 4 bit su un modello da 1.3 miliardi di parametri che su uno da 175 miliardi, e sugli smartphone i modelli da tre miliardi di parametri o meno diventano inutilizzabili a 3 bit [63, 60]. LLM.int8() mostra che un pugno di feature outlier controlla una quota rilevante della massa di probabilità dell'attenzione [62]. Per un modello il cui output è una probabilità da calibrare, e non un testo che deve soltanto risultare scorrevole, queste osservazioni suggeriscono una precisione prudente: GroundOne usa pesi a 8 bit. Una misura condotta in questa tesi conferma che, a questa precisione, la quantizzazione non costa accuratezza: applicando lo stesso adapter del modello 0.5B ai pesi originali a 16 bit, la balanced accuracy a tre classi sul test set di RAGTruth (T1) resta praticamente identica (0.768 contro 0.769), le probabilità cambiano in media di 0.011 e la classe predetta coincide nel 98 % delle frasi (Sezione 7.11).

2.5.4 Generare più in fretta senza generare meno

Una diversa famiglia di metodi accelera la generazione senza modificare il modello. Nello speculative decoding un piccolo modello bozza propone diversi token, e il modello grande li verifica tutti in un unico forward pass, accettando il prefisso più lungo che avrebbe prodotto esso stesso; l'output è identico a quello del modello grande, e lo speed-up arriva a due-tre volte [66]. Il metodo è utile per qualunque sistema debba generare, ma non cambia la natura del costo: ogni blocco di token proposti richiede comunque un forward pass del modello grande, e la quantità totale di calcolo aumenta [66]. Rende la scrittura più economica, non gratuita.

2.6 Energia

Su un dispositivo a batteria l'energia è una proprietà del metodo e non soltanto dell'hardware. Misure su hardware da datacenter mostrano che l'energia di una richiesta cresce con il numero di token generati e dipende fortemente dalla dimensione del modello e dal task [67, 68]. Sugli smartphone, un modello da 3 miliardi di parametri a 4 bit spende tra 0.58 e 0.76 joule per token generato, con una potenza sostenuta intorno ai 14 W e temperature superficiali vicine ai 48 °C [60]; una regola empirica tratta dai lavori sui modelli piccoli stima il costo in circa 0.1 joule per token generato per ogni miliardo di parametri [39]. Spostare il prefill sulla NPU di uno smartphone ne riduce l'energia di 1.9–4.3 volte rispetto all'unità grafica [55].

La distinzione tra le due fasi vale anche per la potenza. Il prefill tiene occupate le unità aritmetiche e assorbe più potenza; il decoding attende la memoria e assorbe meno potenza, ma per molto più tempo [42]. Un metodo che fa risparmiare tempo fa quindi risparmiare anche energia, ma in misura minore, e il Capitolo 7 misura

proprio questo effetto: GroundOne spende in media 5.5 joule per risposta con il modello da 0.5B e 33 con il 3B, meno di qualunque giudice LLM della stessa dimensione, ma con un vantaggio inferiore a quello sul tempo (Sezione 7.10).

2.7 Conseguenze per la verifica sul dispositivo

Il capitolo si può ora riassumere in un'unica osservazione: su un dispositivo locale, che serve una richiesta alla volta, leggere un token costa molto meno che scriverne uno, quattordici-sedici volte meno sulla macchina della tesi (Sezioni 2.3.1–2.3.3), e le generazioni più recenti di hardware accelerano la lettura molto più della scrittura (Sezione 2.4.2). Ne discende una conseguenza diretta per un verificatore che gira accanto al generatore.

Un giudice LLM verifica una risposta leggendo il documento e la risposta e poi scrivendo i propri verdetti. Paga un prefill, come ogni metodo che legge il documento, e poi un passo di decoding per ogni token che scrive. Nel protocollo di latenza di questa tesi (Sezione 7.9), per una risposta di quattordici o più frasi un giudice LLM sintetico da 3B scrive in mediana 65 token, e uno verboso, che motiva ogni verdetto, ne scrive 388. Il limite inferiore della Sezione 2.3.3 traduce questi conteggi in un tempo minimo che nessuna implementazione del decoding standard, con pesi a 8 bit, può battere (Figura 2.9b): sulla macchina della tesi, almeno 1.8 secondi per il giudice LLM sintetico e 10.6 per quello verboso, oltre al prefill; persino sulla scheda grafica più veloce, 0.12 e 0.71 secondi.

Un decision model elimina del tutto questo termine. Legge il documento e la risposta una sola volta e prende ogni decisione dai logit calcolati durante quell'unica lettura, quindi il suo costo coincide con il solo prefill: la fase limitata dal calcolo, quella che l'hardware locale esegue bene e che il nuovo hardware accelera di più. Il suo vantaggio su un giudice LLM non è quindi una proprietà di una particolare macchina, ma della struttura dei costi dell'inferenza locale, ed è massimo proprio dove l'inferenza è locale. La località, che a prima vista è soltanto un vincolo sulla dimensione del modello, diventa la ragione per cui il progetto conta.

Da questo capitolo discendono tre requisiti per il verificatore, che guidano il metodo del Capitolo 4. Non deve generare alcun token, così che il suo costo sia un singolo prefill. Deve usare un modello abbastanza piccolo da condividere una macchina da 16 GB con un generatore e un retriever, quantizzato in modo prudente perché il suo output è una probabilità. E deve leggere le proprie decisioni dai logit, che solo un modello locale espone, così che possano essere calibrate.

Capitolo 3

Fondamenti e stato dell'arte

Questo capitolo passa in rassegna i lavori su cui GroundOne si fonda e quelli con cui viene confrontato. Il costo dell'inferenza su un dispositivo locale, da cui discende il progetto, è già stato trattato nel Capitolo 2. Si parte dai decision model, cioè dall'idea di leggere le decisioni di un modello linguistico invece di farle generare, e dal loro ecosistema, in rapida crescita. Seguono il problema delle allucinazioni nella retrieval-augmented generation (RAG) e i metodi che verificano le risposte rispetto alle fonti. Il capitolo si chiude con la calibrazione, con il parameter-efficient fine-tuning e con la lacuna che questa tesi intende colmare.

3.1 Decision Model

Il termine *System One model* è stato introdotto da TypeSafe con Jev, un modello offerto come servizio remoto. Jev risponde a domande chiuse su uno stato dato, cioè sul contesto fornito nella richiesta, e restituisce output tipizzati, come un booleano, una scelta tra opzioni o un punteggio, senza generare testo [14]. Il nome richiama il pensiero veloce e intuitivo descritto da Kahneman, contrapposto al ragionamento deliberato. Il fornitore dichiara latenze comprese tra le decine e le centinaia di millisecondi e forti risparmi rispetto ai giudici LLM. Queste cifre, però, restano dichiarazioni del fornitore, e l'architettura non è resa pubblica.

Le implementazioni open arrivate in seguito si distinguono per il modo in cui producono le probabilità, e se ne possono individuare tre famiglie. La più diffusa presenta la domanda come una scelta multipla e conserva la head del modello linguistico, cioè lo strato finale che assegna un punteggio a ogni token del vocabolario: la decisione si legge dai logit delle lettere delle opzioni, nella posizione in cui il modello scriverebbe la risposta. SemIf applica questo readout a un modello da 4B parametri lasciato congelato, cioè senza modificarne i pesi, e riporta che 21 criteri relativi a un documento ottengono risposta in circa un secondo; la migliore

baseline generativa capace di produrre JSON valido impiega invece più di cinque secondi [15]. Rizzo-Flow, a differenza di SemIf, addestra con LoRA un modello da 4B su decisioni tipizzate ed espone la stessa interfaccia di Jev. I suoi autori riportano che il fine-tuning ne migliora sia l'accuratezza sia la calibrazione [16]. È uno dei due decision model generalisti usati come baseline in questa tesi.

La seconda famiglia codifica separatamente lo stato e ciascuna risposta candidata, e ne confronta gli embedding, cioè i vettori numerici che rappresentano ciascun testo. I Contrastive Language Models, che appartengono a questa famiglia, sono molto veloci quando i candidati sono numerosi e riutilizzabili. Nei file di risultati pubblicati dagli stessi autori, però, un Contrastive Language Model sceglie la mossa migliore indicata nel prompt in circa due casi su tre (0.66), contro 0.99 per Jev, contrariamente alla parità dichiarata nel testo che li accompagna [69]. La terza famiglia usa piccoli encoder con una head decisionale dedicata. Laya, per esempio, si basa su un encoder ModernBERT da circa 400M parametri e assegna un punteggio a ogni opzione in corrispondenza del relativo token di maschera[1]. Le domande di una richiesta sono valutate in un'unica chiamata, raggruppate in un batch, ma ciascuna viene codificata insieme a una propria copia del contesto [70, 71].

Le evidenze a supporto di questi sistemi sono disomogenee. La maggior parte proviene dagli autori stessi, spesso su una sola macchina e su un solo benchmark. Le valutazioni indipendenti sono recenti e meno favorevoli ai piccoli modelli open. Una valutazione di Jev su 37 dataset trova ben calibrate le probabilità che il modello assegna alle scelte fra opzioni. Le probabilità binarie, invece, ordinano bene gli esempi ma risultano mal posizionate rispetto a una soglia fissa di 0.5. Lo stesso studio riporta per Jev una balanced accuracy media di 78.6, espressa in percentuale, su LLM-AggreFact [20]. Una riproduzione indipendente di Laya osserva una calibrazione diversa da quella dichiarata e una forte dipendenza da una temperatura di calibrazione stimata sui dati di destinazione [21]. Un benchmark costruito su coppie contrastive, cioè su decisioni quasi identiche che differiscono per un solo dettaglio decisivo, colloca i piccoli modelli open molto al di sotto di Jev [72]. Infine, è stato mostrato che, quando l'etichetta di un'opzione e la sua definizione sono in conflitto, i decision model tipizzati seguono l'etichetta anziché la definizione [71].

L'ecosistema, intanto, cresce rapidamente. Il 9 ottobre 2026 l'hub di Hugging Face ha introdotto ufficialmente un tag dedicato a questi *decision model* [17]. Il giorno successivo il tag raccoglieva già circa 1500 modelli, pubblicati da circa 600 autori e di qualità molto variabile. Questa tesi usa il termine *decision model*,

[1] Il *token di maschera* è un token speciale che, durante il preaddestramento, prende il posto delle parole che il modello deve ricostruire.

adottato dall'ecosistema; *System One* resta il nome con cui TypeSafe ha introdotto la categoria, e compare nel seguito soltanto come nome dell'interfaccia compatibile con Jev.

Poche settimane dopo il rilascio di Jev, anche organizzazioni affermate hanno pubblicato i propri decision model open. Clef di Cloudflare aggiunge a un decoder una head decisionale dedicata e risponde a tutte le domande con un solo forward pass sullo stato: è l'architettura che per Jev era stata soltanto ipotizzata [19]. d1-3B di Liquid AI legge la decisione da un insieme ristretto di lettere di risposta, con un modello da 3B il cui stato è condiviso da tutte le domande [18]. Perplexity, infine, applica il fine-tuning a un modello da 27B con una head sulle lettere [73]. Una leaderboard della comunità, il Decision Index, valuta questi modelli su una batteria comune di benchmark pubblici, tra cui RAGTruth valutato a livello di risposta intera [22]. I risultati tracciano una linea netta. I decision model generalisti con meno di un miliardo di parametri superano al più a stento la baseline banale su RAGTruth, e per lo più restano al di sotto, e soltanto i modelli da circa quindici miliardi di parametri in su individuano in modo affidabile le risposte allucinate.

Gli studi su Jev aggiungono tre osservazioni. Le sue probabilità sono calibrate se aggregate su molti task, ma non sul singolo task. Soglie e temperature vanno stimate sul carico di lavoro di destinazione [74, 75]. Scegliere la soglia tramite un limite inferiore di confidenza, infine, rende più sicuro mettere in produzione un giudice LLM che restituisce soltanto decisioni [75]. Anche i runtime si sono adeguati: llama.cpp supporta ora nativamente l'interfaccia System One [2]. Nessuno di questi modelli, tuttavia, è specializzato nella groundedness, cioè nell'aderenza della risposta al documento. Nessuno, inoltre, riporta risultati di verifica a tre classi a livello di frase sui benchmark usati in questa tesi.

Il readout sulle lettere è stato studiato anche al di fuori della letteratura sui decision model, nelle domande a scelta multipla. Qui si possono confrontare due modi di ottenere la risposta di un modello addestrato a seguire istruzioni (instruction-tuned): leggere quale lettera ha la probabilità più alta come primo token, oppure lasciare che il modello scriva la risposta per esteso. Le due risposte spesso non coincidono [76]. Il readout, inoltre, privilegia particolari identificatori di opzione, come certe lettere, e questo bias si può stimare e rimuovere [77]. Entrambi i risultati riguardano modelli non addestrati sul task, usati zero-shot o con pochi esempi. Suggeriscono che un readout sulle lettere, se deve servire da decisione, vada addestrato, calibrato o entrambe le cose. Nessun decision model open, inoltre, è stato specializzato nella verifica della groundedness e poi confrontato, in condizioni controllate e sullo stesso hardware, con giudici LLM, con verificatori specializzati e con decision model generalisti, di cui uno della stessa dimensione.

3.2 Retrieval-augmented generation e allucinazioni

La retrieval-augmented generation (RAG) dà a un modello linguistico accesso a documenti su cui non è stato addestrato: un retriever seleziona i passaggi pertinenti alla domanda e il modello scrive la risposta con questi passaggi nel contesto [1]. È l'approccio standard per costruire assistenti su documenti privati e può girare interamente su una macchina locale. Non elimina però le allucinazioni. Le rassegne della letteratura distinguono due tipi di errore. Gli errori di *fattualità* (factuality) si misurano rispetto alla conoscenza del mondo, quelli di *fedeltà* (faithfulness) rispetto all'input o al contesto forniti al modello [9]. Una risposta RAG, in particolare, può essere infedele proprio ai passaggi che ha ricevuto, contraddicendoli o aggiungendo informazioni che essi non contengono.

RAGTruth documenta quanto ciò sia frequente. Il dataset raccoglie circa 18,000 risposte, scritte da sei modelli linguistici in tre task di tipo RAG, e vi annota con precisione al carattere le porzioni di testo in conflitto con il contesto o non supportate da esso [8]. La distinzione di RAGTruth tra contenuto in conflitto e contenuto privo di fondamento corrisponde alle classi *contraddetta* e *non menzionata* adottate in questa tesi.

3.3 Verifica della groundedness

Verificare una risposta rispetto alla fonte è un problema strettamente legato alla natural language inference (NLI). Nella NLI si stabilisce se una premessa implica un'ipotesi (entailment), la contraddice o è neutrale rispetto a essa. Grandi dataset di NLI forniscono dati di addestramento: MultiNLI [78] e ANLI [79], quest'ultimo costruito in modo avversariale, cioè raccogliendo esempi scritti apposta per ingannare i modelli del momento. VitaminC [80] aggiunge coppie contrastive, in cui una revisione minima di una frase di Wikipedia ribalta il verdetto: il modello è così costretto a guardare al fatto preciso e non alla sovrapposizione di parole.

Applicare questi modelli a testi generati lunghi richiede di scomporli. SummaC suddivide in frasi sia il documento sia il riassunto e aggrega i punteggi di inferenza calcolati frase per frase [81]. FActScore, invece, scompone le generazioni lunghe in fatti atomici e li verifica uno per uno [82]. La verifica a livello di frase, adottata da GroundOne, è una via di mezzo tra un unico punteggio per l'intera risposta e la scomposizione in fatti atomici. Le frasi sono le unità naturali di una risposta, l'utente può intervenire su una frase segnalata e il numero di decisioni cresce con la lunghezza della risposta.

Nella pratica prevalgono due famiglie di verificatori. La prima è quella degli encoder specializzati, piccoli e veloci. AlignScore addestra un'unica funzione

di allineamento su un'ampia miscela di task [11]. MiniCheck addestra piccoli verificatori su dati sintetici, costruiti in modo da richiedere un ragionamento su più frasi, ed eguaglia modelli molto più grandi sui benchmark di grounding [12]. HHEM è un modello di valutazione delle allucinazioni dello stesso tipo, rilasciato come modello open [13]. Questi modelli valutano ogni coppia documento–frase in modo indipendente e restituiscono un'unica probabilità di supporto.

La seconda famiglia usa un modello linguistico come giudice, il giudice LLM, secondo lo schema LLM-as-a-judge[2] [83]. Su giudici LLM di questo tipo si basano framework di valutazione per RAG come RAGAS [84] e ARES [85]. Lynx addestra con fine-tuning un giudice LLM dedicato al rilevamento delle allucinazioni [86], mentre Self-RAG addestra il generatore stesso a emettere token di critica, cioè token speciali con cui il modello valuta i passaggi recuperati e il proprio output [87]. I giudici LLM sono flessibili, ma il loro costo cresce con la quantità di testo che scrivono. I modelli piccoli usati come giudici LLM, inoltre, violano spesso il formato di output richiesto. Per garantire una risposta che il parser sappia interpretare serve allora un decoding vincolato da una grammatica, che a ogni passo ammette soltanto i token compatibili con il formato richiesto [88]. Il benchmark di riferimento per entrambe le famiglie è LLM-AggreFact, che riunisce undici dataset di grounding annotati manualmente e li riconduce a un protocollo binario comune [12, 89]. La Figura 3.1 mette a confronto le due famiglie con il decision model specialista studiato in questa tesi.

3.4 Calibrazione e selective prediction

Una probabilità è calibrata quando, tra le predizioni fatte con una certa confidenza, la frazione di quelle corrette coincide con tale confidenza: in un modello calibrato, per esempio, circa l'80 % delle predizioni fatte con confidenza 0.8 risulta corretto. Le reti neurali moderne sono spesso mal calibrate, e una correzione semplice ed efficace è il temperature scaling: i logit vengono divisi per un'unica costante, la temperatura[3], stimata su dati tenuti da parte [90]. La misura abituale della calibrazione è l'Expected Calibration Error (ECE), che confronta confidenza e frequenza di predizioni corrette all'interno di fasce di confidenza [91] (Sezione 4.4). Per i modelli linguistici interrogati tramite prompt può servire anche un bias per classe, che corregga una preferenza sistematica verso alcune risposte [92].

[2]Nello schema *LLM-as-a-judge* un modello linguistico riceve tramite prompt il testo da valutare e i criteri di valutazione, e scrive il proprio giudizio, a volte preceduto da una motivazione.

[3]Con una temperatura $T > 1$ le probabilità diventano meno estreme, con $T < 1$ più estreme. Poiché tutti i logit sono divisi per la stessa costante, la classe più probabile non cambia.

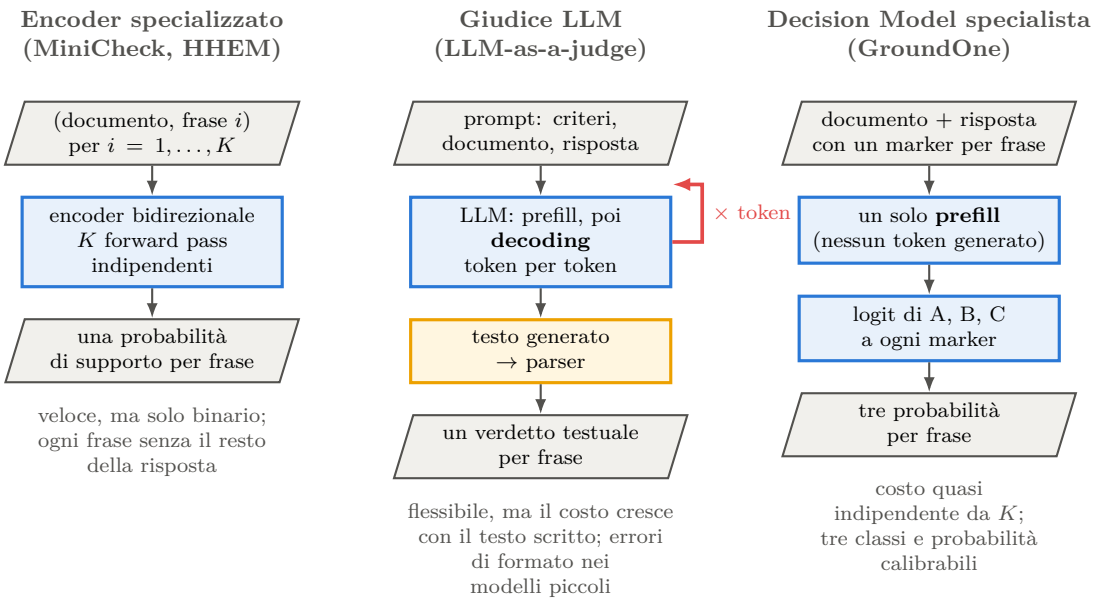


Figura 3.1: Tre modi di verificare le K frasi di una risposta. Un encoder specializzato valuta ogni coppia (documento, frase) in un forward pass separato e restituisce solo una probabilità di supporto. Un giudice LLM legge tutto, ma scrive il proprio verdetto token per token (ciclo rosso), quindi il costo cresce con il testo prodotto e l'output va interpretato da un parser. Un decision model specialista legge documento e risposta in un solo prefill e ricava da ogni marker tre probabilità, senza generare alcun token.

I modelli linguistici sanno, entro certi limiti, quello che sanno: sulle domande chiuse, le probabilità dei loro token sono spesso informative sulla correttezza della risposta [93]. Quando le probabilità non sono accessibili, si può chiedere al modello di esprimere la propria confidenza a parole. Nei modelli grandi sottoposti a fine-tuning con feedback umano, questa confidenza verbalizzata può risultare calibrata meglio delle probabilità stimate per campionamento [94]. Valutazioni sistematiche, però, la trovano grossolana e troppo sicura, con valori concentrati su pochi numeri tondi [95].

Una probabilità calibrata diventa utile grazie alla selective prediction: il sistema agisce sulle decisioni di cui è sicuro e rinvia le altre. La curva risk–coverage descrive questo compromesso. Per ogni quota di decisioni accettate (la coverage) riporta il tasso di errore su di esse (il risk), e mostra così come il tasso di errore scenda man mano che si rinviano più decisioni [96]. La Figura 3.2 ne illustra la forma tipica.

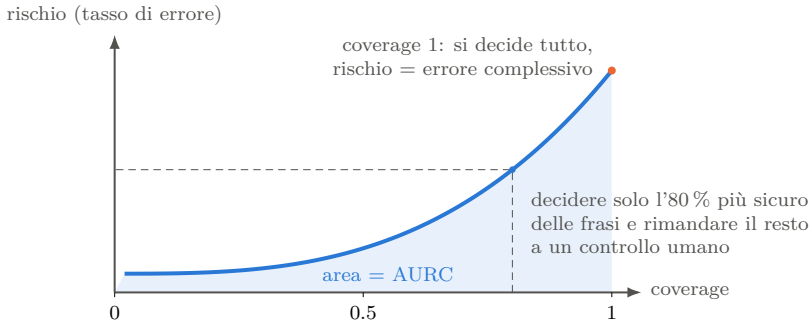


Figura 3.2: Schema di una curva risk–coverage (forma illustrativa, non un risultato). Le decisioni sono ordinate dalla più sicura alla meno sicura; per ogni quota decisa (coverage) si riporta il tasso di errore (rischio) delle decisioni accettate. A coverage 1 il rischio coincide con l'errore complessivo; rinunciando alle decisioni meno sicure l'errore scende. L'area sotto la curva (AURC) riassume la curva in un numero: più è piccola, meglio la confidenza separa le decisioni corrette da quelle errate.

3.5 Parameter-efficient fine-tuning

Specializzare un modello preaddestrato non richiede di aggiornarne tutti i pesi. I metodi di parameter-efficient fine-tuning (PEFT) addestrano soltanto una piccola quota di parametri e lasciano invariato il resto del modello. La low-rank adaptation (LoRA) congela il modello e, per alcune matrici di pesi, addestra soltanto un aggiornamento a basso rango[4]. Al termine dell'addestramento, l'aggiornamento si può fondere nei pesi oppure mantenere come piccolo adapter separato [24]. Applicare LoRA a tutti gli strati lineari conta più che usare un rango elevato, e la tecnica si combina con pesi di base quantizzati, così che anche modelli grandi stiano in poca memoria [65]. La famiglia Qwen2.5 offre modelli open a partire da 0.5B parametri con un tokenizer condiviso, e permette quindi di confrontare dimensioni diverse con la stessa ricetta [23]. La Figura 3.3 schematizza un adapter LoRA applicato a uno strato lineare.

Il fine-tuning su dataset piccoli, però, è notoriamente instabile. I risultati variano con il seed casuale, che determina sia l'inizializzazione dei nuovi parametri sia

[4]Il *rango* di una matrice è il numero massimo di sue righe (o colonne) linearmente indipendenti. LoRA impone che la correzione appresa per una matrice di pesi $d \times k$ abbia un rango r piccolo. Una matrice di questo tipo si può scrivere come prodotto di due matrici strette, una $d \times r$ e una $r \times k$, e basta quindi memorizzare e addestrare queste due: $r(d+k)$ parametri invece dei dk della matrice completa. In GroundOne 3B, per esempio, una matrice 2048×2048 ha circa 4.2 milioni di pesi, mentre la sua correzione di rango 16 ne richiede circa 65 mila, l'1.6 %.

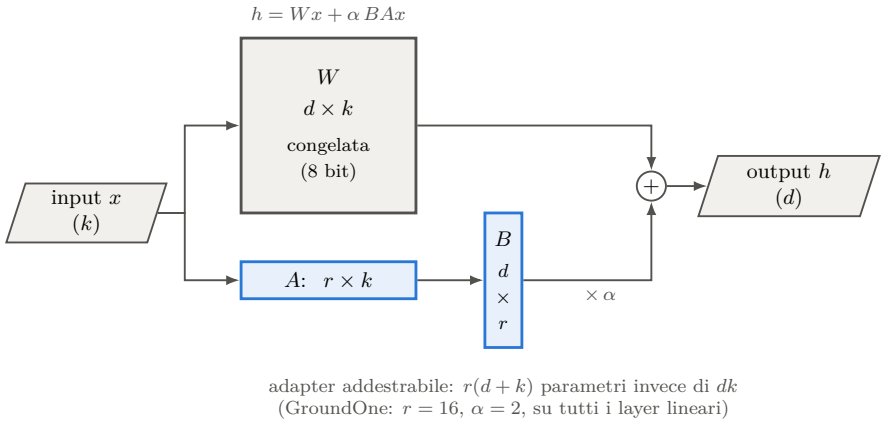


Figura 3.3: Low-rank adaptation applicata a uno strato lineare. La matrice dei pesi W resta congelata (in GroundOne a 8 bit); si addestrano soltanto le due matrici piccole A e B, il cui prodotto, scalato di α, si somma all'output dello strato. Con rango r l'adapter ha $r(d+k)$ parametri invece dei dk di W.

l'ordine dei dati di addestramento [97]. Alcuni addestramenti falliscono del tutto, e questo comportamento è legato a dettagli dell'ottimizzazione come l'assenza della bias correction in Adam[5] [98]. Il gradient clipping, che limita la norma del gradiente, è infine la difesa standard contro occasionali aggiornamenti esplosivi [99].

3.6 Lacuna nella letteratura

Gli elementi necessari a un verificatore locale, veloce e calibrato esistono già, ma separatamente: modelli open compatti e runtime che li eseguono su un laptop, l'idea dei decision model di leggere le decisioni anziché generarle, verificatori specializzati e calibrazione post-hoc. Manca uno studio indipendente e controllato che li metta insieme su un unico task. In particolare, nessun lavoro ha misurato se un decision model compatto, specializzato nella verifica della groundedness, possa eguagliare su questo task i giudici LLM e gli encoder dedicati. Non è noto nemmeno da dove provenga il suo vantaggio: dalla specializzazione, dal readout o dalla dimensione del modello. Resta infine da stabilire se le sue probabilità siano abbastanza buone da fissare soglie e rinviare decisioni, e come il suo tempo e la sua energia si confrontino

[5] Adam è un ottimizzatore che aggiorna ogni peso usando due medie mobili, una del gradiente e una del suo quadrato, dette stime dei momenti. Poiché queste medie partono da zero, nei primi passi sottostimano i valori veri; la *bias correction* le riscala per compensare. AdamW è la variante di Adam che applica il weight decay separatamente dal gradiente.

con quelli di un giudice LLM sullo stesso hardware consumer. Il resto della tesi affronta queste domande.

Capitolo 4

GroundOne: metodo e implementazione

GroundOne è un modello linguistico compatto usato come decision model. Legge una sola volta il documento e la risposta e, senza generare testo, emette un verdetto per ciascuna frase valutata della risposta, ricavandolo dai logit di poche lettere di risposta. Il capitolo descrive anzitutto la decisione che il modello prende e il prompt che raccoglie in un unico forward pass tutte le decisioni relative a una risposta. Presenta poi l'obiettivo di addestramento, la calibrazione delle probabilità in uscita e la regola che converte le probabilità nelle etichette restituite, e si chiude con il software che implementa il tutto.

4.1 Task e decisione

Per ogni frase di una risposta, GroundOne sceglie fra tre classi, definite nella Sezione 5.1: rispetto al documento, la frase è *supportata*, *contraddetta* o *non menzionata*. Per *documento* si intende l'intero contesto che il generatore ha ricevuto. Può comprendere più passaggi recuperati, anche provenienti da fonti diverse, concatenati nel prompt: è il caso del question answering di RAGTruth (Sezione 5.2). Una frase è quindi supportata quando almeno un passaggio la sostiene, anche combinando informazioni sparse su passaggi diversi.

A ogni classe corrisponde una lettera (A, B e C), e il modello restituisce una probabilità per ciascuna. È l'unica domanda che il modello riceve: tutto il resto si ricava da queste tre probabilità. Il punteggio binario di groundedness è la probabilità che la frase sia supportata. La policy strict segnala ogni frase non supportata, mentre la policy lenient segnala soltanto le frasi contraddette. Un solo forward pass basta quindi per tutti questi usi.

Porre al modello una domanda separata per ciascuna policy non aggiungerebbe nulla: una volta nota la classe di una frase, si sa già come la giudica ogni policy. Domande separate moltiplicherebbero soltanto il numero di decisioni e, in addestramento, rischierebbero di insegnare al modello risposte incoerenti tra loro sulla stessa frase.

4.2 Tutti i verdetti in un solo forward pass

Il prompt contiene una breve istruzione, il documento e la risposta. Le frasi della risposta sono numerate, e ogni frase a cui è associata una decisione è seguita da un marker, cioè da una breve stringa fissa che indica il punto in cui leggere il verdetto: la stringa “ `Verdict:`”. Le frasi prive di contenuto verificabile (Sezione 5.3) restano nel testo come contesto, ma senza marker. Il modello elabora l'intera sequenza una sola volta. In corrispondenza dell'ultimo token di ciascun marker si leggono i logit delle lettere A, B e C, che vengono normalizzati con una softmax[1] ristretta a queste tre lettere. In un decoder ogni posizione vede soltanto quelle precedenti, quindi il verdetto sulla frase i dipende dal documento e dalle frasi $1, \ldots, i$. È esattamente ciò che serve alla verifica, perché i riferimenti, come i pronomi, puntano all'indietro. Quanto segue l'ultimo marker non influisce su alcun verdetto: dopo di esso vengono soltanto un a capo e, in poche risposte, una frase finale priva di contenuto verificabile. La Figura 4.1 mostra la struttura del prompt e i punti in cui avviene il readout.

Due accorgimenti rendono il readout esatto ed efficiente. Il primo riguarda l'esattezza: il prompt viene costruito tokenizzando separatamente le sue parti e poi concatenandole, così che la posizione di ogni marker sia nota con esattezza e resti identica in addestramento e in inferenza. Il secondo riguarda l'efficienza: la proiezione di output sul vocabolario si applica solo nelle posizioni dei marker. Il corpo del transformer elabora l'intera sequenza, ma la grande matrice del vocabolario viene moltiplicata soltanto per i pochi stati nascosti effettivamente letti, cioè per i vettori che il modello calcola nelle posizioni dei marker.

La lettura a marker determina anche il costo di una verifica. Si indichino con S la lunghezza complessiva di documento e risposta, con K il numero di decisioni e con m la lunghezza in token di un marker. Il decision model richiede un solo prefill di $S + Km$ token. Un giudice LLM, invece, deve anche produrre i propri verdetti in fase di decoding. Se ogni verdetto richiede n token e ogni token in decoding richiede un tempo t_{dec}, il costo del giudice LLM è all'incirca $\text{prefill}(S) + K\,n\,t_{\text{dec}}$. La lunghezza m di un marker è di soli tre token, mentre sull'hardware di riferimento il

[1] La *softmax* trasforma un vettore di punteggi in una distribuzione di probabilità: ogni punteggio z_i diventa $e^{z_i} / \sum_j e^{z_j}$. Restringerla a tre lettere significa calcolarla soltanto sui loro tre logit, ignorando il resto del vocabolario.

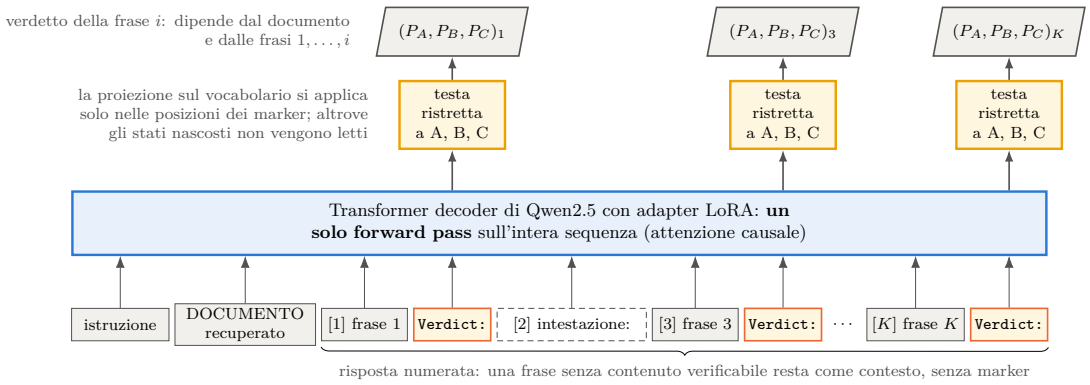


Figura 4.1: Il prompt a marker di GroundOne (design b). Le frasi della risposta sono numerate e ogni frase valutata è seguita dal marker “ `Verdict:`”; una frase senza contenuto verificabile (qui un'intestazione) resta come contesto, senza marker. Il modello elabora l'intera sequenza in un solo forward pass, e l'output head, ristretto alle lettere A, B e C, si applica soltanto nelle posizioni dei marker. Per l'attenzione causale il verdetto della frase i dipende dal documento e dalle frasi da 1 a i.

decoding è molto più lento del prefill a parità di token; il divario fra i due costi, quindi, si allarga al crescere di K. Sull'M4 usato in questa tesi, con il modello 0.5B il prefill costa circa 0.37 ms per token e il decoding 5.9 ms per token generato; con il 3B i due valori sono 2.2 e 31.8 ms. Un token in decoding costa quindi quanto quattordici-sedici token in prefill. Le due fasi, inoltre, sollecitano l'hardware in modo diverso. Il prefill elabora molti token insieme ed è limitato dalla capacità di calcolo, mentre il decoding produce un token alla volta ed è limitato dalla banda necessaria a leggere i pesi [10, 42]. La differenza riemerge nelle misure di energia del Capitolo 7. La Figura 4.2 traduce il modello di costo in secondi per risposta, usando soltanto queste costanti misurate.

Esiste anche una seconda soluzione, che legge una sola volta il prefisso condiviso e vi accoda poi una breve domanda per ogni frase, valutando le domande in batch. A differenza della soluzione a marker, che si accontenta di un solo forward pass, questa richiede però una KV cache replicata K volte. È mantenuta come alternativa di riserva ed è il formato naturale per un modello non addestrato, che comprende una domanda esplicita ma non ha motivo di interpretare un marker come una richiesta di verdetto. Per questo è il formato usato dalla baseline non addestrata (Sezione 6.2). La Figura 4.3 confronta le due soluzioni.

L'ordine del prompt ha una seconda conseguenza sul costo. Istruzioni, documento e risposta compaiono in quest'ordine, e l'attenzione è causale: le chiavi e i valori calcolati per un prefisso dipendono soltanto da quel prefisso. La KV cache delle

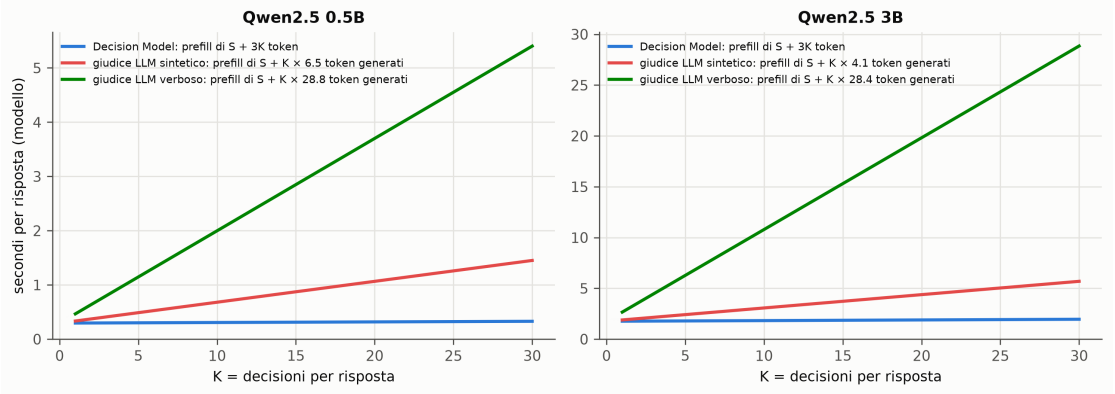


Figura 4.2: Costo stimato della verifica di una risposta di $S = 800$ token in funzione di K, calcolato con le sole costanti misurate sull'M4: il tempo per token del prefill e del decoding e il numero medio di token che ciascun giudice LLM genera per verdetto sul sottoinsieme di latenza (K medio 8.7). È un modello analitico, non una misura: le latenze misurate sono nella Sezione 7.9. A parità di testo, il costo del decision model cresce di soli tre token di prefill per decisione, quello dei giudici LLM di alcuni token di decoding per decisione. Nelle risposte reali, però, le frasi in più allungano anche il testo, il cui prefill è comune a entrambi: la Sezione 7.9 separa le due componenti.

istruzioni, identiche per ogni richiesta, e quella del documento possono quindi essere conservate e riusate in modo esatto da qualunque risposta successiva sullo stesso documento, che a quel punto costa solo la lettura della risposta e dei suoi marker. Il riuso della KV cache di un prefisso condiviso è una pratica comune nei sistemi di serving [41] ed è offerto anche dalle librerie MLX [58]. È il caso di una risposta riscritta e verificata di nuovo, di più risposte alternative generate dalle stesse fonti o di più domande sulla stessa libreria. Poiché le fonti sono note prima che la risposta venga verificata, il loro prefisso si può anche leggere in anticipo, appena termina la generazione e mentre l'utente legge la risposta, così che anche la prima verifica legga soltanto la risposta e i suoi marker. Il riuso del prefisso non è un vantaggio esclusivo del decision model: anche il prompt di un giudice LLM comincia con istruzioni e documento, e può riusarli allo stesso modo. Il formato a marker, però, lo rende particolarmente efficace, perché dopo il prefisso resta da leggere soltanto la risposta, e ogni frase in più costa i tre token del suo marker. Lo stesso ragionamento vale dentro la risposta: quando una riscrittura cambia una frase, la parte di risposta che la precede resta identica, e con essa i verdetti dei suoi marker, che dipendono soltanto da ciò che li precede; va riletto solo ciò che segue la prima modifica. Un giudice LLM non può sfruttarlo allo stesso modo, perché i suoi verdetti seguono l'intera risposta e vanno riscritti tutti. GroundOne conserva

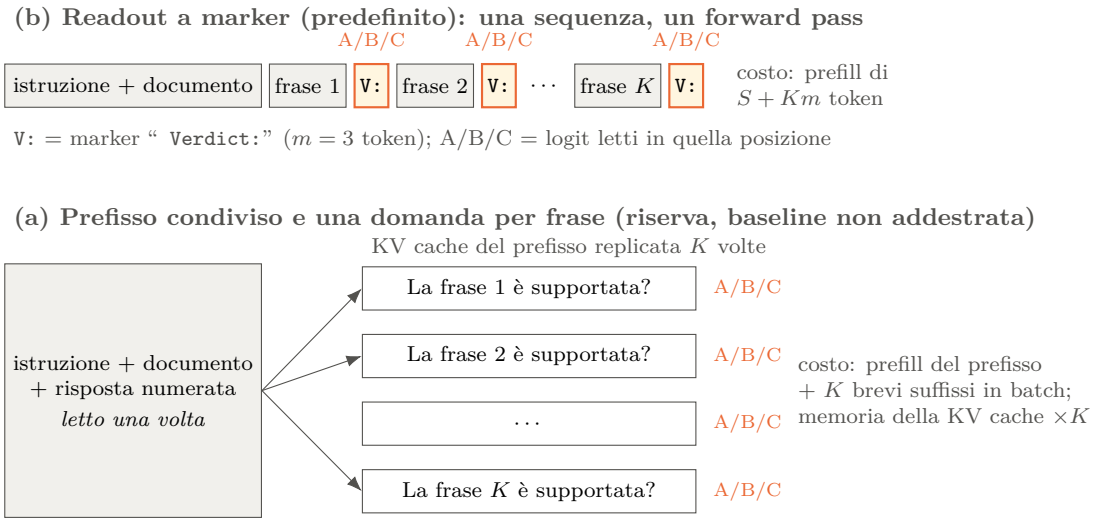


Figura 4.3: Le due soluzioni per ottenere K verdetti da una sola lettura. (b) Il readout a marker, adottato come predefinito, inserisce un marker dopo ogni frase e legge tutti i verdetti nello stesso passaggio. (a) La soluzione di riserva legge una volta il prefisso condiviso e vi accoda una breve domanda per ogni frase, valutate in batch; richiede però K copie della KV cache del prefisso, ed è il formato naturale per un modello non addestrato.

le istruzioni, gli ultimi documenti letti e l'ultima risposta verificata, sia nel servizio sia nell'applicazione del Capitolo 8; la Sezione 7.9.1 analizza la composizione del prefill e misura l'effetto della cache per GroundOne e per i giudici LLM.

Un classificatore, non un generatore più veloce. Il readout restringe la decisione a tre lettere, e la restrizione non è un dettaglio. Dopo il marker, il modello sottoposto a fine-tuning non scriverebbe la lettera che viene letta. Il suo token successivo più probabile è infatti di solito una lettera preceduta da uno spazio, che per il tokenizer è un token diverso. In corrispondenza dei marker, le tre lettere del readout raccolgono insieme appena il 4–5 % della massa di probabilità. Una loss ristretta a queste lettere addestra i loro logit relativi, non la loro probabilità assoluta, e il readout si comporta quindi come un classificatore a tre classi innestato sul modello linguistico. È questo a definire un decision model: la risposta non passa mai per il decoding, ma viene scelta fra le opzioni ammissibili. Il fenomeno richiama anche due risultati della letteratura: la probabilità del primo token di risposta e la risposta effettivamente scritta dal modello possono non coincidere [76], e la scelta fra lettere è soggetta a bias di selezione [77]. Un readout specializzato e calibrato deve assorbire entrambi gli effetti. Un esperimento di controllo ne quantifica la

differenza rispetto alla generazione: mantiene gli stessi pesi e lo stesso forward pass, ma al posto del readout ristretto prende il token che la generazione emetterebbe (Sezione 7.6).

4.3 Obiettivo di addestramento

GroundOne si ottiene da Qwen2.5-0.5B-Instruct e Qwen2.5-3B-Instruct [23] tramite low-rank adaptation (LoRA) [24], descritta nella Sezione 3.5 (Figura 3.3). Gli adapter hanno rango 16, fattore di scala 2 e dropout 0.05[2]. Sono applicati a tutti i layer lineari di tutti i blocchi transformer, cioè alle sette proiezioni di ciascun blocco (Figura 4.4), perché coprire ogni layer conta più che usare un rango elevato [65]. In totale si addestrano 8.8 milioni di parametri nel 0.5B e 29.9 milioni nel 3B, circa l'1.8 % e l'1.0 % dei rispettivi modelli. I pesi del modello base restano congelati in precisione a 8 bit. Ogni esempio di addestramento è una risposta con tutte le sue frasi valutate, e la loss viene calcolata su ciascuno dei suoi marker.

La loss è una cross-entropy[3] calcolata sulle sole tre lettere. Il prompt non viene mai supervisionato, quindi il segnale di addestramento proviene interamente dai verdetti. Circa l'88 % delle frasi del training set è supportato, per cui le classi sono pesate in modo che ciascuna contribuisca in egual misura alla loss. Con la distribuzione del training set si ottengono pesi di circa 0.38 per le frasi supportate, 7.5 per quelle contraddette e 4.4 per quelle non menzionate. Senza questi pesi, un modello può ottenere una loss bassa rispondendo quasi sempre "supportata". Ne discende una conseguenza utile: un modello che avesse appreso soltanto le frequenze delle classi resterebbe a una loss di $\ln 3 \approx 1.10$, quindi una loss inferiore a questo valore indica che il modello sfrutta effettivamente il testo.

L'ottimizzatore è AdamW, usato senza weight decay, cioè senza la penalità che a ogni passo riduce l'ampiezza dei pesi. Come nella configurazione predefinita di MLX, le stime dei momenti non ricevono la bias correction, e non si applica gradient clipping. L'addestramento dura un'epoca, cioè un solo passaggio sulle risposte del training set. Il learning rate sale fino a 10^{-4} con un warm-up lineare sul

[2]Il *fattore di scala* moltiplica l'aggiornamento calcolato dall'adapter prima di sommarlo all'output dello strato congelato. Il *dropout* azzera a caso, durante l'addestramento, una frazione degli input dell'adapter (qui il 5 %), così da ridurre il rischio che il modello memorizzi il training set.

[3]La *cross-entropy* di una predizione è il logaritmo negativo della probabilità che il modello assegna alla classe corretta: vale zero quando questa probabilità è uno e cresce senza limite quando il modello sbaglia con sicurezza.

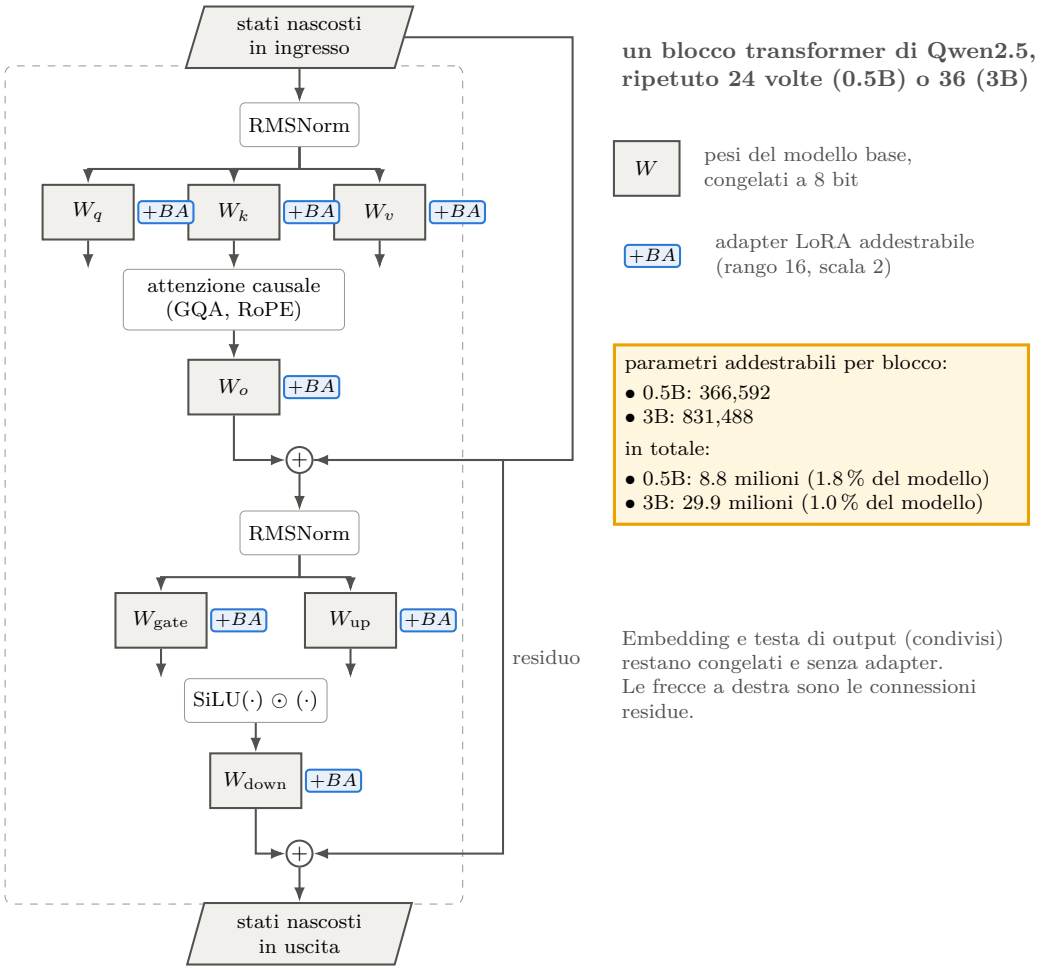


Figura 4.4: Dove GroundOne applica LoRA. Ogni blocco transformer di Qwen2.5 contiene sette proiezioni lineari: quattro nell'attenzione (W_q, W_k, W_v, W_o) e tre nel blocco MLP (W_{gate}, W_{up}, W_{down}). I loro pesi restano congelati a 8 bit, e a ciascuna si affianca un adapter di rango 16 (in blu) che ne corregge l'output secondo lo schema della Figura 3.3. Il blocco è ripetuto 24 volte nel 0.5B e 36 nel 3B; embedding e output head non hanno adapter.

primo 3 % dei passi (5 % per il 3B) e poi scende fino a zero con un cosine schedule[4]. Le risposte di lunghezza simile sono raggruppate in micro-batch, ciascuno entro un budget di token che comprende anche il padding, cioè i token di riempimento che uniformano le lunghezze. I gradienti di più micro-batch vengono poi accumulati, in modo che ogni passo dell'ottimizzatore veda circa 16 risposte, ovvero circa 110 decisioni. Così quasi ogni passo contiene qualche frase contraddetta, nonostante la rarità della classe. Il gradient checkpointing, che durante il calcolo dei gradienti ricalcola alcune attivazioni invece di conservarle, mantiene l'occupazione di memoria entro i 16 GB del portatile. Durante l'addestramento il modello viene valutato periodicamente sul dev set, e si conserva il checkpoint, cioè la copia dei pesi, con la balanced accuracy a tre classi più alta, mediata sui tre task di RAGTruth (question answering, summarization e data-to-text). La Sezione 6.1 riporta le impostazioni di ciascun run.

4.4 Calibrazione

I pesi delle classi addestrano il modello come se le tre classi fossero ugualmente frequenti, per cui le sue probabilità grezze non rispecchiano le frequenze reali delle classi. Sul dev set si stima quindi una trasformazione post-hoc, applicata ai logit dopo l'addestramento e senza modificare i pesi. I tre logit vengono divisi per una temperatura T e traslati di un bias per classe, $\mathrm{softmax}(z/T + b)$, con il bias della classe supportata fissato a zero. I parametri T e b sono scelti minimizzando la negative log-likelihood (NLL) delle etichette del dev set[5], cioè la cross-entropy media [90]. Il bias svolge il ruolo della correzione contestuale proposta per i modelli linguistici interrogati tramite prompt [92]; a differenza di quella, però, qui è stimato su dati etichettati. La sola temperatura cambia le probabilità ma non la classe più probabile né l'ordinamento delle frasi. Il bias, invece, può cambiare la classe più probabile e, con tre classi, può anche riordinare leggermente $P(\text{supported})$ fra una frase e l'altra. Per questo le metriche di classificazione e l'AUROC[6] sono calcolate

[4]Durante il *warm-up* il learning rate cresce gradualmente fino al valore scelto, così da evitare aggiornamenti bruschi all'inizio dell'addestramento. Il *cosine schedule* lo riduce poi seguendo mezzo periodo di un coseno: lentamente all'inizio, più in fretta a metà e di nuovo lentamente verso la fine.

[5]La *negative log-likelihood* di un insieme di n predizioni è la media, cambiata di segno, del logaritmo della probabilità assegnata alla classe corretta: $\mathrm{NLL} = -\frac{1}{n}\sum_{i=1}^{n} \log p_i(y_i)$, dove y_i è la classe corretta della predizione i. Vale zero quando il modello assegna sempre probabilità uno alla classe giusta e cresce rapidamente quando assegna una probabilità bassa alla classe giusta, cioè quando sbaglia con sicurezza: per questo penalizza sia gli errori sia l'eccesso di confidenza.

[6]L'*AUROC* (area under the ROC curve) misura quanto bene un punteggio separa due classi, qui le frasi supportate da quelle non supportate. Fissata una soglia, si accettano come supportate

sull'output grezzo. Le probabilità calibrate si usano invece dove una probabilità deve corrispondere a una frequenza: nelle metriche di calibrazione, nelle soglie e nella selective prediction (Sezione 7.7).

Calibrazione in addestramento o dopo l'addestramento. GroundOne calibra le probabilità dopo l'addestramento. Jev, il decision model che ha introdotto la categoria, segue la strada opposta: secondo il fornitore, le sue probabilità diventano affidabili già in addestramento, grazie a una fase di reinforcement learning con ricompense pensate per premiare la calibrazione (*Reinforcement Learning with Calibrated Decisions*, RLCD) [14]. La ricetta non è pubblica, e un confronto diretto non è stato possibile: Jev è un servizio remoto e chiuso, e valutarlo sui test set di questa tesi avrebbe richiesto di inviare i dati a un servizio esterno. Il confronto riguarda quindi gli approcci, sulla base delle valutazioni indipendenti (Tabella 4.1).

Queste valutazioni mostrano che la calibrazione ottenuta in addestramento vale in aggregato, ma non sul singolo carico di lavoro. Su 31 benchmark l'ECE di Jev è 0.047 se calcolato su tutti i dati insieme, ma 0.168 come mediana dei singoli benchmark [74]. Le sue probabilità binarie ordinano bene gli esempi, ma sono leggermente sotto-confidenti, per cui la soglia fissa di 0.5 risulta mal posizionata: la probabilità media di risposta affermativa è 0.465, contro una frequenza osservata di 0.518 [20]. Per questo gli studi raccomandano di stimare soglie e temperature sul carico di lavoro di destinazione [75]. Anche la ricetta RLCD rilasciata apertamente non offre vantaggi misurabili: in un confronto controllato resta da 2.5 a 3 punti sotto la semplice cross-entropy, con una variabilità tra seed fino a quattro volte maggiore, e dopo un temperature scaling nessun obiettivo di addestramento risulta meglio calibrato degli altri [100].

GroundOne parte da qui. Uno specialista lavora su un solo dominio, quindi può stimare la propria calibrazione proprio sulla distribuzione in cui verrà usato, con un dev set e pochi parametri. Su T1 l'ECE binario scende da 0.30 a 0.019 per il 0.5B e da 0.18 a 0.019 per il 3B. Il prezzo è lo stesso che gli studi rilevano per Jev, visto dall'altro lato: la calibrazione stimata su RAGTruth non si trasferisce a VitaminC (Sezione 7.7). Il vantaggio è che il procedimento è aperto, riproducibile e legato al modello che lo ha prodotto, e che la soglia di decisione fa parte della calibrazione invece di essere lasciata all'utente.

La calibrazione è misurata principalmente con l'Expected Calibration Error (ECE) [91, 90], che misura di quanto la confidenza dichiarata da un modello si

---

le frasi con punteggio superiore: la quota di frasi supportate accettate è il tasso di veri positivi, la quota di frasi non supportate accettate per errore è il tasso di falsi positivi. La curva ROC riporta queste due quantità per tutte le soglie possibili, e l'AUROC è l'area sotto di essa. Equivale alla probabilità che una frase supportata scelta a caso riceva un punteggio più alto di una frase non supportata scelta a caso: vale 0.5 per un punteggio casuale e 1 per una separazione perfetta.

Tabella 4.1: Due approcci alla calibrazione di un decision model. I valori di Jev provengono da valutazioni indipendenti su benchmark diversi da quelli di questa tesi; quelli di GroundOne sono misurati sul test set T1.

	Jev	GroundOne
Quando	In addestramento: SFT seguito da RL con ricompense di calibrazione (RLCD).	Dopo l'addestramento: temperatura e bias per classe stimati sul dev set.
Ambito	Un solo modello per tutti i task.	Un solo dominio, quello in cui il modello viene usato.
Ricetta	Non pubblica (dichiarazione del fornitore).	Aperta e legata al fingerprint del modello.
Soglia	Lasciata all'utente; va stimata per ogni carico di lavoro.	Stimata sul dev set e parte della regola di output.
Evidenze	ECE di 0.047 in aggregato e di 0.168 per singolo benchmark; probabilità binarie sottoconfidenti.	ECE binario su T1 da 0.30 a 0.019 (0.5B) e da 0.18 a 0.019 (3B); non si trasferisce a VitaminC.

discosta, in media, dalla frequenza con cui le sue predizioni risultano corrette. Le n predizioni vengono ripartite, in base alla confidenza, in M intervalli di uguale ampiezza, con $M = 15$ in questa tesi. Per ogni intervallo B_m si confrontano la confidenza media delle sue predizioni, $\mathrm{conf}(B_m)$, e la frazione di quelle risultate corrette, $\mathrm{acc}(B_m)$. L'ECE è la media degli scarti, pesata con la numerosità degli intervalli:

$$\mathrm{ECE} = \sum_{m=1}^{M} \frac{|B_m|}{n} \Big|\mathrm{acc}(B_m) - \mathrm{conf}(B_m)\Big|. \tag{4.1}$$

Un modello perfettamente calibrato ha un ECE pari a zero; un ECE di 0.05, per esempio, indica che la confidenza dichiarata si discosta in media di cinque punti percentuali dalla frequenza osservata. Nella variante binaria la confidenza è $P(\text{supported})$ e la frequenza osservata è la quota di frasi supportate nell'intervallo. Nella variante top-label a tre classi, invece, la confidenza è la probabilità massima e la frequenza osservata è la quota di predizioni corrette. L'ECE non confronta la distribuzione delle classi predette con quella del test set. Verifica piuttosto se, fra le frasi a cui il modello assegna una certa confidenza, quella confidenza corrisponde alla realtà. La misura ha però due limiti: dipende dalla scelta degli intervalli, e un predittore costante che restituisce sempre la frequenza di base ottiene un ECE vicino a zero pur non discriminando nulla. Per questi motivi l'ECE è sempre riportato insieme alla negative log-likelihood e ai reliability diagram, i grafici che

riportano per ogni intervallo la frequenza osservata in funzione della confidenza media. La capacità discriminativa delle probabilità si misura invece a parte, con due misure. La prima è l'AUROC, descritto qui sotto, che misura quanto bene la probabilità di supporto separa le frasi supportate da quelle non supportate. La seconda è l'AURC (area under the risk–coverage curve), cioè l'area sotto la curva risk–coverage della Sezione 3.4 (Figura 3.2): misura il tasso di errore medio che si ottiene accettando le decisioni dalla più sicura alla meno sicura, ed è tanto più piccola quanto più gli errori si concentrano tra le decisioni meno sicure, che sono quelle che un sistema rinvierebbe.

Calibrazione e AUROC rispondono a due domande diverse, ed è per questo che la tesi le riporta sempre entrambe. L'ECE chiede se una probabilità di 0.8 corrisponde davvero a una frase supportata otto volte su dieci. L'AUROC chiede invece se le frasi supportate ricevono punteggi più alti di quelle non supportate, qualunque sia la scala dei punteggi (Figura 4.5). Le due proprietà sono indipendenti. Un predittore costante è perfettamente calibrato rispetto alla frequenza di base, ma ha un AUROC di 0.5; viceversa, un modello può ordinare le frasi in modo quasi perfetto, con un AUROC vicino a 1, e assegnare comunque probabilità troppo estreme. L'AUROC, inoltre, non dipende da alcuna soglia né dalla frequenza delle classi, e non cambia se i punteggi vengono trasformati in modo monotono, come fa la temperatura. Per questo è la misura principale con cui GroundOne è confrontato con verificatori che restituiscono un punteggio binario, come gli encoder specializzati, mentre la scelta della soglia e la sua coerenza con le probabilità mostrate all'utente sono trattate a parte.

Dalle probabilità alle etichette restituite. Chi usa il verificatore vede per ogni frase un'etichetta e una probabilità, che devono essere coerenti tra loro. Questa tesi valuta la decisione grezza, cioè la classe più probabile secondo l'output non calibrato. La decisione grezza, però, può contraddire la probabilità calibrata mostrata accanto: una frase può essere etichettata "non menzionata" pur avendo una $P(\text{supported})$ calibrata di poco superiore a un mezzo. L'output restituito ricava quindi ogni elemento dalle probabilità calibrate con un'unica regola. Una frase è etichettata come supportata se e solo se $P(\text{supported}) \geq \tau$; altrimenti riceve la più probabile fra le due classi restanti. La policy strict segnala ogni frase non supportata, quella lenient soltanto le contraddette. La soglia τ è stimata sul dev set in modo da massimizzare la balanced accuracy a tre classi. L'utente può modificarla a ogni richiesta, scegliendo così un diverso punto operativo senza riaddestrare il modello. La Figura 4.6 riassume il percorso dai logit grezzi alle etichette restituite.

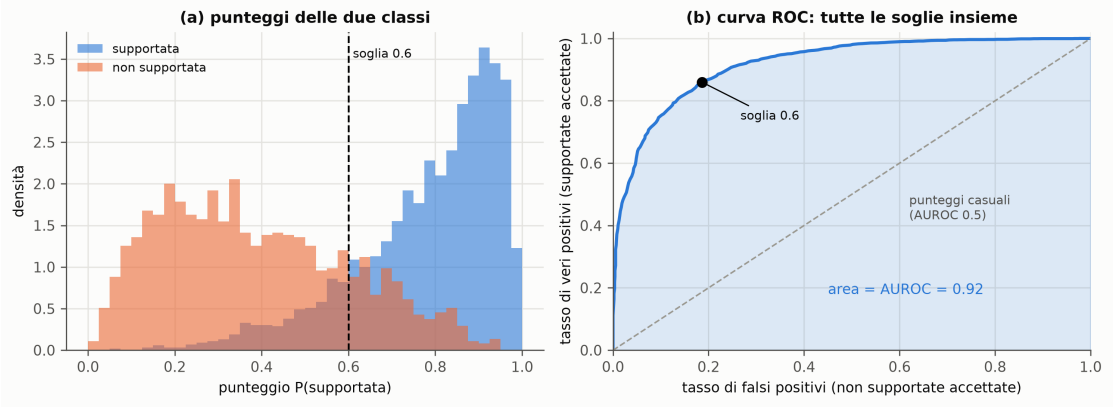


Figura 4.5: Come nasce l'AUROC (schema con punteggi sintetici, non un risultato). (a) Distribuzione di $P(\text{supported})$ per le frasi supportate e non supportate: le due distribuzioni si sovrappongono, e ogni soglia accetta una parte delle une e delle altre. (b) Spostando la soglia da 1 a 0 si ottiene la curva ROC; il punto nero corrisponde alla soglia del pannello (a). L'area sotto la curva è l'AUROC: più le due distribuzioni sono separate, più la curva si avvicina all'angolo in alto a sinistra e l'area a 1. La diagonale corrisponde a punteggi casuali.

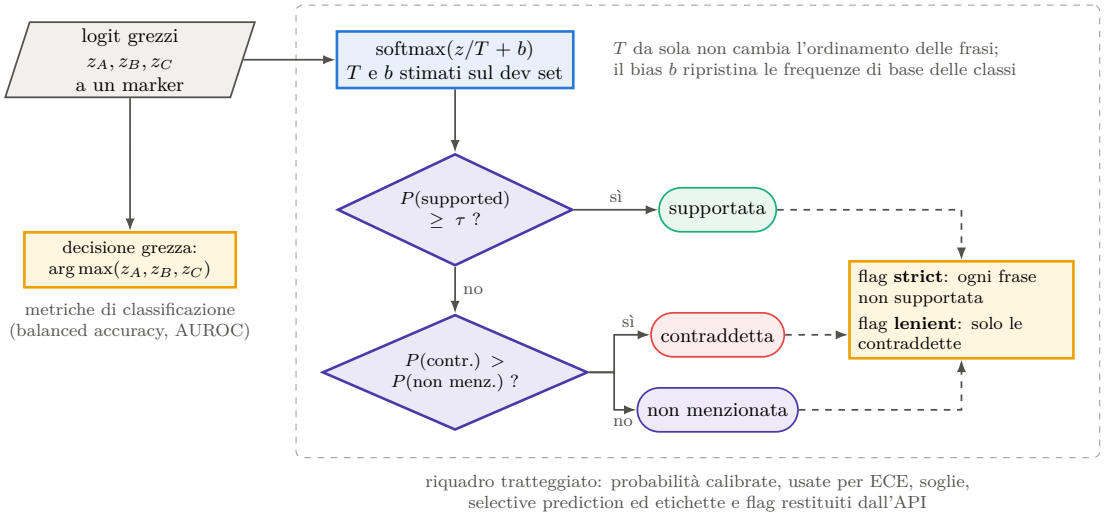


Figura 4.6: Dai logit alle etichette restituite. La decisione grezza, cioè l'argmax dei logit, serve alle metriche di classificazione del Capitolo 7. Le probabilità calibrate, ottenute con temperatura e bias stimati sul dev set, alimentano invece l'unica regola dell'output restituito: supportata se $P(\text{supported}) \geq \tau$, altrimenti la più probabile fra contraddetta e non menzionata. Da qui derivano i flag strict e lenient.

4.5 Software

GroundOne è implementato come pacchetto Python installabile basato su MLX [3, 58], il framework per array pensato per Apple silicon. Tutte le fasi di addestramento e di inferenza descritte finora vengono eseguite con MLX sullo stesso portatile. Il pacchetto comprende il costruttore del dataset con i relativi controlli, il ciclo di addestramento, la calibrazione, la valutazione sui test set congelati, le baseline e un meccanismo di protezione della memoria. Quest'ultimo esegue i processi lunghi uno alla volta e interrompe un processo prima che il sistema esaurisca la memoria.

Il verificatore è esposto tramite un'interfaccia a riga di comando e un server HTTP. Il server offre un endpoint nativo e un endpoint compatibile con l'interfaccia System One di Jev, già usata da altri decision model, così che i client esistenti possano adottare GroundOne cambiando soltanto l'indirizzo. L'endpoint nativo riceve un documento e una risposta. Segmenta la risposta con la stessa regola usata per costruire i dati ed esegue il singolo forward pass della Sezione 4.2. Per ogni frase riporta se è stata valutata, le tre probabilità calibrate, l'etichetta restituita e i flag delle policy strict e lenient, insieme alla regola di decisione e alla soglia che li hanno prodotti. Indica inoltre il numero di token in ingresso, il numero di token generati, sempre pari a zero, e il tempo impiegato. L'endpoint compatibile, invece, risponde a domande chiuse generiche su un contesto condiviso, con il formato a una domanda per frase. Tutto il calcolo del modello avviene su un unico worker thread di lunga durata, perché il contesto Metal della GPU, cioè lo stato con cui il programma la usa attraverso Metal, l'API grafica di Apple, non deve spostarsi da un thread all'altro. Infine, nulla esce dalla macchina: modelli, dati e richieste restano in locale. La Figura 4.7 riassume l'architettura del pacchetto.

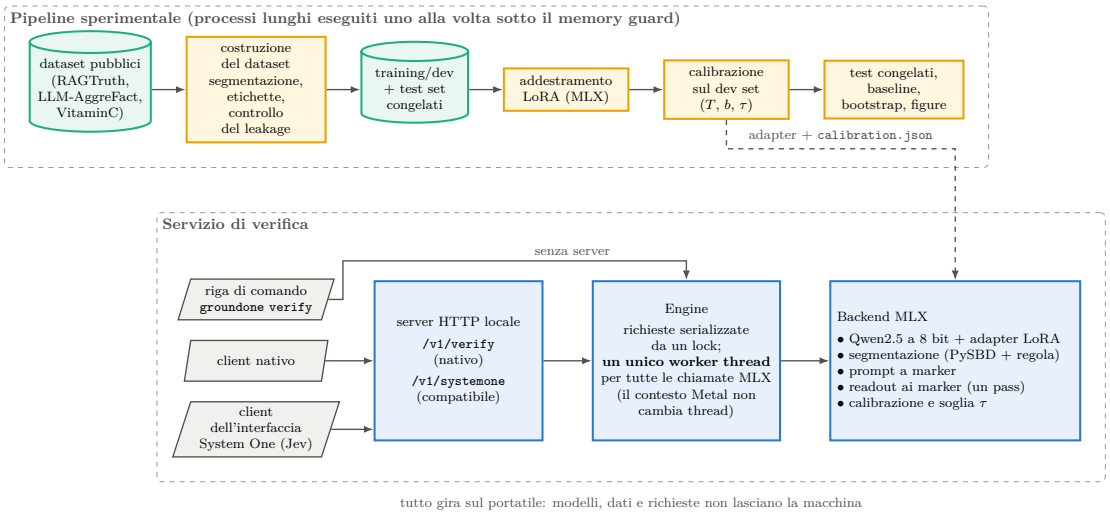


Figura 4.7: Architettura del software. In alto la pipeline sperimentale, dai dataset pubblici ai test congelati, eseguita sotto il memory guard; in basso il servizio di verifica, in cui riga di comando e server HTTP (endpoint nativo e compatibile) condividono lo stesso Engine, che serializza le richieste ed esegue ogni chiamata MLX su un unico worker thread. L'adapter e il file di calibrazione prodotti dalla pipeline sono gli unici artefatti che il servizio legge.

Capitolo 5

Dati

GroundOne apprende un'unica decisione, quindi i dati devono insegnare esattamente quella decisione e permettere di misurarla in modo affidabile. Il capitolo definisce anzitutto la decisione e le sue etichette. Descrive poi i tre dataset pubblici da cui le etichette provengono e il modo in cui vengono trasformati in training set, dev set e test set. Le ultime sezioni mostrano come l'affidabilità dei test set sia stata verificata senza nuove annotazioni, che cosa emerge da un'analisi esplorativa del dataset costruito e come sia stato escluso il leakage tra i dati di addestramento e quelli di test.

5.1 Task ed etichette

L'input è costituito da un documento recuperato e da una risposta, scritta da un modello linguistico e suddivisa in frasi. Per ogni frase il modello stabilisce se, *rispetto al documento*, essa è *supportata*, *contraddetta* o *non menzionata*. Una frase è supportata quando il documento dice, o implica direttamente, tutto ciò che essa afferma. È contraddetta quando una sua parte è in conflitto con il documento. È non menzionata quando aggiunge informazioni che il documento non contiene, ma nemmeno contraddice. Quando una frase contiene sia una parte in conflitto sia una parte non verificabile, viene etichettata come contraddetta, perché la contraddizione è l'errore più grave. Conta soltanto il documento: un'affermazione vera nel mondo reale ma assente dal documento resta non menzionata.

Il numero di decisioni richieste da una risposta coincide con il numero delle sue frasi valutate, indicato con K. Questa grandezza è centrale nella tesi. Un decision model legge documento e risposta una sola volta, quindi ogni decisione aggiuntiva gli costa poco, soltanto i token della frase e i tre del suo marker; un giudice LLM, invece, deve produrre testo per ogni frase. Per questo il confronto con i giudici

LLM è condotto in funzione di K, e i dati devono comprendere risposte lunghe oltre che brevi.

Per ogni frase il modello restituisce tre probabilità, e ogni altra grandezza è derivata da queste, invece di essere appresa separatamente. Il punteggio binario di groundedness, usato per il confronto con i benchmark binari pubblicati, è $P(\text{supported})$. Le segnalazioni dipendono invece dalla nozione di errore adottata. Secondo una policy *strict* è un errore tutto ciò che il documento non afferma, e una frase viene segnalata quando $P(\text{supported})$ scende sotto una soglia τ. Secondo una policy *lenient* sono errori soltanto le contraddizioni, e una frase viene segnalata solo quando è giudicata contraddetta. In questo modo l'utente sceglie la nozione di errore e la soglia al momento dell'inferenza, senza riaddestrare il modello. La Sezione 4.4 riporta la regola esatta con cui il verificatore produce le etichette che restituisce.

5.2 Dataset di partenza

Il dataset è costruito di proposito a partire dal minor numero possibile di fonti: una per l'addestramento e tre per il test (Tabella 5.1). Con meno fonti la definizione delle etichette e il formato del testo restano unici, e si riducono i punti in cui la costruzione può introdurre errori.

Tabella 5.1: I dataset di partenza: licenza, ruolo in GroundOne e tipo delle etichette originali.

Dataset	Licenza	Ruolo	Etichette
RAGTruth [8]	MIT	Training set, dev set e test T1	Span di caratteri delle risposte di LLM, annotati con quattro tipi di allucinazione (conflitto o informazione infondata, evidente o sottile).
LLM-AggreFact [12, 89]	CC BY-ND 4.0	Solo test T2	Un'etichetta binaria per ogni affermazione: supportata o non supportata.
VitaminC [80]	CC BY-SA 3.0	Solo test T3	Tre classi per ogni affermazione: *supports*, *refutes* e *not enough information*.

RAGTruth. RAGTruth [8] contiene 17,790 risposte scritte da sei modelli linguistici (GPT-3.5, GPT-4, Llama-2 7B, 13B e 70B, e Mistral-7B) in tre task di RAG, che si distinguono per il tipo di contesto. Nel question answering il contesto è un insieme di passaggi recuperati per una domanda di MS MARCO [101]. Nella summarization è un articolo di cronaca, tratto da CNN/DailyMail [102, 103] o da notizie recenti. Nella generazione data-to-text, in cui il modello descrive in prosa dati strutturati, il contesto è la scheda di un'attività commerciale di Yelp in formato JSON [104]. In ciascuna risposta, due annotatori formati hanno individuato gli span di caratteri non supportati dal contesto[1], con una terza revisione nei casi di disaccordo. A ogni span hanno poi assegnato uno di quattro tipi: *conflitto*, evidente o sottile, e *informazione infondata*, evidente o sottile. L'articolo riporta un accordo tra annotatori del 91.8 % a livello di risposta e del 78.8 % a livello di span. RAGTruth è l'unico dataset pubblico che unisca risposte naturali di più frasi, prodotte da modelli diversi, alla distinzione tra contenuto contraddetto e contenuto non supportato, ed è per questo l'unica fonte di addestramento. Lo split ufficiale separa 450 fonti di test dalle restanti, destinate all'addestramento.

LLM-AggreFact. LLM-AggreFact [12, 89] aggrega undici dataset di fact checking annotati manualmente, ciascuno composto da coppie (documento, affermazione). I dataset coprono tre ambiti: la summarization (AggreFact-CNN e XSum [105], TofuEval [106], con i due sottoinsiemi MediaS e MeetB), il question answering basato su retrieval o con risposte in forma estesa (RAGTruth [8], ClaimVerify [107], ExpertQA [108], LFQA [109]) e il fact checking vero e proprio (WiCE [110], REVEAL [111], FactCheck-GPT [112]). Il benchmark ha una leaderboard pubblica, che rende i risultati confrontabili con quelli dei sistemi pubblicati. La sua condizione di accesso, però, vieta di usare i dati per addestrare modelli [113]. In questa tesi il dataset serve quindi soltanto alla valutazione: nessun addestramento, calibrazione o selezione avviene su alcuno dei suoi split.

VitaminC. VitaminC [80, 114] è un dataset di verifica dei fatti costruito a partire da revisioni di Wikipedia che cambiano un fatto. Per ogni revisione, annotatori formati hanno scritto affermazioni supportate da una versione della frase e confutate dall'altra. Quando non era possibile formulare una contraddizione, la coppia è stata etichettata come priva di informazioni sufficienti. Le due versioni dell'evidenza sono quasi identiche, quindi per decidere il modello deve guardare al fatto preciso, e non alla sovrapposizione lessicale. Su un campione ri-annotato di 2,000 coppie

[1] Uno *span* è un tratto contiguo di testo, individuato dalla posizione del suo primo e del suo ultimo carattere. Un'annotazione a livello di span marca la porzione esatta della risposta che contiene l'errore, invece di giudicare la risposta nel suo insieme.

gli autori riportano un κ di Fleiss pari a 0.71[2]. In questa tesi VitaminC colma una lacuna precisa. RAGTruth non pubblica l'accordo tra annotatori sul *tipo* di allucinazione, quindi da solo non può dimostrare che il modello apprenda il confine tra contraddetta e non menzionata. VitaminC fornisce proprio questo confine, con etichette di affidabilità nota e in un dominio diverso.

Diversi altri candidati sono stati esaminati e scartati. I corpora di NLI come ANLI [79] hanno premesse brevi, lontane dai contesti tipici della RAG, e la stessa distinzione a tre classi su testo fattuale è già coperta da VitaminC. I dati di addestramento sintetici o soltanto binari, come quelli rilasciati con MiniCheck [12], non hanno etichette a tre classi. Infine, sono stati esclusi i dataset con etichette generate da un modello linguistico e quelli che riutilizzano risposte di test di RAGTruth: in questo modo le etichette restano umane e i test set restano indipendenti.

5.3 Costruzione

Segmentazione in frasi. Le risposte contengono spesso elenchi e intestazioni, quindi vengono prima spezzate in corrispondenza degli a capo. Ogni riga viene poi divisa in frasi con PySBD [115], un segmentatore basato su regole che gestisce abbreviazioni e numeri decimali. I simboli di elenco iniziali, come "3." o "*", vengono rimossi, perché riguardano l'impaginazione e non il contenuto. Lo stesso segmentatore è usato in addestramento, in valutazione e in inferenza, così che il modello veda sempre frasi tagliate allo stesso modo. La Figura 5.1 riassume l'intero processo di costruzione, dalle fonti ai test set congelati.

Frasi senza contenuto verificabile. Alcune frasi non affermano nulla sul documento: saluti, intestazioni che introducono un elenco, righe che contengono soltanto una citazione, come "(Passage 2)", e formule di rifiuto. Queste frasi restano nella risposta numerata come contesto, ma non costituiscono decisioni e non hanno etichetta. Una breve regola le individua, e riguarda l'8.2 % di tutte le frasi di RAGTruth, in gran parte intestazioni di elenchi. La regola considera soltanto la forma della frase, cioè meno di due parole, i due punti finali, una riga di sola citazione o una formula conversazionale o di rifiuto, e non modifica mai un'etichetta. La sua copertura è stata verificata rispetto alla segmentazione indipendente di LLM-AggreFact, descritta nella Sezione 5.5.

Etichette. In RAGTruth l'etichetta di una frase valutata dipende dagli span con cui la frase si sovrappone. La frase è contraddetta se si sovrappone a uno span di

[2]Il κ di Fleiss misura l'accordo tra più annotatori al netto dell'accordo che si otterrebbe per puro caso: vale 1 quando l'accordo è perfetto e 0 quando non supera quello casuale.

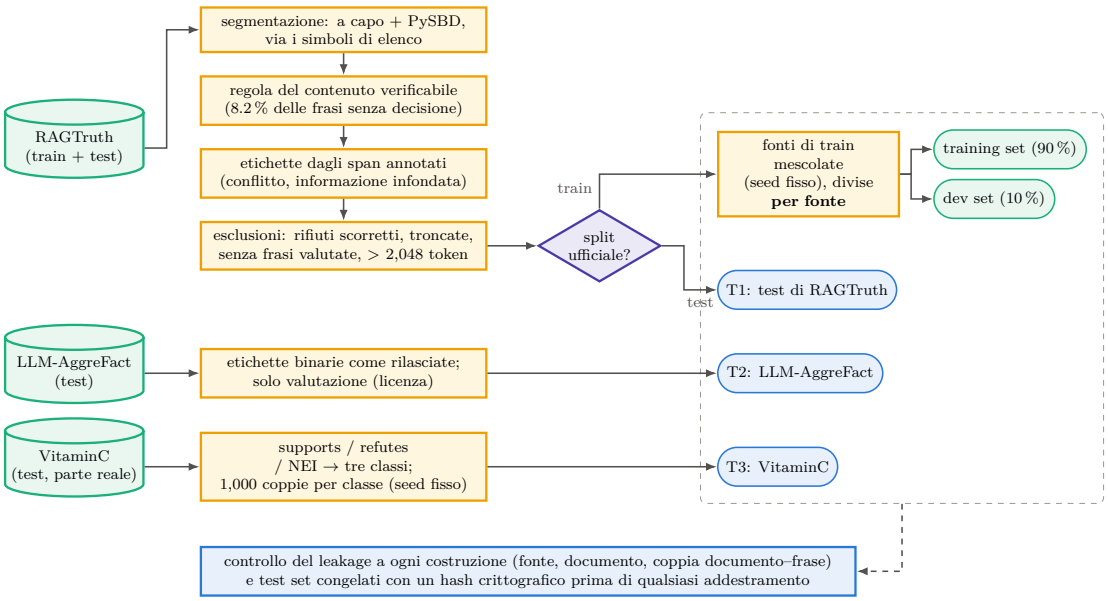


Figura 5.1: Costruzione del dataset. Le risposte di RAGTruth sono segmentate, filtrate dalle frasi senza contenuto verificabile, etichettate a partire dagli span e ripulite dalle esclusioni; lo split ufficiale di test diventa T1, mentre le fonti di addestramento sono divise per fonte in training set e dev set. LLM-AggreFact e VitaminC forniscono soltanto test set (T2 e T3). Un controllo automatico del leakage accompagna ogni costruzione, e i test set sono congelati con un hash prima di qualsiasi addestramento.

conflitto, non menzionata se si sovrappone soltanto a span di informazione infondata, e supportata in tutti gli altri casi. Soltanto 27 dei 14,226 span annotati (0.19 %) non toccano alcuna frase valutata, quindi la conversione non perde quasi nessuna annotazione. Per LLM-AggreFact, invece, l'etichetta binaria è mantenuta così come rilasciata. Le etichette di VitaminC sono convertite direttamente: *supports* diventa supportata, *refutes* contraddetta e *not enough information* non menzionata. La Figura 5.2 riassume la regola applicata a RAGTruth.

Esclusioni e split. Vengono rimosse tre categorie di risposte: quelle che RAGTruth segnala come rifiuti scorretti o come troncate, quelle senza alcuna frase valutata e quelle in cui documento, risposta e i circa 80 token del prompt superano insieme i 2,048 token. Quest'ultimo limite di lunghezza è imposto dalla memoria del portatile da 16 GB. Lo split di test ufficiale di RAGTruth diventa il test set T1. Le fonti di addestramento, invece, vengono mescolate con un seed fisso e divise in due parti: il 10 % forma il dev set e il resto il training set. Poiché la divisione avviene per fonte, le risposte relative alla stessa fonte non compaiono mai in entrambi gli

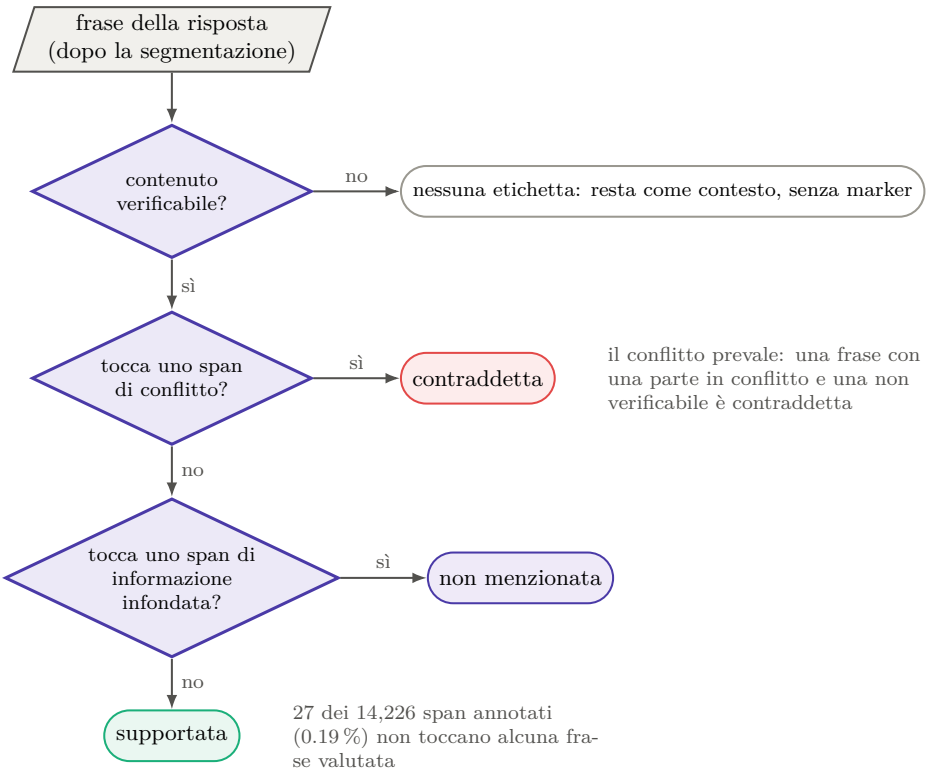


Figura 5.2: Regola con cui le annotazioni a livello di span di RAGTruth diventano etichette di frase. Le frasi senza contenuto verificabile restano nel prompt come contesto ma non sono decisioni; fra le altre, il conflitto prevale sull'informazione infondata.

insiemi. Vengono inoltre rimosse sei risposte di addestramento relative a un articolo di cronaca presente anche nel test set di LLM-AggreFact. Infine, la parte reale (non sintetica) dello split di test di VitaminC è sbilanciata tra le classi, quindi T3 è formato campionando da essa, con un seed fisso, 1,000 coppie per classe.

5.4 Il dataset risultante

La Tabella 5.2 riassume i cinque file del dataset. Il training set contiene 13,203 risposte e 90,795 frasi etichettate. Ogni record corrisponde a una risposta e contiene un'etichetta per ciascuna frase: in questo modo gli stessi dati possono alimentare modi diversi di leggere le K decisioni di una risposta.

RAGTruth è fortemente sbilanciato: circa l'88 % delle frasi etichettate è supportato, e le contraddizioni sono appena il 4 % circa (Figura 5.3). Questa è la frequenza naturale degli errori nelle risposte dei modelli, e viene preservata. Il test set riflette

Tabella 5.2: Il dataset GroundOne: numero di record e di decisioni per split e per classe. Una decisione è una frase etichettata. T2 ha etichette binarie, quindi le frasi contraddette e non menzionate vi sono riunite nella classe non supportata.

Split	Fonte	Record	Decisioni	Supportate	Contraddette	Non menzionate
Train	RAGTruth	13,203	90,795	79,898	4,039	6,858
Dev	RAGTruth	1,468	9,996	8,827	410	759
T1	RAGTruth test	2,647	17,284	15,745	584	955
T2	LLM-AggreFact test	29,320	29,320	22,832	6,488 non supportate	
T3	VitaminC test	3,000	3,000	1,000	1,000	1,000

così ciò che un verificatore incontra nella pratica, mentre lo sbilanciamento viene gestito in fase di addestramento. T3 compensa offrendo un test bilanciato fra le tre classi.

Le risposte contengono in media 6.9 frasi valutate nel training set e 6.5 in T1, con un massimo di 28 nel training set e di 23 in T1 (Figura 5.4). Per analizzare i risultati in funzione della lunghezza, T1 è diviso in quattro fasce di K: 756 risposte con 1–4 frasi, 1,288 con 5–8, 497 con 9–13 e 106 con 14 o più. Quando una cella dei risultati contiene al più 30 frasi di una classe minoritaria, come accade per le frasi contraddette nel question answering e nelle risposte con quattordici o più frasi, il valore viene riportato ma segnalato come indicativo.

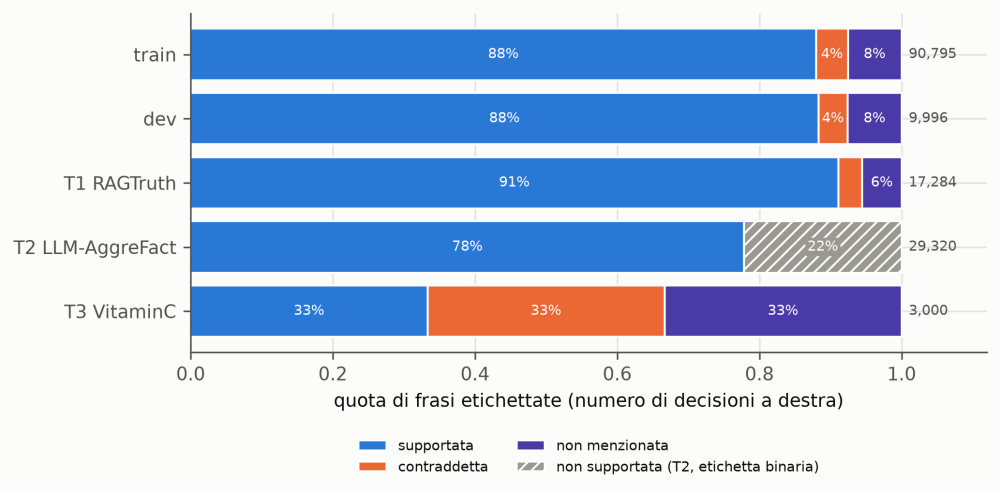


Figura 5.3: Distribuzione delle classi fra le frasi etichettate di ciascuno split. Negli split di RAGTruth (train, dev e T1) circa l'88–91 % delle frasi è supportato. T2 (LLM-AggreFact) ha etichette binarie, quindi le affermazioni contraddette e non menzionate vi formano un'unica classe non supportata (tratteggio). T3 è campionato con 1,000 coppie per classe.

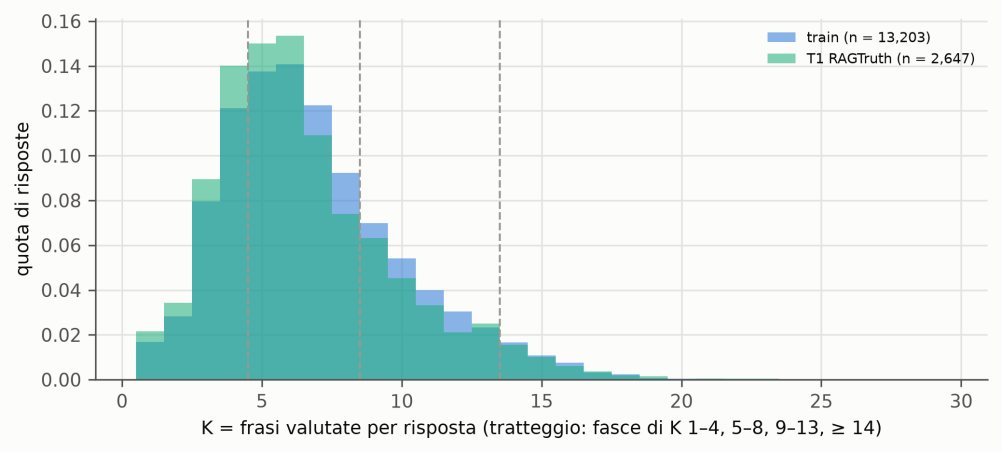


Figura 5.4: Distribuzione di K, il numero di frasi valutate per risposta, nel training set e in T1. Le linee tratteggiate delimitano le fasce di K usate per riportare i risultati.

5.5 Affidabilità dei test set

I test set sono stati verificati senza nuove annotazioni, ricorrendo a evidenze indipendenti dalla costruzione descritta sopra (Tabella 5.3). Tutte le etichette di test provengono dagli annotatori umani dei dataset pubblicati. Le due scelte che potevano introdurre errori sono la segmentazione e la conversione dagli span alle etichette di frase. Entrambe sono state confrontate con LLM-AggreFact, i cui autori hanno convertito in modo indipendente le stesse risposte di test di RAGTruth in affermazioni a livello di frase. Il segmentatore di questa tesi ritrova esattamente il 96.3 % delle loro affermazioni, e solo l'8.5 % delle frasi valutate è assente dal loro insieme. Si tratta per lo più di frasi eliminate dal loro filtro delle affermazioni "non meritevoli di verifica", che non è documentato. Sulle 15,492 frasi presenti in entrambi gli insiemi, le etichette binarie concordano nel 98.75 % dei casi. Tutti i 193 disaccordi, inoltre, vanno nella stessa direzione: la regola basata sugli span marca come non supportata una frase che LLM-AggreFact considera supportata. Infine, una baseline basata su encoder, valutata su T2 senza modifiche, riproduce il punteggio pubblicato dai suoi autori (balanced accuracy di 74.0 misurata, contro 73.5 pubblicata), il che convalida il codice di valutazione.

Questi controlli convalidano il versante binario di T1, cioè la distinzione tra frasi supportate e non supportate. La distinzione tra contraddetta e non menzionata poggia invece sugli annotatori di RAGTruth, il cui accordo sul tipo di allucinazione non è pubblicato. Inoltre, una recente ri-annotazione dello split di test di RAGTruth ha trovato 1.68 volte più risposte con allucinazioni rispetto alle etichette

Tabella 5.3: Controlli di affidabilità eseguiti prima del congelamento dei test set, con il criterio di superamento e l'esito di ciascuno.

Controllo	Criterio	Esito
Provenienza delle etichette	Ogni etichetta di test proviene da annotatori umani.	Superato
Segmentazione	Almeno il 90 % delle affermazioni di LLM-AggreFact ritrovate tra le frasi segmentate, e al più il 10 % delle frasi segmentate assenti da LLM-AggreFact.	96.3 % e 8.5 %
Derivazione delle etichette	Accordo di almeno il 97 % con le etichette binarie di LLM-AggreFact.	98.75 %
Baseline di riferimento	MiniCheck-RoBERTa su T2 entro 1.5 punti dal punteggio pubblicato.	74.0 contro 73.5
Leakage	Nessuna fonte, documento o coppia (documento, frase) in comune tra addestramento e test.	Superato

originali [116], il che suggerisce che T1 sottostimi le due classi minoritarie. Per questi motivi i risultati a tre classi su T1 vengono sempre letti insieme a quelli su T3.

Completati questi controlli, e prima di addestrare qualsiasi modello, i tre file di test sono stati congelati con hash crittografici[3]. Da quel momento il programma che genera il dataset a partire dalle fonti grezze (il comando di costruzione del pacchetto GroundOne, Sezione 4.5) confronta ogni nuovo file di test con la sua impronta e si rifiuta di sovrascriverlo se il contenuto è cambiato. Rieseguendo la costruzione da zero, inoltre, si riottengono esattamente i file congelati: i test set non possono quindi essere modificati, nemmeno per errore, dopo aver visto i risultati.

5.6 Analisi esplorativa

Un'analisi esplorativa delle fonti e del dataset costruito ha messo in luce quattro proprietà che condizionano la lettura dei risultati.

[3]Un *hash* crittografico è un'impronta di lunghezza fissa calcolata dal contenuto di un file. Anche una modifica minima del file produce un'impronta completamente diversa, quindi confrontare le impronte basta a rilevare qualunque cambiamento.

Gli errori dipendono dal task e dal modello. Le risposte data-to-text contengono allucinazioni con una frequenza da due a quattro volte maggiore rispetto a quelle degli altri due task. Anche il generatore conta: le risposte di Llama-2 e Mistral concentrano la maggior parte delle allucinazioni, mentre quelle di GPT-3.5 e GPT-4 sono quasi sempre fedeli al documento (Figura 5.5). Per questo i risultati sono riportati task per task: una media unica rifletterebbe soprattutto il data-to-text.

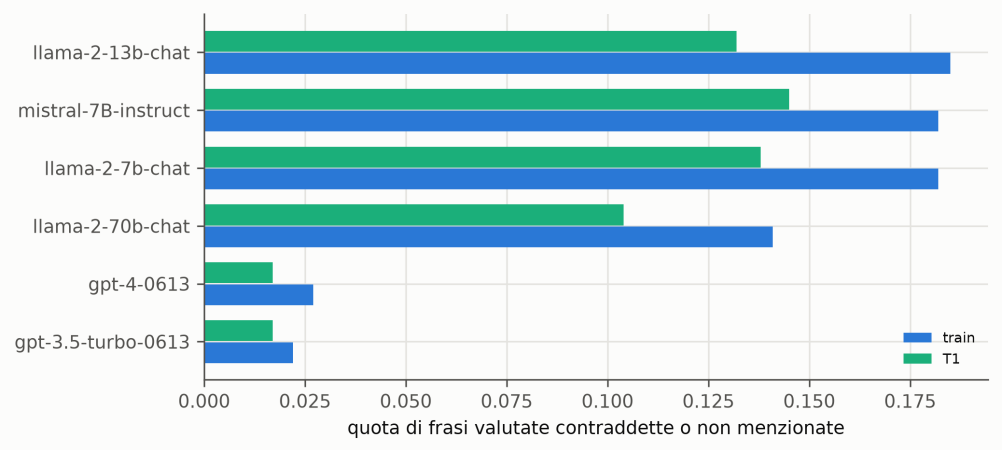


Figura 5.5: Quota di frasi contraddette o non menzionate in base al modello che ha scritto la risposta, nel training set e in T1.

Le risposte di test sono più pulite di quelle di addestramento. In ogni task e per ogni generatore, la quota di frasi contraddette e non menzionate è più bassa in T1 che nel training set. Nel question answering, per esempio, è contraddetto lo 0.6 % delle frasi di T1, contro l'1.6 % di quelle del training set. Di conseguenza, le metriche che dipendono dalla frequenza di base delle classi, come la precisione o l'F1 sulle classi minoritarie[4], non sono confrontabili tra dev set e test set, perché il dev set, estratto dal training set, ne conserva la distribuzione. Le metriche principali sono quindi la balanced accuracy, la recall per classe e l'AUROC, che dalla frequenza di base non dipendono.

Le contraddizioni sono per lo più evidenti. Circa l'85 % delle frasi contraddette del training set deriva da span annotati come conflitti *evidenti*, per

[4]La *precisione* è la quota delle predizioni di quella classe che risultano corrette, e per questo cambia con la frequenza della classe anche quando il modello resta lo stesso. L'F1 è la media armonica delle due.

esempio numeri o nomi sbagliati, mentre soltanto 147 derivano da conflitti *sottili*. La classe contraddetta è quindi composta soprattutto da contraddizioni palesi, e le contraddizioni sottili non possono essere valutate separatamente.

Esistono indizi superficiali, e definiscono le baseline. Due indizi semplici predicono le etichette senza verificare la frase rispetto al documento. Il primo è la sovrapposizione lessicale, cioè la quota delle parole di contenuto della frase che compaiono anche nel documento; le parole di contenuto sono quelle che restano escludendo le parole funzionali, come articoli, preposizioni e verbi ausiliari. In tutti e tre i test set questa quota è più alta per le frasi supportate che per quelle contraddette e non menzionate (Figura 5.6). Usata da sola come punteggio, separa le frasi supportate da quelle non supportate con un AUROC di 0.74 su T1 e di 0.70 su T3. Il secondo indizio è la formulazione della frase. Nel data-to-text, un classificatore che vede soltanto la frase raggiunge una balanced accuracy a tre classi di 0.66, perché nelle descrizioni di Yelp alcuni dettagli vengono inventati spesso, come il numero di recensioni o la disponibilità di Wi-Fi o del parcheggio con valet. Nel question answering e nella summarization, invece, lo stesso classificatore resta al livello del caso (0.36 e 0.35), e lo stesso accade su T3 (0.33), dove la costruzione contrastiva del dataset elimina l'indizio. Un verificatore è utile solo nella misura in cui batte questi indizi, per cui entrambi sono riportati come baseline, task per task.

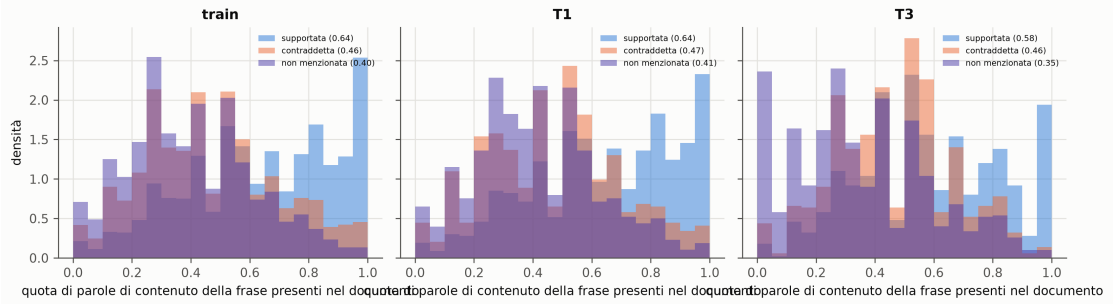


Figura 5.6: Sovrapposizione lessicale tra una frase e il suo documento, cioè quota delle parole di contenuto della frase presenti nel documento, per classe, nel training set, in T1 e in T3. Tra parentesi è indicata la media.

Infine, le frasi non supportate non si concentrano alla fine della risposta. La prima frase è raramente non supportata, mentre la quota di frasi non supportate raggiunge il massimo tra la terza e la quinta posizione e resta tra l'8 e l'11 % nelle posizioni successive (Figura 5.7). Anche le risposte lunghe, quindi, contengono errori verso la fine, e l'accuratezza per valori elevati di K resta rilevante.

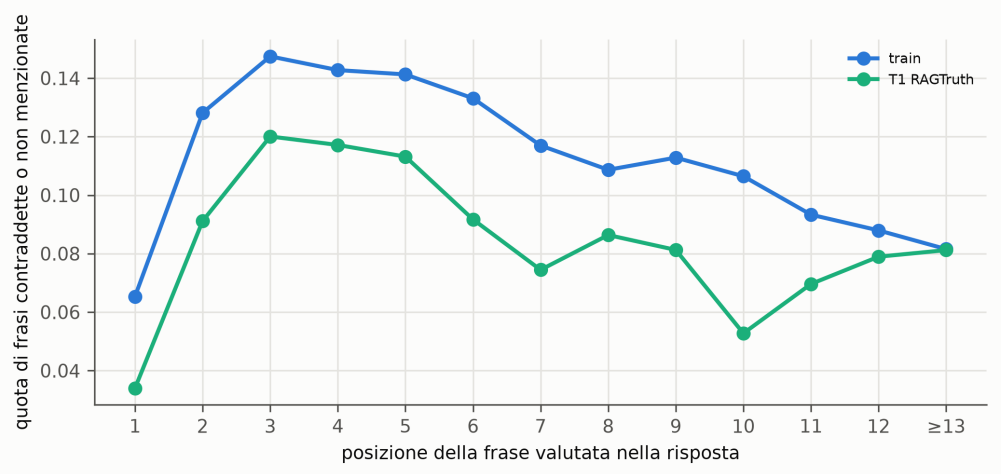


Figura 5.7: Quota di frasi contraddette o non menzionate in base alla posizione della frase nella risposta.

5.7 Controllo del leakage

Il leakage, cioè la presenza tra i dati di addestramento di informazioni del test set, renderebbe ottimistiche tutte le metriche dei capitoli successivi. In questo dataset il rischio è concreto: RAGTruth contiene, per ogni documento, più risposte scritte da modelli diversi. Se queste risposte finissero in split diversi, il modello vedrebbe in addestramento proprio il documento su cui viene poi valutato. Per questo gli split sono definiti per fonte e mai per frase, così che tutte le risposte relative a una stessa fonte cadano nello stesso split. A ogni costruzione del dataset viene inoltre eseguito un controllo automatico, che fallisce in due casi: quando una fonte, un documento o una coppia (documento, frase) del training set o del dev set compare in uno qualsiasi dei test set, e quando dev set e training set condividono una fonte. Sul dataset finale il controllo non ha rilevato alcuna sovrapposizione di questo tipo. Il controllo elenca anche, senza bloccare la costruzione, le frasi che compaiono con le stesse parole sia nei dati di addestramento sia in quelli di test, ma riferite a documenti diversi. Sono 788 nel training set e 82 nel dev set. La maggior parte, 702 delle 788, sono frasi standard del data-to-text, come “The business has a rating of 4.0 stars.”: il modello generatore le ripete per attività commerciali diverse, quindi la loro presenza nei dati di addestramento non anticipa alcuna etichetta di test, che dipende sempre dal documento a cui la frase si riferisce. Le altre sono frasi generiche oppure provengono da articoli diversi sullo stesso fatto di cronaca, che il controllo, basato su documenti identici, non riconosce come collegati; sono poche, ma la sovrapposizione fra articoli diversi sulla stessa notizia non è controllata. Resta un aspetto che non è possibile verificare: se i dataset

pubblici usati qui facessero parte dei dati di pre-training di Qwen2.5. È un limite comune alla maggior parte dei lavori su benchmark pubblici.

Capitolo 6

Impostazione sperimentale

Questo capitolo presenta i modelli addestrati, i sistemi con cui vengono confrontati, le metriche, il protocollo statistico e il modo in cui sono misurati tempo ed energia. Tutti gli esperimenti si svolgono su un'unica macchina: un MacBook Pro con chip Apple M4 e 16 GB di memoria unificata, con CPU e GPU a 10 core ciascuna e una banda di memoria di 120 GB/s [45]. Ogni risultato riflette così ciò che un verificatore può fare sullo stesso dispositivo su cui gira un assistente locale. Anche tutte le baseline, compresi gli encoder e i due decision model generalisti, sono eseguite su questo portatile, e nessun risultato dipende da un servizio remoto.

6.1 Modelli

Entrambi i modelli GroundOne partono dalla versione di Qwen2.5 addestrata a seguire istruzioni (instruction-tuned) [23], convertita in MLX con pesi a 8 bit, e sono addestrati con la procedura descritta nella Sezione 4.3. I due modelli differiscono per la dimensione, per il numero di risposte di addestramento, per la composizione dei micro-batch, che dipende dalla memoria disponibile, per il warm-up del learning rate (il 3 % dei passi per il 0.5B, il 5 % per il 3B) e per la frequenza con cui vengono valutati durante l'addestramento e la quota di dev set usata.

Il modello 0.5B è addestrato sull'intero training set di 13,203 risposte. Un'epoca di 802 passi di ottimizzazione ha richiesto 5.5 ore di tempo wall-clock[1] e ha occupato al massimo 2.6 GB di memoria; ogni 150 passi il modello è stato valutato sull'intero dev set. Il modello 3B, invece, è circa quattro volte e mezzo più lento in addestramento, misurato in token all'ora. Per questo viene addestrato nell'arco di

[1]Il tempo *wall-clock* è il tempo reale trascorso dall'inizio alla fine di un'operazione, come lo misurerebbe un orologio, attese comprese. Si distingue dal tempo di CPU, che conta soltanto il tempo in cui il processore lavora effettivamente.

una notte su un sottoinsieme casuale di 6,500 risposte, pari a circa 45,000 decisioni: 403 passi in 12.25 ore, con un picco di 5.9 GB. Una valutazione completa sul dev set richiederebbe circa un'ora, quindi il 3B viene valutato ogni 80 passi su un sottoinsieme fisso di 200 risposte. In entrambi i casi si conserva il checkpoint con la balanced accuracy a tre classi più alta sul dev set, che viene poi calibrato come descritto nella Sezione 4.4; per il 3B si tratta del passo 320.

Il seed determina l'inizializzazione degli adapter e l'ordine dei batch, ed è noto che l'esito del fine-tuning varia con entrambi questi fattori [97]. Per stimare quanto i risultati dipendano dal seed, la procedura del 0.5B viene quindi ripetuta con un secondo seed. Questa seconda esecuzione è stata portata a termine ed è valutata su tutti e tre i test set esattamente come la prima. Un'ulteriore esecuzione con un terzo seed, invece, è collassata presto su una predizione costante ed è stata interrotta al passo 450 di 801, il 56 % dell'epoca. Essendo incompleta, è esclusa dalle tabelle e viene discussa nella Sezione 7.2.

6.2 Baseline

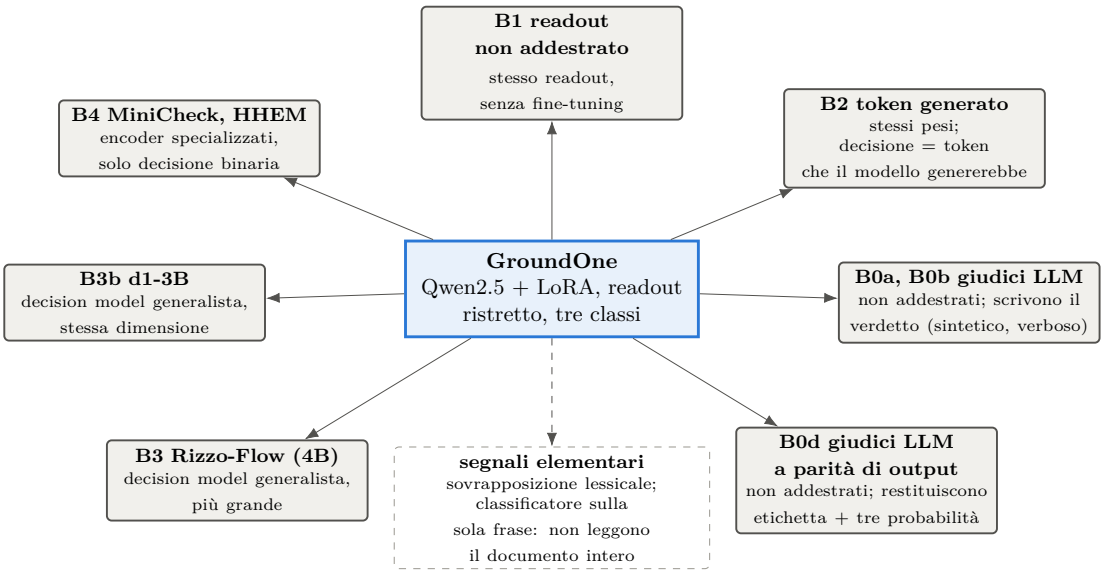
Le baseline servono a isolare l'origine di un eventuale vantaggio di GroundOne, e ciascuna risponde a una domanda precisa. La Figura 6.1 riassume che cosa ciascuna baseline cambia rispetto a GroundOne.

Segnali che non leggono mai il documento nella sua interezza. Due predittori elementari fissano il livello minimo che qualsiasi verificatore deve superare. Il primo assegna a una frase un punteggio pari alla frazione delle sue parole di contenuto che compaiono anche nel documento. Il secondo è un classificatore bag-of-words[2] addestrato sulle sole frasi del training set, senza il documento. Entrambi sono descritti nella Sezione 5.6.

Readout senza addestramento (B1). Agli stessi modelli Qwen2.5, senza fine-tuning, si pone per ogni frase la domanda a tre classi, e si leggono i logit delle lettere di risposta. Un modello non addestrato non ha alcun motivo di interpretare il marker `Verdict:` come una domanda. Per questo la baseline adotta il formato con una domanda esplicita per ogni frase (Sezione 4.2). In questo modo misura ciò che il meccanismo del decision model offre prima di qualunque specializzazione.

Giudici LLM (B0a, B0b). I modelli non addestrati sono impiegati anche nel modo più diffuso nella pratica, cioè come giudici LLM. Ricevono il documento, la

[2]Un classificatore *bag-of-words* rappresenta un testo con le parole, o le brevi sequenze di parole, che contiene e con le loro frequenze, ignorandone l'ordine.



ogni baseline isola un aspetto: l'addestramento (B1), il readout (B2), la generazione del verdetto (B0a, B0b, B0d), la specializzazione (B3, B3b), l'architettura (B4) e il ruolo del documento (segnali elementari)

Figura 6.1: Mappa delle baseline. Ciascuna differisce da GroundOne per un aspetto preciso e risponde quindi a una domanda diversa: quanto conta l'addestramento (B1), quanto il readout ristretto rispetto al token generato (B2), quanto il modo di produrre il verdetto (giudici LLM B0a, B0b, B0d), quanto la specializzazione rispetto a un decision model generalista (B3, B3b), quanto l'architettura (encoder B4) e quanto basta senza leggere il documento (segnali elementari).

risposta numerata e l'elenco delle frasi da verificare, e scrivono un verdetto per ogni frase con greedy decoding[3]. Il giudice LLM *sintetico* produce una riga "`<number>: <letter>`" per frase. Il giudice LLM *verboso*, invece, scrive per ogni frase una breve motivazione seguita dal verdetto. Quando un verdetto non può essere interpretato, si ha un errore di formato: nel calcolo dell'accuratezza viene contato come errore, e viene inoltre riportato a parte.

Giudici LLM a parità di output (B0d). I giudici LLM sintetico e verboso restituiscono meno di GroundOne: una lettera per frase e nessuna probabilità. Non consentono quindi né la calibrazione, né una soglia regolabile, né la scelta di una policy di decisione. Per questo a due ulteriori giudici LLM si chiede esattamente ciò che produce GroundOne, cioè un'etichetta e tre probabilità per frase. Il primo

[3]Nel *greedy decoding* il modello sceglie a ogni passo il token più probabile, senza campionamento: a parità di input, quindi, l'output è sempre lo stesso.

scrive etichetta e probabilità in un oggetto JSON, esprimendo le probabilità come testo: è quanto uno sviluppatore otterrebbe con il solo prompt. Il secondo è il giudice LLM sintetico, le cui tre probabilità sono lette dai logit nella posizione della lettera che genera. Ottiene così lo stesso contenuto al costo del giudice LLM sintetico, ed è l'avversario generativo più forte. Entrambi sono calibrati con la stessa trasformazione usata per GroundOne, una temperatura e un bias, stimati per ciascun giudice LLM su 200 risposte del dev set: in questo modo le loro probabilità ricevono lo stesso trattamento. Il prompt JSON è stato scelto su dodici risposte del dev set, badando unicamente alla validità del formato. I modelli copiavano alla lettera un esempio numerico presente nel prompt, che è stato perciò sostituito da segnaposto. Il parsing è permissivo, a vantaggio dei giudici LLM: di un oggetto troncato si conservano le voci complete, e un'etichetta mancante si ricava dalle probabilità. Il decoding, infine, non è vincolato da una grammatica [88], così che il protocollo resti quello degli altri giudici LLM. Questa scelta pesa soprattutto sugli errori di formato del modello più piccolo.

Readout e generazione a confronto (B2). I modelli GroundOne addestrati sono eseguiti con lo stesso prompt e lo stesso singolo forward pass, ma con una diversa regola di decisione. Il verdetto a ogni marker non è scelto fra le sole tre lettere, ma è il token con la probabilità più alta sull'intero vocabolario, cioè quello che produrrebbe la generazione greedy di un solo token. Le tre lettere, con o senza spazio iniziale, corrispondono alle tre classi, e qualunque altro token è un errore di formato. Questo controllo lascia invariati pesi, prompt e costo, e cambia soltanto un aspetto: se la decisione sia ristretta o meno alle opzioni ammissibili.

Un decision model generalista: Rizzo-Flow (B3). Il progetto open Rizzo-Flow [16] realizza l'idea del decision model con un modello da 4B parametri, sottoposto a fine-tuning su decisioni tipizzate generiche. Gira in un proprio server, basato su llama.cpp [2], e viene interrogato via HTTP. Il documento e la risposta numerata gli vengono passati come stato condiviso, cioè come contesto comune a tutte le domande, insieme a una domanda a scelta fra tre opzioni per ogni frase. Si usa il modello quantizzato a 4 bit, perché quello a 8 bit non entra in memoria insieme al sistema operativo.

Un decision model generalista della stessa dimensione: d1-3B (B3b). d1-3B di Liquid AI [18] è un decision model open da 3.1B parametri, post-addestrato per decisioni tipizzate su un'ampia varietà di task. Legge la decisione da lettere di risposta ristrette e condivide lo stato tra le domande. Appartiene quindi alla stessa famiglia di readout di GroundOne e ha la dimensione del suo modello più grande, ma, a differenza di GroundOne, è generalista. Il confronto con d1-3B isola così il valore della specializzazione rispetto a un decision model già addestrato a decidere,

anziché rispetto a un modello non addestrato. Il modello viene eseguito zero-shot con il proprio codice di inferenza, in PyTorch sulla GPU del portatile e senza accesso alla rete. Riceve lo stesso stato e le stesse domande di Rizzo-Flow, con al più sei domande per chiamata sullo stesso stato. Su LLM-AggreFact i documenti più lunghi di 1,500 token vengono divisi, per d1-3B come per GroundOne, in frammenti di 1,500 token sovrapposti per 200, e per ogni frase si conserva la probabilità di supporto più alta fra i frammenti. Ai fini della riproducibilità conta un dettaglio pratico. Sulla GPU Apple, PyTorch conserva i kernel compilati, cioè i programmi eseguiti dalla GPU, per ogni nuova lunghezza di input, e non ne rilascia mai la memoria. Per questo la valutazione si svolge in processi worker che vengono riavviati quando la memoria occupata dal driver della GPU supera 11 GB; i riavvii non hanno alcun effetto sugli output.

Encoder specializzati (B4). MiniCheck-RoBERTa [12] e HHEM-2.1-open [13] sono due fra i più forti verificatori open di piccole dimensioni. Valutano ogni coppia (documento, frase) in modo indipendente e restituiscono un'unica probabilità di supporto. Come in MiniCheck, i documenti lunghi vengono suddivisi in frammenti di circa 400 parole, e per ogni frase si conserva la probabilità di supporto più alta fra i frammenti. Gli encoder non hanno un output a tre classi, quindi sono confrontati soltanto sulla decisione binaria. Girano in PyTorch sulla GPU del portatile.

Risultati pubblicati. Per LLM-AggreFact si riportano anche i punteggi di sistemi più grandi presenti nella leaderboard pubblica, come Qwen2.5-7B usato zero-shot. Questi punteggi sono ripresi così come pubblicati, senza rieseguire i sistemi.

I sistemi più lenti sono valutati su sottocampioni dei test set, per lo più stratificati[4]. Rizzo-Flow è valutato su 300 risposte di T1, 600 coppie di T3 e 1,100 elementi di T2, di cui ne ha valutati 1,093, perché sette eccedevano il suo contesto. Il modello d1-3B è valutato su un sottocampione di 4,000 elementi di T2, estratti a caso all'interno di ciascuna etichetta, il 3B non addestrato su 600 risposte di T1 e i giudici LLM sulle 200 risposte del protocollo di latenza descritto più avanti. Sono invece valutati sui test set completi GroundOne, MiniCheck-RoBERTa e, su T1 e T3, il 0.5B non addestrato, HHEM e d1-3B; il 3B non addestrato è valutato anche sull'intero T3. Ogni confronto con un sistema sottocampionato è condotto sugli elementi valutati da entrambi i sistemi.

[4]Un sottocampione è *stratificato* quando viene estratto separatamente da ciascun sottogruppo (strato) dell'insieme di partenza, con un numero di elementi fissato per ogni strato, invece che dall'insieme intero in modo puramente casuale.

6.3 Metriche

La quota di frasi allucinate è diversa nel dev set e in T1 (Sezione 5.6), quindi le metriche primarie sono scelte in modo da non dipendere dal tasso di base delle classi. Per la decisione a tre classi la metrica principale è la balanced accuracy, cioè la recall media sulle tre classi. Accanto a essa si riportano la recall di ciascuna classe e la frazione di predizioni assegnate a ciascuna classe, che rivela un modello collassato su un'unica risposta. Per la decisione binaria si riportano due metriche: la balanced accuracy con soglia 0.5, come nella leaderboard di LLM-AggreFact, e l'AUROC di $P(\text{supported})$, che non dipende da alcuna soglia. La calibrazione è misurata con l'ECE definito nella Sezione 4.4, con il Brier score e con la negative log-likelihood. La selective prediction è misurata con le curve risk–coverage e con l'AURC (Sezione 4.4) [96]. Tutte le metriche su T1 sono riportate anche per task e per fascia di K.

6.4 Protocollo statistico

Ogni differenza tra due sistemi è accompagnata da un intervallo di confidenza al 95 %, ottenuto con un paired bootstrap con $B = 2{,}000$ resampling [117, 118, 119]. Il bootstrap ricalcola la differenza su molti campioni estratti con reimmissione dal test set, e la dispersione dei valori ottenuti ne misura l'incertezza. L'unità di resampling, però, non è la frase, ma il gruppo impiegato nel controllo del leakage: il documento sorgente in RAGTruth, il documento in LLM-AggreFact e la pagina di Wikipedia in VitaminC. Le frasi di una stessa risposta, e le risposte relative a uno stesso documento, sono infatti fortemente correlate, e ricampionarle in modo indipendente porterebbe a intervalli troppo stretti. Su LLM-AggreFact i gruppi sono ricampionati all'interno di ciascuno degli undici dataset, perché la media macro assegna a ogni dataset lo stesso peso. Il bootstrap è *paired* perché i due sistemi di un confronto sono valutati sugli stessi resampling. Il p-value riportato è bilaterale: è il doppio della quota di resampling in cui la differenza ha segno opposto a quello osservato, con un minimo di $1/B$, dove B è il numero di resampling. La Figura 6.2 schematizza la procedura.

Due limiti del protocollo vanno dichiarati in anticipo. Il primo è che si eseguono una settantina di confronti senza alcuna correzione per confronti multipli[5]. Per questo le conclusioni si fondano su intervalli ben lontani dallo zero, e nessuna differenza con un p-value prossimo a 0.05 viene considerata acquisita. Il secondo è

[5]Quando si eseguono molti test statistici, cresce la probabilità che alcune differenze risultino significative per puro caso. Le correzioni per confronti multipli, come quella di Bonferroni, compensano questo effetto rendendo più severa la soglia di ciascun test.

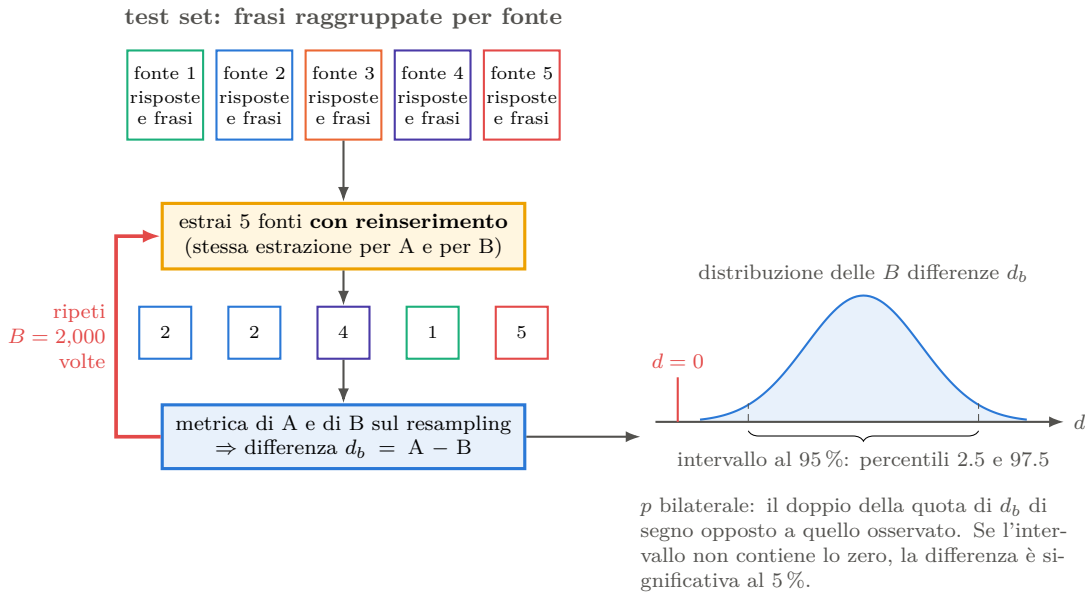


Figura 6.2: Bootstrap appaiato a cluster. Le frasi del test set sono raggruppate per gruppo di leakage (fonte, documento o pagina); a ogni ripetizione si estraggono i gruppi con reimmissione, si calcola la metrica dei due sistemi sulle stesse fonti estratte e se ne registra la differenza. Dopo $B = 2{,}000$ ripetizioni, i percentili 2.5 e 97.5 delle differenze danno l'intervallo al 95 %, e il doppio della quota di differenze di segno opposto a quello osservato dà il p-value bilaterale.

che il resampling dei dati non coglie la variabilità dovuta all'addestramento, che le due esecuzioni del 0.5B documentano a parte (Sezione 7.2).

6.5 Latenza, energia e hardware

La latenza è misurata su 200 risposte di T1, 50 per ciascuna fascia di K, così che le risposte lunghe siano rappresentate quanto quelle brevi. GroundOne, il readout con una domanda per frase e tutti i giudici LLM girano in-process su MLX, cioè all'interno dello stesso processo che li invoca, e verificano una risposta alla volta, come farebbe un verificatore integrato in un assistente locale. Le prime tre risposte vengono prima eseguite una volta come warm-up, non cronometrato; poi tutte le 200 risposte vengono cronometrate. Per GroundOne e per il readout con una domanda per frase ogni risposta è cronometrata tre volte e si conserva la mediana. I giudici LLM generativi, invece, sono cronometrati una sola volta, perché il greedy decoding è deterministico e ogni esecuzione dura molto di più. Il tempo riportato è il tempo wall-clock della chiamata al modello per una risposta, e da esso si ricava

il tempo per decisione. Il Capitolo 7 ripete questa misura, sulle stesse risposte, in tre varianti descritte dove se ne riportano i risultati (Sezione 7.9.1): con la lettura del testo separata dalla decisione, con una parte del prompt già nella KV cache, la stessa per GroundOne e per i giudici LLM, e con una frase della risposta modificata dopo una prima verifica. La lettura anticipata dell'applicazione è misurata in Swift sulle stesse risposte (Sezione 8.6).

I tempi sono stati registrati anche per gli encoder, per Rizzo-Flow e per d1-3B, ma in condizioni che non permettono un confronto equo. Gli encoder giravano in PyTorch e valutavano ogni frase separatamente, rileggendo ogni volta il documento, il che li penalizza. Rizzo-Flow girava in un altro motore di inferenza, con pesi a 4 bit e dietro un'interfaccia HTTP. Il modello d1-3B, infine, girava in PyTorch con il proprio codice e con i riavvii dei worker descritti sopra. Per questi sistemi, quindi, non si trae alcuna conclusione sulla latenza.

L'energia è misurata con `powermetrics`, lo strumento di macOS che riporta ogni 200 millisecondi la potenza assorbita da CPU, GPU e Neural Engine, la NPU dei processori Apple. Per ciascun sistema si misura dapprima, per 60 secondi, la potenza a riposo con il modello già caricato. Si verificano poi, una sola volta, 100 risposte del sottoinsieme di latenza, 25 per fascia di K. L'energia di una verifica è la potenza media durante l'esecuzione, al netto della potenza a riposo, moltiplicata per la durata dell'esecuzione e divisa per il numero di risposte. La misura comprende le unità di calcolo del chip, ma non la memoria, lo schermo o l'archiviazione. È stata effettuata di notte, con la macchina altrimenti inattiva, e soltanto senza cache.

Tre misure riguardano direttamente la località. La prima verifica l'indipendenza dalla rete: una valutazione completa di T1 viene ripetuta con le librerie in modalità offline e all'interno di una sandbox di macOS che nega al processo qualsiasi accesso alla rete, e le sue predizioni vengono confrontate con quelle dell'esecuzione originale. La seconda misura l'effetto della quantizzazione: lo stesso adapter del modello 0.5B viene applicato ai pesi originali a 16 bit (bf16) e valutato su T1 e T3. La terza misura la co-residenza: in un unico processo vengono caricati il generatore dell'applicazione dimostrativa (Capitolo 8), Qwen2.5-3B-Instruct quantizzato a 4 bit, e un verificatore GroundOne; per 30 documenti di T1, dieci per task, il generatore scrive una risposta di al più 300 token e GroundOne la verifica. Si registrano il picco di memoria allocata da MLX e i tempi di generazione e di verifica. Il documento è fornito direttamente, come in RAGTruth, per cui il retriever non è incluso. Anche queste misure girano interamente nella sandbox priva di rete.

A parte la misura di co-residenza, in ogni esperimento è in esecuzione un solo modello alla volta, e una guardia di memoria (memory guard) sorveglia ogni job lungo, registrando per tutta la sua durata la memoria libera e lo swap. I risultati vengono scritti una sola volta e mai sovrascritti, e ogni esecuzione conserva la propria configurazione. In questo modo ogni numero del Capitolo 7 può essere

ricondotto all'esecuzione che lo ha prodotto.

6.6 Licenze e condizioni d'uso

L'indipendenza che la tesi persegue riguarda anche il piano giuridico: un verificatore locale serve a poco se uno dei suoi componenti può essere usato soltanto attraverso un servizio esterno o con una licenza a pagamento. La Tabella 6.1 riporta la licenza di ogni modello, dataset e componente software usato nella tesi, verificata sulla pagina ufficiale di ciascuno.

Ne derivano tre conseguenze. La prima è che tutti i componenti si possono scaricare ed eseguire in locale con licenze che ne consentono l'uso per ricerca, senza dipendere da alcun servizio remoto: l'indipendenza della soluzione vale anche sul piano delle licenze. La seconda riguarda il riuso dei modelli addestrati. L'adapter di GroundOne 0.5B si applica a una base rilasciata con licenza Apache 2.0, mentre quello di GroundOne 3B si applica a una base con licenza di ricerca, che ne limita l'uso a ricerca e valutazione; lo stesso vale per il generatore dell'applicazione del Capitolo 8. Un impiego commerciale richiederebbe quindi il modello 0.5B oppure una base con licenza permissiva. La terza riguarda i dati di addestramento: le annotazioni di RAGTruth sono rilasciate con licenza MIT, ma i contesti su cui sono state scritte provengono in parte da fonti destinate alla ricerca non commerciale o a un uso educativo. Anche per questo gli adapter addestrati vanno considerati artefatti di ricerca; una valutazione giuridica del loro uso commerciale esula dagli scopi di questa tesi. LLM-AggreFact, infine, è usato soltanto come test set, nel rispetto della sua condizione di accesso (Sezione 5.2).

Tabella 6.1: Licenze dei componenti usati nella tesi, verificate sulle pagine ufficiali il 22 ottobre 2026. Le versioni quantizzate in formato MLX ereditano la licenza del modello originale.

Componente e ruolo	Licenza	Condizioni rilevanti
Modelli		
Qwen2.5-0.5B-Instruct: base di GroundOne 0.5B	Apache 2.0	Uso libero, anche commerciale, con attribuzione.
Qwen2.5-3B-Instruct: base di GroundOne 3B e generatore dell'applicazione	Qwen Research License [120]	Solo ricerca e valutazione; l'uso commerciale richiede una licenza di Alibaba Cloud.
MiniCheck-RoBERTa-Large (B4)	MIT	Uso libero.
HHEM-2.1-open (B4)	Apache 2.0	Uso libero, con attribuzione.
Rizzo-Flow, Spark-X2.5 4B con LoRA (B3)	Apache 2.0	Uso libero, con attribuzione.
d1-3B (B3b)	LFM Open License 1.0 [121]	Uso commerciale consentito sotto i 10 milioni di dollari di fatturato annuo.
bge-small-en-v1.5: modello di embedding dell'applicazione	MIT	Uso libero.
Dati		
Annotazioni di RAGTruth	MIT	I contesti provengono da MS MARCO, riservato alla ricerca non commerciale [122], da articoli di cronaca e dallo Yelp Open Dataset, destinato a un uso educativo [104].
LLM-AggreFact	CC BY-ND 4.0	La condizione di accesso ne consente l'uso come benchmark di valutazione e ne vieta l'uso per l'addestramento [113].
VitaminC	CC BY-SA 3.0	Condivisione con la stessa licenza.
Software		
MLX, mlx-lm, MLX Swift	MIT	Uso libero.
PySBD, llama.cpp	MIT	Uso libero.
PyTorch, Transformers, swift-transformers	BSD, Apache 2.0	Uso libero.

Capitolo 7

Risultati

Questo capitolo riporta i risultati sperimentali. Si parte da come GroundOne apprende il task e da quanto il suo addestramento sia stabile. Seguono i risultati sui tre test set congelati, il confronto con le baseline e il contributo che il readout del decision model dà di per sé. Il capitolo esamina poi la qualità delle probabilità, anche a confronto con giudici LLM che producono lo stesso output, il tempo e l'energia necessari per verificare una risposta, le misure di località (esecuzione offline, quantizzazione e co-residenza) e, infine, gli errori che restano. Gli intervalli, riportati tra parentesi nella forma "da a a b", sono intervalli di confidenza al 95 % ottenuti con un bootstrap a cluster, calcolati come descritto nella Sezione 6.4; per i rapporti di latenza le unità ricampionate sono le risposte. La Figura 7.1 raccoglie in un unico grafico le differenze appaiate discusse nel capitolo.

7.1 Addestramento

Entrambi i modelli hanno appreso il task. Prima dell'addestramento, un modello che riceve il formato con i marker non sa che cosa il marker gli chieda, e i suoi verdetti sono casuali: il 0.5B risponde "contraddetta" per l'88 % delle frasi del dev set e raggiunge una balanced accuracy a tre classi di 0.32. Nelle esecuzioni completate, invece, la loss di addestramento è scesa già nei primi cento passi sotto il valore di un modello che conosca soltanto le frequenze delle classi ($\ln 3 \approx 1.10$), e il punteggio sul dev set è poi cresciuto con regolarità (Figura 7.2).

Il 0.5B è stato addestrato su tutte le 13,203 risposte e ha raggiunto il punteggio migliore al passo 600 di 802, con una balanced accuracy media sui tre task di 0.633; da quel punto in poi il punteggio si è stabilizzato. Il 3B, addestrato per 12.25 ore su 6,500 risposte, ha raggiunto 0.705 al passo 320 di 403, misurato sul proprio sottoinsieme del dev set. Sull'intero dev set la balanced accuracy a tre classi è di

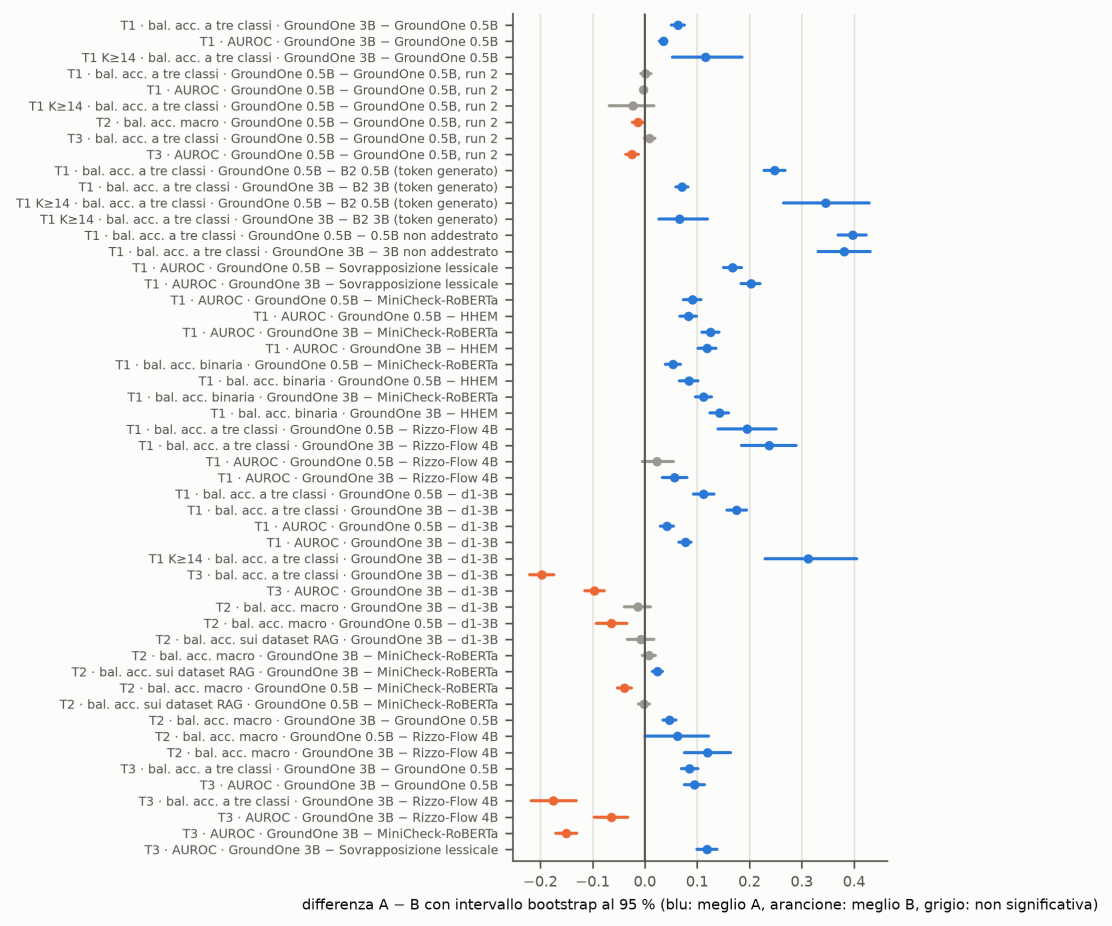


Figura 7.1: Tutte le differenze appaiate tra sistemi sui test set congelati, con l'intervallo bootstrap a cluster al 95 %. Il primo sistema (A) è sempre GroundOne, e nei confronti fra due modelli GroundOne il più grande o la prima esecuzione. In blu le differenze a favore di A, in arancione quelle a favore del secondo sistema (B), in grigio quelle non significative, il cui intervallo contiene lo zero. Sul test set di dominio (T1) quasi tutte le differenze favoriscono GroundOne, e le più ampie lo separano dallo stesso modello non addestrato e dal token che genererebbe (controllo B2): specializzazione e readout pesano più della dimensione. Su LLM-AggreFact (T2) le differenze si riducono e diverse non sono significative, mentre su VitaminC (T3) il quadro si rovescia a favore di d1-3B, Rizzo-Flow e MiniCheck-RoBERTa. Le righe "run 2" confrontano due addestramenti con la stessa procedura: due differenze sono significative anche lì, ed è per questo che le differenze più piccole della variabilità fra seed non vengono interpretate.

0.731 per il 0.5B e di 0.784 per il 3B. In entrambe le esecuzioni, inoltre, tutte e tre le classi sono rimaste presenti fra le predizioni per tutta la durata dell'addestramento.

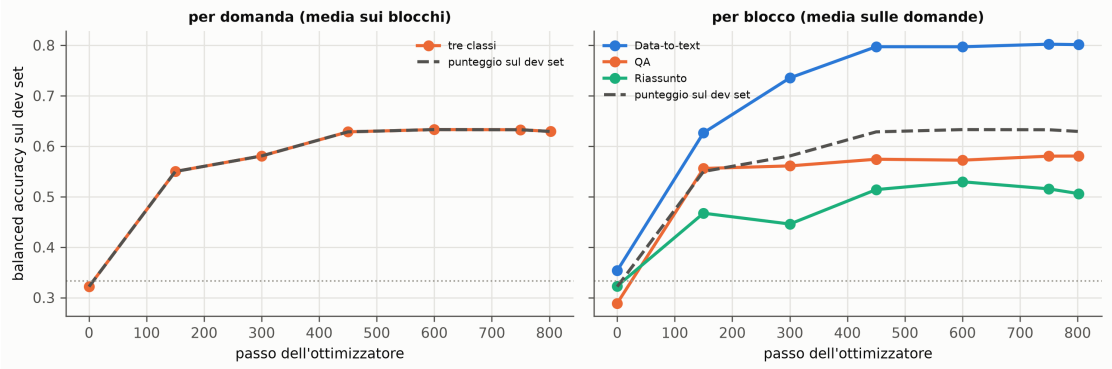


Figura 7.2: Balanced accuracy a tre classi sul dev set durante l'addestramento del modello 0.5B: valore complessivo (a sinistra) e valore per task (a destra). La linea punteggiata indica il livello casuale. Il 3B mostra lo stesso andamento sul proprio sottoinsieme di 200 risposte del dev set.

7.2 Variabilità tra seed

Per capire quanto i risultati dipendano dal seed, la procedura del 0.5B è stata ripetuta con un secondo seed, che cambia l'inizializzazione degli adapter e l'ordine dei batch. Quando l'addestramento converge, converge allo stesso punto (Figura 7.3). Su T1 la seconda esecuzione raggiunge una balanced accuracy a tre classi di 0.767, contro 0.769 della prima, e un AUROC di 0.907 contro 0.905. Su LLM-AggreFact la balanced accuracy media macro è 71.5 contro 70.1, e su VitaminC la balanced accuracy a tre classi è 0.434 contro 0.442. Su T1 la differenza appaiata tra le due esecuzioni, calcolata come prima meno seconda, è +0.001 (da −0.008 a +0.012) e non è significativa.

Le differenze emergono nei dettagli. Anzitutto, gli errori si distribuiscono in modo diverso tra le classi: la recall delle frasi supportate e quella delle frasi non menzionate si spostano di circa 0.04, in direzioni opposte. Inoltre, le porzioni più piccole dei dati oscillano di più. La balanced accuracy della fascia con quattordici o più decisioni varia di 0.023, l'AUROC su VitaminC di 0.025, e i singoli dataset di LLM-AggreFact variano fino a dieci punti, come WiCE (67.9 contro 78.0).

Da questi risultati seguono due conseguenze. La prima riguarda gli intervalli: il bootstrap ricampiona i dati di test, e quindi non coglie la variabilità dovuta all'addestramento. Su LLM-AggreFact e su VitaminC, infatti, le due esecuzioni della stessa procedura differiscono più di quanto i loro intervalli consentirebbero

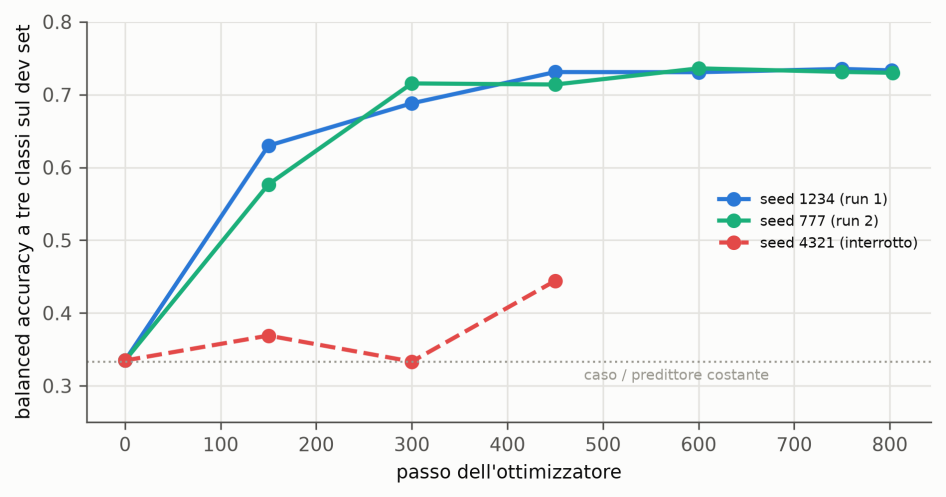


Figura 7.3: Balanced accuracy a tre classi sul dev set durante l'addestramento del modello 0.5B, con la stessa procedura e tre seed diversi. Due esecuzioni convergono allo stesso livello; la terza è collassata su un predittore costante ed è stata interrotta.

(prima meno seconda esecuzione: -1.3 punti sulla media macro di T2, -0.025 sull'AUROC di T3). Per questo non vengono interpretate le differenze tra sistemi inferiori alla dispersione tra seed, cioè a circa 1.3 punti sulla media macro di LLM-AggreFact e a 0.025 di AUROC su VitaminC. Sui singoli dataset di LLM-AggreFact la dispersione è maggiore, fino a dieci punti sui più piccoli come WiCE, e scarti di questa entità fra sistemi vanno letti solo come indicativi.

La seconda conseguenza è che l'addestramento non sempre converge. Un'esecuzione con un terzo seed è rimasta vicina al livello casuale. La sua balanced accuracy a tre classi sul dev set era 0.369 al passo 150 e 0.333 al passo 300, quando il modello prediceva "supportata" per ogni frase, e la loss di addestramento è rimasta prossima a quella di un modello privo di informazione. Al passo 450 era risalita a 0.444, mentre il punteggio di selezione, la media sui task, era ancora 0.364, e l'esecuzione è stata interrotta lì, al passo 450 di 801. Non è quindi possibile sapere se si sarebbe ripresa entro la fine dell'epoca e, poiché incompleta, è esclusa dalle tabelle. La procedura ha due caratteristiche note per rendere fragile il fine-tuning: non applica gradient clipping [99], e l'ottimizzatore lavora senza bias correction. L'assenza della bias correction è l'impostazione predefinita del framework ed è stata indicata come una delle cause principali dei fine-tuning non riusciti [98]. Un solo collasso su tre esecuzioni non basta a stimare un tasso di fallimento, ma mostra che la procedura non è del tutto robusta rispetto all'inizializzazione.

7.3 Accuratezza sul test set RAG (T1)

Sulle 17,284 frasi di T1 il modello 0.5B raggiunge una balanced accuracy a tre classi di 0.769 e il 3B di 0.832 (Tabella 7.1). La differenza tra i due, +0.063 (da +0.051 a +0.076), è l'effetto più netto della dimensione del modello. Sulla decisione binaria il 0.5B ottiene una balanced accuracy di 0.815 e un AUROC di 0.905, mentre il 3B ottiene rispettivamente 0.874 e 0.940. Entrambi superano di gran lunga gli indizi elementari che non leggono mai il documento nel suo insieme: la sovrapposizione lessicale arriva a un AUROC di 0.737, e il classificatore che vede soltanto la frase arriva a una balanced accuracy a tre classi di 0.570.

Tabella 7.1: GroundOne su T1, sull'intero test set, per task e per numero di decisioni per risposta (K). Per ciascun modello sono riportate la balanced accuracy a tre classi, la recall delle frasi contraddette e l'AUROC di P(supported). *Valore indicativo: la cella contiene al più 30 frasi contraddette.

		GroundOne 0.5B			GroundOne 3B		
Sottoinsieme	Frasi	Bal. acc.	Contr.	AUROC	Bal. acc.	Contr.	AUROC
Tutte	17,284	0.769	0.68	0.905	0.832	0.76	0.940
Question answering	4,876	0.589	0.03*	0.916	0.699	0.30*	0.948
Summarization	4,538	0.544	0.13	0.775	0.629	0.30	0.873
Data-to-text	7,870	0.812	0.84	0.929	0.873	0.90	0.955
$K = 1$–4	2,434	0.606	0.18	0.857	0.677	0.25	0.921
$K = 5$–8	8,012	0.758	0.67	0.899	0.829	0.78	0.936
$K = 9$–13	5,201	0.824	0.82	0.926	0.863	0.86	0.945
$K \geq 14$	1,637	0.723	0.50*	0.908	0.839	0.68*	0.957

Dalla tabella emergono tre aspetti. Il primo è che l'accuratezza non crolla con la lunghezza della risposta. Le risposte con quattordici o più decisioni raggiungono una balanced accuracy di 0.839 con il 3B, tra le migliori, e di 0.723 con il 0.5B, leggermente al di sotto delle fasce intermedie. La fascia più difficile è invece quella delle risposte più brevi, che comprende soprattutto risposte di question answering e di summarization. Il dato è importante perché è proprio sulle risposte lunghe che un decision model fa risparmiare più tempo; su queste risposte il 3B guadagna sul 0.5B +0.116 (da +0.053 a +0.186).

Il secondo aspetto è che le contraddizioni vengono riconosciute soprattutto nel data-to-text, il task in cui RAGTruth le concentra. Nel question answering e nella summarization il 0.5B distingue bene le frasi supportate da quelle non menzionate, ma non individua quasi nessuna contraddizione: la recall delle frasi contraddette è 0.03 e 0.13, e il primo valore è solo indicativo, perché nel question answering le frasi contraddette sono soltanto 30. Il 3B la porta a 0.30 in entrambi i task, quindi

la dimensione del modello compensa in parte la scarsità di questi esempi nei dati di addestramento. Il terzo aspetto è che question answering e summarization offrono la prova più chiara che i modelli leggono davvero il documento. In questi due task il classificatore che vede soltanto la frase resta al livello casuale (0.36 e 0.35), mentre i due modelli raggiungono 0.59–0.70 nel question answering e 0.54–0.63 nella summarization.

Le stesse predizioni si possono valutare anche a livello di risposta intera. È il criterio con cui il Decision Index della comunità valuta i decision model generalisti su RAGTruth: una risposta è allucinata se contiene un qualsiasi contenuto non supportato, e la metrica è l'F1 di questa classe. Un sistema che risponda sempre "allucinata" raggiunge già un F1 di 0.52 [22]. Per giudicare una risposta, GroundOne prende il minimo della $P(\text{supported})$ calibrata sulle sue frasi e lo confronta con una soglia stimata sul dev set. Con questa regola, sulle 2,647 risposte di T1 raggiunge un F1 di 0.733 con il 0.5B e di 0.784 con il 3B. Nella leaderboard, invece, nessun decision model generalista sotto il miliardo di parametri supera 0.553, Jev raggiunge 0.765 e il modello migliore, da 27B parametri, 0.803. Il confronto è solo indicativo, perché GroundOne è stato addestrato su RAGTruth, mentre i modelli della leaderboard sono valutati zero-shot, con un prompt diverso e su 53 risposte in più. Colloca comunque uno specialista da 0.5B molto al di sopra dei decision model generalisti della stessa dimensione.

7.4 Confronto con le baseline

La Figura 7.5 mette a confronto tutti i sistemi su T1. Gli encoder specializzati raggiungono un AUROC di 0.814 (MiniCheck-RoBERTa) e di 0.821 (HHEM): più della sovrapposizione lessicale, ma meno di entrambi i modelli GroundOne. Il 0.5B supera MiniCheck-RoBERTa di +0.091 (da +0.074 a +0.108) e HHEM di +0.083 (da +0.067 a +0.099); il 3B li supera rispettivamente di +0.126 e +0.119. Il confronto per task, però, ridimensiona questo risultato. Il vantaggio di GroundOne viene in gran parte dal data-to-text, dove lo avvantaggiano l'addestramento nel dominio e la struttura ricorrente dei template, e dove gli encoder sono più deboli (AUROC 0.71–0.75). Nella summarization, invece, MiniCheck-RoBERTa supera il modello 0.5B (0.872 contro 0.775) ed è alla pari con il 3B (0.873). La Figura 7.4 riporta l'AUROC per task di tutti i sistemi.

I modelli non addestrati mostrano quanta parte dell'accuratezza si debba all'addestramento. Il 0.5B non addestrato è al livello casuale, con una balanced accuracy a tre classi di 0.372, perché non risponde mai "supportata". Il 3B non addestrato, a cui si pone la stessa domanda, raggiunge una balanced accuracy a tre classi di 0.437, contro 0.818 dello stesso modello dopo l'addestramento, sulle

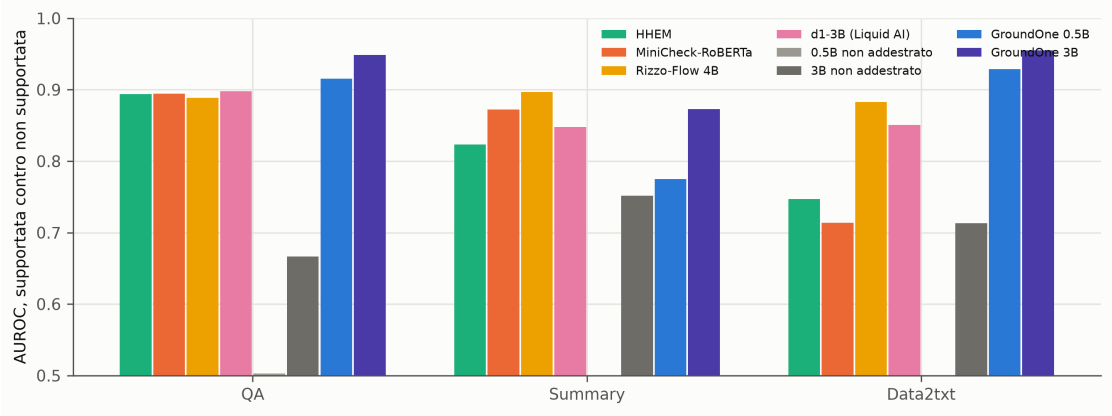


Figura 7.4: AUROC di $P(\text{supported})$ su T1 per task (question answering, summarization, data-to-text) e per sistema. Il vantaggio di GroundOne si concentra nel data-to-text; nella summarization MiniCheck-RoBERTa supera il 0.5B ed è alla pari con il 3B.

stesse risposte. Il contributo del readout ristretto, al di là dell'addestramento, è misurato separatamente nella Sezione 7.6.

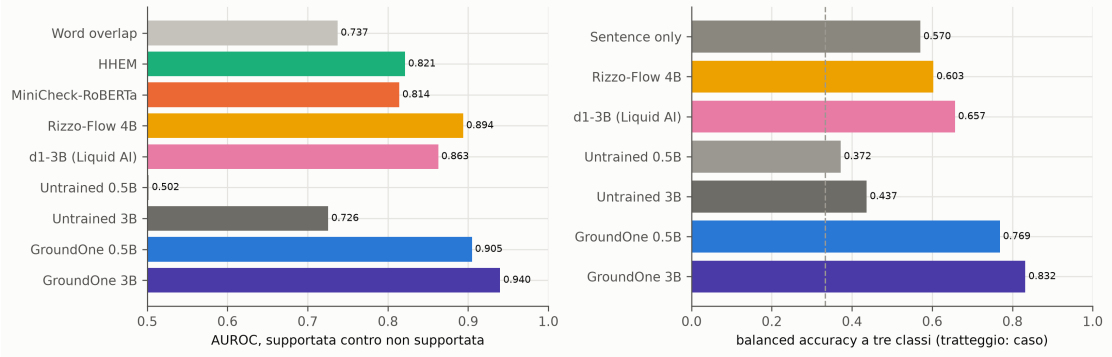


Figura 7.5: T1: AUROC di $P(\text{supported})$ per ogni sistema (a sinistra) e balanced accuracy a tre classi per i sistemi che hanno un output a tre classi (a destra). Rizzo-Flow è valutato su 300 risposte e il 3B non addestrato su 600; tutti gli altri sistemi, compreso d1-3B, sono valutati sull'intero test set.

Il confronto più istruttivo è quello con Rizzo-Flow, il decision model generalista più grande: un modello da 4B sottoposto a fine-tuning per decisioni generiche. Sulle stesse 300 risposte di T1, Rizzo-Flow raggiunge una balanced accuracy a tre classi di 0.603, contro 0.798 del GroundOne 0.5B e 0.840 del 3B. Le differenze sono ampie: +0.195 (da +0.140 a +0.251) per il 0.5B e +0.237 (da +0.184 a +0.289) per il 3B. In AUROC, invece, Rizzo-Flow (0.894) è vicino al 0.5B, che su queste

risposte ottiene 0.916, e la differenza non è significativa. Rizzo-Flow, infatti, ordina bene le frasi, ma predice "supportata" per il 90 % di esse. Il 3B le ordina meglio di Rizzo-Flow (+0.056, da +0.034 a +0.081). Uno specialista otto volte più piccolo, quindi, supera il generalista nella decisione per cui è stato progettato e lo eguaglia nella capacità di ordinare le frasi.

d1-3B, un decision model generalista della stessa dimensione del 3B, offre la verifica più severa del valore della specializzazione. È infatti già addestrato a prendere decisioni tipizzate, e si differenzia da GroundOne per i dati su cui è stato addestrato, ma anche per il modello base, per il formato del prompt e per il runtime, e non è mai stato addestrato su questo task. Sull'intero T1 raggiunge una balanced accuracy a tre classi di 0.657 e un AUROC di 0.863. Entrambi i modelli GroundOne fanno nettamente meglio. Il 0.5B, sei volte più piccolo, lo supera di +0.112 (da +0.092 a +0.133) in balanced accuracy a tre classi e di +0.042 in AUROC; il 3B lo supera di +0.175 (da +0.157 a +0.195) e di +0.077. Il divario è massimo sulle risposte lunghe: quando la risposta contiene quattordici o più decisioni, d1-3B scende a 0.527, mentre il GroundOne 3B resta a 0.839 (+0.312, da +0.230 a +0.405). Inoltre, d1-3B riconosce soltanto metà delle frasi non menzionate (recall 0.49). Nel dominio delle risposte RAG, dunque, la specializzazione vale molto più di un addestramento generico a prendere decisioni.

Su LLM-AggreFact (T2) il modello 0.5B raggiunge una balanced accuracy media macro di 70.1 sugli undici dataset, contro 64.2 dello stesso modello usato zero-shot (punteggio pubblicato nella leaderboard) e 72.8 del modello 7B zero-shot riportato nella leaderboard pubblica. Resta invece 3.9 punti sotto MiniCheck-RoBERTa (74.0), una differenza significativa. Sui quattro dataset più vicini alla retrieval-augmented generation i due sistemi sono alla pari (74.4 per GroundOne 0.5B, 74.6 per MiniCheck-RoBERTa). Nella colonna di RAGTruth GroundOne è in vantaggio, 82.1 contro 76.5, ma il confronto lo favorisce, perché è stato addestrato sulle risposte del training set di RAGTruth. Al di fuori del RAG, invece, il 0.5B è inferiore all'encoder di sette-nove punti su AggreFact-CNN, AggreFact-XSum, FactCheck-GPT e REVEAL: è il costo atteso di un addestramento sui soli dati RAG.

Il modello 3B, valutato sull'intero test set, colma gran parte di questo divario. La sua balanced accuracy media macro è 74.8: è alla pari con quella di MiniCheck-RoBERTa (74.0; differenza appaiata +0.8 punti, intervallo da −0.5 a +2.0) e superiore al punteggio zero-shot pubblicato per il modello 7B (72.8), per il quale non si può calcolare un intervallo. Sui dataset RAG raggiunge 76.9, 2.4 punti sopra l'encoder (intervallo da +1.4 a +3.4). Il suo guadagno rispetto al 0.5B, +4.7 punti (da +3.4 a +5.9), è diffuso tra i dataset, con i miglioramenti maggiori su REVEAL e FactCheck-GPT, gli unici in cui supera anche la variabilità fra seed: la dimensione del modello migliora quindi il trasferimento al di fuori del dominio di addestramento. Il 3B resta nettamente sotto l'encoder soltanto nella summarization

di notizie (AggreFact-CNN, 59.3 contro 67.1). Rizzo-Flow raggiunge 61.5 sui 1,093 elementi del suo sottocampione, e su questi elementi il GroundOne 3B fa meglio di 12.0 punti (da +7.6 a +16.4).

Su questo benchmark, tuttavia, i sistemi più forti restano sopra GroundOne. Una valutazione indipendente del decision model closed Jev, sullo stesso test set e con la stessa metrica, riporta 78.6, e 76.9 per un modello open da 27B letto attraverso le lettere di risposta. I prompt sono diversi da quelli usati qui, e non è possibile calcolare alcun intervallo [20]. Su un benchmark ampio di groundedness, quindi, uno specialista da 3B addestrato soltanto su risposte RAG eguaglia il miglior encoder di piccole dimensioni, ma resta sotto lo stato dell'arte closed e sotto modelli open molto più grandi. A parità di dimensione, il generalista d1-3B è alla pari con il GroundOne 3B. Su un sottocampione di 4,000 elementi, estratti a caso all'interno di ciascuna etichetta, raggiunge 75.7, contro 74.3 del GroundOne 3B sugli stessi elementi, una differenza non significativa (-1.3, da -4.0 a $+1.0$), mentre supera il 0.5B di 6.5 punti. Sugli stessi elementi d1-3B è più debole del GroundOne 3B nella colonna di RAGTruth (78.9 contro 85.9), più forte su WiCE (84.6 contro 72.1) e su TofuEval-MediaS (84.0 contro 78.5) e più debole su TofuEval-MeetB (71.3 contro 75.1); WiCE e i due insiemi di TofuEval contengono soltanto da 51 a 119 elementi, per cui questi scarti sono solo indicativi.

7.5 Trasferimento a un dominio diverso (T3)

Su VitaminC il quadro si rovescia. Sull'intero test set il 0.5B raggiunge una balanced accuracy a tre classi di 0.442 e il 3B di 0.527, con un AUROC rispettivamente di 0.722 e di 0.817, mentre MiniCheck-RoBERTa arriva a un AUROC di 0.968. Sulle 600 coppie valutate con Rizzo-Flow, il modello generalista ottiene una balanced accuracy a tre classi di 0.712 e un AUROC di 0.909, contro 0.442 e 0.744 del 0.5B e 0.537 e 0.845 del 3B. La Figura 7.6 mostra il confronto completo su T3.

Due fatti aiutano a interpretare questi numeri. Il primo è che MiniCheck-RoBERTa parte dal modello AlignScore, i cui dati di addestramento comprendono VitaminC [11]. Per l'encoder, quindi, T3 appartiene alla distribuzione di addestramento, mentre per GroundOne misura il trasferimento da RAGTruth. Il secondo è che il guadagno del 3B sul 0.5B in T3 si deve alla dimensione del modello più che all'addestramento su dati RAG: il 3B non addestrato raggiunge già 0.531 e un AUROC di 0.821. d1-3B, il decision model generalista della stessa dimensione, rende esplicito il contrasto. Sull'intero T3 raggiunge 0.724 e un AUROC di 0.913, e supera il GroundOne 3B di 0.197 e di 0.096: l'esatto opposto di quanto accade su T1. La specializzazione su risposte RAG migliora quindi in modo sostanziale il task RAG, ma da sola non basta a produrre un fact checker generale. La Sezione 7.12 mostra quali casi sfuggono.

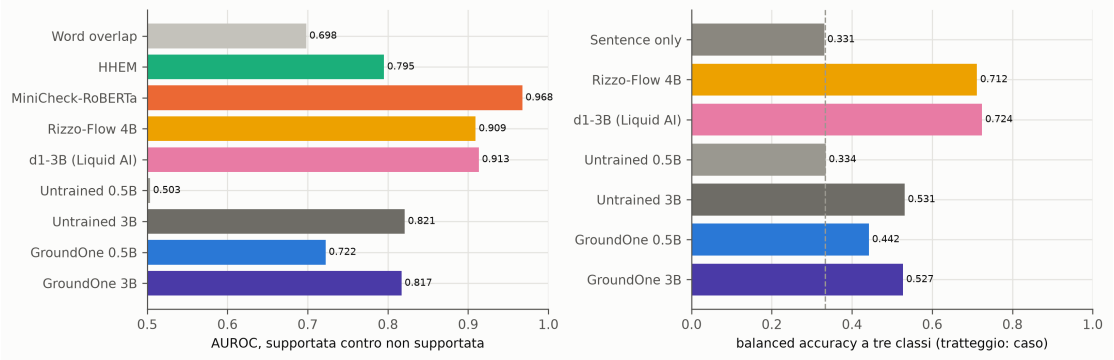


Figura 7.6: Confronto dei sistemi su T3 (VitaminC): a sinistra l'AUROC di $P(\text{supported})$, a destra la balanced accuracy a tre classi per i sistemi con un output a tre classi. Rizzo-Flow è valutato su un sottocampione di 600 coppie; il tratteggio indica il livello casuale. Per MiniCheck-RoBERTa VitaminC fa parte della genealogia dei dati di addestramento.

7.6 Readout e generazione a confronto

Il controllo B2 isola il contributo del readout. Il confronto mantiene invariati i pesi ottenuti con il fine-tuning, il prompt e il singolo forward pass, e cambia soltanto il modo in cui si ricava il verdetto a ogni marker. Il verdetto è letto dalle tre lettere di risposta, come fa GroundOne, oppure è il token che emetterebbe la generazione greedy (Figura 7.7). Per il 0.5B il token generato dà una balanced accuracy a tre classi di 0.521, contro 0.769 del readout, con una differenza di +0.248 (da +0.228 a +0.268) a favore del readout. In un quarto dei marker (24.7 %) il modello non emetterebbe affatto una lettera, ma per lo più un semplice spazio, cioè l'inizio di una risposta più lunga. Per il 3B, invece, il token generato è quasi sempre una lettera (1.2 % di errori di formato) e concorda con il readout nel 92 % dei marker; eppure il readout resta migliore, con 0.832 contro 0.761 (+0.071, da +0.059 a +0.082). Quando la risposta contiene quattordici o più decisioni, il divario è massimo per il modello piccolo: +0.346.

Le due opzioni hanno la stessa latenza, perché entrambe richiedono un solo forward pass: a cambiare è soltanto la regola di decisione. Restringere la scelta alle opzioni ammissibili elimina per costruzione gli errori di formato. Inoltre, poiché il modello è addestrato soltanto a ordinare le tre lettere, la scelta ristretta fornisce anche la decisione più accurata (Sezione 4.2). Questa restrizione conta tanto più quanto più il modello è piccolo. Si ripete spesso che leggere i logit delle risposte e generare un singolo token di risposta siano operazioni equivalenti: per un verificatore sottoposto a fine-tuning l'equivalenza vale per il costo, ma non per l'accuratezza.

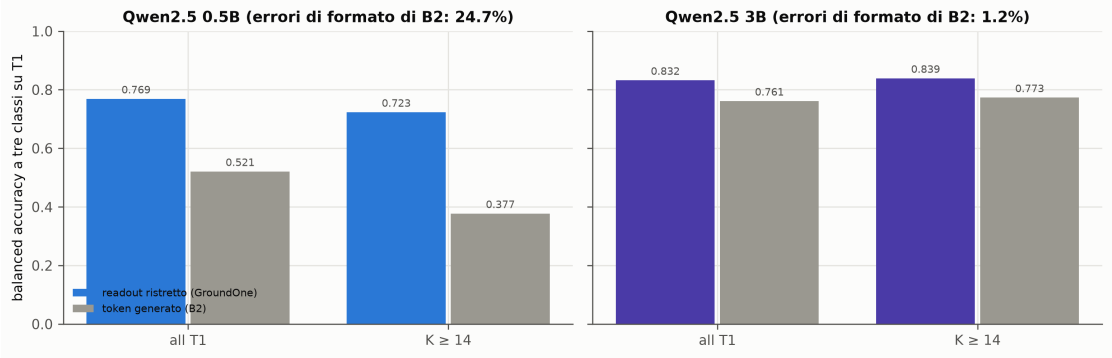


Figura 7.7: Controllo B2 sull'intero T1. Con gli stessi pesi e lo stesso forward pass, il verdetto è letto dalle tre lettere di risposta (GroundOne) oppure preso come il token che emetterebbe la generazione greedy; gli errori di formato sono contati come errori.

7.7 Calibrazione e selective prediction

Prima della calibrazione, le probabilità sottostimano il supporto. Nel reliability diagram (Figura 7.8) la curva delle probabilità grezze giace sopra la diagonale, perché i pesi delle classi addestrano il modello come se le classi fossero bilanciate. L'ECE binario su T1 è 0.30 per il 0.5B e 0.18 per il 3B. La temperatura e il bias stimati sul dev set lo portano a 0.019 per entrambi i modelli, e a 0.020 per la seconda esecuzione del 0.5B. Riducono inoltre la negative log-likelihood da 0.55 a 0.21 per il 0.5B e da 0.36 a 0.17 per il 3B, lasciando l'AUROC praticamente invariato. La mappa stimata sul dev set si trasferisce quindi al test set dello stesso dominio. La Figura 7.9 mostra lo stesso diagramma per il 3B.

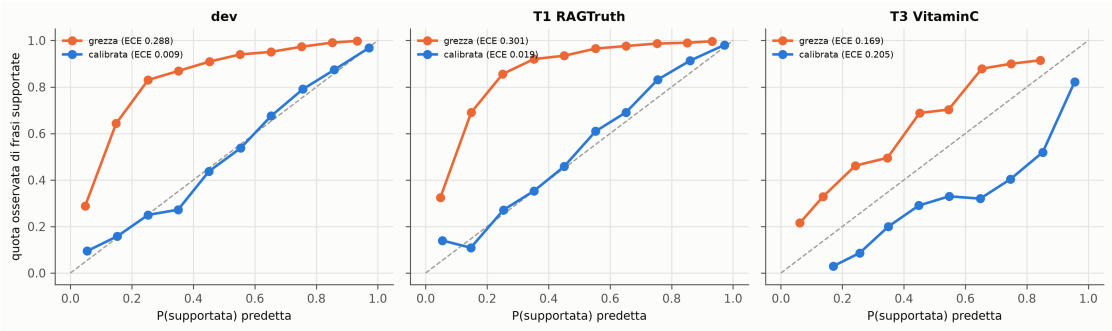


Figura 7.8: Reliability diagram di $P(\text{supported})$ del 0.5B, prima della calibrazione (grezza) e dopo la calibrazione stimata sul dev set, per il dev set, T1 e T3. Ogni punto rappresenta una fascia di probabilità che contiene almeno 20 frasi.

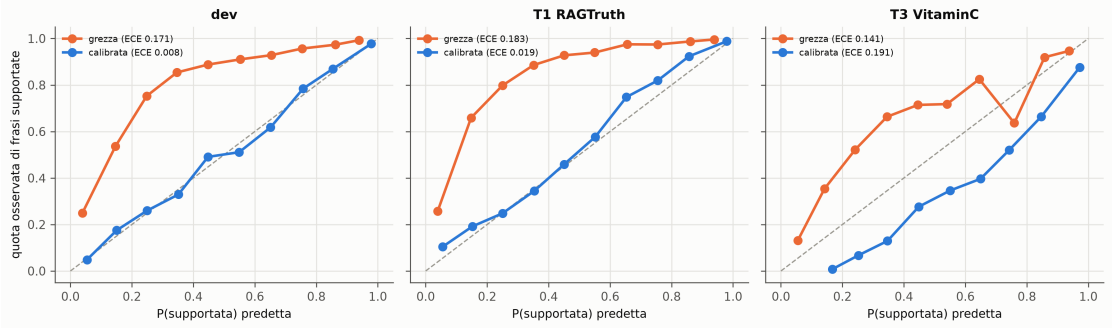


Figura 7.9: Reliability diagram di $P(\text{supported})$ del 3B, prima e dopo la calibrazione stimata sul dev set, per il dev set, T1 e T3; ogni punto è una fascia di probabilità con almeno 20 frasi. Come per il 0.5B, la calibrazione si trasferisce a T1 ma non a T3.

La calibrazione ha però una conseguenza da tenere presente. Il bias ripristina la frequenza reale di ciascuna classe, per cui la classe più probabile dopo la calibrazione diventa più spesso "supportata". Per il 0.5B su T1 l'accuratezza sale così da 0.82 a 0.93, ma la balanced accuracy a tre classi scende da 0.77 a 0.63. Quando i tre tipi di errore hanno lo stesso peso, quindi, scegliere la classe calibrata più probabile non è una buona regola di decisione. La regola con cui vengono restituite le etichette, descritta nella Sezione 4.4, risolve il problema. La regola usa una soglia τ stimata sul dev set, pari a 0.935 per il 0.5B, a 0.895 per la sua seconda esecuzione e a 0.925 per il 3B. Con queste soglie raggiunge su T1 una balanced accuracy a tre classi di 0.758, 0.769 e 0.830, entro circa 0.01 dalla decisione grezza valutata in tutto il capitolo, e mantiene le etichette coerenti con le probabilità calibrate. Le soglie sono alte perché circa l'88 % delle frasi di addestramento e del dev set è supportato: una frase viene restituita come supportata soltanto quando il modello è molto sicuro.

Usate come confidenze, le probabilità calibrate rendono efficace la selective prediction. Rinviare le frasi su cui il modello è meno sicuro riduce rapidamente il tasso di errore della decisione binaria: su T1 l'AURC è 0.015 per il 0.5B e 0.010 per il 3B (Figura 7.10).

Su VitaminC, invece, la calibrazione non si trasferisce. L'ECE binario sale da 0.17 a 0.21 per il 0.5B e da 0.14 a 0.19 per il 3B, e la regola di restituzione delle etichette perde 0.02–0.04 rispetto alla decisione grezza. Il bias, infatti, codifica il tasso di base di RAGTruth, mentre VitaminC è bilanciato per costruzione. Una calibrazione vale per la distribuzione su cui è stata stimata, per cui ogni impiego reale richiede un piccolo campione etichettato dei propri dati.

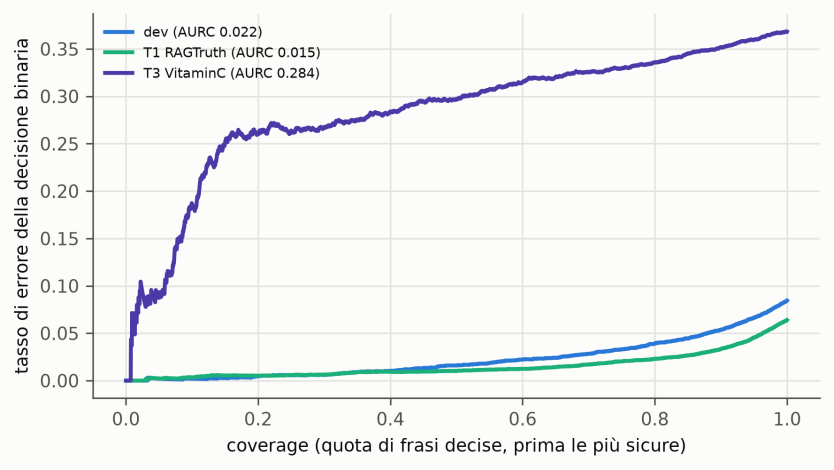


Figura 7.10: Curve risk–coverage della decisione binaria del 0.5B con probabilità calibrate: tasso di errore al crescere del numero di frasi meno sicure che vengono rinviate.

7.8 Probabilità a parità di output

I giudici LLM a parità di output servono a stabilire se un giudice LLM della stessa dimensione, a cui si chiede lo stesso contenuto di GroundOne, possa eguagliare la qualità delle sue probabilità. La risposta è negativa (Figura 7.11). Il confronto usa le 200 risposte del sottoinsieme di latenza, con tutti i sistemi calibrati allo stesso modo sul dev set. Per il 0.5B e per il 3B rispettivamente, l'AUROC di $P(\text{supported})$ è 0.94 e 0.97 per GroundOne, 0.48 e 0.68 per il giudice LLM le cui probabilità sono lette dai logit, e 0.47 e 0.58 per il giudice LLM che le scrive. L'AURC è 0.009 e 0.005 per GroundOne, contro valori da 0.048 a 0.063 per i giudici LLM, cioè da circa sette a dodici volte maggiori di quelli di GroundOne della stessa dimensione. L'accuratezza delle decisioni segue lo stesso andamento: 0.835 e 0.900 per GroundOne, al massimo 0.41 per qualsiasi giudice LLM.

Nella pratica contano altre due osservazioni. La prima è che le probabilità scritte a parole non portano quasi alcuna informazione. Il 3B scrive un vettore con tutta la massa su una sola classe per il 93 % delle frasi, e usa appena sedici vettori distinti. Il 0.5B scrive invece pareggi non informativi, come probabilità uguali per tutte le classi: se i pareggi privi di etichetta vengono contati come errori, la sua balanced accuracy scende da 0.234 a 0.081. Il dato concorda con l'osservazione che la confidenza verbalizzata dei modelli piccoli è grossolana e poco informativa [95, 94]. La seconda osservazione è che l'ECE, da solo, nasconderebbe tutto ciò. Dopo la calibrazione ogni sistema, giudici LLM compresi, ottiene un ECE binario compreso tra 0.03 e 0.05, perché una mappa di calibrazione può allineare la confidenza media

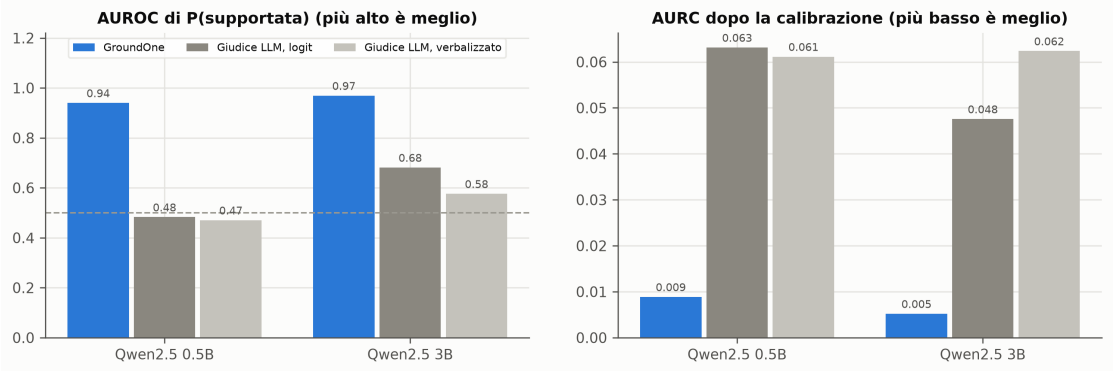


Figura 7.11: Confronto a parità di output sulle 200 risposte del sottoinsieme di latenza. Ai giudici LLM della stessa dimensione si chiede l'output di GroundOne, con le probabilità lette dai logit della lettera generata oppure scritte in JSON; tutti i sistemi sono calibrati sul dev set con la stessa mappa. Sono considerate soltanto le frasi con un verdetto valido.

al tasso di base anche quando le probabilità non separano le classi. La capacità discriminativa va quindi misurata a parte, con l'AUROC e con l'AURC.

Chiedere le probabilità, infine, ha un costo. Il giudice LLM che le legge dai logit è veloce quanto il giudice LLM sintetico, perché genera le stesse lettere. Il giudice LLM che scrive l'oggetto JSON, invece, impiega con il 3B 17.0 secondi per una risposta con quattordici o più decisioni, quanto il giudice LLM verboso, e non è più accurato del giudice LLM sintetico.

7.9 Latenza in funzione di K

La Figura 7.12 riporta la misura centrale della tesi: il tempo necessario per verificare una risposta al crescere del numero di decisioni, misurato sulle stesse 200 risposte di T1. Tra i sistemi eseguiti in-process su MLX, GroundOne è il più veloce con entrambe le dimensioni e in ogni fascia di K, e il suo vantaggio aumenta con K. Quando la risposta contiene quattordici o più decisioni, il GroundOne 0.5B impiega 0.41 secondi, contro 0.80 del giudice LLM sintetico e 2.51 del giudice LLM verboso della stessa dimensione. È quindi 1.95 volte più veloce del primo (da 1.82 a 2.12) e 6.16 volte più veloce del secondo (da 5.72 a 6.66). Nella stessa fascia il GroundOne 3B impiega 2.57 secondi, contro 4.44 e 15.86 secondi dei due giudici LLM 3B, ed è quindi 1.73 volte (da 1.65 a 1.82) e 6.18 volte (da 5.88 a 6.63) più veloce. La misura è stata ripetuta, sulle stesse risposte e con lo stesso protocollo, per le analisi della Sezione 7.9.1, che confrontano le situazioni con e senza cache all'interno della stessa esecuzione: i suoi tempi sono entro il 5 % di questi, e sulle risposte lunghe

GroundOne è 2.00 e 1.79 volte più veloce dei giudici LLM sintetici e 6.17 e 6.62 volte più veloce di quelli verbosi (Tabella 7.5). Gli speed-up citati nel resto della tesi vengono dalla misura ripetuta: senza alcuna cache, sulle risposte di quattordici o più frasi, GroundOne è da 1.8 a 2 volte più veloce del giudice LLM sintetico.

Leggere tutti i verdetti in un unico forward pass è anche più rapido che porre una domanda per frase in un batch: ai valori più alti di K il guadagno è di un fattore 1.4–1.5. L'altra leva è la dimensione del modello: il GroundOne 0.5B verifica una risposta circa sei volte più in fretta del 3B, con un tempo mediano di 0.33 secondi contro 1.99.

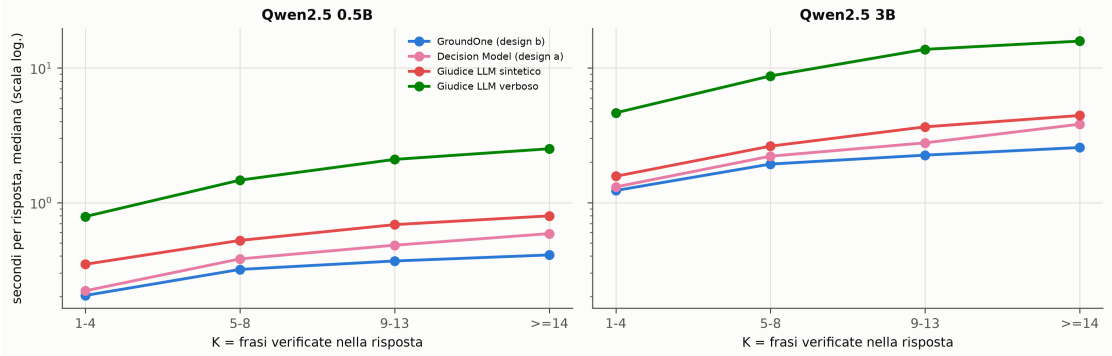


Figura 7.12: Tempo mediano per risposta in funzione di K sulle stesse 200 risposte di T1 (MLX in-process, una risposta alla volta, M4 con 16 GB). Sono confrontati GroundOne, il decision model con una domanda per frase e i giudici LLM sintetico e verboso. Scala logaritmica.

7.9.1 Lettura del testo e decisione

Il tempo di GroundOne cresce con K, ma non per il numero di decisioni in sé. Le risposte con più frasi sono anche più lunghe: nel sottoinsieme di latenza il prompt passa da circa 550 token nella fascia $K \leq 4$ a circa 1,140 token con $K \geq 14$, e il tempo del prefill cresce con la lunghezza del testo. Per separare le due componenti, il tempo di ogni risposta è stato scomposto in una parte di *lettura*, cioè il prefill di istruzioni, documento e risposta, che ogni approccio deve pagare, e in una parte di *decisione*. Per GroundOne la lettura è un forward pass sullo stesso testo senza marker, e la decisione è la differenza rispetto al passaggio servito, cioè il costo dei marker e del readout; le due misure sono alternate cinque volte con il 0.5B e tre con il 3B, e se ne tiene la mediana. Per i giudici LLM la lettura è il tempo fino al primo token generato, e la decisione è il decoding dei verdetti. La misura usa le stesse 200 risposte e lo stesso protocollo della sezione precedente, e ne riproduce i

tempi complessivi entro il 5 %. La Tabella 7.2 riporta le mediane, la Figura 7.13 il loro andamento con K.

Tabella 7.2: Tempo per risposta scomposto in lettura del testo (prefill) e decisione, sulle stesse 200 risposte di T1: mediane su tutte le risposte, in secondi. Per GroundOne la decisione è il costo dei marker e del readout, per i giudici LLM il decoding dei verdetti. La quota di lettura è la mediana delle quote per risposta.

Modello	Sistema	Lettura	Decisione	Totale	Quota di lettura
0.5B	GroundOne	0.330	0.012	0.342	97 %
	Giudice LLM sintetico	0.297	0.383	0.673	46 %
	Giudice LLM verboso	0.305	1.509	1.826	18 %
3B	GroundOne	1.941	0.067	2.002	97 %
	Giudice LLM sintetico	1.753	1.196	3.102	61 %
	Giudice LLM verboso	1.756	8.313	10.277	18 %

Per GroundOne la lettura vale il 97 % del tempo con entrambe le dimensioni. La decisione costa in mediana 12 millisecondi per risposta con il 0.5B e 67 con il 3B, cioè, in mediana, 1.3 e 6.7 millisecondi per frase: sono i tre token del marker e la proiezione sul vocabolario nelle sole posizioni dei marker. Il giudice LLM sintetico spende invece 30 e 139 millisecondi per frase, quello verboso 170 e 1,033. Per i giudici LLM, invece, la decisione è una parte consistente del tempo, e per il giudice LLM verboso la parte principale. Al netto della lettura, e confrontando le mediane per risposta della Tabella 7.2, GroundOne decide 33 volte più in fretta del giudice LLM sintetico con il 0.5B (da 30 a 38) e 18 volte con il 3B (da 15 a 20); rispetto al giudice LLM verboso, 131 volte (da 112 a 148) e 125 volte (da 116 a 142). Con quattordici o più frasi i rapporti sono simili: 29 e 24 volte rispetto al giudice LLM sintetico, 141 e 151 rispetto a quello verboso.

Lo speed-up complessivo resta di circa due volte rispetto al giudice LLM sintetico perché la lettura, che domina il tempo, è comune a tutti gli approcci: il vantaggio di GroundOne sta nella parte che il readout sostituisce, non nel prefill. La scomposizione mostra anche un costo che i tempi complessivi nascondono. La lettura di GroundOne è circa il 10 % più lenta di quella dei giudici LLM, benché il suo prompt sia leggermente più corto: è il calcolo aggiuntivo dell'adapter LoRA, che resta separato dai pesi base quantizzati. Fondere l'adapter nei pesi eliminerebbe questo costo, ma richiederebbe di quantizzare di nuovo il modello e di ricalibrarlo.

Composizione del prefill. Il prefill è quasi tutto il tempo di GroundOne, ma le sue parti non cambiano allo stesso modo da una verifica all'altra. Il prompt ne ha quattro, nell'ordine: le istruzioni, identiche per ogni richiesta; il documento,

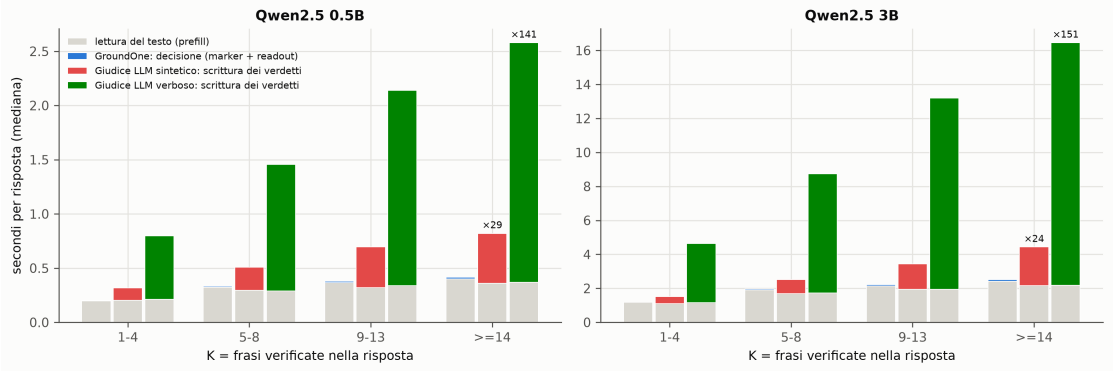


Figura 7.13: Tempo mediano per risposta scomposto in lettura del testo (prefill, in grigio, comune a ogni approccio) e decisione (in colore), per fascia di K, sulle stesse 200 risposte di T1. Le etichette indicano, per $K \geq 14$, quante volte il giudice LLM impiega più di GroundOne a decidere.

identico finché si verificano risposte sulle stesse fonti; la risposta, che cambia a ogni versione; i marker, tre token per frase (Figura 7.14a). Sulle 200 risposte della misura di latenza le istruzioni sono 63 token, il 7 % del prompt; il documento ne conta in mediana 577, il 65 %; risposta e marker insieme formano il restante 28 %, una quota che cresce con il numero di frasi, dal 19 % sotto le cinque frasi al 35 % da quattordici in su. Il tempo si ripartisce allo stesso modo (Figura 7.14b): con il 3B, sulle risposte di quattordici o più frasi, la lettura del documento è il 60 % del tempo di GroundOne, quella della risposta il 34 %, le istruzioni il 2 % e la decisione il 3 %. Il giudice LLM sintetico legge lo stesso documento, ma metà del suo tempo va nella scrittura dei verdetti.

Da questa composizione seguono le scelte su cosa tenere in cache. Le istruzioni si possono riusare sempre, ma pesano poco: conservarle costa una sola KV cache per processo e fa guadagnare pochi punti percentuali. Il documento è la parte che conta: è la quota maggiore del prompt e del tempo, e resta lo stesso in tutti i casi in cui si verifica di nuovo sulle stesse fonti, cioè una risposta riscritta, più risposte alternative o più domande sulla stessa libreria. Tenerlo in memoria costa poco: con il 3B la KV cache occupa circa 36 KB per token, e un documento mediano circa 21 MB. Per questo il servizio conserva gli ultimi quattro documenti letti e l'applicazione le ultime sedici intestazioni (istruzioni e documento). Il documento, inoltre, è noto prima della risposta: lo si può leggere appena il generatore ha finito, mentre l'utente legge la risposta, così che anche la prima verifica legga soltanto la risposta (Capitolo 8). La risposta, invece, non si può riusare come blocco, perché cambia a ogni versione; se ne può riusare soltanto la parte iniziale, fino alla prima frase modificata, come mostra il paragrafo *Riuso del prefisso della risposta*. La decisione di GroundOne, infine, è già una frazione trascurabile del tempo, mentre

quella del giudice è decoding, che nessuna cache elimina: per questo la cache allarga il divario tra i due.

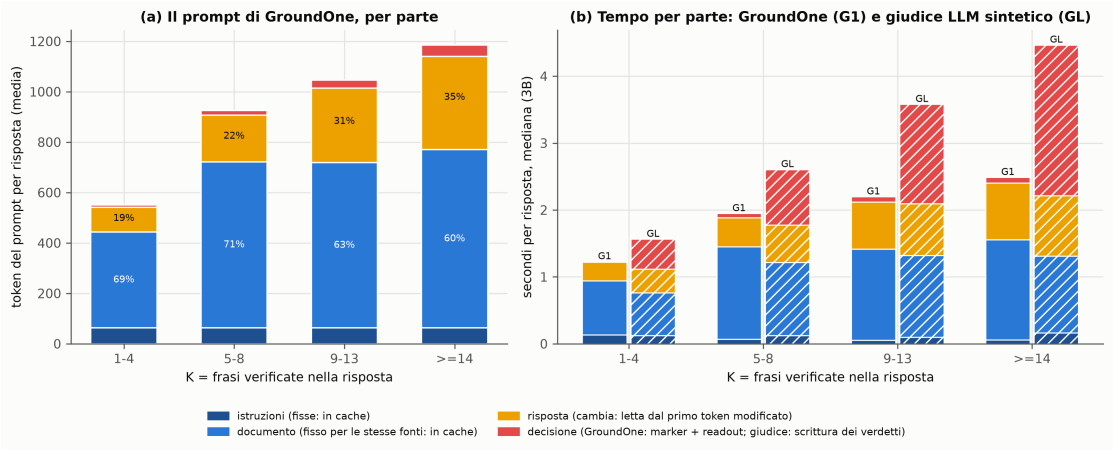


Figura 7.14: Composizione del prefill sulle 200 risposte di T1 usate per la latenza. (a) Token del prompt di GroundOne per parte, media per fascia di K; le etichette danno la quota del documento e quella di risposta e marker. (b) Tempo per parte con il 3B, ricavato dalle misure senza cache, con le sole istruzioni e con istruzioni e documento in cache come differenza tra le mediane per fascia, per cui ogni colonna somma al tempo mediano senza cache. In blu le parti che restano uguali tra verifiche sulle stesse fonti, le sole che si possono tenere in cache come blocco.

Riuso del prefisso. La stessa misura è stata ripetuta con una parte del prompt già nella KV cache quando parte il cronometro, la stessa per GroundOne e per i giudici LLM: le sole istruzioni, identiche per ogni richiesta (da 63 a 81 token), oppure istruzioni e documento (circa 640 token in mediana), come accade quando una risposta riscritta viene verificata di nuovo sulle stesse fonti (Sezione 4.2).[1] La Tabella 7.3 riporta i tempi complessivi.

[1]Nella versione di MLX usata per le misure (0.29.3) il kernel di attenzione fuso con maschera causale implicita restituisce risultati errati per alcune forme quando molte query seguono chiavi già in cache, per esempio 501 token letti dopo 523 in cache. I percorsi con prefisso in cache usano quindi una maschera causale esplicita, che coincide con un riferimento in float32; dopo questa correzione, su 100 risposte, le probabilità con e senza cache differiscono al più di 0.014 con il 0.5B e di 0.005 con il 3B, e la classe predetta cambia per 3 e 1 frasi su 1,758, tutte vicine alla parità: le differenze rientrano nell'arrotondamento in bfloat16. Le misure senza cache, e quindi tutti gli altri risultati, non passano da questo percorso. La versione di MLX per Swift usata dall'applicazione non presenta l'errore.

Tabella 7.3: Tempo complessivo per risposta con una parte del prompt già nella KV cache, sulle stesse 200 risposte di T1: mediane in secondi. La stessa cache vale per GroundOne e per i giudici LLM. L'ultima colonna è il rapporto fra i tempi mediani senza cache e con il documento in cache.

Modello	Sistema	Nessun prefisso	Istruzioni in cache	Documento in cache	Risparmio con il documento
0.5B	GroundOne	0.342	0.333	0.108	3.2×
	Giudice LLM sintetico	0.673	0.652	0.520	1.3×
	Giudice LLM verboso	1.826	1.844	1.683	1.1×
3B	GroundOne	2.002	1.913	0.583	3.4×
	Giudice LLM sintetico	3.102	3.002	1.795	1.7×
	Giudice LLM verboso	10.277	9.998	8.742	1.2×

Come anticipa la composizione del prefill, tenere in cache le sole istruzioni fa risparmiare al più il 5 % del tempo, poco più del rumore di misura, mentre il documento fa una differenza netta. Con il documento in cache GroundOne verifica una risposta 3.2 volte più in fretta con il 0.5B (0.11 secondi in mediana) e 3.4 volte con il 3B (0.58 secondi). I giudici LLM guadagnano molto meno, 1.3 e 1.7 volte quello sintetico e 1.1 e 1.2 quello verboso, perché la cache elimina soltanto la lettura e lascia intatto il decoding dei verdetti, che non si può riusare. Di conseguenza il vantaggio di GroundOne sul giudice LLM sintetico sale da circa 2 a 4.8 volte con il 0.5B (da 4.1 a 5.2) e da 1.6 a 3.1 volte con il 3B (da 2.8 a 3.3), e quello sul giudice LLM verboso a circa 15 volte. Sulle risposte di quattordici o più frasi, sulle quali senza cache GroundOne è da 1.8 a 2 volte più veloce, il vantaggio sul giudice LLM sintetico passa a 3.6 volte con il 0.5B (da 3.5 a 3.8) e a 3.4 volte con il 3B (da 3.2 a 3.4). Con il documento in cache, il tempo di GroundOne è fatto per il 90 % della lettura della sola risposta e per il resto della decisione: la verifica di una risposta riscritta costa quindi poco più della sua lunghezza.

Riuso del prefisso della risposta. Una riscrittura cambia di solito una o poche frasi, e tutto ciò che precede il primo token modificato coincide con la versione già verificata. La cache può quindi conservare l'intera sequenza dell'ultima verifica, risposta compresa: il nuovo passaggio parte dal primo token modificato, e i verdetti dei marker precedenti, che l'attenzione causale rende indipendenti da ciò che li segue, sono ripresi senza modifiche dal passaggio precedente. Per misurarlo, in ciascuna delle 200 risposte è stata modificata una frase valutata, la prima, quella centrale o l'ultima, aggiungendole poche parole (", as reported."), e la nuova versione è stata verificata una volta con il solo documento in cache e una volta con in cache anche la versione precedente della risposta. La modifica fa le veci di una riscrittura: il

tempo dipende soltanto da dove cade il primo token cambiato e da quanti token lo seguono, non da ciò che la frase dice. La Tabella 7.4 riporta le mediane.

Tabella 7.4: Verifica di una risposta con una frase modificata, sulle stesse 200 risposte di T1: tempi mediani in secondi con il solo documento in cache e con in cache anche la versione precedente della risposta, e fra parentesi il rapporto fra i due. Il giudice LLM riusa lo stesso prefisso, ma riscrive tutti i propri verdetti. I tempi con il documento in cache vengono da un'esecuzione distinta e differiscono da quelli della Tabella 7.3 al più del 2 %.

Modello	Sistema	Documento in cache	Cambia la prima frase	Cambia la frase centrale	Cambia l'ultima frase
0.5B	GroundOne	0.106	0.095 (1.1×)	0.051 (2.1×)	0.021 (5.0×)
	Giudice LLM sintetico	0.512	0.516 (1.0×)	0.485 (1.1×)	0.452 (1.1×)
3B	GroundOne	0.589	0.515 (1.2×)	0.285 (2.1×)	0.093 (6.3×)
	Giudice LLM sintetico	1.828	1.717 (1.1×)	1.549 (1.2×)	1.412 (1.3×)

Per GroundOne il tempo segue i token che restano da leggere. Quando cambia l'ultima frase si leggono 8 token in mediana invece di 249, e la verifica richiede 0.02 secondi con il 0.5B e 0.09 con il 3B, cinque e sei volte meno che con il solo documento in cache; una modifica della frase centrale dimezza il tempo; una modifica della prima frase lascia da leggere quasi tutta la risposta, e il guadagno è dal 13 al 15 %. Sulle tre posizioni insieme il guadagno è di 2.6 volte con il 0.5B e di 2.7 volte con il 3B. Il giudice LLM sintetico guadagna dal 3 al 29 %: anch'esso legge meno, ma tutti i suoi verdetti seguono l'intera risposta, quindi una modifica in una frase qualsiasi li invalida tutti, e il loro decoding, che è la maggior parte del suo tempo, va ripetuto per intero. Con in cache la versione precedente, il vantaggio di GroundOne sul giudice LLM sintetico sale quindi da 4.8 a 12 volte con il 0.5B (da 11.2 a 12.9) e da 3.1 a 7.1 volte con il 3B (da 6.6 a 7.8). Il servizio e l'applicazione riusano il prefisso della risposta nello stesso modo (Capitolo 8), e gli stessi test che controllano la cache del documento verificano che i verdetti riusati coincidano con quelli di un passaggio senza cache.

Lo speed-up nelle diverse situazioni. Le misure di questa sezione confrontano GroundOne e i giudici LLM sempre a parità di condizioni: stesse risposte, stessa macchina e, quando c'è, la stessa cache. La Tabella 7.5 e la Figura 7.15 le riuniscono. Le differenze fra una riga e l'altra non dipendono da ottimizzazioni concesse a un solo sistema, ma da quanto pesa, in ciascuna situazione, la parte che il readout elimina. Senza cache la lettura del testo, comune ai due approcci, è quasi tutto

il tempo di GroundOne e circa metà di quello del giudice sintetico, e lo speed-up complessivo resta fra 1.6 e 2 volte, da 1.8 a 2 sulle risposte di quattordici o più frasi; al netto della lettura, la decisione di GroundOne è da 18 a 33 volte più rapida di quella del giudice sintetico e da 125 a 131 volte più rapida di quella del verboso. Ogni riduzione della lettura avvicina lo speed-up complessivo a quello della sola decisione. Con le fonti già in cache, lette in anticipo mentre l'utente legge la risposta oppure per una verifica precedente (la KV cache è la stessa nei due casi), GroundOne è da 3.1 a 4.8 volte più veloce del giudice sintetico e circa 15 volte più veloce del verboso. Dopo una riscrittura, quando anche l'inizio della risposta è in cache e i suoi verdetti si riusano, il vantaggio sul giudice sintetico sale a 7.1 volte con il 3B e a 12 con il 0.5B. Quest'ultima riga è la sola in cui conta anche il formato, e non soltanto il costo del decoding: il giudice riusa la stessa cache, ma i suoi verdetti seguono l'intera risposta e vanno riscritti tutti. Il caso di riferimento resta la prima riga, la verifica di una risposta nuova su fonti mai lette, che è anche il caso meno favorevole; il più favorevole fra quelli misurati rispetto al giudice LLM sintetico è l'ultima, e le altre descrivono come il vantaggio cresce nell'uso reale di un assistente, in cui le stesse fonti vengono lette più volte.

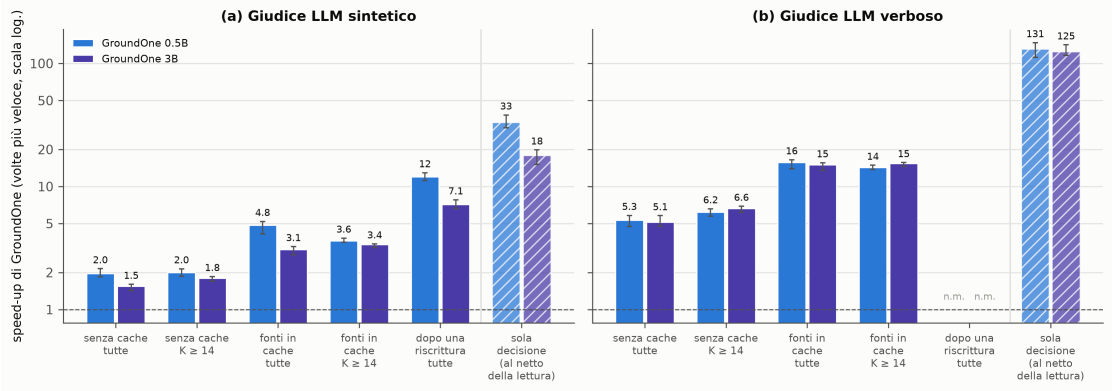


Figura 7.15: Speed-up di GroundOne sui giudici LLM nelle diverse situazioni, sulle stesse 200 risposte di T1 (rapporto fra i tempi mediani, scala logaritmica, intervalli bootstrap al 95 %; "tutte": tutte le risposte). In ogni situazione GroundOne e il giudice hanno la stessa cache. Le colonne tratteggiate, a destra della linea, escludono la lettura del testo: sono il limite a cui tende lo speed-up complessivo quando la lettura si riduce. n.m.: non misurato.

La velocità non è l'unica differenza (Figura 7.16). I giudici LLM non addestrati sono anche molto meno accurati, e non sempre rispettano il formato di output. Il giudice LLM verboso 0.5B produce un verdetto interpretabile soltanto per il 3 % delle frasi, perché per lo più ricopia la risposta, mentre il giudice LLM sintetico 0.5B fallisce sul 23 % delle frasi. I giudici LLM 3B rispettano il formato molto

Tabella 7.5: Speed-up di GroundOne sui giudici LLM nelle diverse situazioni, sulle stesse 200 risposte di T1: rapporto fra i tempi mediani, con l'intervallo bootstrap al 95 %. In ogni riga GroundOne e il giudice hanno la stessa cache; la riga della sola decisione esclude la lettura del testo (Tabella 7.2). Le righe senza cache e con le fonti in cache vengono dalla stessa esecuzione (Tabella 7.3), che ripete la misura della Sezione 7.9 entro il 5 %; l'ultima riga viene dall'esecuzione della Tabella 7.4. n.m.: non misurato.

Situazione	Giudice LLM			
	0.5B sintetico	0.5B verboso	3B sintetico	3B verboso
Prima verifica, nessuna cache: tutte le risposte	1.97 (1.84–2.15)	5.34 (4.72–5.82)	1.55 (1.42–1.60)	5.13 (4.75–5.79)
Prima verifica, nessuna cache: 14 o più frasi	2.00 (1.87–2.14)	6.17 (5.74–6.59)	1.79 (1.69–1.86)	6.62 (6.18–6.91)
Sola decisione, al netto della lettura	33.2 (29.9–38.1)	131 (112–148)	17.9 (15.1–19.8)	125 (116–142)
Fonti in cache (lette in anticipo o per una verifica precedente): tutte le risposte	4.83 (4.13–5.21)	15.6 (13.9–16.5)	3.08 (2.78–3.25)	15.0 (13.5–15.6)
Fonti in cache: 14 o più frasi	3.62 (3.52–3.81)	14.3 (13.7–14.9)	3.38 (3.18–3.42)	15.4 (14.6–15.6)
Dopo una riscrittura (in cache anche l'inizio della risposta)	12.0 (11.2–12.9)	n.m.	7.15 (6.62–7.79)	n.m.

meglio (0.1 % di errori di formato per il giudice LLM sintetico e 7.6 % per quello verboso), ma si fermano a una balanced accuracy a tre classi di circa 0.40, contro 0.90 del GroundOne 3B sulle stesse risposte. Il giudice LLM verboso 3B, infine, scrive in media 248 token per risposta, che vanno tutti generati prima di poter usare il verdetto; GroundOne, invece, non ne genera nessuno.

7.10 Energia per verifica

La misura dell'energia aggiunge una precisazione che la sola latenza nasconde (Figura 7.17). Fra i sistemi misurati, cioè GroundOne e i giudici LLM, GroundOne è quello che consuma meno energia con entrambe le dimensioni: 5.5 joule per risposta con il 0.5B e 33 con il 3B, contro 8.9 e 43 joule del giudice LLM sintetico

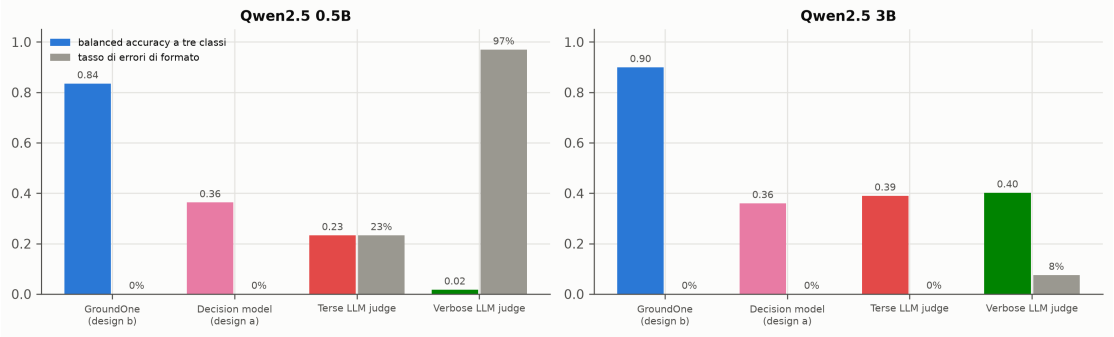


Figura 7.16: GroundOne, il decision model non addestrato e i giudici LLM sul sottoinsieme di latenza: balanced accuracy a tre classi, con gli errori di formato contati come errori, e quota di frasi il cui verdetto non è stato possibile interpretare.

e 22.5 e 112 joule del giudice LLM verboso. Il suo vantaggio sull'energia, tuttavia, è minore di quello sul tempo. Rispetto al giudice LLM sintetico, GroundOne consuma 1.6 volte meno energia con il 0.5B e 1.3 volte meno con il 3B; rispetto al giudice LLM verboso, 4.1 e 3.4 volte meno. L'energia è stata misurata soltanto senza cache: con le fonti già lette anche l'energia di una verifica diminuisce, ma di quanto non è stato misurato.

Il motivo è la potenza assorbita durante il calcolo. GroundOne trascorre il suo tempo in un unico, lungo prefill, che tiene la GPU pienamente occupata e assorbe circa 16 W oltre la potenza a riposo. Il decoding autoregressivo dei giudici LLM, invece, è limitato dalla banda di memoria e assorbe 11–14 W, ma per un tempo molto più lungo. È il comportamento atteso dalle due fasi dell'inferenza dei transformer [42], e implica che uno speed-up non vada mai letto come un risparmio di energia equivalente [67, 68].

In termini assoluti i valori sono piccoli. Un consumo di 5.5 joule corrisponde a circa 0.0015 wattora: con l'energia di un wattora, quindi, il GroundOne 0.5B potrebbe verificare circa 650 risposte, interamente sul portatile.

7.11 Località: esecuzione offline, quantizzazione e co-residenza

Tre misure completano il quadro del costo sul dispositivo (Sezione 6.5). La prima riguarda l'indipendenza dalla rete. La valutazione completa di T1 con il modello 0.5B, ripetuta all'interno di una sandbox che nega al processo qualsiasi accesso alla rete, produce predizioni identiche bit per bit a quelle dell'esecuzione originale su tutte le 17,284 frasi. Caricamento del modello, inferenza e valutazione non richiedono quindi alcuna connessione. La prova è più forte di una macchina

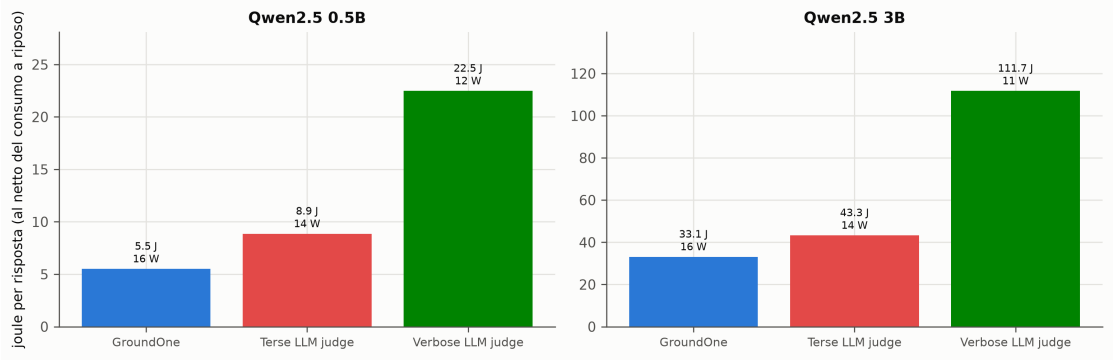


Figura 7.17: Energia per risposta verificata su 100 risposte del sottoinsieme di latenza, misurata con `powermetrics` su CPU, GPU e Neural Engine al netto della potenza a riposo, insieme alla potenza netta media durante l'esecuzione.

disconnessa, perché il processo non può raggiungere la rete nemmeno quando la macchina è collegata.

La seconda riguarda la quantizzazione. Quando lo stesso adapter del 0.5B viene applicato ai pesi originali in bf16 invece che a quelli a 8 bit, le probabilità cambiano in media di 0.011 su T1 e di 0.007 su T3, e la classe predetta coincide nel 98.3 % e nel 98.9 % delle frasi. Le metriche restano invariate: la balanced accuracy a tre classi è 0.769 con la base a 8 bit e 0.768 con quella in bf16 su T1, 0.442 in entrambi i casi su T3, e l'AUROC su T1 è 0.905 contro 0.904. La base a 8 bit, che dimezza la memoria dei pesi, non costa quindi accuratezza misurabile. La misura riguarda però la sensibilità alla precisione della base di un adapter addestrato sulla base a 8 bit, non un modello addestrato interamente in bf16.

La terza riguarda la co-residenza con il generatore. Nello stesso processo, il generatore Qwen2.5-3B-Instruct a 4 bit e GroundOne verificano 30 risposte generate da documenti di T1, con una mediana di 169 token generati e di sette frasi valutate per risposta (Tabella 7.6). Con il verificatore 3B il picco di memoria allocata da MLX è di 6.1 GB, con il 0.5B di 3.3 GB: entrambi ben al di sotto dei 16 GB della macchina. La verifica occupa il 30 % del tempo complessivo per risposta con il 3B e il 6.7 % con il 0.5B. Il modello piccolo aggiunge quindi una frazione modesta al tempo della generazione, mentre il 3B, confrontando le mediane dei due tempi, lo allunga di circa un terzo in cambio di una maggiore accuratezza. Durante l'esecuzione con il 3B, con le normali applicazioni del desktop aperte, la memoria libera dell'intero sistema è scesa per qualche istante a circa 1.6 GB: la coppia sta comodamente nel processo, ma su un portatile da 16 GB lascia poco margine a un uso intenso del desktop. Il retriever non è incluso in questa misura; l'applicazione del Capitolo 8 lo aggiunge.

Tabella 7.6: Co-residenza di generatore e verificatore in un unico processo: Qwen2.5-3B-Instruct a 4 bit come generatore, 30 documenti di T1, generazione greedy fino a 300 token. Memoria allocata da MLX; tempi mediani per risposta; la quota della verifica è la mediana delle quote per risposta.

Verificatore	Memoria dopo il caricamento	Picco di memoria	Generazione	Verifica	Quota della verifica
GroundOne 3B	5.0 GB	6.1 GB	4.75 s	1.68 s	30 %
GroundOne 0.5B	2.3 GB	3.3 GB	4.65 s	0.28 s	6.7 %

7.12 Analisi degli errori

Il risultato debole su VitaminC e le contraddizioni mancate su T1 mostrano uno schema comune, che la sovrapposizione lessicale mette in evidenza. Su VitaminC, quando un'affermazione supportata condivide poche parole con la propria evidenza (sovrapposizione inferiore a 0.4), il 0.5B la riconosce soltanto nel 2 % dei casi. Quando la sovrapposizione supera 0.7, invece, la riconosce nel 64 % dei casi. Inoltre, il 0.5B non riconosce mai una contraddizione in un'affermazione priva di cifre. I modelli, quindi, si appoggiano in parte alla sovrapposizione lessicale: un'affermazione parafrasata sembra "non menzionata", mentre una piccola modifica a una frase copiata, spesso un numero, passa inosservata.

La stessa debolezza si ritrova su T1, anche se con un peso minore. Quando la sovrapposizione lessicale con il documento è bassa o intermedia (fino a 0.7), la balanced accuracy a tre classi del 0.5B è 0.77. Per le frasi che riprendono dal documento più del 70 % delle proprie parole, invece, scende a 0.54, con una recall di 0.24 per le frasi contraddette e di 0.43 per quelle non menzionate. Il 3B riduce questo punto cieco senza eliminarlo: sulle stesse frasi la sua recall è 0.36 e 0.56, e la sua balanced accuracy 0.63. Le allucinazioni nascoste in frasi che per il resto ricopiano la fonte restano così il limite principale di entrambi i modelli. VitaminC non è più difficile in assoluto: è composto in gran parte proprio da casi di questo tipo, cioè da supporto parafrasato e da modifiche minime, che in RAGTruth sono meno numerosi.

L'Appendice A, infine, mostra l'output di ogni sistema su una stessa risposta di esempio.

Capitolo 8

GroundOne Studio: un'applicazione locale e un caso di studio

I capitoli precedenti misurano GroundOne come componente isolato. Questo capitolo lo mette al lavoro dentro un'applicazione completa, GroundOne Studio, un assistente RAG per macOS in cui recupero dei documenti, generazione della risposta e verifica avvengono nello stesso processo, sullo stesso portatile da 16 GB usato per gli esperimenti. L'obiettivo è duplice. Da un lato l'applicazione completa l'argomento della località (Capitolo 2): non basta che il verificatore possa girare in locale, serve mostrare che attorno a esso si può costruire un sistema utilizzabile senza alcun servizio esterno. Dall'altro rende visibili, su risposte vere, le proprietà misurate nel Capitolo 7: la verifica di tutte le frasi in un solo forward pass, le probabilità calibrate, il confronto con un giudice LLM. Le misure raccolte nell'applicazione costituiscono un caso di studio e restano separate dai risultati del Capitolo 7: descrivono il comportamento del sistema completo, non stabiliscono nuovi primati.

8.1 Obiettivi e requisiti

L'applicazione è stata progettata attorno a cinque elementi che l'utente deve poter vedere, ciascuno legato a un'affermazione della tesi (Tabella 8.1). Un vincolo li accompagna tutti: nessun dato lascia la macchina. Modelli, indice dei documenti, conversazioni e registri risiedono sul disco locale, e l'applicazione funziona senza connessione.

Tabella 8.1: Che cosa mostra l'applicazione e quale affermazione della tesi sostiene.

Che cosa vede l'utente	Affermazione sostenuta
Ogni frase della risposta colorata secondo il verdetto di GroundOne, con le probabilità calibrate.	Le probabilità sono utilizzabili e coerenti con l'etichetta mostrata (RQ3).
Il confronto, sulla stessa risposta, con un giudice LLM eseguito localmente: verdetti e tempi affiancati.	Leggere tutti i verdetti in un solo forward pass, senza generare testo, è più accurato di un giudice LLM che scrive i verdetti, e più veloce, tanto più quanto più lunga è la risposta (RQ2).
Un pannello con i tempi di generazione e di verifica e la memoria occupata.	Generatore e verificatore convivono in 16 GB, e la verifica aggiunge una frazione del tempo di generazione, piccola con il 0.5B (RQ4).
La riscrittura delle frasi segnalate a partire dai documenti, verificata di nuovo.	La verifica costa abbastanza poco da stare dentro il ciclo di generazione.
Per ogni frase, il passaggio del documento che la sostiene o la contraddice, evidenziato.	L'attribuzione al passaggio si può ottenere con lo stesso modello; è un prototipo non valutato (Sezione 10.2).

8.2 Scelte di piattaforma

L'applicazione è scritta in Swift, con interfaccia SwiftUI, ed esegue i modelli con MLX Swift [123, 124], la versione per Swift della stessa libreria usata per addestrare GroundOne. Sono state considerate tre alternative: un'applicazione in Python attorno al pacchetto esistente, con interfaccia web; un'applicazione in Rust, con collegamenti non ufficiali a MLX [125] o con un altro runtime; un porting su llama.cpp con pesi convertiti in formato GGUF. La prima avrebbe mostrato che l'esperimento può essere servito in locale, ma come server e pagina nel browser, non come applicazione installabile. Le ultime due avrebbero richiesto di dimostrare di nuovo l'equivalenza numerica con i risultati, e nel caso di llama.cpp di ricalibrare il modello dopo una nuova quantizzazione. MLX Swift carica invece gli stessi pesi e lo stesso adapter e si appoggia allo stesso backend di MLX: se un test di conformità lo conferma (Sezione 8.4), i numeri della tesi valgono anche per l'applicazione, senza riaddestrare né ricalibrare nulla. Il prezzo è la portabilità: l'interfaccia è legata alle piattaforme Apple, e la compilazione degli shader di MLX richiede Xcode.

8.3 Architettura

L'applicazione è divisa in tre livelli (Figura 8.1). Il primo è l'interfaccia. Il secondo è un nucleo che non dipende dai motori: gestisce la sessione (risposta, verifica, riscrittura), applica la policy e scrive il registro delle azioni, mentre le conversazioni vengono salvate dal livello dell'interfaccia. Il nucleo conosce cinque interfacce astratte, dette *porte*: retriever, generatore, verificatore, giudice LLM e attributore. Il terzo livello contiene i motori che implementano le prime quattro; l'attribuzione è calcolata da un componente di GroundOne che l'interfaccia chiama direttamente. Grazie a questa separazione il nucleo è stato collaudato con motori fittizi, deterministici, come il pacchetto Python viene collaudato con un backend fittizio, e un motore diverso, per esempio un generatore su llama.cpp, potrebbe sostituire quello attuale senza toccare il resto.

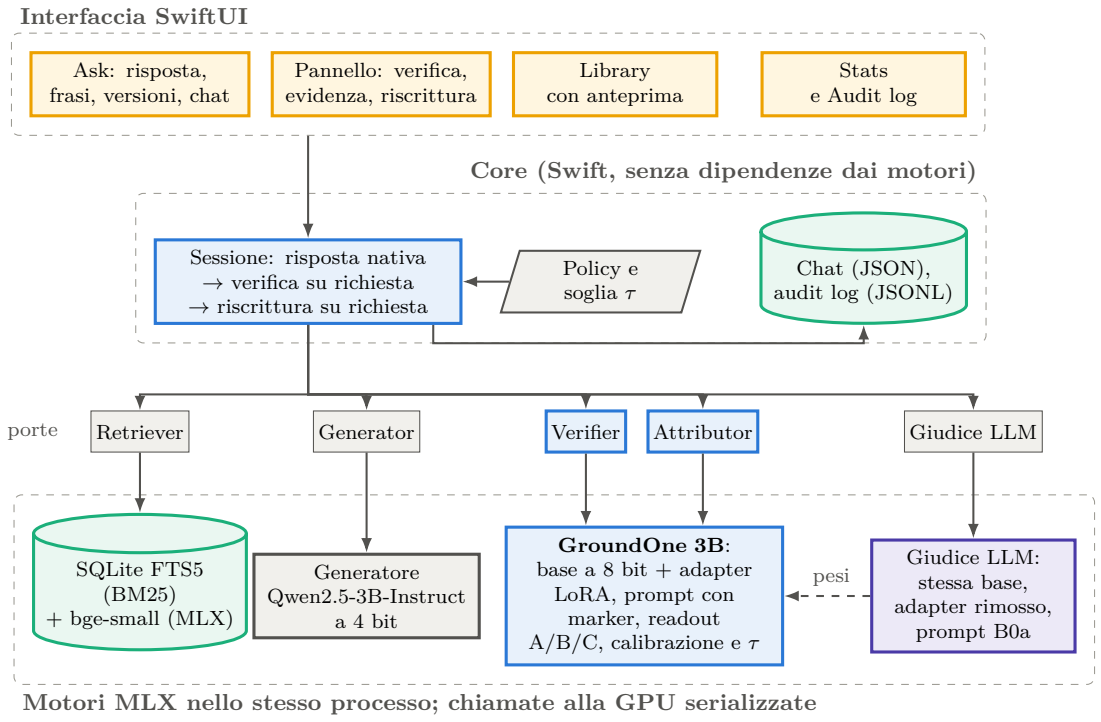


Figura 8.1: Architettura di GroundOne Studio. Il nucleo conosce solo le porte; i motori, tutti nello stesso processo, sono il retriever, il generatore, GroundOne (verificatore e, passaggio per passaggio, attributore) e il giudice LLM, che usa gli stessi pesi di GroundOne con l'adapter rimosso. In blu le componenti in cui interviene GroundOne.

I motori sono quattro. Il generatore è Qwen2.5-3B-Instruct quantizzato a 4 bit,

lo stesso della misura di co-residenza della Sezione 7.11. Il verificatore è GroundOne 3B, cioè la base a 8 bit con l'adapter LoRA, il prompt con i marker, il readout delle lettere A, B e C e la calibrazione stimata sul dev set. È il modello predefinito perché è il più accurato, e nell'applicazione la verifica avviene solo su richiesta, in circa due secondi sulle risposte brevi della misura di latenza e in circa tre sulle risposte più lunghe dell'applicazione (3.3 secondi in mediana sulle domande di esempio), e in meno di un terzo di questo tempo quando le fonti sono già state lette in anticipo (Sezione 8.6); un selettore permette di passare al 0.5B, più rapido. Il giudice LLM del confronto è lo stesso modello base di GroundOne con l'adapter rimosso a runtime e il prompt del giudice LLM sintetico B0a (Sezione 6.2): è esattamente il giudice LLM misurato nella tesi, non occupa memoria aggiuntiva e non lascia la macchina. Il retriever, infine, combina un indice full-text e un piccolo modello di embedding (Sezione 8.5).

Tutte le chiamate a un modello passano per il suo contenitore di MLX Swift, che le serializza, come fa il singolo thread di lavoro del servizio Python (Sezione 4.5). Generatore e GroundOne hanno contenitori distinti: la lettura anticipata delle fonti, che parte in background quando una risposta è completa, fa attendere la propria fine a una verifica, a un confronto con il giudice LLM o a una nuova risposta chiesti mentre è in corso, e l'interfaccia disattiva le azioni di una risposta mentre viene elaborata, ma nulla impedisce di generare una nuova domanda mentre si verifica una risposta precedente. I tempi riportati in questo capitolo sono stati misurati un'operazione alla volta, quindi non sono confusi da esecuzioni concorrenti. Con i tre modelli caricati, la memoria allocata da MLX è di circa 5.3 GB e raggiunge un picco di 6.2 GB durante una domanda e di 6.9 GB dopo una sessione di dodici domande, quando la KV cache conserva anche le fonti di quelle precedenti. Il primo valore è in linea con la misura di co-residenza della Tabella 7.6, che non comprendeva il retriever. Il modello di embedding aggiunge quindi poco: occupa circa 130 MB su disco.

8.4 Porting di GroundOne in Swift

Quattro parti di GroundOne sono state riscritte in Swift; il resto, cioè pesi, adapter e calibrazione, viene caricato così com'è. La prima è la costruzione del prompt. Come in addestramento, intestazione, frasi numerate, marker e a capo vengono tokenizzati separatamente e poi concatenati, perché tokenizzare la stringa unita produrrebbe identificativi diversi ai confini fra i pezzi. Il tokenizer è quello di swift-transformers [126]. La seconda è il readout: il modello calcola gli stati nascosti dell'intera sequenza, ma l'output head viene applicato solo alle posizioni dei marker, e di ciascuna si leggono i soli logit delle tre lettere. La terza è la calibrazione: temperatura, bias e soglia τ vengono letti dallo stesso file prodotto

in Python. La quarta è la segmentazione in frasi: PySBD non esiste per Swift, e la regola di segmentazione della Sezione 5.3 è stata riprodotta con il tokenizer di frasi del sistema operativo [127], aggiungendo le stesse regole per gli elenchi e per il contenuto verificabile.

Test di conformità. Prima di costruire l'interfaccia, il porting è stato confrontato con Python su 200 risposte di T1, stratificate per numero di frasi come il sottoinsieme usato per la latenza, per un totale di 1,747 marker. Python esporta, per ogni risposta, gli identificativi dei token, le posizioni dei marker, i logit, le probabilità calibrate e le etichette; Swift deve riprodurli (Tabella 8.2). Gli identificativi dei token e le posizioni dei marker coincidono in tutte le 200 risposte con entrambi i modelli. Con il 3B, il modello predefinito dell'applicazione, la massima differenza tra le probabilità calibrate è 0.005 e le etichette coincidono tutte: a parità di input, i risultati della tesi valgono quindi anche per il verificatore dell'applicazione. Con il 0.5B tre frasi su 1,747 superano una differenza di 0.01, con un massimo di 0.031, e le etichette coincidono nel 99.71 % dei casi; ogni disaccordo riguarda una frase la cui probabilità di supporto cade a meno di 0.01 dalla soglia. Una causa plausibile, non verificata, è un diverso ordine delle somme in precisione ridotta, che pesa di più sul modello piccolo. Lo stesso test confronta in Swift il percorso con la cache, che riusa le fonti o l'inizio di una risposta già verificata dopo la modifica di un token, con il passaggio senza cache: le probabilità differiscono al più di 0.007 con il 3B e di 0.019 con il 0.5B, lo stesso ordine di grandezza osservato in Python (Sezione 7.9.1).

Tabella 8.2: Test di conformità tra l'implementazione Swift e quella Python su 200 risposte di T1 (1,747 marker). I logit sono calcolati in Swift sugli stessi identificativi dei token prodotti da Python.

Controllo	GroundOne 3B	GroundOne 0.5B
Identificativi dei token e posizioni dei marker identici	200/200	200/200
Massima differenza tra i logit	0.070	0.172
Massima differenza tra le probabilità calibrate	0.005	0.031
Frasi con differenza di probabilità sotto 0.01	100 %	99.83 %
Etichette servite identiche	100 %	99.71 %
Massima differenza tra le probabilità con e senza cache	0.007	0.019

Anche la velocità è quasi la stessa. Sulle stesse 200 risposte, la verifica richiede in media 2.05 secondi in Swift contro 2.04 in Python con il 3B, meno dell'1 % in

più, e 0.335 contro 0.333 secondi con il 0.5B; sono medie, mentre il Capitolo 7 riporta le mediane. La segmentazione, infine, produce le stesse frasi di PySBD nel 98.4 % delle 2,647 risposte di T1. Le differenze residue riguardano soprattutto titoli abbreviati e citazioni che attraversano più frasi. Senza tre regole aggiuntive, che non spezzano la frase dopo le iniziali e le abbreviazioni comuni né prima di una parola minuscola e che uniscono i simboli di elenco alla frase seguente, l'accordo scenderebbe al 95.2 %.

8.5 Libreria e recupero dei documenti

La libreria dell'applicazione è formata dalle fonti di T1: i 147 articoli di cronaca CNN e Daily Mail del task di summarization e i 450 passaggi web di MS MARCO del question answering, legati alle 150 domande reali da cui provengono. Le schede strutturate di Yelp, in formato JSON, sono escluse, perché non sono documenti con cui conversare. I documenti appartengono così al dominio in cui GroundOne è stato addestrato e calibrato, e le probabilità mostrate all'utente dovrebbero conservare in buona parte il loro significato. Non è stato misurato: generatore, prompt e contesto composto da più passaggi differiscono comunque da quelli di RAGTruth.

Ogni documento viene diviso in passaggi di circa 140 parole, allineati ai confini delle frasi, che conservano il file di origine e la posizione nel testo. Il recupero è ibrido. Un indice full-text di SQLite [128] ordina i passaggi con BM25[1], mentre un piccolo modello di embedding, bge-small-en-v1.5 [130], eseguito anch'esso con MLX, li ordina per similarità semantica. Le due classifiche vengono fuse con la reciprocal rank fusion[2], e ogni documento può contribuire con al massimo tre passaggi, così che una domanda di confronto raggiunga fonti diverse. I sei passaggi recuperati, preceduti dalla domanda, formano il documento che GroundOne legge, nella stessa forma del question answering di RAGTruth.

Sulle 150 domande reali di MS MARCO, il recupero ibrido riporta fra i sei passaggi tutti i passaggi originali della domanda, con BM25 da solo come con la fusione. Il risultato è però ottimistico per costruzione: nella libreria ogni passaggio è preceduto dalla propria domanda, usata come titolo, e la domanda posta è identica. La misura conferma che l'indice funziona, non che il recupero sia robusto a domande formulate liberamente.

[1]BM25 è una funzione di punteggio classica del recupero dell'informazione: premia i passaggi che contengono i termini della domanda, pesando di più i termini rari nella collezione e attenuando l'effetto delle ripetizioni e della lunghezza del passaggio [129].

[2]La *reciprocal rank fusion* assegna a ogni passaggio la somma, sulle classifiche da combinare, di $1/(60 + r)$, dove r è la posizione del passaggio in ciascuna classifica: un passaggio ben piazzato in entrambe supera uno che compare in testa a una sola [131].

8.6 L'uso dell'applicazione

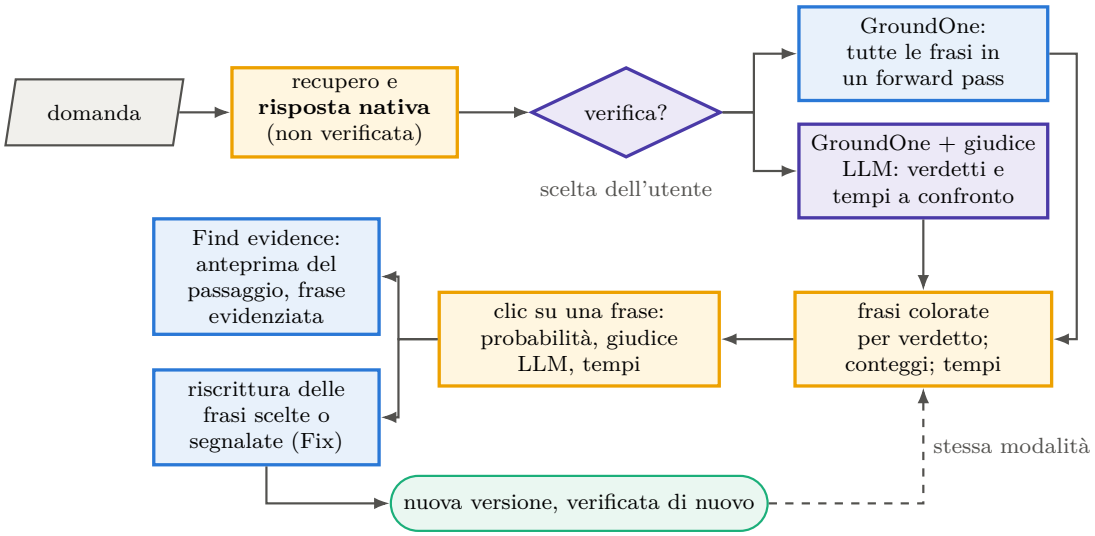


Figura 8.2: Il flusso d'uso. La risposta compare come l'ha scritta il generatore; la verifica, con GroundOne o con GroundOne e il giudice LLM, e la riscrittura avvengono solo su richiesta, e ogni riscrittura produce una nuova versione verificata di nuovo con la stessa modalità.

Il flusso d'uso è riassunto nella Figura 8.2. L'utente pone una domanda, oppure sceglie uno degli esempi proposti nella schermata iniziale. Il generatore riceve i passaggi recuperati e scrive una risposta in più paragrafi, che compare così come è stata generata, senza alcun intervento (Figura 8.3). Solo a questo punto l'utente decide se verificarla, e come: con il solo GroundOne, oppure con GroundOne e il giudice LLM, per confrontare verdetti e tempi. La separazione è voluta: mostrando per prima la risposta nativa, l'effetto della verifica resta visibile, invece di consegnare direttamente una risposta già filtrata. La separazione ha anche un vantaggio di costo. Le fonti sono note prima della risposta, quindi, appena il generatore ha finito, GroundOne legge in background istruzioni e fonti nella propria KV cache mentre l'utente legge la risposta, e la verifica, se richiesta, legge soltanto la risposta. Sulle 200 risposte della misura di latenza, con il 3B la prima verifica scende in mediana da 2.11 a 0.59 secondi (3.6 volte), mentre la lettura anticipata, 1.41 secondi, occupa la GPU quando sarebbe altrimenti inattiva; con il 0.5B la verifica scende da 0.35 a 0.10 secondi. Se l'utente chiede la verifica prima che la lettura anticipata sia finita, la verifica la attende invece di ripeterla e costa quanto senza lettura anticipata (2.11 secondi in mediana con il 3B). Il servizio Python offre lo stesso meccanismo con una chiamata dedicata (`/v1/prefetch`).

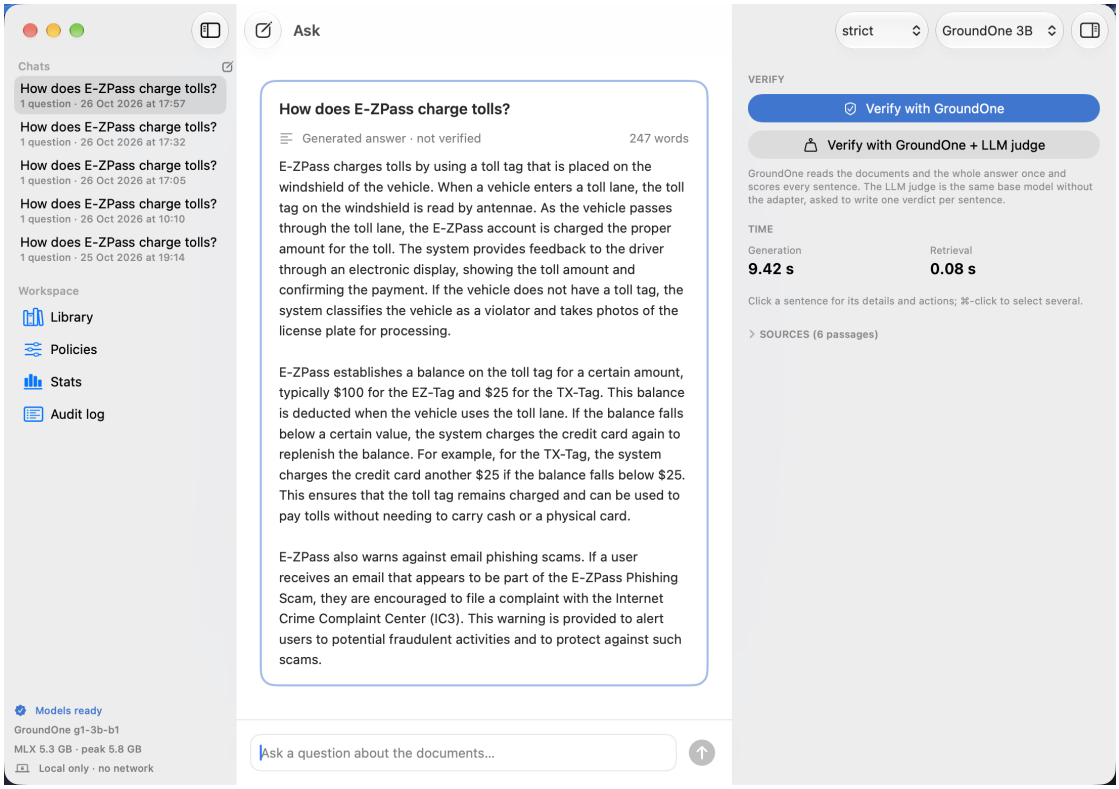


Figura 8.3: La risposta nativa del generatore alla domanda "How does E-ZPass charge tolls?", prima di qualunque verifica. A destra le due modalità di verifica.

La verifica di GroundOne, in entrambe le modalità, legge l'intera risposta in un solo forward pass: tutte le frasi ricevono il loro verdetto insieme, e una risposta con molte frasi non richiede più passaggi. Dopo la verifica le frasi si colorano: verde tenue per le frasi supportate, rosso per quelle contraddette, arancione per quelle non menzionate dal documento; le frasi senza contenuto verificabile restano in grigio (Figura 8.4). Il pannello laterale riporta i conteggi, la soglia τ, i tempi di generazione, di verifica e, se richiesto, del giudice LLM, e le frasi su cui GroundOne e il giudice LLM non concordano.

Ogni frase è selezionabile. Un clic mostra, nel pannello, le tre probabilità calibrate, il verdetto del giudice LLM e i tempi; con il tasto Comando si possono selezionare più frasi (Figura 8.5). Da qui l'utente può chiedere l'evidenza a supporto, oppure la riscrittura delle frasi selezionate. In assenza di selezione, un pulsante riscrive tutte le frasi segnalate secondo la policy scelta. Ogni riscrittura produce una nuova versione della risposta, verificata di nuovo con la stessa modalità, e un selettore permette di confrontare le versioni.

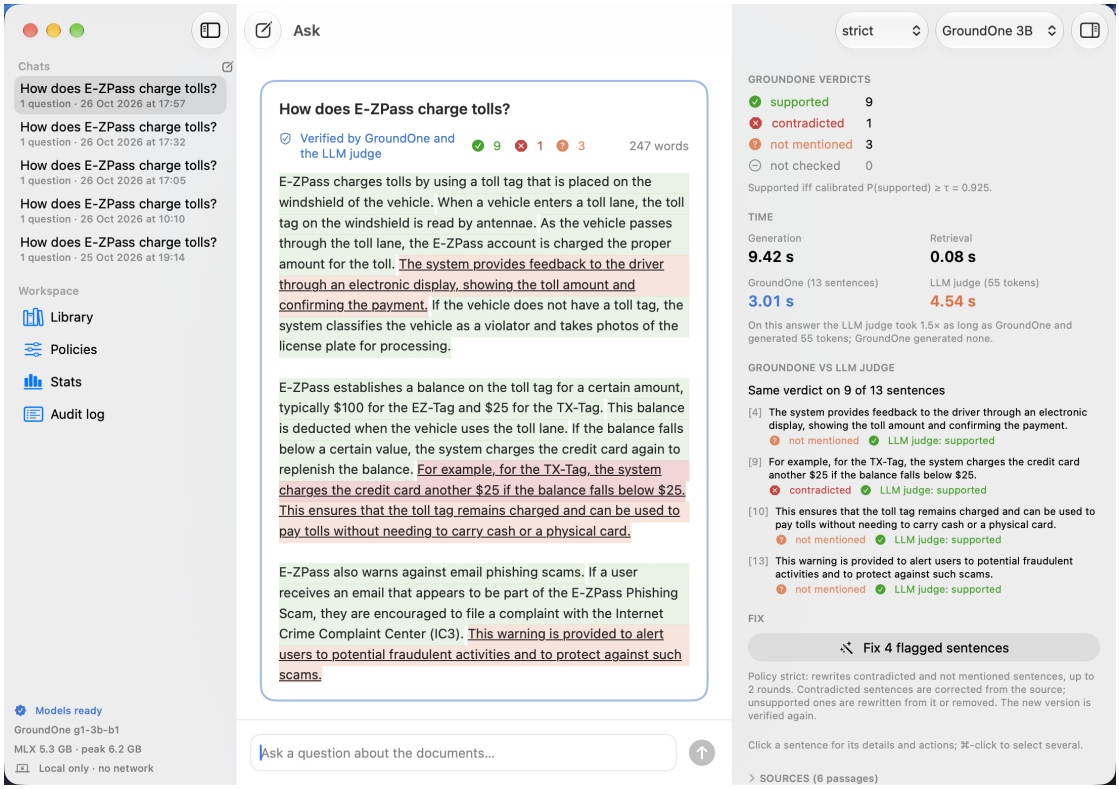


Figura 8.4: La stessa risposta dopo la verifica con GroundOne e il giudice LLM. Le frasi sono colorate secondo il verdetto di GroundOne; il pannello riporta conteggi, tempi e disaccordi con il giudice LLM.

Evidenza. GroundOne indica se una frase è supportata, ma non da quale passaggio (Sezione 9.2). L'applicazione ricostruisce l'informazione in due passi. Nel primo verifica la risposta contro ciascun passaggio recuperato separatamente, con un forward pass per passaggio, e conserva il passaggio in cui la frase ottiene la probabilità di supporto più alta e quello in cui ottiene la probabilità di contraddizione più alta, ciascuno solo se quel passaggio, da solo, produce quel verdetto; il passaggio a sostegno viene mostrato per primo. Nel secondo, dentro il passaggio scelto, individua la frase più vicina a quella della risposta, pesando le parole condivise in base alla loro rarità nel passaggio. L'anteprima del documento si apre con quel tratto evidenziato (Figura 8.6). È il primo prototipo del readout per passaggio indicato tra gli sviluppi futuri (Sezione 10.2). Non è stato valutato, perché RAGTruth non indica quale passaggio sostenga una frase, e l'applicazione lo presenta come evidenza suggerita da GroundOne. Il calcolo avviene solo su richiesta e viene conservato: con sei passaggi costa sei forward pass, cioè alcuni secondi con il 3B, e non modifica i tempi della verifica principale.

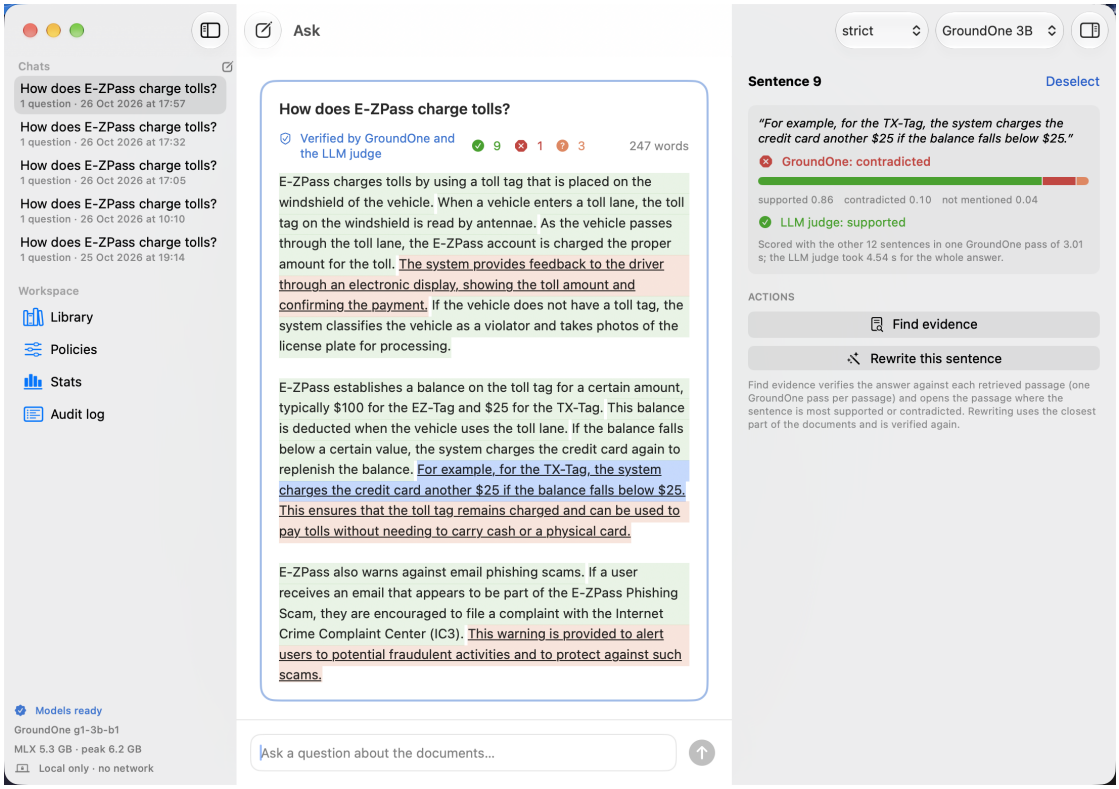


Figura 8.5: Il pannello di una frase selezionata: probabilità calibrate di GroundOne, verdetto del giudice LLM, tempi e azioni disponibili.

Riscrittura mirata. La riscrittura segue un principio dei cicli di verifica e revisione che si sono dimostrati efficaci in letteratura: un critico esterno, o un'evidenza recuperata, segnala gli errori e il generatore modifica soltanto ciò che è stato segnalato [132, 133], mentre la correzione spontanea, senza un segnale esterno, non migliora in modo affidabile le risposte [134]. GroundOne è il critico, ed è economico: verificare di nuovo costa un solo prefill, e nemmeno completo. Le istruzioni e le fonti, già lette in anticipo o alla prima verifica, restano nella KV cache (Sezione 4.2), quindi la nuova versione richiede soltanto la lettura della risposta riscritta, che nelle misure della Sezione 7.9.1 rende la verifica 3.4 volte più rapida con il 3B. Resta in cache anche la parte della risposta che precede la prima frase riscritta, insieme ai verdetti delle sue frasi, quindi la lettura riparte dalla prima modifica: quando viene riscritta l'ultima frase, la verifica è circa sei volte più rapida che con le sole fonti in cache (Tabella 7.4). Il giudice LLM, quando è richiesto, riusa la cache delle fonti, ma riscrive tutti i propri verdetti; il pannello dei tempi indica quanti token sono stati riusati. Per ogni frase da riscrivere, il generatore riceve una richiesta breve, con la frase e il solo estratto del documento che la riguarda, e

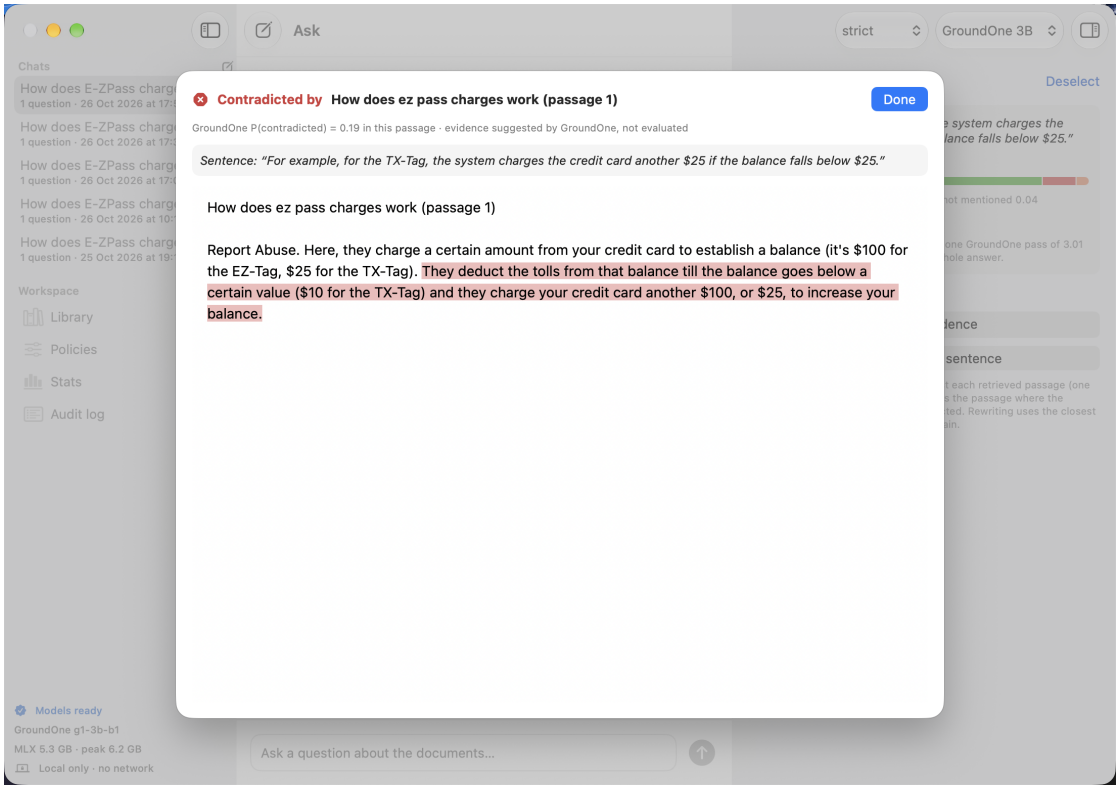


Figura 8.6: L'evidenza per una frase: il passaggio che, secondo GroundOne, contraddice più nettamente la frase, con il tratto più vicino evidenziato.

un'istruzione che dipende dal tipo di errore. Una frase contraddetta va corretta con i fatti della fonte, e non può essere cancellata: se il generatore non restituisce una frase utilizzabile, quella originale resta al suo posto e viene ripresentata al giro successivo. Una frase non menzionata va riscritta con ciò che la fonte dice sullo stesso punto, oppure tolta se la fonte non ne parla. In entrambi i casi l'istruzione chiede esplicitamente di non restituire la frase invariata. Se il generatore la ricopia comunque, cosa che con un modello piccolo accade, la richiesta viene ripetuta una volta citando la copia e respingendola; se anche il secondo tentativo restituisce la stessa frase, la frase resta com'è, segnalata, e il pannello indica che il generatore non è riuscito a correggerla. Nei giri successivi non viene ritentata, perché con la decodifica greedy la risposta sarebbe la stessa. Le altre frasi restano invariate. Il numero massimo di giri e le classi da correggere sono fissati dalla policy.

Policy e soglia. Una policy è un piccolo file JSON che stabilisce quali verdetti vanno corretti, quanti giri di riscrittura sono ammessi, che cosa fare se l'errore persiste (evidenziare, nascondere la frase o astenersi, un'azione che applica il ciclo

batch da riga di comando, mentre l'interfaccia evidenzia sempre) e quale soglia usare: quella stimata sul dev set oppure una scelta dall'utente. Le due policy predefinite corrispondono alle due letture già introdotte nella tesi (Sezione 4.4): la policy strict corregge sia le frasi contraddette sia quelle non menzionate, la policy lenient soltanto le prime.

Conversazioni e statistiche. Le domande sono organizzate in conversazioni separate, che si possono rinominare, cancellare e riprendere in qualunque momento. Una sezione dedicata raccoglie le statistiche di tutte le verifiche eseguite nell'applicazione, anche nelle sessioni precedenti (Figura 8.7): il tempo di GroundOne e quello del giudice LLM in funzione del numero di frasi, l'accordo tra i due sulle stesse frasi, la distribuzione dei verdetti e il costo che la stessa verifica avrebbe avuto con un giudice LLM in cloud. Il costo usa gli stessi prezzi di listino della Tabella 9.1: i token di ingresso sono quelli del documento e della risposta più l'istruzione, quelli di uscita sono i token effettivamente scritti dal giudice LLM locale oppure, se il giudice LLM non è stato eseguito, il loro numero medio per frase misurato nella tesi. Dal costo si sottrae quello dell'elettricità consumata in locale, stimato dal tempo di verifica e dalla potenza misurata nella Sezione 7.10.

Persistenza. Tutti i dati dell'applicazione risiedono sul disco locale, nella cartella di supporto dell'applicazione prevista da macOS, senza alcun database server (Tabella 8.3). La cartella di supporto è stata preferita a quelle dei documenti dell'utente per una ragione pratica: macOS protegge le cartelle Scrivania e Documenti e ne subordina l'accesso a un'autorizzazione esplicita, che un'applicazione dovrebbe chiedere all'avvio.

8.7 Caso di studio: errori iniettati

Le risposte generate su domande libere non hanno un'etichetta di riferimento: misurare su di esse quanto il ciclo di verifica e riscrittura migliori la risposta richiederebbe un giudizio indipendente su ogni frase riscritta. Il caso di studio usa quindi errori iniettati, la cui posizione è nota in anticipo e non dipende da GroundOne.

Protocollo. Fra le risposte di T1 le cui etichette di riferimento sono tutte "supportata" e che GroundOne 3B accetta per intero, ne sono state estratte 100, dai tre task: 46 di summarization, 29 di question answering e 25 di data-to-text. In ciascuna è stato iniettato un solo errore, di quattro tipi, 25 per tipo: un numero sostituito con un valore assente dal documento, un nome sostituito con uno inventato, una data spostata, oppure una frase inventata inserita dopo

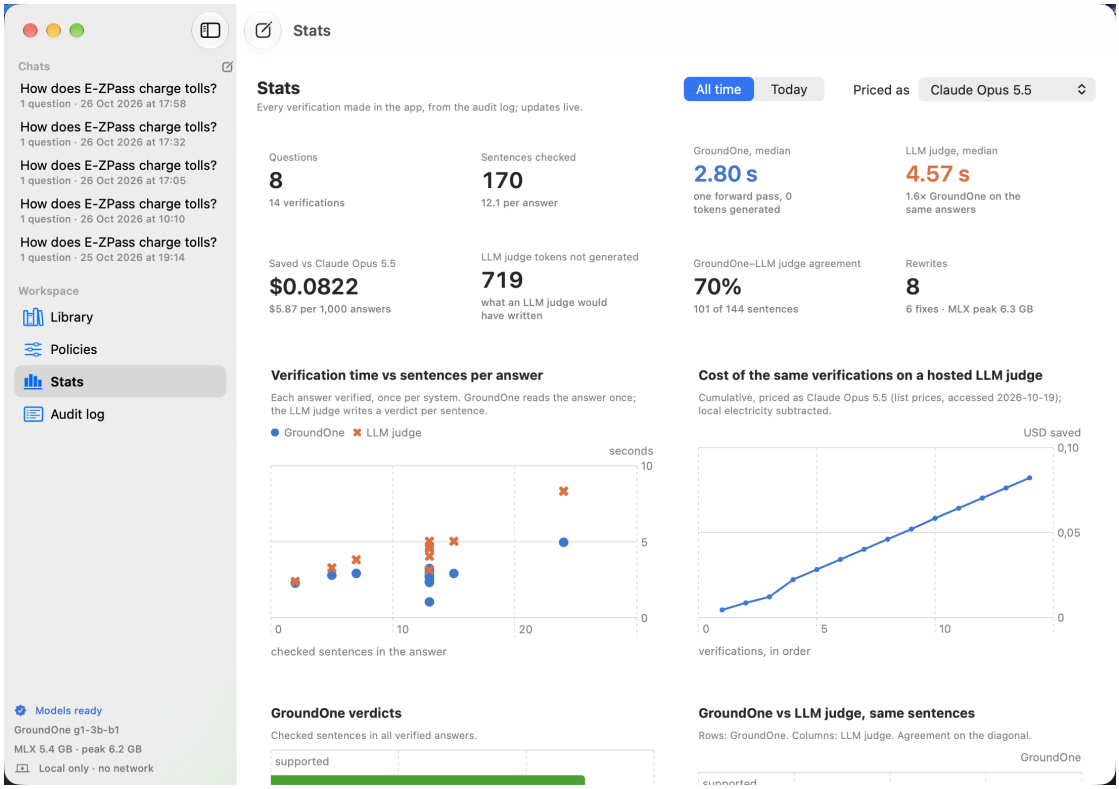


Figura 8.7: La sezione delle statistiche: indicatori principali, tempo di verifica in funzione del numero di frasi per GroundOne e per il giudice LLM, costo della stessa verifica su un giudice LLM in cloud.

una frase esistente. Le risposte passano poi per lo stesso motore dell'applicazione: GroundOne verifica la risposta, il giudice LLM la verifica a sua volta per il confronto, e una policy strict, che evidenzia le frasi che restano segnalate, riscrive le frasi segnalate fino a due giri. Un errore conta come rimosso quando il valore sbagliato non compare più nel testo, o quando nessuna frase resta simile a quella inventata. Il caso di studio non usa il recupero: il documento è quello di T1.

Risultati. La Tabella 8.4 e la Figura 8.8 riassumono il caso di studio. In 98 risposte la frase con l'errore viene valutata, in una di esse unita dal segmentatore alla frase precedente; nelle altre due è unita a una frase introduttiva priva di contenuto verificabile, e non viene valutata. GroundOne segnala l'errore in 97 delle 98 risposte, il giudice LLM in 84. Il ciclo riduce le risposte che contengono ancora l'errore dal 100 % all'8 % dopo un giro e al 6 % dopo due, secondo il conteggio automatico. Il modo in cui gli errori vengono rimossi conta quanto il numero. Per i numeri e le date sostituiti, nella maggior parte dei casi il generatore ripristina il

Tabella 8.3: Persistenza dei dati nell'applicazione. Tutto risiede sul disco locale.

Dati	Formato	Uso
Conversazioni	Un file JSON per conversazione.	Domande, versioni della risposta, verdetti, tempi; ripresa delle conversazioni.
Registro delle azioni	File JSONL in sola aggiunta.	Una riga per ogni generazione, verifica e riscrittura; base delle statistiche e del registro consultabile.
Libreria	Database SQLite.	Indice full-text per BM25 ed embedding dei passaggi, con l'origine di ciascun passaggio.
Policy	File JSON.	Regole di decisione e di riscrittura selezionabili.
KV cache delle fonti	Solo in memoria.	Istruzioni, ultimi documenti già letti (anche in anticipo, mentre l'utente legge la risposta) e ultima risposta verificata, riusati dalle verifiche successive; non è salvata su disco.

valore della fonte: 19 numeri e 16 date su 25. Le frasi inventate vengono invece cancellate, tutte e 25, ed è la correzione appropriata. I nomi inventati, infine, sono etichettati correttamente come non menzionati, e per questo vengono per lo più tolti, 18 su 25, anziché sostituiti con quello originale, 7 su 25: la frase perde l'errore, ma anche l'informazione. Il controllo delle copie interviene tre volte: in tre frasi il generatore restituisce la stessa frase anche al secondo tentativo, e la frase resta segnalata. Delle sei risposte che conservano l'errore, tre restano segnalate e vengono quindi evidenziate dalla policy. Nelle altre tre l'errore non viene mai segnalato: in una la probabilità di supporto, 0.93, supera di poco la soglia di 0.925; nelle altre due la frase iniettata non riceve un proprio verdetto.

Il tipo di errore decide la riparazione. Ripetere il caso di studio con GroundOne 0.5B come verificatore mostra perché il verdetto a tre classi conta, e non soltanto la segnalazione. Il 0.5B segnala l'errore in 97 risposte su 98, come il 3B, ma etichetta quasi tutti i numeri e le date sostituiti come non menzionati (44 su 50), mentre il 3B li riconosce come contraddetti (40 su 50). Per una frase non menzionata la riscrittura può togliere la frase, e il generatore lo fa: con il 0.5B gli errori rimossi cancellando la frase sono 84 e quelli rimossi ripristinando il valore appena 12. Le risposte che conservano l'errore scendono al 3 %, ma a prezzo di informazione persa e di molti falsi allarmi: il 0.5B segnala il 17 % delle altre frasi,

Tabella 8.4: Caso di studio sugli errori iniettati: 100 risposte di T1, un errore ciascuna, GroundOne 3B e generatore Qwen2.5-3B-Instruct a 4 bit nello stesso processo, senza il modello di embedding, con la KV cache delle fonti attiva. Rilevamento calcolato sulle 98 risposte in cui la frase con l'errore viene valutata.

Misura	Valore
Frase con l'errore segnalata da GroundOne	97 su 98
Frase con l'errore segnalata dal giudice LLM	84 su 98
Falsi allarmi di GroundOne sulle altre frasi	1.8 %
Risposte che contengono ancora l'errore: senza ciclo, dopo uno e dopo due giri	100 %, 8 %, 6 %
Errori rimossi ripristinando il valore della fonte	42
Errori rimossi riscrivendo la frase	1
Errori rimossi cancellando la frase	51
Errori rimasti: ancora segnalati / mai segnalati	3 / 3
Frasi che il generatore ricopia anche al secondo tentativo	3
Altre frasi rimaste identiche	98.0 %
Risposte accettate da GroundOne al termine	94 %
Tempo mediano per risposta: GroundOne, giudice LLM, riscrittura per giro	1.74 s, 2.36 s, 0.92 s
Memoria allocata da MLX: dopo il caricamento e al picco	5.1 GB, 6.7 GB

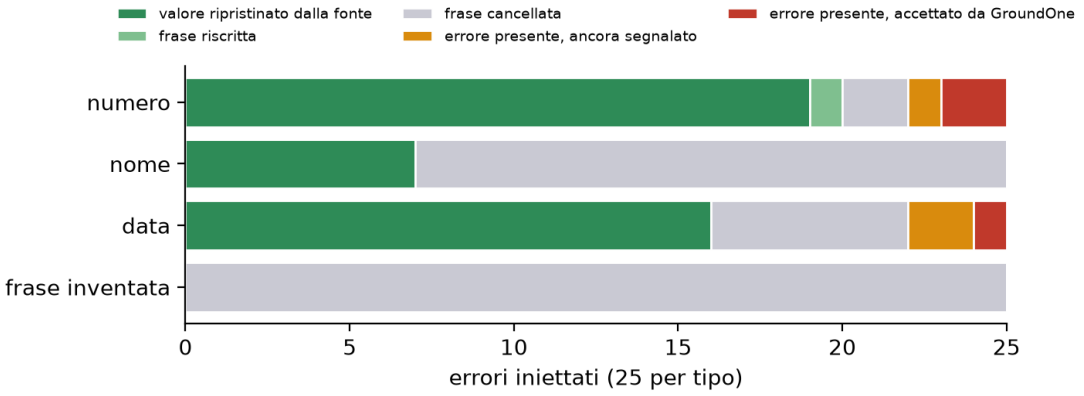


Figura 8.8: Esito di ciascun errore iniettato dopo il ciclo, per tipo di errore, con GroundOne 3B: valore ripristinato dalla fonte, frase riscritta, frase cancellata, errore ancora presente e segnalato, errore accettato da GroundOne.

che sono corrette, e solo l'84 % di esse resta invariato. Il confronto con l'1.8 % del 3B favorisce quest'ultimo, perché le risposte sono state scelte fra quelle che il 3B accetta per intero. La distinzione fra frase contraddetta e frase non menzionata, che il Capitolo 4 motiva in astratto, qui decide se la correzione ripristina l'informazione o la elimina.

Tempi. Il confronto dei tempi conferma il quadro della Sezione 7.9. Su queste risposte, con una mediana di circa 770 token in ingresso a GroundOne e di sei frasi valutate, il tempo mediano del giudice LLM è 1.36 volte quello di GroundOne (2.36 contro 1.74 secondi, entrambi alla prima lettura delle fonti), e il giudice LLM scrive una ventina di token, mentre GroundOne non ne genera nessuno. La differenza è piccola perché il giudice LLM sintetico scrive poco e le risposte sono brevi. Il confronto sul rilevamento, 97 errori segnalati contro 84, favorisce invece GroundOne per costruzione: le risposte sono state scelte fra quelle che GroundOne accetta per intero, un filtro che il giudice LLM non ha superato, e i falsi allarmi del giudice LLM sulle frasi corrette non sono stati misurati.

Un confronto a parità di calcolo. Su 60 nuove risposte di T1, generate dal modello per ciascun task, il ciclo completo, cioè risposta, verifica e fino a due giri di riscrittura mirata, è stato confrontato con una strategia che non corregge nulla: generare fino a tre risposte con campionamento e tenere la prima che GroundOne accetta. La prima risposta è accettata nel 52 % dei casi. Al termine, il ciclo porta le risposte accettate al 70 %, la generazione multipla al 62 % (42 e 37 risposte su 60, una differenza piccola su questo campione). Il ciclo genera però la metà dei token, 115 contro 218 in mediana, in un tempo simile, 6.3 secondi contro 7.0: anche la generazione multipla verifica ogni campione sullo stesso documento, e riusa quindi la sua KV cache. Riscrivere le sole frasi segnalate, quindi, accetta almeno tante risposte quante rigenerarle da capo, con la metà della generazione. Una parte delle risposte resta segnalata perché il generatore da 3B non riesce a correggere una frase contraddetta, che il ciclo non può cancellare.

Un generatore più grande. Il generatore si può scegliere nell'applicazione: oltre al 3B è disponibile Qwen2.5-7B-Instruct a 4 bit. Sullo stesso caso di studio il 7B corregge tutti gli errori che GroundOne segnala: le risposte che contengono ancora l'errore scendono al 3 %, cioè alle tre in cui GroundOne non lo segnala, contro il 6 % con il 3B, e quelle accettate da GroundOne salgono al 98 %. Il prezzo è il tempo e la memoria: una riscrittura costa 2.1 secondi per giro contro 0.9, e il picco di memoria allocata da MLX sale a 9.2 GB contro 6.7. Sulle dodici domande di esempio della libreria, inoltre, il 7B scrive risposte di lunghezza simile (276 parole in mediana contro 250) in più del doppio del tempo (17.7 secondi contro 7.6), e aggiunge più contenuto che le fonti non riportano: GroundOne considera

supportato il 66 % delle sue frasi, contro l'85 % di quelle del 3B. Per questo il 3B resta il generatore predefinito.

Come leggere i risultati. Tre avvertenze delimitano la portata del caso di studio, a cui va aggiunta una nota di procedura: il prompt di riscrittura è stato scelto dopo aver esaminato un primo insieme disgiunto di risposte con errori iniettati, ma il controllo delle copie è stato aggiunto in seguito e misurato di nuovo sullo stesso insieme riportato qui, che quindi ha orientato anche il progetto finale. La prima riguarda il rilevamento. Le risposte sono state scelte fra quelle che GroundOne accetta, e gli errori iniettati sono netti: valori e nomi assenti dal documento. L'alta percentuale di errori segnalati mostra quindi il funzionamento del ciclo, non la recall di GroundOne, che è misurata nel Capitolo 7. La seconda riguarda le frasi riscritte: non hanno un'etichetta di riferimento, e la loro correttezza è giudicata soltanto da GroundOne, lo stesso modello che decide quando fermare il ciclo. Una riscrittura che cade in un punto cieco del modello viene quindi contata come riuscita, e il conteggio automatico registra soltanto la scomparsa dell'errore iniettato, non eventuali nuovi errori introdotti dalla riscrittura. Per questo i risultati sono espressi come risposte "accettate da GroundOne", non come risposte corrette, e il 94 % di risposte accettate comprende tre risposte che contengono ancora l'errore. La terza riguarda il generatore. Un modello da 3B a volte non sa correggere una frase e a volte la toglie: 26 dei 51 errori rimossi per cancellazione portano via anche un'informazione corretta, per cui una parte delle risposte accettate è semplicemente più breve.

8.8 Un esempio: un errore numerico sottile

La domanda della Figura 8.3 mostra in piccolo sia il valore sia i limiti del sistema. Fra le tredici frasi della risposta, il generatore scrive che, per la tessera TX-Tag, la carta di credito viene ricaricata di 25 dollari quando il saldo scende sotto i 25 dollari. Il passaggio recuperato dice invece che la ricarica avviene quando il saldo scende sotto i 10 dollari. La frase ricalca la fonte quasi parola per parola, ed è proprio il tipo di errore che la Sezione 7.12 indica come il più difficile per GroundOne. GroundOne le assegna una probabilità di supporto di 0.86, sotto la soglia di 0.925, e indica la contraddizione come errore più probabile; il giudice LLM la considera supportata. GroundOne segnala inoltre come non menzionate tre frasi che aggiungono dettagli o deduzioni assenti dai documenti, per esempio che il display mostri l'importo del pedaggio, mentre il giudice LLM le accetta tutte. La riscrittura, però, non riesce: il generatore da 3B restituisce la stessa frase, con lo stesso importo sbagliato, anche al secondo tentativo, che cita la copia e la respinge.

L'applicazione lo rileva e lascia la frase segnalata: la qualità del ciclo dipende anche dal generatore.

8.9 Probabilità calibrate e soglia di decisione

L'esempio aiuta a chiarire un punto che l'uso dell'applicazione rende evidente. Le probabilità di GroundOne sono calibrate: su T1, fra le frasi a cui il 3B assegna una probabilità di supporto compresa tra 0.80 e 0.925, il 93 % è effettivamente supportato. Eppure tutte queste frasi vengono segnalate, perché la soglia è 0.925. Le due cose non sono in contraddizione. La calibrazione riguarda il significato delle probabilità; la soglia è una regola di decisione, scelta sul dev set per massimizzare la balanced accuracy a tre classi (Sezione 4.4). Poiché la grande maggioranza delle frasi è supportata, circa l'88 % nel dev set e il 91 % in T1, una metrica che pesa allo stesso modo le tre classi spinge la soglia verso l'alto: per trovare gli errori, rari, accetta molti falsi allarmi (Tabella 8.5).

Tabella 8.5: Effetto della soglia sulle frasi di T1 con GroundOne 3B: quota di frasi segnalate e recall per classe.

τ	Frasi segnalate	Recall supportate	Recall contraddette	Recall non menzionate	Balanced accuracy
0.5	7 %	0.98	0.56	0.60	0.71
0.8	15 %	0.92	0.71	0.83	0.82
0.925	25 %	0.82	0.78	0.89	0.83

Passare da 0.8 a 0.925 aggiunge appena 0.01 di balanced accuracy, ma porta le frasi segnalate dal 15 % al 25 %, quando gli errori veri in T1 sono il 9 %. D'altra parte, l'errore sulla tessera TX-Tag sta proprio in questa fascia: con una soglia di 0.8 sarebbe passato inosservato. Il caso di studio offre l'esempio speculare: l'unico errore valutato che GroundOne lascia passare ha una probabilità di supporto di 0.93, appena sopra la soglia. Nessuna delle due scelte è sbagliata. Una soglia alta conviene quando un errore non segnalato costa molto, una soglia più bassa quando i falsi allarmi disturbano l'utente. È questo il vantaggio pratico delle probabilità calibrate: la soglia si può scegliere in modo consapevole, e l'applicazione la espone come parametro della policy. L'etichetta mostrata per una frase sotto soglia va letta di conseguenza: indica il tipo di errore più probabile, non una certezza, ed è per questo che il pannello riporta sempre le tre probabilità.

8.10 Limiti

Il generatore. Il generatore da 3B scrive spesso risposte più brevi di quanto richiesto, fra 122 e 440 parole con una mediana di 250 sulle domande di esempio, contro le almeno 300 chieste dal prompt, e non sempre riesce a correggere una frase segnalata: nell'esempio della Sezione 8.8 restituisce la frase invariata. Il 7B a 4 bit corregge più errori, ma scrive risposte di lunghezza simile, è circa due volte più lento e aggiunge più contenuto che le fonti non riportano (paragrafo *Un generatore più grande*).

Le frasi riscritte. La correttezza delle frasi riscritte è giudicata solo da GroundOne. Un controllo indipendente, con un secondo verificatore come un encoder specializzato oppure con una lettura umana di un campione, permetterebbe di misurare quante riscritture accettate siano davvero corrette.

L'evidenza. L'evidenza suggerita non è stata valutata, perché i dati non indicano quale passaggio sostenga ciascuna frase. È una funzione dimostrativa.

Ambito. L'applicazione eredita i limiti di GroundOne (Sezione 9.2): verifica documenti e risposte in inglese, nel dominio dei dati di addestramento, e si basa sui documenti recuperati, non sulla verità del mondo. Domande che riguardano l'intera libreria, per esempio una panoramica dei documenti, non sono alla portata di un sistema che recupera sei passaggi. L'interfaccia, infine, gira soltanto su macOS, e il generatore e il verificatore 3B sono soggetti alla licenza di Qwen per la ricerca (Sezione 6.6): l'applicazione è un prototipo di ricerca, non un prodotto.

Capitolo 9

Discussione, limiti e minacce alla validità

Questo capitolo interpreta i risultati alla luce delle cinque domande di ricerca. Indica poi ciò che gli esperimenti non possono dimostrare e quali scelte potrebbero averli distorti.

9.1 Quando conviene un decision model specialista

Specializzazione (RQ1). A rendere GroundOne accurato è l'addestramento sulla decisione. I modelli non addestrati restano vicini al caso, mentre gli stessi modelli, una volta addestrati, raggiungono sul test set di RAGTruth una balanced accuracy a tre classi di 0.769 (0.5B) e 0.832 (3B). Superano così gli encoder specializzati in AUROC, e Rizzo-Flow, un decision model generalista otto volte più grande del 0.5B, in balanced accuracy a tre classi. Il vantaggio, però, si concentra dove si trovano i dati di addestramento. Su LLM-AggreFact il 3B si porta alla pari con il miglior encoder di piccole dimensioni, senza superarlo, e resta sotto il decision model chiuso Jev e un modello open da 27B, misurati in modo indipendente; il 0.5B rimane al di sotto dell'encoder. Su VitaminC, infine, il 3B addestrato non fa meglio di quello non addestrato.

Il confronto con d1-3B, un decision model generalista della stessa dimensione, rende esplicito il compromesso. d1-3B è già addestrato a decidere, ma su un'ampia miscela di task. Su RAGTruth è molto lontano da GroundOne, soprattutto sulle risposte lunghe; su LLM-AggreFact è alla pari con il 3B; su VitaminC è nettamente superiore. Uno specialista è dunque una scelta solida per il dominio su cui è stato addestrato, ma uno strumento debole per la verifica dei fatti in generale. All'interno

del dominio la specializzazione garantisce accuratezza e robustezza sulle risposte lunghe, a scapito del trasferimento; fuori dal dominio, invece, sono la dimensione del modello oppure un'ampia miscela di addestramento a migliorare il trasferimento.

Readout e generazione a confronto (RQ2). Il meccanismo del decision model contribuisce in due modi distinti. Il primo riguarda il costo: un solo forward pass sulla risposta sostituisce la generazione di K verdetti, per cui il tempo risparmiato cresce con la lunghezza della risposta. Quando la risposta contiene quattordici o più frasi, il risparmio arriva a un fattore di circa due rispetto a un giudice LLM sintetico e di circa sei rispetto a uno verboso. Questo rapporto complessivo è limitato dalla lettura del testo, che ogni approccio deve pagare e che occupa il 97 % del tempo di GroundOne: al netto di essa, GroundOne decide da 18 a 33 volte più in fretta di un giudice LLM sintetico e da 125 a 131 volte più in fretta di uno verboso (Sezione 7.9.1). Ne segue che ogni riduzione del prefill, come il riuso del prefisso già letto, aumenta il vantaggio relativo del readout. Con le fonti già in cache, lette in anticipo mentre l'utente legge la risposta oppure per una verifica precedente, il vantaggio sul giudice LLM sintetico, con quattordici o più frasi, sale da 1.8–2 a 3.4–3.6 volte: la cache elimina la parte condivisa e lascia al giudice il decoding, che non si può riusare. Conservando anche la versione precedente della risposta, GroundOne rilegge soltanto ciò che segue la prima frase riscritta e riusa i verdetti delle frasi precedenti, mentre il giudice deve riscriverli tutti: su tutte le risposte il vantaggio sul giudice LLM sintetico sale da 4.8 a 12 volte con il 0.5B e da 3.1 a 7.1 volte con il 3B (Tabella 7.4). Il secondo contributo, che questa tesi non aveva previsto, riguarda l'accuratezza. Con gli stessi pesi e lo stesso costo, scegliere tra le tre lettere ammissibili è più accurato che prendere il token che il modello genererebbe, con un guadagno di balanced accuracy a tre classi di 0.25 per il 0.5B e di 0.07 per il 3B. Un decision model sottoposto a fine-tuning si comprende quindi meglio come un classificatore a tre classi innestato su un modello linguistico che come un generatore che si ferma dopo un token. La distinzione pesa soprattutto per i modelli piccoli, cioè proprio per quelli che un portatile può permettersi. Il confronto con i giudici LLM, infine, misura anche l'effetto dell'addestramento: poiché i giudici LLM non sono addestrati, le ampie differenze di accuratezza rispetto a GroundOne vanno lette come l'effetto congiunto della specializzazione e del readout. La Figura 9.1 scompone il guadagno su T1 nei due passaggi, l'addestramento e il readout ristretto.

Calibrazione (RQ3). Una temperatura e un bias stimati sul dev set allineano le probabilità alle frequenze osservate sul test set dello stesso dominio, e le probabilità calibrate rendono efficace la selective prediction. Due indicazioni valgono al di là di GroundOne. La prima è che l'Expected Calibration Error, da solo, non basta a ordinare i sistemi. Dopo la stessa calibrazione, giudici LLM le cui probabilità

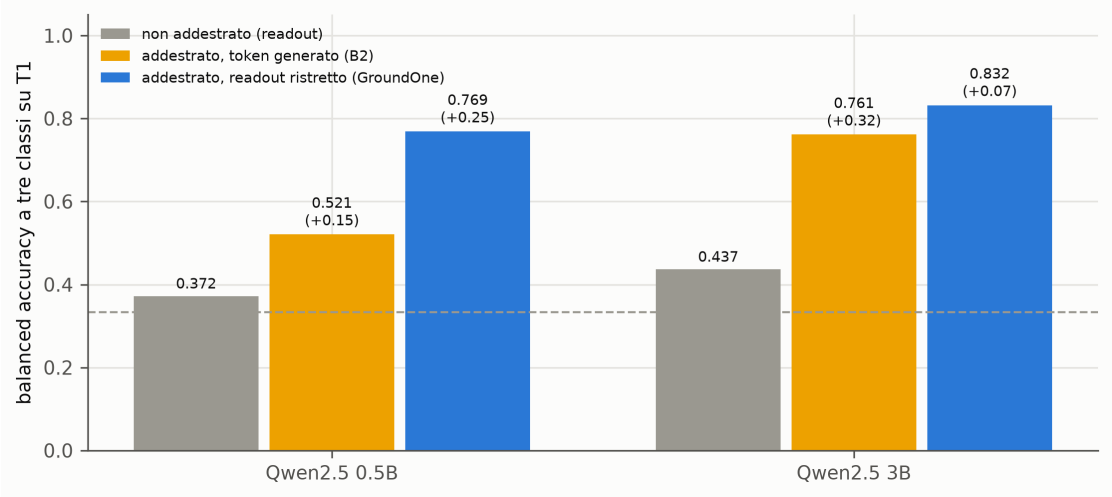


Figura 9.1: Da dove viene l'accuratezza di GroundOne su T1: lo stesso modello base non addestrato (readout, design a), addestrato ma con la decisione presa dal token che genererebbe (controllo B2, errori di formato contati come errori) e addestrato con il readout ristretto. Tra parentesi il guadagno rispetto al passaggio precedente. Il 3B non addestrato è valutato su 600 risposte; il tratteggio indica il livello casuale.

separano a malapena le classi raggiungono lo stesso ECE di GroundOne, e soltanto l'AUROC e l'AURC ne rivelano la differenza. La seconda è che decisioni e probabilità vanno ricavate in modo coerente. Se si sceglie la classe calibrata più probabile, la decisione collassa verso la classe maggioritaria; una soglia stimata sul dev set, invece, recupera la decisione bilanciata e mantiene l'etichetta coerente con la probabilità mostrata all'utente. Come mostrano i risultati su VitaminC, infine, la calibrazione vale soltanto per la distribuzione su cui è stata stimata.

Costo sul dispositivo (RQ4). Il verificatore sta comodamente nel portatile da 16 GB. Durante l'addestramento la memoria occupata raggiunge un picco di 2.6 GB con il 0.5B e di 5.9 GB con il 3B. Verificare una risposta lunga richiede 0.41 secondi con il 0.5B e 2.57 con il 3B, e l'energia, in media su risposte di ogni lunghezza, è di 5.5 e 33 joule per risposta. Il 0.5B rientra in un budget interattivo. Il 3B scambia tempo con accuratezza: leggendo ogni risposta da zero, è più lento di quanto un uso interattivo continuo richiederebbe. Nell'applicazione del Capitolo 8, però, la verifica avviene su richiesta e le fonti vengono lette in anticipo mentre l'utente legge la risposta, e sulle risposte della misura di latenza la prima verifica con il 3B richiede allora 0.59 secondi in mediana, contro 2.11 senza lettura anticipata. Le misure di energia precisano la portata dei risultati sulla velocità. Un singolo

prefill lungo assorbe più potenza del decoding token per token, per cui l'energia risparmiata è inferiore al tempo risparmiato, e la maggiore velocità non va letta come un risparmio equivalente di batteria. Il verificatore convive inoltre con un generatore nello stesso processo: insieme a un generatore 3B a 4 bit, il picco di memoria è di 6.1 GB con il 3B e di 3.3 GB con il 0.5B. La valutazione del 0.5B su T1, ripetuta senza alcun accesso alla rete, dà risultati identici bit per bit, e per il 0.5B i pesi a 8 bit non costano un'accuratezza misurabile rispetto a quelli in bf16 (Sezione 7.11). Il retriever aggiunge poco: nell'applicazione del Capitolo 8, con generatore, GroundOne 3B e modello di embedding caricati insieme, la memoria allocata da MLX raggiunge un picco di 6.2 GB durante una domanda e di 6.9 GB dopo una sessione di dodici domande, con la KV cache delle fonti già lette.

Anche il costo economico va letto con misura (Tabella 9.1). Verificare 10,000 risposte con GroundOne richiede un'energia che, al prezzo medio europeo dell'elettricità per le famiglie [135], vale meno di un centesimo di euro con il 0.5B e circa tre centesimi con il 3B. Affidare la stessa verifica a un giudice LLM in cloud, ai prezzi di listino dei fornitori [136, 137, 138], costa invece da circa un dollaro con i modelli più economici a oltre duecento con quelli di fascia più alta. Il rapporto va quindi da circa un ordine di grandezza e mezzo a quasi cinque, ma in valore assoluto i giudici LLM economici restano poco costosi, e il confronto non considera né l'acquisto dell'hardware né la qualità dei giudici LLM in cloud, che questa tesi non ha misurato. L'argomento decisivo a favore della verifica locale resta quindi l'indipendenza: i documenti non lasciano la macchina e il servizio non dipende da un fornitore esterno.

Oltre un punteggio binario (RQ5). L'output a tre classi distingue bene le frasi contraddette da quelle non menzionate nel data-to-text, il task in cui RAGTruth concentra le proprie contraddizioni. Le distingue molto meno nel question answering e nella summarization, dove nei dati di addestramento le contraddizioni sono rare. Il 3B migliora sensibilmente su questo fronte, e ciò suggerisce che la capacità del modello compensi in parte la scarsità delle contraddizioni; contraddizioni più varie in addestramento restano il rimedio più ovvio per il modello piccolo. Le policy strict e lenient e la soglia derivano tutte dalle stesse tre probabilità. L'utente può quindi cambiare la nozione di errore senza riaddestrare il modello, cosa che nessun verificatore binario consente. La Figura 9.2 riassume queste indicazioni in forma di albero decisionale.

9.2 Limiti

Una sola piattaforma e una sola famiglia di modelli. Tutti i risultati provengono da un unico portatile, un unico runtime e un'unica famiglia di modelli.

Tabella 9.1: Costo indicativo della verifica di 10,000 risposte RAG. Giudici LLM in cloud: prezzi di listino del livello standard, consultati il 19 ottobre 2026, con circa 900 token in ingresso per risposta (documento e risposta mediani di T1 più le istruzioni) e i token in uscita misurati per i giudici LLM 3B di questa tesi (36 per il giudice LLM sintetico, 248 per quello verboso). GroundOne: energia netta misurata del chip moltiplicata per il prezzo medio dell'elettricità per le famiglie nell'UE (0.29 €/kWh, secondo semestre 2025). Sono esclusi il costo dell'hardware e gli sconti per caching o elaborazione in batch.

Sistema	Prezzo ingresso / uscita (USD per Mtoken)	Giudice LLM sintetico	Giudice LLM verboso
Claude Haiku 5, gpt-6-luna	0.10 / 0.50	1.1 USD	2.2 USD
Gemini 3.5 Flash-Lite	0.30 / 2.50	3.6 USD	8.9 USD
Gemini 3.8 Flash	0.75 / 3.75	8.2 USD	16 USD
Claude Sonnet 5.5, gpt-6.1-sol, Gemini 4 Argon	2.00 / 10.00	22 USD	43 USD
Claude Opus 5.5	4.00 / 20.00	43 USD	86 USD
gpt-6-astra	10.00 / 50.00	109 USD	215 USD
GroundOne 0.5B (locale)	0.015 kWh, circa 0.004 €		
GroundOne 3B (locale)	0.092 kWh, circa 0.03 €		

Latenza ed energia dipendono dall'hardware e dall'implementazione: ciò che dovrebbe valere anche altrove sono i rapporti tra i metodi, non i valori assoluti. La latenza di GroundOne non viene confrontata con quella degli encoder né con quella dei decision model generalisti, perché questi sono stati eseguiti in runtime diversi e in condizioni che renderebbero il confronto iniquo (si veda anche il paragrafo "Una sola macchina" nella Sezione 9.3).

Stabilità dell'addestramento. Due run completi del 0.5B concordano su tutte le metriche aggregate, ma un terzo run è collassato nelle prime fasi ed è stato interrotto. La ricetta di addestramento non prevede gradient clipping e usa AdamW senza bias correction, due cause note di fine-tuning instabile [99, 98]. L'una o l'altra potrebbe spiegare il collasso, ma nessuna delle due ipotesi è stata verificata. Il 3B, inoltre, è stato addestrato una sola volta, su metà delle risposte di addestramento, e la sua variabilità al cambiare del seed resta ignota.

Dati di addestramento. RAGTruth è l'unica fonte di addestramento. Le sue contraddizioni sono concentrate nel data-to-text e, al di fuori di questo task, vengono

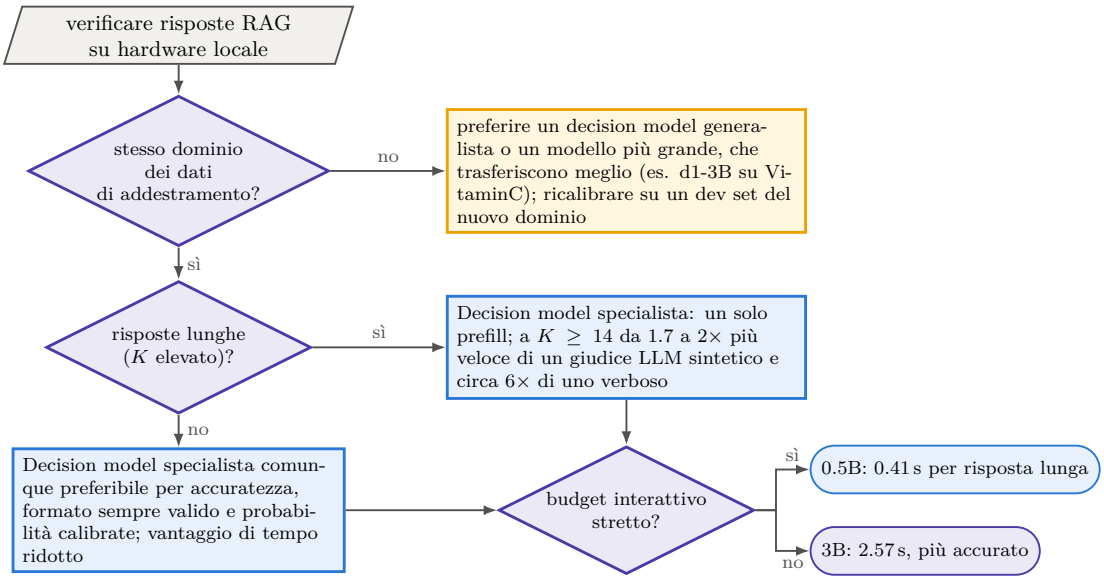


Figura 9.2: Quando conviene un decision model specialista, secondo i risultati di questa tesi. È una sintesi qualitativa: i tempi si riferiscono al portatile M4 e alle risposte con 14 o più frasi, e il trasferimento fuori dominio è quello osservato su LLM-AggreFact e VitaminC.

apprese solo in parte. I modelli, inoltre, si affidano in parte alla sovrapposizione lessicale. Quando il supporto è espresso con parole diverse, la frase appare non supportata; quando una frase copia la fonte salvo una piccola modifica, la modifica passa spesso inosservata. Questo punto cieco si riduce al crescere del modello, ma resta il limite principale di entrambi.

Ambito della decisione. La verifica avviene frase per frase e soltanto rispetto al documento recuperato. Una frase vera nel mondo ma assente dal documento conta quindi come non menzionata: è il comportamento corretto per la groundedness, ma non per la verifica dei fatti. Le frasi prive di contenuto verificabile vengono escluse da una regola, e la segmentazione stessa può dividere o accorpare le affermazioni in modo diverso da un lettore umano. Infine, il verdetto su una frase dipende soltanto dal documento e dalle frasi che la precedono.

Lingua. Tutti i dati di addestramento e di test sono in inglese, quindi GroundOne è stato addestrato, calibrato e misurato soltanto su documenti e risposte in inglese. Il modello base Qwen2.5 è multilingue [23], ma non è stato misurato quanto la specializzazione appresa si trasferisca ad altre lingue, né se la calibrazione resti valida: la calibrazione stimata su RAGTruth non si trasferisce nemmeno a un

altro dominio inglese come VitaminC. Un uso con documenti o risposte in un'altra lingua, o in lingue diverse tra loro, richiede quindi una nuova valutazione.

Contesti composti da più documenti. Quando la risposta è scritta a partire da più passaggi recuperati, GroundOne li legge concatenati come un unico documento, come nel question answering di RAGTruth. Restano però tre limiti. Il primo riguarda la lunghezza: in addestramento documento e risposta non superano 2,048 token, per cui un contesto più lungo esce dalla distribuzione su cui il modello è stato misurato e va diviso in frammenti, conservando per ogni frase la probabilità di supporto più alta, come avviene su LLM-AggreFact; un fatto che richiede di combinare due frammenti diversi può allora sfuggire. Il secondo riguarda le fonti in conflitto: quando un passaggio sostiene una frase e un altro la contraddice, il verdetto atteso non è definito in modo univoco, e RAGTruth non contiene casi di questo tipo. Il terzo riguarda l'attribuzione: GroundOne indica se una frase è supportata, ma non da quale passaggio; un primo prototipo, non valutato, è descritto nella Sezione 8.6.

Portata statistica. Gli intervalli bootstrap descrivono la variabilità del test set, non quella dell'addestramento. Inoltre, una settantina di confronti sono stati sottoposti a test senza correzione per confronti multipli. Per questo le conclusioni poggiano su effetti ben lontani dallo zero, e non si rivendicano differenze su LLM-AggreFact e VitaminC inferiori alla dispersione tra seed. Diverse baseline, infine, sono state valutate su sottocampioni, il che ne allarga gli intervalli.

9.3 Minacce alla validità

Etichette. La distinzione tra frase contraddetta e non menzionata si basa sugli annotatori di RAGTruth, il cui accordo sul tipo di allucinazione non è pubblicato. Inoltre, una recente riannotazione della partizione di test di RAGTruth ha individuato un numero di risposte allucinate considerevolmente superiore a quello indicato dalle etichette originali [116]. Il test set potrebbe quindi sottostimare le classi minoritarie. Per questo i risultati a tre classi su RAGTruth vanno sempre letti insieme a quelli su VitaminC, le cui etichette hanno un accordo tra annotatori misurato. LLM-AggreFact, infine, unifica le etichette di undici dataset di qualità diversa, e alcune delle sue colonne sono notoriamente rumorose.

Vantaggio nel dominio. GroundOne è addestrato su RAGTruth. I suoi risultati sul test set di RAGTruth e sulla colonna RAGTruth di LLM-AggreFact lo avvantaggiano quindi rispetto a sistemi addestrati altrove. Per contro, VitaminC fa parte dei dati da cui discende l'addestramento di MiniCheck-RoBERTa. Ogni confronto

è riportato con la relativa avvertenza, e le conclusioni poggiano sull'andamento complessivo nei tre test set anziché su uno solo.

Configurazione delle baseline. I giudici LLM sono sensibili al prompt. I loro prompt sono stati fissati prima di esaminare i risultati di test, e quello del giudice LLM a parità di output è stato scelto sul dev set unicamente in base alla validità del formato. Il parsing dell'output è stato permissivo, a vantaggio dei giudici LLM. Il decoding non era vincolato da una grammatica, e questo incide soprattutto sugli errori di formato del modello più piccolo. Non sono stati valutati né un giudice LLM sottoposto a fine-tuning sugli stessi dati né un giudice LLM più grande: il confronto misura dunque ciò che offre, senza addestramento, un giudice LLM della stessa dimensione. Rizzo-Flow è stato eseguito con pesi a 4 bit, perché il modello a 8 bit non trovava posto in memoria accanto al sistema operativo, e questo potrebbe sottostimarne l'accuratezza. d1-3B, infine, è stato eseguito zero-shot e, su LLM-AggreFact, soltanto su un sottocampione. Ha ricevuto le domande usate per tutte le baseline di tipo decision model, che potrebbero non essere la formulazione a esso più congeniale.

Contaminazione. I modelli base sono stati preaddestrati su ampi corpora web che potrebbero includere parti dei test set pubblici[1]. Gli stessi modelli base, però, usati senza addestramento come baseline, raggiungono un'accuratezza vicina al caso sul task a tre classi. La contaminazione non può quindi spiegare i guadagni dovuti all'addestramento; per i valori assoluti, invece, non può essere esclusa del tutto.

Una sola macchina. Tutte le misure di tempo e di energia provengono da un unico portatile, un Apple M4 con 16 GB, e da un unico runtime, MLX. Il modello di costo del Capitolo 2 prevede che il vantaggio di un decision model valga su ogni classe di hardware locale, perché poggia sulla differenza tra prefill e decoding, che produttori e studi indipendenti osservano ovunque. Anche i limiti inferiori al costo del decoding calcolati in quel capitolo per altre macchine discendono dalle specifiche pubblicate. Gli speed-up effettivi su una scheda grafica dedicata, su un DGX Spark o su uno smartphone, invece, non sono stati misurati. La loro entità dipende dall'equilibrio tra calcolo e banda di ciascuna macchina: il modello di costo sostiene la direzione del vantaggio, non la sua entità.

[1]Si parla di *contaminazione* dei dati quando esempi di un test set compaiono, anche solo in parte, nei dati di preaddestramento di un modello. Un modello contaminato può ricordare gli esempi anziché valutarli, e i suoi punteggi su quel test set risultano allora troppo ottimistici.

Capitolo 10

Conclusioni e sviluppi futuri

10.1 Sintesi dei risultati

Questa tesi si è chiesta se un modello linguistico compatto, specializzato in un'unica decisione e impiegato come decision model, possa verificare frase per frase, su un portatile, le risposte di un sistema RAG, e da dove provenga l'eventuale vantaggio. GroundOne, un modello Qwen2.5 sottoposto a fine-tuning che legge i verdetti di un'intera risposta in un solo forward pass, fornisce una risposta positiva, sebbene con alcune riserve.

La specializzazione funziona là dove era mirata. Sul test set di RAGTruth GroundOne raggiunge una balanced accuracy a tre classi di 0.769 con 0.5B parametri e di 0.832 con 3B. Supera di molto gli stessi modelli non addestrati, ordina le frasi supportate meglio degli encoder specializzati ed è nettamente superiore, in balanced accuracy a tre classi, a Rizzo-Flow, un decision model generalista otto volte più grande del 0.5B. Su LLM-AggreFact il 3B è alla pari con il miglior encoder di piccole dimensioni. Su VitaminC, invece, il guadagno scompare: uno specialista non è uno strumento generale di verifica dei fatti. d1-3B, un decision model generalista della stessa dimensione addestrato a decidere su un'ampia miscela di task, conferma il compromesso: GroundOne lo supera nettamente su RAGTruth, con il 3B lo eguaglia su LLM-AggreFact e resta molto indietro su VitaminC.

Il meccanismo del decision model ripaga su due fronti. Il primo è la velocità. Leggere tutti i verdetti in un solo forward pass rende la verifica delle risposte lunghe, anche nel caso meno favorevole in cui nulla è stato letto prima, da 1.8 a 2 volte più rapida di quella di un giudice LLM sintetico e sei volte più rapida di quella di un giudice LLM verboso della stessa dimensione, con un output sempre valido. Con le fonti già nella KV cache, lette in anticipo mentre l'utente legge la risposta, il vantaggio sul giudice LLM sintetico diventa di 3.4–3.6 volte, e dopo una riscrittura, quando soltanto GroundOne può riusare i verdetti delle frasi che precedono la prima

modifica, da 7 a 12 volte su tutte le risposte. Il secondo è l'accuratezza: restringere la decisione alle risposte ammissibili è di per sé più accurato che lasciare allo stesso modello la generazione del verdetto. Inoltre, anche quando si chiede loro lo stesso output, i giudici LLM della stessa dimensione non riescono a fornire probabilità di qualità paragonabile. Le loro probabilità separano a malapena le decisioni corrette da quelle errate, e quelle espresse a parole sono del tipo tutto-o-niente con il 3B e pareggi uniformi con il 0.5B.

Le probabilità di GroundOne si possono calibrare con una temperatura e un bias stimati sul dev set. Una soglia scelta sugli stessi dati le converte poi in etichette coerenti sia con le probabilità sia con la decisione valutata. L'Expected Calibration Error, da solo, non distingue però le probabilità utili da quelle inutili: la capacità discriminativa va misurata a parte.

L'intero sistema gira su un portatile da 16 GB. Una risposta lunga viene verificata in 0.41 secondi con il 0.5B e in 2.57 con il 3B, e l'energia, in media su risposte di ogni lunghezza, è di 5.5 e 33 joule per risposta; quando le fonti sono già nella KV cache, lette in anticipo o per una verifica precedente, per le stesse risposte lunghe bastano 0.17 e 0.93 secondi, e dopo una riscrittura ancora meno. Rispetto a un giudice LLM il risparmio di energia è reale, ma inferiore al risparmio di tempo, perché un singolo prefill lungo assorbe più potenza del decoding.

L'applicazione GroundOne Studio mostra che attorno al verificatore si può costruire un assistente RAG completo, in un unico processo e senza rete: recupero, generazione, verifica e confronto con un giudice LLM richiedono al massimo 6.9 GB di memoria allocata da MLX con il generatore 3B predefinito. Nel caso di studio con errori iniettati GroundOne segnala l'errore in 97 delle 98 risposte in cui la frase riceve un verdetto, contro 84 del giudice LLM, e la riscrittura mirata riduce dal 100 % al 6 % le risposte che contengono ancora l'errore, secondo il conteggio automatico: numeri e date vengono per lo più ripristinati dalla fonte, le frasi inventate cancellate. Il caso di studio mostra anche che il tipo di errore conta: una frase contraddetta viene corretta, una non menzionata spesso soltanto tolta. Le risposte che superano il ciclo sono accettate da GroundOne, non verificate in modo indipendente.

I limiti principali sono due. Il primo è la ristrettezza dei dati di addestramento, a causa della quale le contraddizioni al di fuori del data-to-text e le allucinazioni nascoste in frasi copiate vengono apprese solo in parte. Il secondo è una ricetta di addestramento non del tutto robusta rispetto alla scelta del seed.

10.2 Sviluppi futuri

Da questi limiti discendono direttamente diverse linee di lavoro. La ricetta di addestramento andrebbe resa robusta abilitando la bias correction e il gradient

clipping, registrando le norme dei gradienti e ripetendo i run con più seed, anche per il 3B. Servirebbero poi dati di addestramento con contraddizioni più varie, con supporto parafrasato e con modifiche minime come quelle di VitaminC: dovrebbero intervenire sia sulla bassa recall al di fuori del data-to-text sia sul punto cieco delle frasi copiate. Infine, addestrare il readout sulla lettera che il modello scriverebbe spontaneamente dopo il marker potrebbe allineare readout e generazione, con effetti sull'accuratezza ancora da misurare.

Sul versante dei sistemi, il modello di costo del Capitolo 2 andrebbe verificato su altro hardware. Un porting del readout su llama.cpp permetterebbe di misurare GroundOne su una scheda grafica dedicata, su un DGX Spark o su una macchina AMD Strix Halo, e su uno smartphone, le cui unità di elaborazione neurale accelerano proprio il prefill su cui si regge un decision model. Anche i confronti di latenza con le altre famiglie di verificatori richiedono condizioni eque: gli encoder vanno eseguiti in batch, mentre GroundOne e i decision model generalisti vanno interrogati attraverso la stessa interfaccia HTTP. Un intervento ridurrebbe inoltre la lettura del testo, che è ormai quasi tutto il tempo di GroundOne: fondere l'adapter LoRA nei pesi base, che toglierebbe il 10 % circa di calcolo aggiuntivo misurato nel prefill, al prezzo di una nuova quantizzazione e di una nuova calibrazione.

Un'altra direzione riguarda la lingua. Il primo passo è misurare quanto l'adapter addestrato in inglese funzioni già su documenti e risposte in un'altra lingua, per esempio traducendo una parte di T1 in italiano. Se il trasferimento non basta, per un modello così piccolo può convenire una soluzione diversa da un unico adapter multilingue: un adapter gemello per ciascuna lingua, addestrato separatamente sulla stessa base, così che le lingue non debbano condividere la poca capacità disponibile. Gli adapter occupano poco spazio e si possono caricare e scaricare a runtime sopra un'unica copia del modello base, scegliendo quello giusto con un riconoscitore della lingua. Restano da risolvere tre problemi: servono dati etichettati in ogni lingua, perché tradurre RAGTruth rompe l'allineamento degli span e richiede di verificare le etichette tradotte; temperatura, bias e soglia vanno stimati di nuovo per ogni lingua; e il caso frequente di un documento in una lingua e di una risposta in un'altra non rientra in nessun singolo adapter. Il confronto tra adapter per lingua e adapter multilingue è quindi un esperimento da fare, non una conclusione.

Per i contesti composti da più documenti, un'estensione naturale è l'attribuzione: leggere, oltre al verdetto, quale passaggio sostiene o contraddice ciascuna frase, per esempio con un readout per passaggio, così da mostrare all'utente la fonte di ogni affermazione e trattare in modo esplicito le fonti in conflitto tra loro.

L'applicazione del Capitolo 8 contiene un primo prototipo di questa attribuzione, che resta da valutare con dati che indichino quale passaggio sostiene ciascuna frase. Dall'applicazione discendono altre tre direzioni. Un generatore più grande, come il 7B a 4 bit già selezionabile nell'applicazione, corregge meglio le frasi segnalate,

ma è più lento e aggiunge più contenuto che le fonti non riportano: la scelta del generatore resta un compromesso da studiare su domande reali. Le frasi riscritte andrebbero controllate in modo indipendente, con un secondo verificatore o con una lettura umana di un campione, perché oggi la loro correttezza è giudicata solo da GroundOne. La verifica, infine, potrebbe procedere durante la generazione della risposta, segnalando ogni frase non appena è completa. L'applicazione legge già le fonti in anticipo, ma solo quando la risposta è completa; leggerle, e poi ogni frase conclusa, mentre il generatore scrive lascerebbe da leggere alla fine della generazione soltanto l'ultima frase, perché il formato a marker conserva i verdetti delle frasi già lette.

Appendice A

Output di ogni sistema su una stessa risposta

Questa appendice mostra che cosa restituisce ciascun sistema per una stessa risposta di T1, in modo da collegare i numeri del Capitolo 7 a output concreti. La risposta (identificativo `rt-7784`) è di tipo data-to-text: un modello linguistico l'ha scritta a partire dalla descrizione strutturata di un ristorante, ossia un record JSON con nome, indirizzo, categorie, orari di apertura (da martedì a domenica, 11:00–21:00), attributi, una valutazione media di 4.5 stelle e due recensioni di clienti. È stata scelta perché tutti i sistemi l'hanno valutata e perché contiene tutte e tre le classi, non in base alle prestazioni di un qualche sistema. Le sei frasi e le relative etichette di riferimento sono:

1. *Mesa Verde is a popular business located in Santa Barbara, CA.* — supportata.
2. *It offers a variety of services including Garage Door Services, Restaurants, Live/Raw Food, . . . , Vegan, and Salad.* — supportata.
3. *The business is open seven days a week from 11 am to 9 pm.* — contraddetta (il lunedì il locale è chiuso).
4. *Mesa Verde has a rating of 4.5 stars on Google and has received multiple positive reviews.* — non menzionata (il record non indica la fonte della valutazione e contiene due recensioni, una delle quali negativa).
5. *One customer praised the restaurant's fresh, delicious, and inventive cuisine, while another was disappointed by the taste and price of the food.* — supportata.
6. *Despite this, many customers have had positive experiences at Mesa Verde and recommend it for its fusion and vegan food options.* — supportata.

A.1 Verdetti frase per frase

La Tabella A.1 riporta il verdetto di ciascun sistema. Per GroundOne l'etichetta è quella restituita dal servizio, ricavata dalle probabilità calibrate con la soglia stimata sul dev set ($\tau = 0.935$ per il 0.5B e 0.925 per il 3B), e il numero è la P(supported) calibrata. Per gli encoder il numero è la probabilità di supporto, con la decisione presa a 0.5. S, C e N stanno per supportata, contraddetta e non menzionata; un trattino indica un errore di formato.

Tabella A.1: Verdetti sulla risposta `rt-7784`. Gli errori rispetto al riferimento sono in grassetto.

Sistema	1	2	3	4	5	6
Riferimento	S	S	C	N	S	S
GroundOne 0.5B (restituita, P_{sup})	S 0.96	S 0.98	C 0.50	N 0.05	S 0.98	S 0.97
GroundOne 3B (restituita, P_{sup})	S 0.96	S 0.99	C 0.58	N 0.21	S 0.99	**N 0.85**
B2 0.5B (token generato)	S	S	C	N	S	–
B2 3B (token generato)	S	S	C	–	S	S
0.5B non addestrato (readout)	**C**	**C**	C	**C**	**C**	**C**
Giudice LLM sintetico 0.5B	S	S	**S**	**S**	S	S
Giudice LLM sintetico 3B	**C**	S	**S**	**S**	**N**	S
Giudice LLM verboso 0.5B	–	–	–	–	–	–
Giudice LLM verboso 3B	–	–	–	–	–	–
Giudice LLM a parità di output 3B, logit	**C**	S	**S**	**S**	**N**	S
Giudice LLM a parità di output 3B, probabilità espresse a parole	S	**C**	**N**	**S**	**C**	**N**
MiniCheck-RoBERTa (P_{sup})	0.78	0.90	0.09	0.03	**0.43**	**0.03**
HHEM-2.1-open (P_{sup})	0.75	0.95	0.01	0.09	0.73	**0.24**
Rizzo-Flow 4B	S	S	**S**	**S**	S	S

GroundOne 0.5B classifica correttamente tutte e sei le frasi. La contraddizione nella frase 3 viene colta con una P(supported) calibrata di 0.50: ben sotto la soglia, ma lontana dalla certezza, ed è esattamente ciò che una probabilità calibrata dovrebbe esprimere per una frase corretta in tutto tranne che in un giorno della settimana. Anche GroundOne 3B coglie entrambi gli errori, ma restituisce come non menzionata la frase 6, una generalizzazione tratta dalle due recensioni: la sua P(supported) di 0.85 è inferiore alla soglia elevata imposta dal tasso di base di RAGTruth, un caso in cui un utente che preferisce meno segnalazioni abbasserebbe la soglia. A parità di pesi, il token generato (B2) dà la lettera corretta su cinque frasi su sei, ma sulla restante produce uno spazio (0.5B) o la parola "We" (3B) al posto di un verdetto. Gli encoder binari separano bene i due errori, ma respingono anche le frasi 5 o 6, che riassumono le recensioni con parole diverse; Rizzo-Flow accetta tutte le frasi. I giudici LLM falliscono nei modi quantificati nel Capitolo 7, come mostrano gli output grezzi che seguono.

A.2 Output grezzi

GroundOne 0.5B (JSON restituito, abbreviato). Un unico forward pass su 1,193 token di input, nessun token generato, 0.47 secondi (2.6 secondi per il 3B); nel JSON le frasi sono numerate a partire da zero:


```
{"design": "b", "threshold": 0.935, "n_decisions": 6,
 "usage": {"input_tokens": 1193, "output_tokens": 0},
 "sentences": [
  {"index": 2, "text": "The business is open seven days a week ...",
   "scored": true, "labels": {"three": "contradicted"},
   "answers": {"three": {"supported": 0.502, "contradicted": 0.462,
                         "not_mentioned": 0.036}},
   "flag_strict": true, "flag_lenient": true},
  {"index": 3, "text": "Mesa Verde has a rating of 4.5 stars ...",
   "scored": true, "labels": {"three": "not_mentioned"},
   "answers": {"three": {"supported": 0.051, "contradicted": 0.003,
                         "not_mentioned": 0.946}},
   "flag_strict": true, "flag_lenient": false}, ...]}
```


Giudice LLM sintetico 3B. Una riga per frase, come richiesto, ma con la lettera sbagliata in quattro frasi:

```
1: B
2: A
3: A
4: A
5: C
6: A
```

Giudice LLM verboso 3B (primi tre verdetti). Il ragionamento riformula la frase e cita il documento a sostegno anche della frase contraddetta e di quella non supportata, e tutti i verdetti sono "A". I verdetti compaiono su una riga a sé anziché sulla stessa riga richiesta dall'istruzione, per cui il protocollo li conta come errori di formato:

```
1: Mesa Verde is located in Santa Barbara, CA, as stated in the document.
Verdict: A

2: Mesa Verde offers a variety of services including Garage Door Services,
   [...], as mentioned in the categories provided.
Verdict: A

3: The business is open seven days a week from 11 am to 9 pm, as indicated
   by the hours provided.
Verdict: A
```

Giudice LLM verboso 0.5B. Ricopia le sei frasi, numerate, senza alcun verdetto.

Giudice LLM a parità di output 3B, probabilità espresse a parole. Le probabilità sono tutte one-hot e, per le frasi 3 e 6, l'etichetta dichiarata (C) contraddice le probabilità dichiarate, che assegnano tutta la massa ad A:


```
{"1": {"label": "A", "p": [1.0, 0.0, 0.0]},
 "2": {"label": "B", "p": [0.0, 1.0, 0.0]},
 "3": {"label": "C", "p": [1.0, 0.0, 0.0]},
 "4": {"label": "A", "p": [1.0, 0.0, 0.0]},
 "5": {"label": "B", "p": [0.0, 1.0, 0.0]},
 "6": {"label": "C", "p": [1.0, 0.0, 0.0]}}
```


Giudice LLM a parità di output 0.5B, probabilità espresse a parole. Lo stesso vettore per ogni frase:


```
{"1": {"label": "A", "p": [0.3, 0.3, 0.3]},
 "2": {"label": "A", "p": [0.3, 0.3, 0.3]},
 ...
 "6": {"label": "A", "p": [0.3, 0.3, 0.3]}}
```

Bibliografia

[1] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni et al. "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks". In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2020 (cit. alle pp. 1, 37).

[2] Georgi Gerganov e ggml-org contributors. *llama.cpp: LLM inference in C/C++*. 2023. URL: `https://github.com/ggml-org/llama.cpp` (cit. alle pp. 1, 28, 31, 36, 73).

[3] Apple. *MLX: An array framework for Apple silicon*. 2023. URL: `https://github.com/ml-explore/mlx` (cit. alle pp. 1, 28, 55).

[4] Tom Gunter, Zirui Wang, Chong Wang, Ruoming Pang et al. *Apple Intelligence Foundation Language Models*. 2024. arXiv: `2407.21075` (cit. alle pp. 1, 14, 19).

[5] Venkat Somala e Luke Emberson. *Frontier AI performance becomes accessible on consumer hardware within a year*. Epoch AI. 15 Ago. 2025. URL: `https://epoch.ai/data-insights/consumer-gpu-model-gap` (visitato il giorno 2026-10-11) (cit. alle pp. 1, 17).

[6] Stanford Institute for Human-Centered Artificial Intelligence. *The 2025 AI Index Report: Technical Performance*. 2025. URL: `https://hai.stanford.edu/ai-index/2025-ai-index-report/technical-performance` (visitato il giorno 2026-10-11) (cit. alle pp. 1, 16, 17).

[7] NYU Shanghai RITS. *OpenAI claims a Navier–Stokes proof, amid a dispute over credit*. 9 Set. 2026. URL: `https://rits.shanghai.nyu.edu/ai/openai-navier-stokes-proof-credit-dispute/` (visitato il giorno 2026-10-11) (cit. alle pp. 2, 12, 13).

[8] Cheng Niu, Yuanhao Wu, Juno Zhu, Siliang Xu et al. "RAGTruth: A Hallucination Corpus for Developing Trustworthy Retrieval-Augmented Language Models". In: *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)*. 2024 (cit. alle pp. 2, 6, 37, 58, 59).

[9] Lei Huang, Weijiang Yu, Weitao Ma, Weihong Zhong et al. “A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions”. In: *ACM Transactions on Information Systems* (2025). DOI: 10.1145/3703155 (cit. alle pp. 2, 37).

[10] Reiner Pope, Sholto Douglas, Aakanksha Chowdhery, Jacob Devlin et al. “Efficiently Scaling Transformer Inference”. In: *Proceedings of Machine Learning and Systems (MLSys)*. 2023 (cit. alle pp. 3, 19, 21, 45).

[11] Yuheng Zha, Yichi Yang, Ruichen Li e Zhiting Hu. “AlignScore: Evaluating Factual Consistency with a Unified Alignment Function”. In: *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL)*. 2023 (cit. alle pp. 3, 38, 88).

[12] Liyan Tang, Philippe Laban e Greg Durrett. “MiniCheck: Efficient Fact-Checking of LLMs on Grounding Documents”. In: *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2024 (cit. alle pp. 3, 38, 58–60, 74).

[13] Vectara. *HHEM-2.1-Open: Hughes Hallucination Evaluation Model*. 2024. URL: https://huggingface.co/vectara/hallucination_evaluation_model (cit. alle pp. 3, 38, 74).

[14] TypeSafe. *Introducing System One Models and Jev*. Blog post. 2026. URL: https://typesafe.ai/blog/introducing-system-one-models-and-jev (cit. alle pp. 3, 34, 51).

[15] TheoLeeCJ. *SemIf: open option-logit System One baseline*. 2026. URL: https://github.com/TheoLeeCJ/SemIf (cit. alle pp. 3, 4, 35).

[16] Simone Rizzo. *Rizzo Flow: typed decisions from an LLM, without generating a single token*. 2026. URL: https://github.com/Rizzo-AI-Academy/rizzo-flow (cit. alle pp. 3, 4, 35, 73).

[17] Hugging Face. *Models tagged decision-model*. URL: https://huggingface.co/models?other=decision-model (visitato il giorno 2026-10-10) (cit. alle pp. 4, 35).

[18] Liquid AI. *d1-3B: a decision model built on LFM2.5-VL-3B (model card, LiquidAI/d1-3B, revision 051bcc4)*. URL: https://huggingface.co/LiquidAI/d1-3B (visitato il giorno 2026-10-10) (cit. alle pp. 4, 36, 73).

[19] Cloudflare. *Clef: open decision models (model card, Cloudflare/clef)*. URL: https://huggingface.co/Cloudflare/clef (visitato il giorno 2026-10-10) (cit. alle pp. 4, 36).

[20] Tobias Deußer, Lorenz Sparrenberg e Rafet Sifa. *Evaluating and Benchmarking the System One Model Jev*. 2026. arXiv: 2609.37647 (cit. alle pp. 4, 35, 51, 88).

[21] Gowthamkumar Nandakishore. *Laya as a Typed Probabilistic Assessor: An Independent Reproduction and a Preregistered Study of Calibration and Selective Escalation*. 2026. arXiv: 2609.33843 (cit. alle pp. 4, 35).

[22] multimodalart. *Jev Decision Index: a leaderboard of System One decision models (Hugging Face Space, v0.2.1)*. URL: https://huggingface.co/spaces/multimodalart/jev-decision-index (visitato il giorno 2026-10-10) (cit. alle pp. 4, 36, 85).

[23] Qwen Team. *Qwen2.5 Technical Report*. 2024. arXiv: 2412.15115 (cit. alle pp. 6, 15, 40, 48, 70, 129).

[24] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang e Weizhu Chen. "LoRA: Low-Rank Adaptation of Large Language Models". In: *International Conference on Learning Representations (ICLR)*. 2022 (cit. alle pp. 6, 40, 48).

[25] Guanqiao Qu, Qiyuan Chen, Wei Wei, Zheng Lin, Xianhao Chen e Kaibin Huang. "Mobile Edge Intelligence for Large Language Models: A Contemporary Survey". In: *IEEE Communications Surveys & Tutorials* 27.6 (2025), pp. 3820–3860. arXiv: 2407.18921 (cit. alle pp. 12, 14).

[26] European Parliament and Council of the European Union. *Regulation (EU) 2016/679 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data (General Data Protection Regulation)*. Official Journal of the European Union, L 119, 4 May 2016, pp. 1–88. 2016. URL: https://eur-lex.europa.eu/eli/reg/2016/679/oj (cit. a p. 12).

[27] Jeremy Kahn. *OpenAI says it cracked a Navier–Stokes math grand challenge; a mathematician raises accusations (Eye on AI)*. Fortune. 8 Set. 2026. URL: https://fortune.com/2026/09/08/openai-says-it-cracked-navier-stokes-math-grand-challenge-buckmaster-accusation-cheating-intimidation-tao-lament/ (visitato il giorno 2026-10-11) (cit. a p. 12).

[28] Larissa G. Capella. *'Why would you ruin your career?': OpenAI claims to have cracked one of math's greatest unsolved problems, but mathematicians allege it played dirty*. Live Science. 9 Set. 2026. URL: https://livescience.com/physics-mathematics/mathematics/why-would-you-ruin-your-career-openai-claims-to-have-cracked-one-of-maths-greatest-unsolved-problems-but-mathematicians-allege-it-played-dirty (visitato il giorno 2026-10-11) (cit. a p. 13).

[29] Apple. *Private Cloud Compute: A new frontier for AI privacy in the cloud*. 10 Giu. 2024. URL: https://security.apple.com/blog/private-cloud-compute/ (visitato il giorno 2026-10-11) (cit. alle pp. 13, 14).

[30] Senyao Li, Haozhao Wang, Wenchao Xu, Rui Zhang, Song Guo, Jingling Yuan, Xian Zhong, Tianwei Zhang e Ruixuan Li. *Collaborative Inference and Learning between Edge SLMs and Cloud LLMs: A Survey of Algorithms, Execution, and Open Challenges*. 2025. arXiv: 2507.16731 (cit. alle pp. 14, 26).

[31] Open Source Initiative. *The Open Source AI Definition, version 1.0*. 28 Ott. 2024. URL: https://opensource.org/ai/open-source-ai-definition (visitato il giorno 2026-10-11) (cit. a p. 14).

[32] Artificial Analysis. *Introducing the Artificial Analysis Openness Index*. 1 Dic. 2025. URL: https://artificialanalysis.ai/articles/announcing-artificial-analysis-openness-index (visitato il giorno 2026-10-11) (cit. a p. 15).

[33] Rishi Bommasani, Alice Hau, Kevin Klyman e Percy Liang. *Foundation models under the EU AI Act*. Stanford Center for Research on Foundation Models. 1 Ago. 2024. URL: https://crfm.stanford.edu/2024/08/01/eu-ai-act.html (visitato il giorno 2026-10-11) (cit. a p. 16).

[34] Epoch AI. *Open-weight models lag the closed frontier by about four months on the Epoch Capabilities Index*. 29 Mag. 2026. URL: https://epoch.ai/data-insights/open-closed-eci-gap (visitato il giorno 2026-10-11) (cit. a p. 16).

[35] Artificial Analysis. *Artificial Analysis Intelligence Index*. Leaderboard, version 4.3.2; snapshot of 20 October 2026. URL: https://artificialanalysis.ai/leaderboards/models (visitato il giorno 2026-10-20) (cit. alle pp. 17, 18).

[36] JustVugg. *colibri: run frontier MoE models on hardware you already own, experts streamed from disk*. URL: https://github.com/JustVugg/colibri (visitato il giorno 2026-10-13) (cit. alle pp. 17, 30).

[37] Venkat Somala e Luke Emberson. *What's the best model you can run on a single consumer GPU?* Epoch AI. 9 Set. 2025. URL: https://epochai.substack.com/p/whats-the-best-model-you-can-run (visitato il giorno 2026-10-11) (cit. a p. 17).

[38] Zhenyan Lu, Xiang Li, Dongqi Cai, Rongjie Yi, Fangming Liu, Xiwen Zhang, Nicholas D. Lane e Mengwei Xu. *Small Language Models: Survey, Measurements, and Insights*. 2024. arXiv: 2409.15790 (cit. alle pp. 17, 19).

[39] Zechun Liu et al. "MobileLLM: Optimizing Sub-billion Parameter Language Models for On-Device Use Cases". In: *Proceedings of the 41st International Conference on Machine Learning (ICML)*. Vol. 235. PMLR. 2024 (cit. alle pp. 19, 32).

[40] Google. *Introducing Gemma 3n: the developer guide*. 20 Mag. 2025. URL: https://developers.googleblog.com/en/introducing-gemma-3n/ (visitato il giorno 2026-10-11) (cit. a p. 19).

[41] Woosuk Kwon, Zhuohan Li, Siyuan Zhuang, Ying Sheng et al. "Efficient Memory Management for Large Language Model Serving with PagedAttention". In: *Proceedings of the 29th Symposium on Operating Systems Principles (SOSP)*. 2023 (cit. alle pp. 20, 46).

[42] Pratyush Patel, Esha Choukse, Chaojie Zhang, Aashaka Shah et al. "Splitwise: Efficient Generative LLM Inference Using Phase Splitting". In: *Proceedings of the 51st Annual International Symposium on Computer Architecture (ISCA)*. 2024 (cit. alle pp. 20, 25, 32, 45, 102).

[43] Samuel Williams, Andrew Waterman e David Patterson. "Roofline: An Insightful Visual Performance Model for Multicore Architectures". In: *Communications of the ACM* 52.4 (2009), pp. 65–76. DOI: 10.1145/1498765.1498785 (cit. alle pp. 20, 22).

[44] Zhihang Yuan et al. *LLM Inference Unveiled: Survey and Roofline Model Insights*. 2024. arXiv: 2402.16363 (cit. a p. 21).

[45] Apple. *MacBook Pro (14-inch, M4, 2024) – Technical Specifications*. URL: https://support.apple.com/en-us/121552 (visitato il giorno 2026-10-10) (cit. alle pp. 21, 26, 70).

[46] Keivan Alizadeh, Iman Mirzadeh, Dmitry Belenko, Karen Khatamifard et al. "LLM in a flash: Efficient Large Language Model Inference with Limited Memory". In: *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)*. 2024 (cit. alle pp. 22, 30).

[47] Apple. *MacBook Pro – Technical Specifications (M5, M5 Pro and M5 Max)*. URL: https://www.apple.com/macbook-pro/specs/ (visitato il giorno 2026-10-11) (cit. a p. 26).

[48] Apple. *Mac mini – Technical Specifications*. URL: https://www.apple.com/mac-mini/specs/ (visitato il giorno 2026-10-11) (cit. alle pp. 24, 26).

[49] Apple. *Mac Studio (2025) – Technical Specifications*. URL: https://support.apple.com/en-us/122211 (visitato il giorno 2026-10-11) (cit. alle pp. 25, 26).

[50] NVIDIA. *DGX Spark User Guide: Hardware Overview*. 10 Set. 2026. URL: https://docs.nvidia.com/dgx/dgx-spark/hardware.html (visitato il giorno 2026-10-11) (cit. alle pp. 25, 26).

[51] Mark Hachman. *Framework Desktop review*. PCWorld. 7 Ago. 2025. URL: https://www.pcworld.com/article/2866400/framework-desktop-review.html (visitato il giorno 2026-10-11) (cit. alle pp. 24, 26).

[52] NVIDIA. *Compare GeForce Graphics Cards: specifications*. URL: https://www.nvidia.com/en-us/geforce/graphics-cards/compare/ (visitato il giorno 2026-10-11) (cit. a p. 26).

[53] EXO Labs. *NVIDIA DGX Spark and Mac Studio: disaggregated prefill and decode*. 2025. URL: https://blog.exolabs.net/nvidia-dgx-spark/ (visitato il giorno 2026-10-11) (cit. a p. 25).

[54] Zhenliang Xue, Yixin Song, Zeyu Mi, Xinrui Zheng, Yubin Xia e Haibo Chen. *PowerInfer-2: Fast Large Language Model Inference on a Smartphone*. 2024. arXiv: 2406.06282 (cit. a p. 26).

[55] Daliang Xu, Hao Zhang, Liming Yang, Ruiqi Liu, Gang Huang, Mengwei Xu e Xuanzhe Liu. "Fast On-device LLM Inference with NPUs". In: *Proceedings of the 30th ACM International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS '25)*. ACM, 2025. DOI: 10.1145/3669940.3707239 (cit. alle pp. 26, 27, 32).

[56] Apple Machine Learning Research. *Exploring LLMs with MLX and the Neural Accelerators in the M5 GPU*. 19 Nov. 2025. URL: https://machinelearning.apple.com/research/exploring-llms-mlx-m5 (visitato il giorno 2026-10-11) (cit. a p. 27).

[57] Subhransu Das, Jiaming Cheng, Arnav Kumar, Sadia Afrose, Mingzhe Han, Michael Silagy, Shreya Palande, Brijesh Soni e Rajiv Ramnath. *Large Models for Small Devices: Edge AI Deployment*. 2026. arXiv: 2608.15693 (cit. a p. 27).

[58] Apple. *mlx-lm: LLMs with MLX*. 2024. URL: https://github.com/ml-explore/mlx-lm (cit. alle pp. 28, 31, 46, 55).

[59] Varun Rajesh, Om Jodhpurkar, Pooja Anbuselvan, Mantinder Singh, Ashok Jallepali, Shantanu Godbole, Pradeep Kumar Sharma e Hritvik Shrivastava. *Production-Grade Local LLM Inference on Apple Silicon: A Comparative Study of MLX, MLC-LLM, Ollama, llama.cpp, and PyTorch MPS*. 2025. arXiv: 2511.05502 (cit. a p. 28).

[60] Stefanos Laskaridis, Kleomenis Katevas, Lorenzo Minto e Hamed Haddadi. "MELTing Point: Mobile Evaluation of Language Transformers". In: *Proceedings of the 30th Annual International Conference on Mobile Computing and Networking (MobiCom)*. 2024. arXiv: 2403.12844 (cit. alle pp. 28, 32).

[61] Salvatore Sanfilippo. *DwarfStar (ds4): DeepSeek 4 Flash and PRO local inference engine for Metal, CUDA and ROCm*. URL: https://github.com/antirez/ds4 (visitato il giorno 2026-10-13) (cit. a p. 28).

[62] Tim Dettmers, Mike Lewis, Younes Belkada e Luke Zettlemoyer. "LLM.int8(): 8-bit Matrix Multiplication for Transformers at Scale". In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 35. 2022 (cit. alle pp. 31, 32).

[63] Elias Frantar, Saleh Ashkboos, Torsten Hoefler e Dan Alistarh. "GPTQ: Accurate Post-Training Quantization for Generative Pre-trained Transformers". In: *International Conference on Learning Representations (ICLR)*. 2023 (cit. alle pp. 31, 32).

[64] Ji Lin et al. "AWQ: Activation-aware Weight Quantization for On-Device LLM Compression and Acceleration". In: *Proceedings of Machine Learning and Systems (MLSys)*. 2024 (cit. alle pp. 31, 32).

[65] Tim Dettmers, Artidoro Pagnoni, Ari Holtzman e Luke Zettlemoyer. "QLoRA: Efficient Finetuning of Quantized LLMs". In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2023 (cit. alle pp. 31, 40, 48).

[66] Yaniv Leviathan, Matan Kalman e Yossi Matias. "Fast Inference from Transformers via Speculative Decoding". In: *Proceedings of the 40th International Conference on Machine Learning (ICML)*. Vol. 202. PMLR. 2023 (cit. a p. 32).

[67] Siddharth Samsi, Dan Zhao, Joseph McDonald, Baolin Li et al. "From Words to Watts: Benchmarking the Energy Costs of Large Language Model Inference". In: *IEEE High Performance Extreme Computing Conference (HPEC)*. 2023 (cit. alle pp. 32, 102).

[68] Alexandra Sasha Luccioni, Yacine Jernite e Emma Strubell. "Power Hungry Processing: Watts Driving the Cost of AI Deployment?" In: *Proceedings of the ACM Conference on Fairness, Accountability, and Transparency (FAccT)*. 2024 (cit. alle pp. 32, 102).

[69] Jacky Kwok, Hangoo Kang, Tarun Suresh, Jon Saad-Falcon, Marco Pavone, Christopher Ré e Azalia Mirhoseini. *Contrastive Language Models: A System One Model for Fast and Generalizable Decision-Making*. Blog post, not peer-reviewed. 2026. URL: `https://contrastive-lm.notion.site` (cit. a p. 35).

[70] Convai Innovations. *Laya: a System One decision model (model card, convaiinnovations/laya)*. URL: `https://huggingface.co/convaiinnovations/laya` (visitato il giorno 2026-10-10) (cit. a p. 35).

[71] Seyedarmin Azizi, Erfan Baghaei Potraghloo e Massoud Pedram. *Labels Override Definitions in Jev-Style Typed Decision Models*. 2026. arXiv: `2610.02586` (cit. a p. 35).

[72] Cho Yin Yong. *DecideBench (dataset card, choyiny/decidebench)*. URL: https://huggingface.co/datasets/choyiny/decidebench (visitato il giorno 2026-10-10) (cit. a p. 35).

[73] Perplexity. *pplx-decider-v1.1-27b (model card)*. URL: https://huggingface.co/perplexity-ai/pplx-decider-v1.1-27b (visitato il giorno 2026-10-10) (cit. a p. 36).

[74] Ruoqi Guo, Yi Liu, Gelei Deng, Yuekang Li et al. *Just Ask Jev: Reinforcement Learning for Calibrated Decisions as a Zero-Shot Detector of AI Alignment Failures*. 2026. arXiv: 2609.29429 (cit. alle pp. 36, 51).

[75] Yubo Li, Yidi Miao, Ramayya Krishnan e Rema Padman. *JEV-as-a-Judge: Accept When Confident, Escalate When Unsure*. 2026. arXiv: 2609.26550 (cit. alle pp. 36, 51).

[76] Xinpeng Wang, Bolei Ma, Chengzhi Hu, Leon Weber-Genzel et al. ""My Answer is C": First-Token Probabilities Do Not Match Text Answers in Instruction-Tuned Language Models". In: *Findings of the Association for Computational Linguistics: ACL 2024*. 2024. arXiv: 2402.14499 (cit. alle pp. 36, 47).

[77] Chujie Zheng, Hao Zhou, Fandong Meng, Jie Zhou e Minlie Huang. "Large Language Models Are Not Robust Multiple Choice Selectors". In: *International Conference on Learning Representations (ICLR)*. 2024 (cit. alle pp. 36, 47).

[78] Adina Williams, Nikita Nangia e Samuel R. Bowman. "A Broad-Coverage Challenge Corpus for Sentence Understanding through Inference". In: *Proceedings of NAACL-HLT 2018*. 2018 (cit. a p. 37).

[79] Yixin Nie, Adina Williams, Emily Dinan, Mohit Bansal, Jason Weston e Douwe Kiela. "Adversarial NLI: A New Benchmark for Natural Language Understanding". In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*. 2020 (cit. alle pp. 37, 60).

[80] Tal Schuster, Adam Fisch e Regina Barzilay. "Get Your Vitamin C! Robust Fact Verification with Contrastive Evidence". In: *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Association for Computational Linguistics, 2021, pp. 624–643. DOI: 10.18653/v1/2021.naacl-main.52. URL: https://aclanthology.org/2021.naacl-main.52 (cit. alle pp. 37, 58, 59).

[81] Philippe Laban, Tobias Schnabel, Paul N. Bennett e Marti A. Hearst. "SummaC: Re-Visiting NLI-based Models for Inconsistency Detection in Summarization". In: *Transactions of the Association for Computational Linguistics* 10 (2022), pp. 163–177 (cit. a p. 37).

[82] Sewon Min, Kalpesh Krishna, Xinxi Lyu, Mike Lewis et al. “FActScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation”. In: *Proceedings of EMNLP 2023*. 2023 (cit. a p. 37).

[83] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang et al. “Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena”. In: *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*. 2023 (cit. a p. 38).

[84] Shahul Es, Jithin James, Luis Espinosa-Anke e Steven Schockaert. “RAGAs: Automated Evaluation of Retrieval Augmented Generation”. In: *Proceedings of EACL 2024: System Demonstrations*. 2024 (cit. a p. 38).

[85] Jon Saad-Falcon, Omar Khattab, Christopher Potts e Matei Zaharia. “ARES: An Automated Evaluation Framework for Retrieval-Augmented Generation Systems”. In: *Proceedings of NAACL 2024*. 2024 (cit. a p. 38).

[86] Selvan Sunitha Ravi, Bartosz Mielczarek, Anand Kannappan, Douwe Kiela e Rebecca Qian. *Lynx: An Open Source Hallucination Evaluation Model*. 2024. arXiv: 2407.08488 (cit. a p. 38).

[87] Akari Asai, Zeqiu Wu, Yizhong Wang, Avirup Sil e Hannaneh Hajishirzi. “Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection”. In: *International Conference on Learning Representations (ICLR)*. 2024 (cit. a p. 38).

[88] Brandon T. Willard e Rémi Louf. *Efficient Guided Generation for Large Language Models*. 2023. arXiv: 2307.09702 (cit. alle pp. 38, 73).

[89] Liyan Tang, Philippe Laban e Greg Durrett. *LLM-AggreFact Leaderboard*. 2024. URL: https://llm-aggrefact.github.io/ (visitato il giorno 2026-10-05) (cit. alle pp. 38, 58, 59).

[90] Chuan Guo, Geoff Pleiss, Yu Sun e Kilian Q. Weinberger. “On Calibration of Modern Neural Networks”. In: *International Conference on Machine Learning (ICML)*. 2017 (cit. alle pp. 38, 50, 51).

[91] Mahdi Pakdaman Naeini, Gregory F. Cooper e Milos Hauskrecht. “Obtaining Well Calibrated Probabilities Using Bayesian Binning”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. 2015 (cit. alle pp. 38, 51).

[92] Tony Z. Zhao, Eric Wallace, Shi Feng, Dan Klein e Sameer Singh. “Calibrate Before Use: Improving Few-Shot Performance of Language Models”. In: *International Conference on Machine Learning (ICML)*. 2021 (cit. alle pp. 38, 50).

[93] Saurav Kadavath, Tom Conerly, Amanda Askell, Tom Henighan et al. *Language Models (Mostly) Know What They Know*. 2022. arXiv: 2207.05221 (cit. a p. 39).

[94] Katherine Tian, Eric Mitchell, Allan Zhou, Archit Sharma et al. "Just Ask for Calibration: Strategies for Eliciting Calibrated Confidence Scores from Language Models Fine-Tuned with Human Feedback". In: *Proceedings of EMNLP 2023*. 2023 (cit. alle pp. 39, 92).

[95] Miao Xiong, Zhiyuan Hu, Xinyang Lu, Yifei Li et al. "Can LLMs Express Their Uncertainty? An Empirical Evaluation of Confidence Elicitation in LLMs". In: *International Conference on Learning Representations (ICLR)*. 2024 (cit. alle pp. 39, 92).

[96] Yonatan Geifman e Ran El-Yaniv. "Selective Classification for Deep Neural Networks". In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2017 (cit. alle pp. 39, 75).

[97] Jesse Dodge, Gabriel Ilharco, Roy Schwartz, Ali Farhadi, Hannaneh Hajishirzi e Noah Smith. *Fine-Tuning Pretrained Language Models: Weight Initializations, Data Orders, and Early Stopping*. 2020. arXiv: 2002.06305 (cit. alle pp. 41, 71).

[98] Marius Mosbach, Maksym Andriushchenko e Dietrich Klakow. "On the Stability of Fine-tuning BERT: Misconceptions, Explanations, and Strong Baselines". In: *International Conference on Learning Representations (ICLR)*. 2021 (cit. alle pp. 41, 83, 128).

[99] Razvan Pascanu, Tomas Mikolov e Yoshua Bengio. "On the Difficulty of Training Recurrent Neural Networks". In: *International Conference on Machine Learning (ICML)*. 2013 (cit. alle pp. 41, 83, 128).

[100] Pritam Deka. *From Retrieval to Typed Decisions: Calibrated System One Models from Biomedical Sentence Encoders*. 2026. arXiv: 2610.02486 (cit. a p. 51).

[101] Tri Nguyen, Mir Rosenberg, Xia Song, Jianfeng Gao, Saurabh Tiwary, Rangan Majumder e Li Deng. *MS MARCO: A Human Generated MAchine Reading COmprehension Dataset*. CoCo Workshop at NIPS 2016. 2016. arXiv: 1611.09268 (cit. a p. 59).

[102] Karl Moritz Hermann, Tomáš Kočiský, Edward Grefenstette, Lasse Espeholt, Will Kay, Mustafa Suleyman e Phil Blunsom. "Teaching Machines to Read and Comprehend". In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2015 (cit. a p. 59).

[103] Abigail See, Peter J. Liu e Christopher D. Manning. "Get To The Point: Summarization with Pointer-Generator Networks". In: *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (ACL)*. 2017 (cit. a p. 59).

[104] Yelp. *Yelp Open Dataset*. URL: `https://business.yelp.com/data/resources/open-dataset/` (visitato il giorno 2026-10-05) (cit. alle pp. 59, 79).

[105] Liyan Tang, Tanya Goyal, Alex Fabbri, Philippe Laban, Jiacheng Xu, Semih Yavuz, Wojciech Kryściński, Justin Rousseau e Greg Durrett. "Understanding Factual Errors in Summarization: Errors, Summarizers, Datasets, Error Detectors". In: *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL)*. 2023 (cit. a p. 59).

[106] Liyan Tang, Igor Shalyminov, Amy Wing-mei Wong et al. "TofuEval: Evaluating Hallucinations of LLMs on Topic-Focused Dialogue Summarization". In: *Proceedings of NAACL 2024*. 2024 (cit. a p. 59).

[107] Nelson F. Liu, Tianyi Zhang e Percy Liang. "Evaluating Verifiability in Generative Search Engines". In: *Findings of EMNLP 2023*. 2023 (cit. a p. 59).

[108] Chaitanya Malaviya, Subin Lee, Sihao Chen, Elizabeth Sieber, Mark Yatskar e Dan Roth. "ExpertQA: Expert-Curated Questions and Attributed Answers". In: *Proceedings of NAACL 2024*. 2024 (cit. a p. 59).

[109] Hung-Ting Chen, Fangyuan Xu, Shane Arora e Eunsol Choi. "Understanding Retrieval Augmentation for Long-Form Question Answering". In: *Conference on Language Modeling (COLM)*. 2024 (cit. a p. 59).

[110] Ryo Kamoi, Tanya Goyal, Juan Diego Rodriguez e Greg Durrett. "WiCE: Real-World Entailment for Claims in Wikipedia". In: *Proceedings of EMNLP 2023*. 2023 (cit. a p. 59).

[111] Alon Jacovi, Yonatan Bitton, Bernd Bohnet, Jonathan Herzig, Or Honovich, Michael Tseng, Michael Collins, Roee Aharoni e Mor Geva. "A Chain-of-Thought Is as Strong as Its Weakest Link: A Benchmark for Verifiers of Reasoning Chains". In: *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)*. 2024 (cit. a p. 59).

[112] Yuxia Wang, Revanth Gangi Reddy, Zain Muhammad Mujahid et al. "Factcheck-Bench: Fine-Grained Evaluation Benchmark for Automatic Fact-checkers". In: *Findings of EMNLP 2024*. 2024 (cit. a p. 59).

[113] Liyan Tang. *LLM-AggreFact dataset card (lytang/LLM-AggreFact)*. URL: `https://huggingface.co/datasets/lytang/LLM-AggreFact` (visitato il giorno 2026-10-05) (cit. alle pp. 59, 79).

[114] Tal Schuster. *VitaminC dataset card (tals/vitaminc)*. URL: `https://huggingface.co/datasets/tals/vitaminc` (visitato il giorno 2026-10-06) (cit. a p. 59).

[115] Nipun Sadvilkar e Mark Neumann. "PySBD: Pragmatic Sentence Boundary Disambiguation". In: *Proceedings of the Second Workshop for NLP Open Source Software (NLP-OSS)*. 2020, pp. 110–114. DOI: 10.18653/v1/2020.nlposs-1.15. URL: https://aclanthology.org/2020.nlposs-1.15 (cit. a p. 60).

[116] Boxi Yu, Yuzhong Zhang, Liting Lin, Lionel Briand e Emir Muñoz. *Retromorphic Testing with Hierarchical Verification for Hallucination Detection in RAG*. 2026. arXiv: 2603.27752. URL: https://arxiv.org/abs/2603.27752 (cit. alle pp. 65, 130).

[117] Philipp Koehn. "Statistical Significance Tests for Machine Translation Evaluation". In: *Proceedings of the 2004 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2004, pp. 388–395. URL: https://aclanthology.org/W04-3250 (cit. a p. 75).

[118] Taylor Berg-Kirkpatrick, David Burkett e Dan Klein. "An Empirical Investigation of Statistical Significance in NLP". In: *Proceedings of EMNLP-CoNLL 2012*. 2012, pp. 995–1005. URL: https://aclanthology.org/D12-1091 (cit. a p. 75).

[119] Rotem Dror, Gili Baumer, Segev Shlomov e Roi Reichart. "The Hitchhiker's Guide to Testing Statistical Significance in Natural Language Processing". In: *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL)*. 2018, pp. 1383–1392. URL: https://aclanthology.org/P18-1128 (cit. a p. 75).

[120] Alibaba Cloud. *Qwen Research License Agreement*. 19 Set. 2024. URL: https://huggingface.co/Qwen/Qwen2.5-3B-Instruct/blob/main/LICENSE (visitato il giorno 2026-10-22) (cit. a p. 79).

[121] Liquid AI. *LFM Open License v1.0*. URL: https://huggingface.co/LiquidAI/d1-3B/blob/main/LICENSE (visitato il giorno 2026-10-22) (cit. a p. 79).

[122] Microsoft. *MS MARCO: terms and conditions*. URL: https://microsoft.github.io/msmarco/ (visitato il giorno 2026-10-22) (cit. a p. 79).

[123] Apple ML Explore. *MLX Swift*. URL: https://github.com/ml-explore/mlx-swift (visitato il giorno 2026-10-18) (cit. a p. 106).

[124] Apple ML Explore. *MLX Swift LM: LLMs and VLMs with MLX Swift*. Ver. 3.32.3. URL: https://github.com/ml-explore/mlx-swift-lm (visitato il giorno 2026-10-18) (cit. a p. 106).

[125] oxiglade. *mlx-rs: unofficial Rust bindings to Apple's MLX*. Ver. 0.32.0. URL: https://github.com/oxiglade/mlx-rs (visitato il giorno 2026-10-18) (cit. a p. 106).

[126] Hugging Face. *swift-transformers: Swift package for tokenizers and model loading*. Ver. 1.3.5. URL: `https://github.com/huggingface/swift-transformers` (visitato il giorno 2026-10-24) (cit. a p. 108).

[127] Apple. *NLTokenizer*. Apple Developer Documentation, Natural Language framework. URL: `https://developer.apple.com/documentation/naturallanguage/nltokenizer` (visitato il giorno 2026-10-18) (cit. a p. 109).

[128] SQLite. *SQLite FTS5 extension*. URL: `https://www.sqlite.org/fts5.html` (visitato il giorno 2026-10-18) (cit. a p. 110).

[129] Stephen Robertson e Hugo Zaragoza. "The Probabilistic Relevance Framework: BM25 and Beyond". In: *Foundations and Trends in Information Retrieval* 3.4 (2009), pp. 333–389 (cit. a p. 110).

[130] Shitao Xiao, Zheng Liu, Peitian Zhang, Niklas Muennighoff, Defu Lian e Jian-Yun Nie. "C-Pack: Packed Resources For General Chinese Embeddings". In: *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2024, pp. 641–649 (cit. a p. 110).

[131] Gordon V. Cormack, Charles L. A. Clarke e Stefan Büttcher. "Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods". In: *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2009, pp. 758–759 (cit. a p. 110).

[132] Luyu Gao et al. "RARR: Researching and Revising What Language Models Say, Using Language Models". In: *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. 2023, pp. 16477–16508 (cit. a p. 114).

[133] Zhibin Gou, Zhihong Shao, Yeyun Gong, Yelong Shen, Yujiu Yang, Nan Duan e Weizhu Chen. "CRITIC: Large Language Models Can Self-Correct with Tool-Interactive Critiquing". In: *International Conference on Learning Representations*. 2024 (cit. a p. 114).

[134] Jie Huang, Xinyun Chen, Swaroop Mishra, Huaixiu Steven Zheng, Adams Wei Yu, Xinying Song e Denny Zhou. "Large Language Models Cannot Self-Correct Reasoning Yet". In: *International Conference on Learning Representations*. 2024 (cit. a p. 114).

[135] Eurostat. *Electricity price statistics*. Statistics Explained; household prices, second half of 2025. URL: `https://ec.europa.eu/eurostat/statistics-explained/index.php?title=Electricity_price_statistics` (visitato il giorno 2026-10-19) (cit. a p. 127).

[136] Anthropic. *Claude API pricing*. URL: `https://platform.claude.com/docs/en/about-claude/pricing` (visitato il giorno 2026-10-19) (cit. a p. 127).

[137] OpenAI. *API pricing*. URL: `https://developers.openai.com/api/docs/pricing` (visitato il giorno 2026-10-19) (cit. a p. 127).

[138] Google. *Gemini API pricing*. URL: `https://ai.google.dev/gemini-api/docs/pricing` (visitato il giorno 2026-10-19) (cit. a p. 127).